DATA ANALYTICS PORTFOLIO

도매 유통 고객 세분화 및 채널 예측 대시보드 구축

머신러닝 기반 TabPy 서버 활용 | AWS EC2 연동

아이티윌 빅데이터 52기 정보희

UCI Wholesale Customer Dataset

* 목차



01 프로젝트 개요

02 데이터 탐색 & 전처리

03 머신러닝 기반 분석

04 태블로 대시보드 시각화 구현

05 TabPy& AWS EC2 인프라 구축

06 비즈니스 내 대시보드 활용

07 개인 회고

1. 프로젝트 개요

프로젝트 개요

데이터 기반 의사결정은
기업의 생존 전략

23배

고객 유치 확률

데이터 기반 의사결정 기업이
그렇지 않은 기업보다 월등히 높음

19배

수익성 향상

데이터 활용 기업의 압도적인 수익성 차이 증명

Source: McKinsey & Company, Bain & Company 2025 Consumer Products Report

Global Best Practices

Amazon (아마존) - AI 기반 예측 배송

구매 이력 기반 사전 물류 배치로 리드타임 및 물류 파이프라인 최적화

- US Patent 8,615,473 - Anticipatory Package Shipping, 2013)

Sysco (시스코) - AI 영업 플랫폼 기반 효율화

외식 시장 둔화 위기를 AI 제안 영업으로 돌파
고객 유지율 및 유통 물량 개선

- Sysco is expanding the platform with new functionality called “Swap and Save. (2026)

**“비즈니스 환경에서 데이터 활용 역량을
어떻게 적용해볼 수 있을까?"**

프로젝트 개요

UCI Wholesale Customer Dataset

프로젝트 핵심 목표

고객 세분화

K-Means 클러스터링을 통해
구매 패턴에 따른 5가지 페르소나 정의

채널 예측

신규 고객의 구매 데이터만으로
Horeca vs Retail 채널 자동 판별

명확한 해석

단순 예측 결과를 넘어 SHAP 분석을
통해 AI 판단 근거를 투명하게 해석

비즈니스 구현

TabPy + Tableau + AWS EC2 연동으로
실시간 예측 대시보드 인프라 구축

2. 데이터 탐색 및 전처리

데이터 탐색 및 전처리 | 데이터 개요

변수명	유형	설명
Channel	Categorical	유통 채널 (Horeca: 호텔/식당/카페 vs Retail: 소매)
Region	Categorical	포르투갈 지역 (Lisbon, Oporto, Other)
Fresh	Numerical	신선식품 연간 구매액
Milk	Numerical	유제품 연간 구매액
Grocery	Numerical	식료품 연간 구매액
Frozen	Numerical	냉동식품 연간 구매액
Detergents_ Paper	Numerical	세제 및 종이류 연간 구매액
Delicassen	Numerical	즉석/가공식품 연간 구매액

포르투갈 도매 유통 고객을 대상으로 연간 구매 금액 기록

(화폐 단위는 monetary unit 으로 미제공)



- Source: UCI Machine Learning Repository Wholesale Customers Dataset

리스본 | 포르투갈 수도이자 최대 도시 및 항구도시



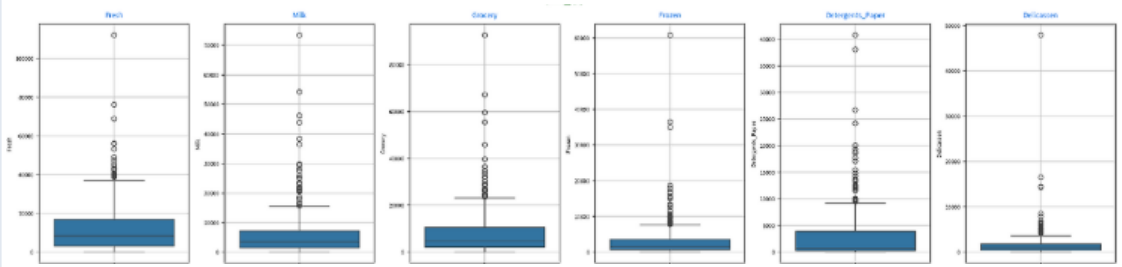
포르투 | 포르투갈 제2의 도시

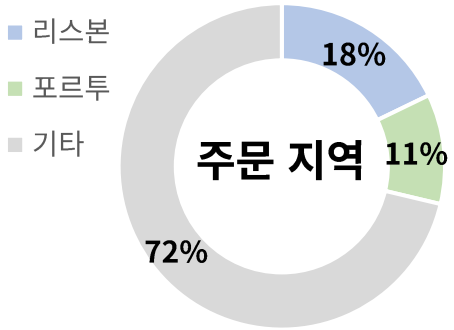


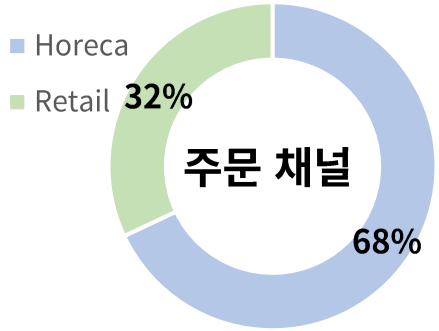
데이터 탐색 및 전처리 | 기초 통계량

Metric	신선식품	유제품	식료품	냉동식품	세제 및 종이류	즉석가공식품
데이터 수	440	440	440	440	440	440
평균	12,000	5,796	7,951	3,072	2,881	1,525
표준편차	12,647	7,380	9,503	4,855	4,768	2,820
min	3	55	3	25	3	3
25%	3,128	1,533	2,153	742	257	408
50%	8,504	3,627	4,756	1,526	817	966
75%	16,934	7,190	10,656	3,554	3,922	1,820

연속형 변수 박스플럿







핵심 발견

결측치 0건 (Missing Values: 0)
440개 샘플 모두 정제되어 있어 데이터 신뢰도 높음

우측으로 긴 꼬리 분포 (Right-Skewed)
모든 품목에서 평균(Mean) > 중앙값(Median) 현상 뚜렷

높은 분산 + 이상치 존재
평균과 표준편차가 비슷한 수준 분산이 커 데이터 변동성 큼

소수 우량 고객에 의한 매출 쏠림
Max 값이 Mean 대비 수십 배에 달하는 이상치 존재

데이터 탐색 및 전처리 | 로그 변환 / 스케일링

품목	로그 변환 전 왜도	로그 변환 후 왜도	|z|>3 이상치 개수 (비중)	평균
신선식품	2.56	-1.71	7 (1.6%)	12,000
유제품	4.05	-0.78	9 (2.0%)	5,796
식료품	3.59	-0.84	7 (1.6%)	7,951
냉동식품	5.91	-0.74	6 (1.4%)	3,072
세제 및 종이류	3.63	-0.32	10 (2.3%)	2,881
즉석 가공식품	11.15	-1.30	4 (1.0%)	1,525

핵심 발견

강한 우측 왜도

모든 변수에서 |skew| > 2 로 데이터가 한쪽으로 치우쳐져 짐

이상치 존재

모든 품목에서 연간 매출액 수준이 z| > 3 인 일부 고객의 극단적 매출 확인

→ 로그 변환 적용 후 분포가 대칭에 가까워지고 모델 학습 왜곡 완화

변수 간 스케일 차이 존재

평균값 차이가 크게 나타나 값이 큰 변수 중심으로 거리 계산 왜곡 가능

→ Standard Scaling 적용 후 변수 간 영향력 균형 확보

판단 기준

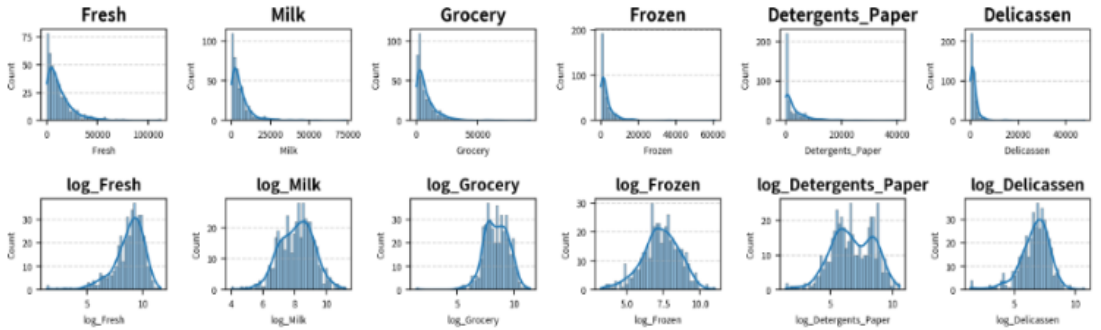
왜도

- 데이터 분포의 비대칭 정도
- **|skew| > 2 → 강한 왜도로 판단**

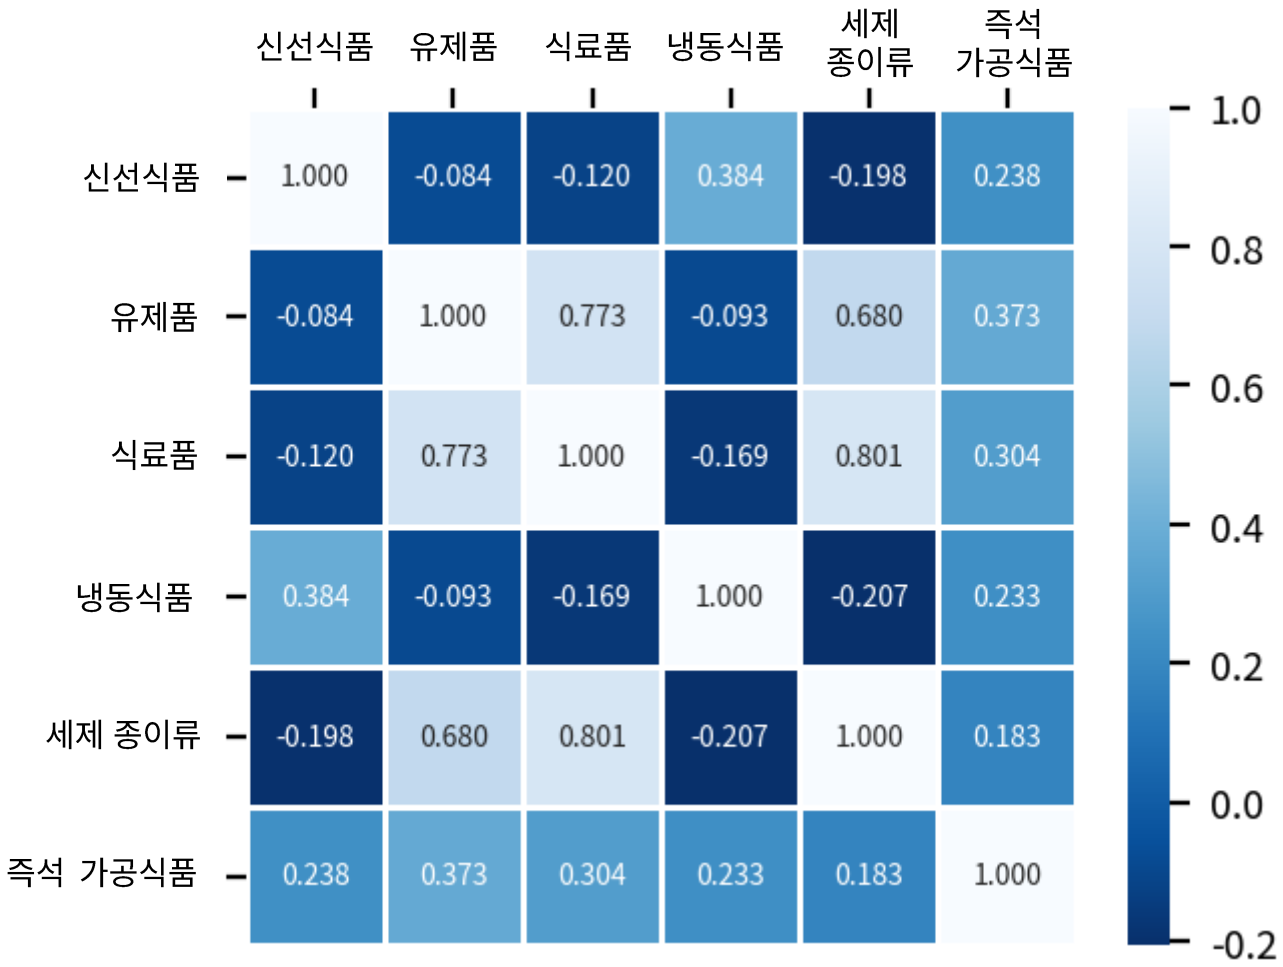
Z-Score (표준 점수)

- 각 값이 평균에서 표준편차 기준으로 얼마나 떨어져 있는지를 나타내는 지표
- **|z| > 3 → 이상치로 판단**

로그 변환 전/후 히스토그램 비교



데이터 탐색 및 전처리 | 상관관계 분석



- Milk –Frozen , Fresh – Milk 조합 외 모든 변수 간의 상관관계 p-value <0.05 로 신뢰성 확보

식료품 ↔ 세제 종이류
매우 강한 상관관계 **0.801**

유제품 ↔ 식료품
매우 강한 상관관계 **0.773**

유제품 ↔ 세제 종이류
강한 상관관계 **0.680**

Spearman 상관 분석
이상치가 많고 변수 간 관계가 비선형적일 가능성을 고려하여
순위 기반 분석 채택

통계적 유의성 확보
총 15개 변수 쌍 중 2개를 제외한 모든 변수 쌍의 p-value가
모두 0.05 미만으로 나타나 도출된 상관관계가 신뢰할 수 있음을 검증

PCA 차원 축소의 정당성
특정 변수 간의 강한 상관성은 이들을 소수의 주성분으로 압축했을 때
정보 손실이 적음을 시사함

3. 머신러닝 기반 분석

머신러닝 기반 분석 프로세스

데이터 전처리

머신러닝 비지도 & 지도 학습

모델 평가

원본 데이터

- Skewed Distribution (비대칭 분포)

로그 변환

- 왜도 완화 및 분포 안정화

StandardScaler

- 변수 스케일 통일 및 거리 왜곡 방지

PCA

- 상관성 제거 및 핵심 축 생성

K-MEANS

- 유사 구매 패턴 기반 고객 군집화

머신러닝 분류 모델 학습

- 7개의 모델 비교를 통한 신규 고객 채널 예측 모델 구축

모델 평가 및 해석

- AUC, Precision, Recall 기반 모델 비교 및 선정
- SHAP 기반 모델 해석

3. 머신러닝 기반 분석

- PCA / K-MEANS

머신러닝 기반 분석 | PCA 주성분 분석

차원 축소 결과

6개의 복잡한 변수를 **3개의 핵심 주성분**으로 압축하여
전체 데이터 변동성의 약 **82%**를 설명

PC1 (제1주성분)

설명력 44%

전체 데이터의 절반 가까운 흐름 설명, 대량 구매 성향을 나타내는 가장 강력한 축

[Loading] 식료품 (0.57) / 세제 종이류 (0.55) / 유제품 (0.54)

PC2 (제2주성분)

설명력 27%

신선 식품과 냉동 식자재 중심의 식당/호텔 구매 성향을 설명하는 두 번째 축

[Loading]신선 식품 (0.579) / 냉동 식품 (0.58) / 즉석 가공식품 (0.53)

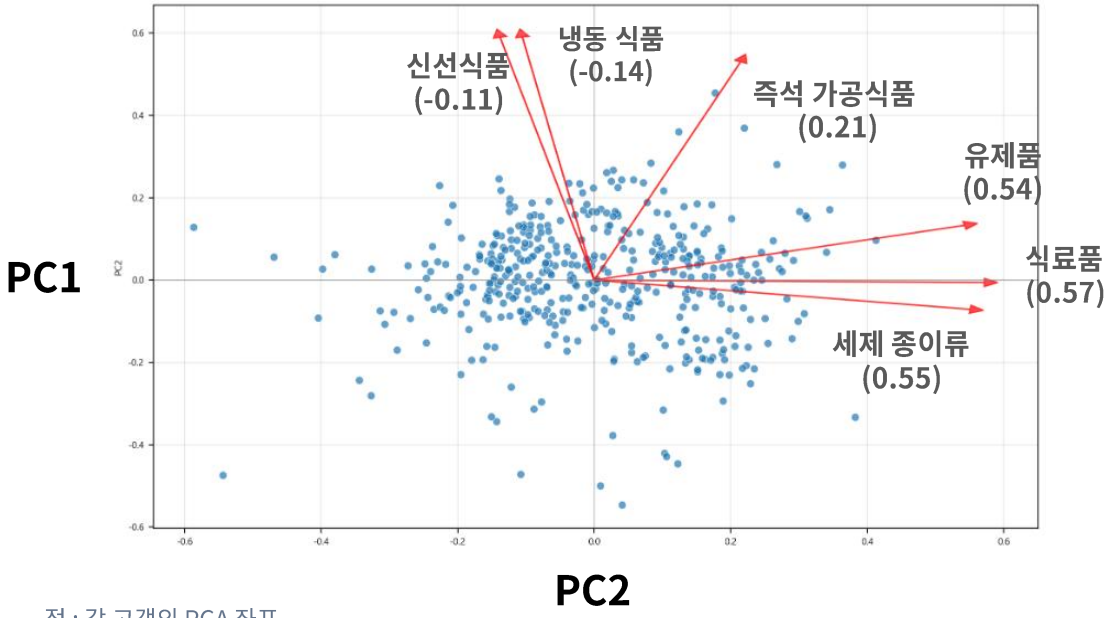
PC3 (제3주성분)

설명력 11%

가공식품이나 특수 품목에 대한 선호도를 설명하는 보조적인 축

[Loading] 즉석 가공식품 (0.72) / 신성식품 (-0.63) / 세제 및 종이류 (-0.19)

고객 데이터와 변수 간 관계 확인 | Biplot 시각화



- 점 : 각 고객의 PCA 좌표
- 화살표 : 변수의 영향 방향 및 크기
- 각도 : 변수 간 상관 관계
- 상단 그래프의 로딩 벡터 방향은 PC1 – PC2 가 동시에 고려되었으며, 변수 뒤의 로딩값은 PC1 기준

» **고객 소비 패턴은 크게 “식료품 중심” vs “신선/냉동 중심”으로 구분**

» **식료품·유제품·세제류는 동일한 소비군으로 묶이는 강한 양의 상관관계 확인**

» **변수 간 관계를 통해 고객 세분화(K-Means)의 기준이 되는 구조 확인**

머신러닝 기반 분석 | K-MEANS 클러스터링 | 최적의 군집 수 선정

Elbow Point (기울기 변화)

K=5 지점 확인

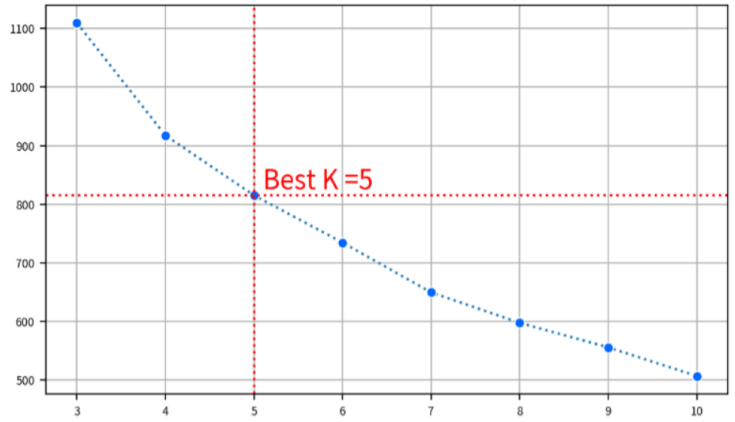
Silhouette Score (분리도)

0.27

최적 군집 수 (Optimal K)

K = 5

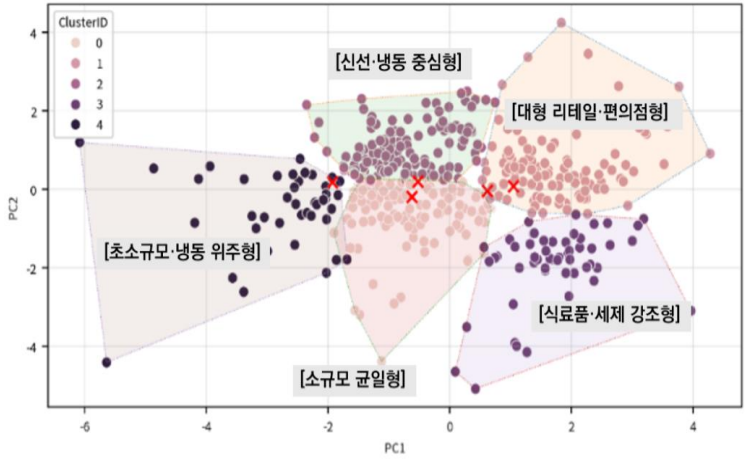
Elbow Method



Silhouette Score

군집 수	Silhouette Score
3	0.258
4	0.263
5	0.268
6	0.265

Cluster Scatter



Elbow Method

군집 내 제곱합(WCSS) 감소폭이 완만해지는 '팔꿈치' 지점인 K=5에서 최적의 군집 효율성 확인

Silhouette Score

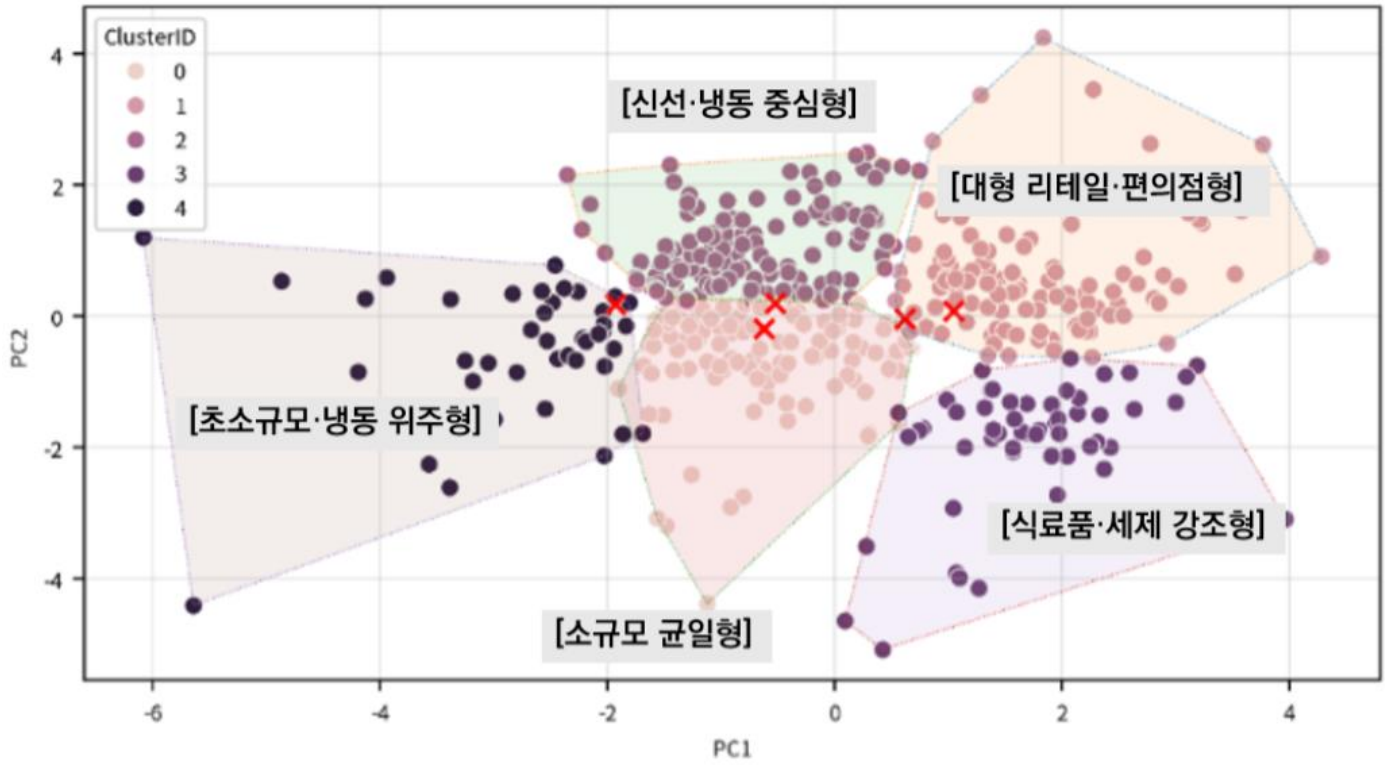
K=5 에서 실루엣 스코어 0.268 점수 기록하며 유의미한 군집 분리도 확보.

K=5 페르소나 도출

440명의 고객을 5개의 전략적 세그먼트로 나누어 차별화된 마케팅 전략 수립 가능

머신러닝 기반 분석 | K-MEANS 클러스터링 | 최적의 군집 수 선정

페르소나	고객 비중	매출 비중	평균 구매액 (MU)
🏬 대형 리테일형	25%	40%	54,557
🍽️ 신선·냉동 중심형	28%	29%	34,441
🛒 식료품·세제 강조형	12%	13%	34,367
⚖️ 소규모 균형형	26%	14%	17,898
❄️ 초소규모·냉동 위주형	9%	4%	14,506



머신러닝 기반 분석 | K-MEANS 클러스터링 | ① 대형 리테일

① 대형 리테일

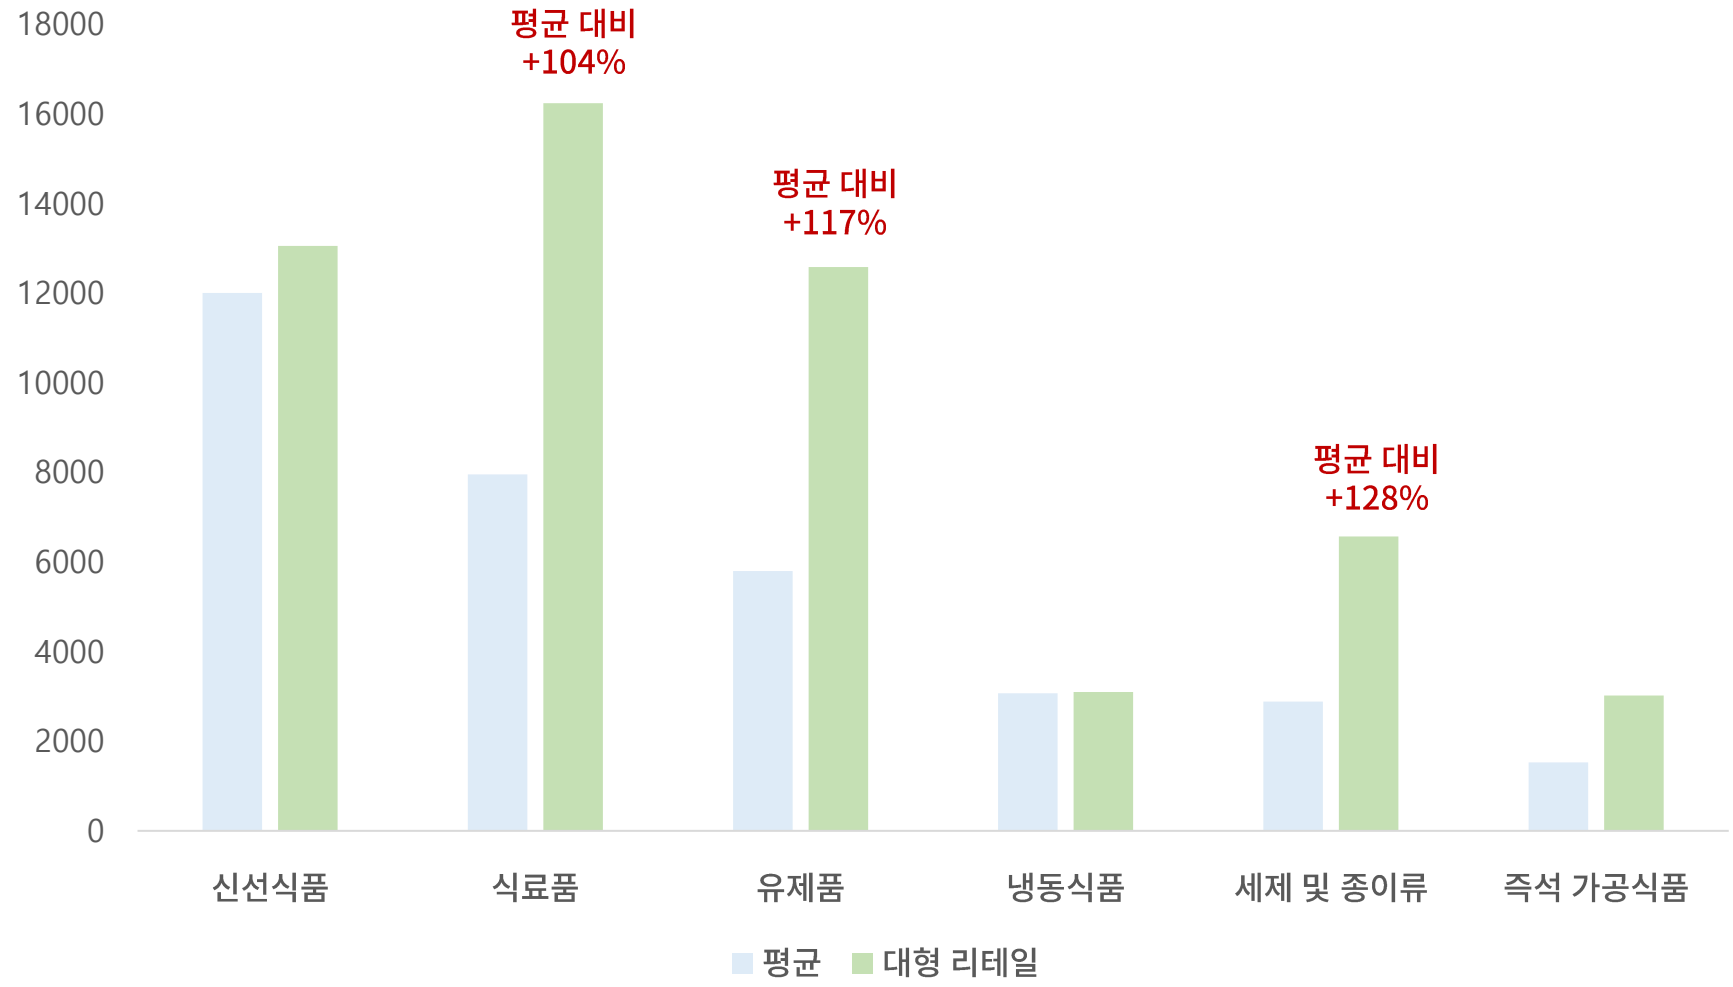
고객 비중	매출 기여
25%	40%

핵심 패턴

- 전 품목 평균 이상 구매력을 보이는 종합 유통 채널
- 식료품/유제품 매출액이 평균 2배 이상으로 대형 마트/기업형 슈퍼마켓에 속할 가능성이 높음

전략 | VIP 파트너쉽 강화

- 전담 매니저 배정
- 대량 구매 전용 단가 및 캐시백 제공을 통한 이탈 차단



머신러닝 기반 분석 | K-MEANS 클러스터링 | ② 신선·냉동 중심형

② 신선·냉동 중심형

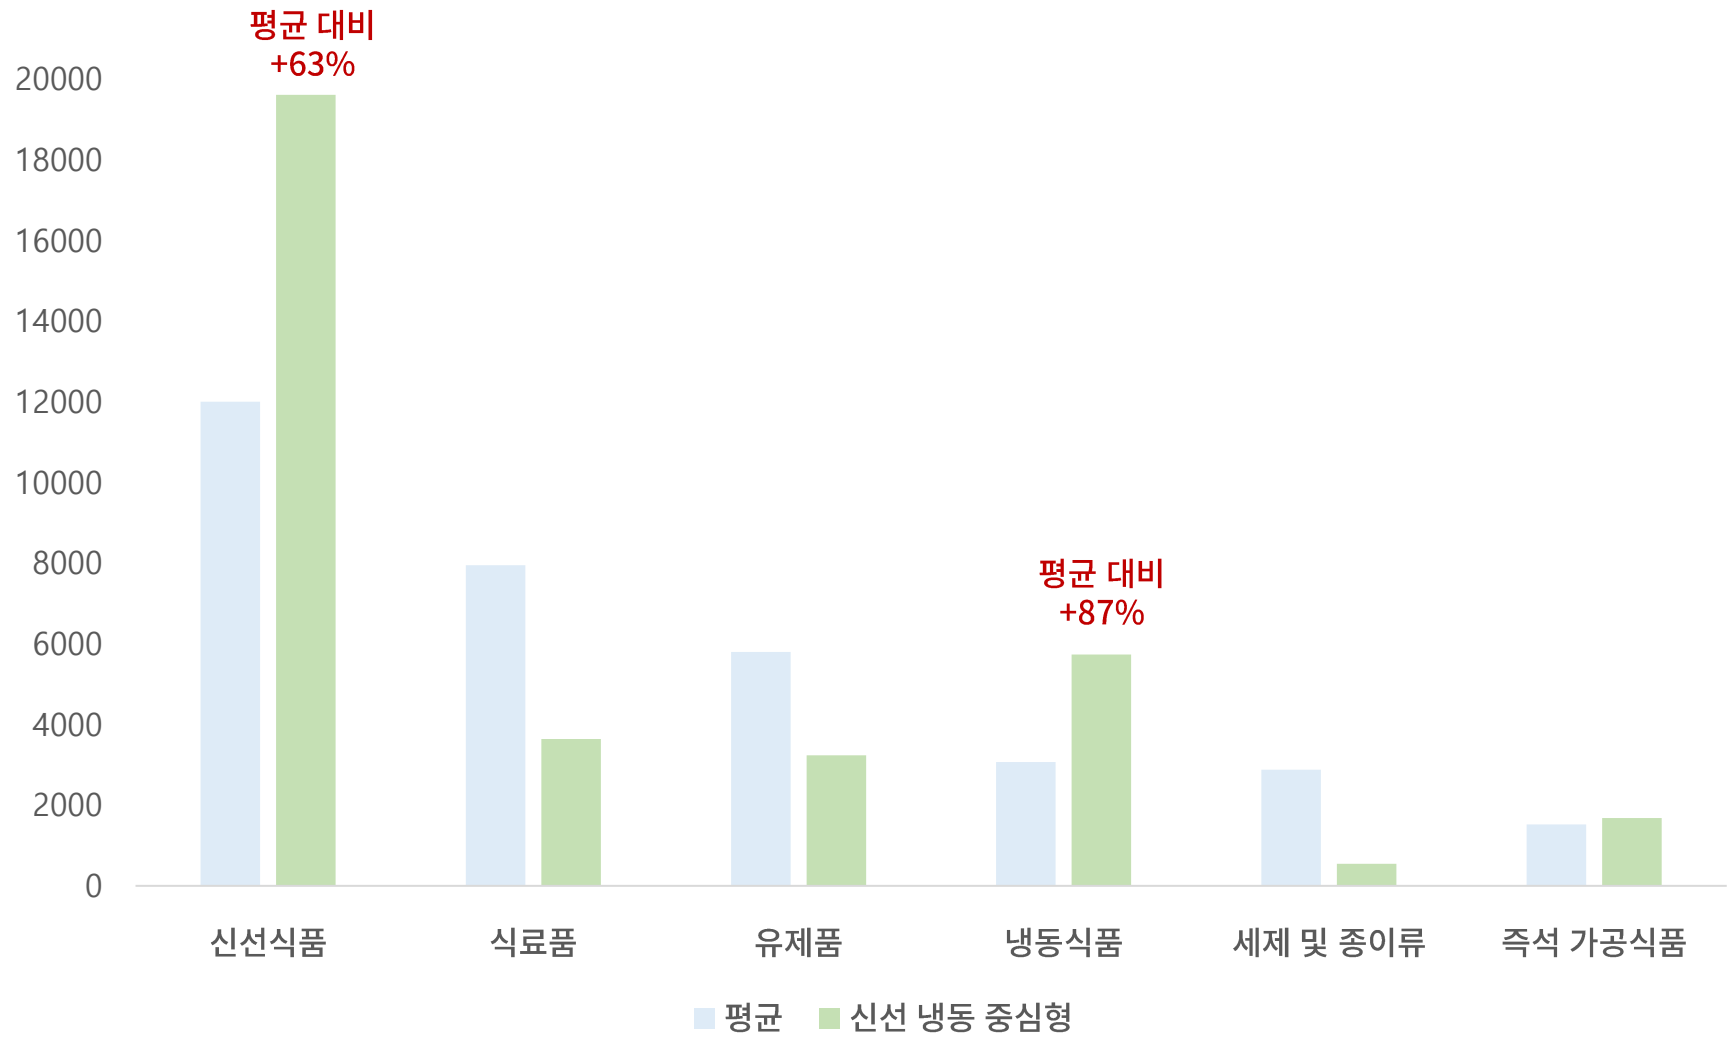
고객 비중	매출 기여
28%	29%

핵심 패턴

- 5개 군집 중 신선식품과 냉동식품 구매액이 가장 높음
- 식재료를 직접 조리하는 업체로 예상 (호텔/레스토랑 등)

전략 | 물류 밸류 체인 최적화

- 콜드체인 물류 강조 (배송 차량 온도 관리 등 품질 안정성 강조)
- 정기 식자재 구독 모델



머신러닝 기반 분석 | K-MEANS 클러스터링 | ③ 식료품·세제 강조형

③ 식료품·세제 강조형

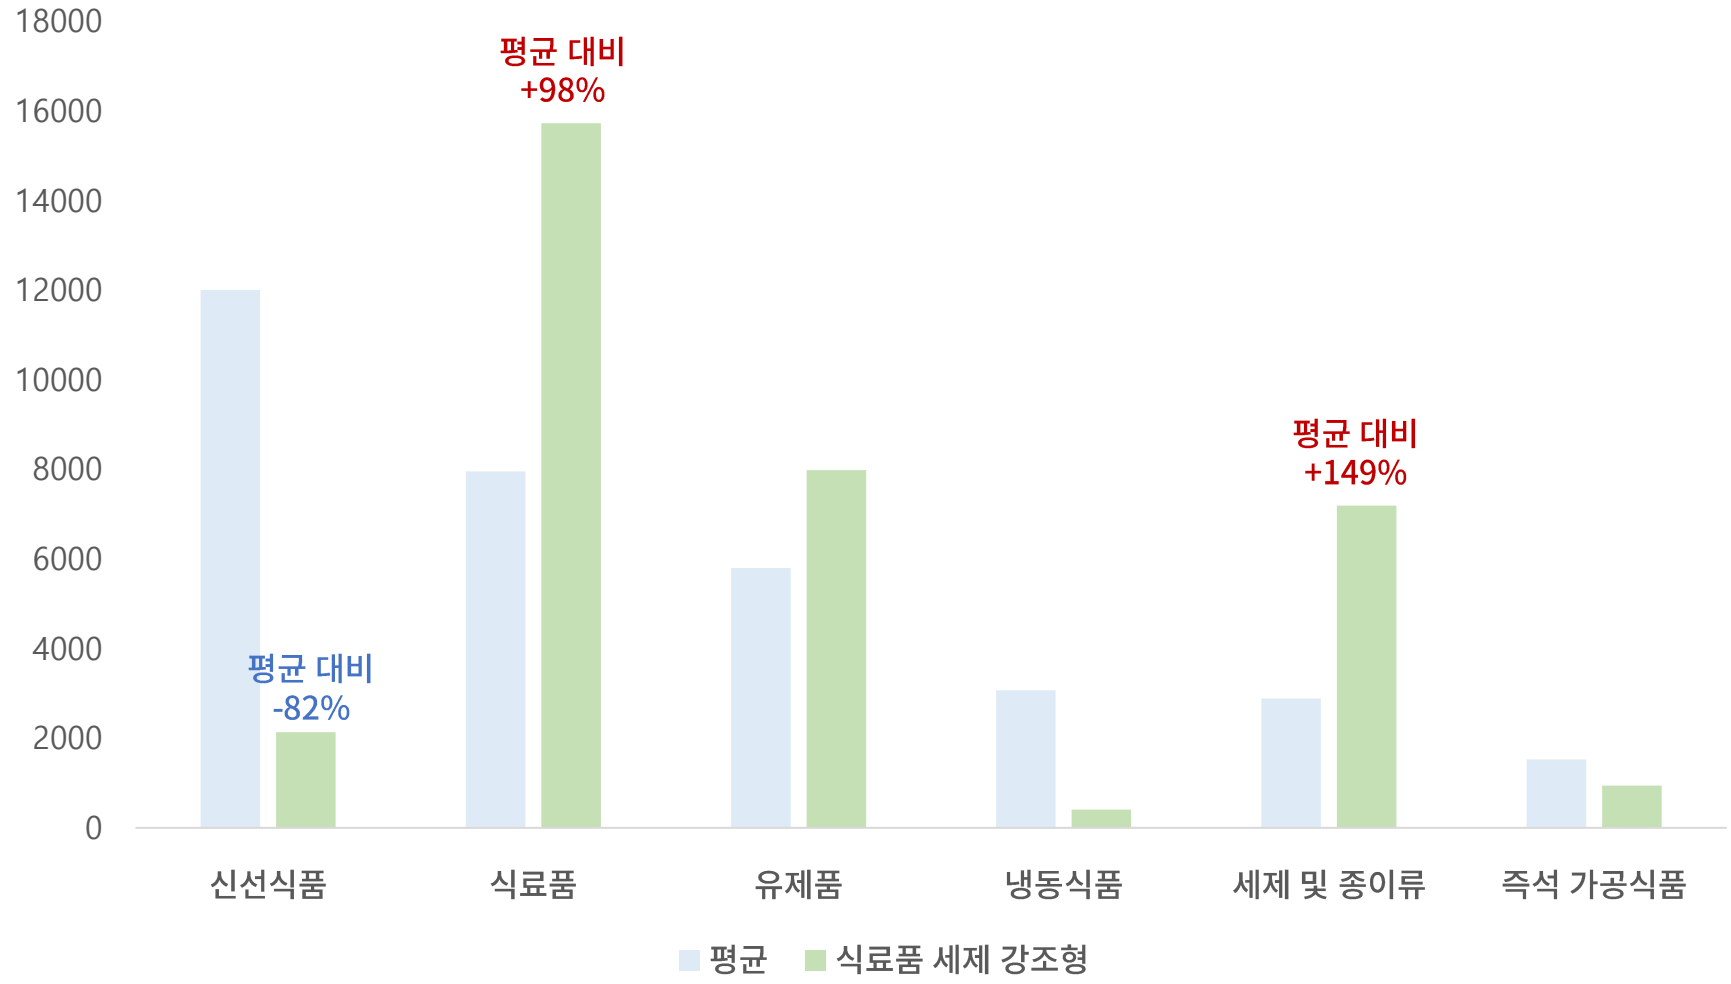
고객 비중	매출 기여
12%	13%

핵심 패턴

- 5개 군집 중 세제 및 종이류 구매 액이 평균 2.5배로 가장 높음
- 신선식품은 거의 취급하지 않아 유통기한이 긴 공산품 위주의 드럭스토어 및 생활용품 전문점 예상

전략 | 장바구니 침투 확대

- 장기 보관 가능한 즉석 가공식품 카테고리 제안을 통한 식품 매출 확대
- 인접 카테고리 크로스셀링
- 세제 및 종이류 구매 주기에 맞는 정기 프로모션



머신러닝 기반 분석 | K-MEANS 클러스터링 | ④ 소규모 균형형

④ 소규모 균형형

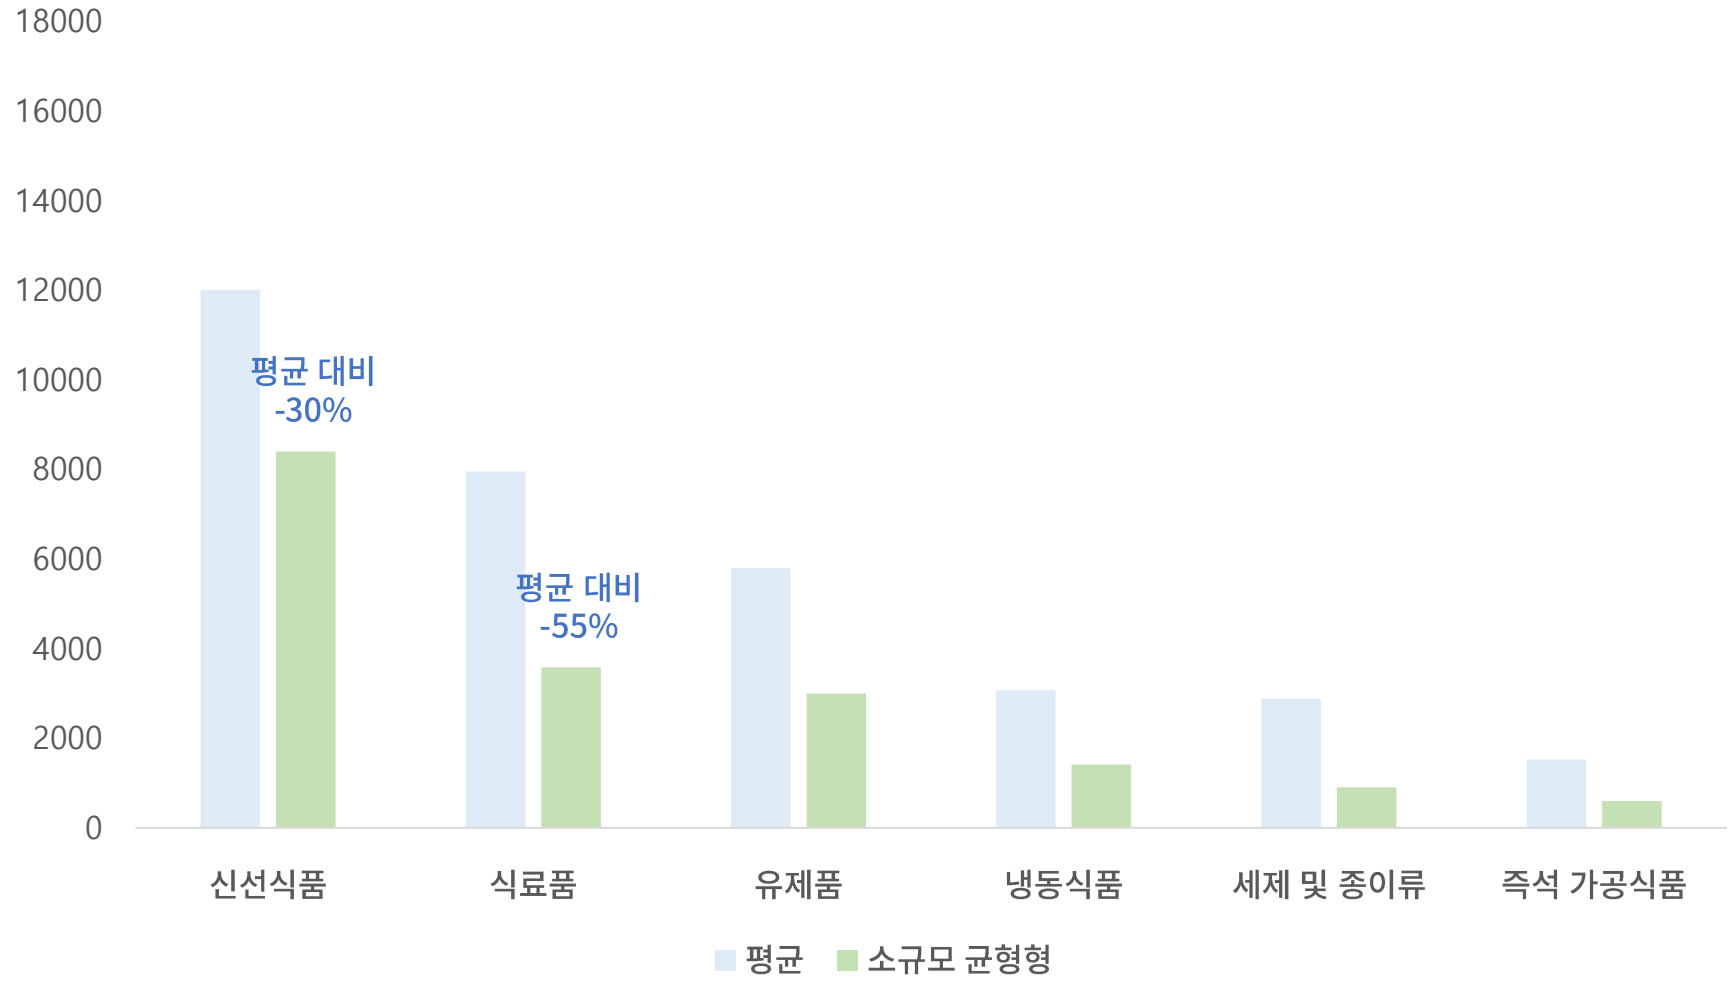
고객 비중	매출 기여
26%	14%

핵심 패턴

- 전 품목 매출액 전체 평균 이하
- 특정 품목에 치우치지 않음
- 규모가 작은 동네 소형 슈퍼나 소규모 개인 식당으로 예상

전략 | 관리 비용 절감 및 자동화

- 구매 금액은 낮지만 고객 비중이 높아 포인트 적립 등 로열티 멤버십으로 이탈은 방지
- 서비스 우선순위는 핵심 군집보다 낮게 설정



머신러닝 기반 분석 | K-MEANS 클러스터링 | ⑤ 초소규모·냉동 위주형

⑤ 초소규모·냉동 위주형

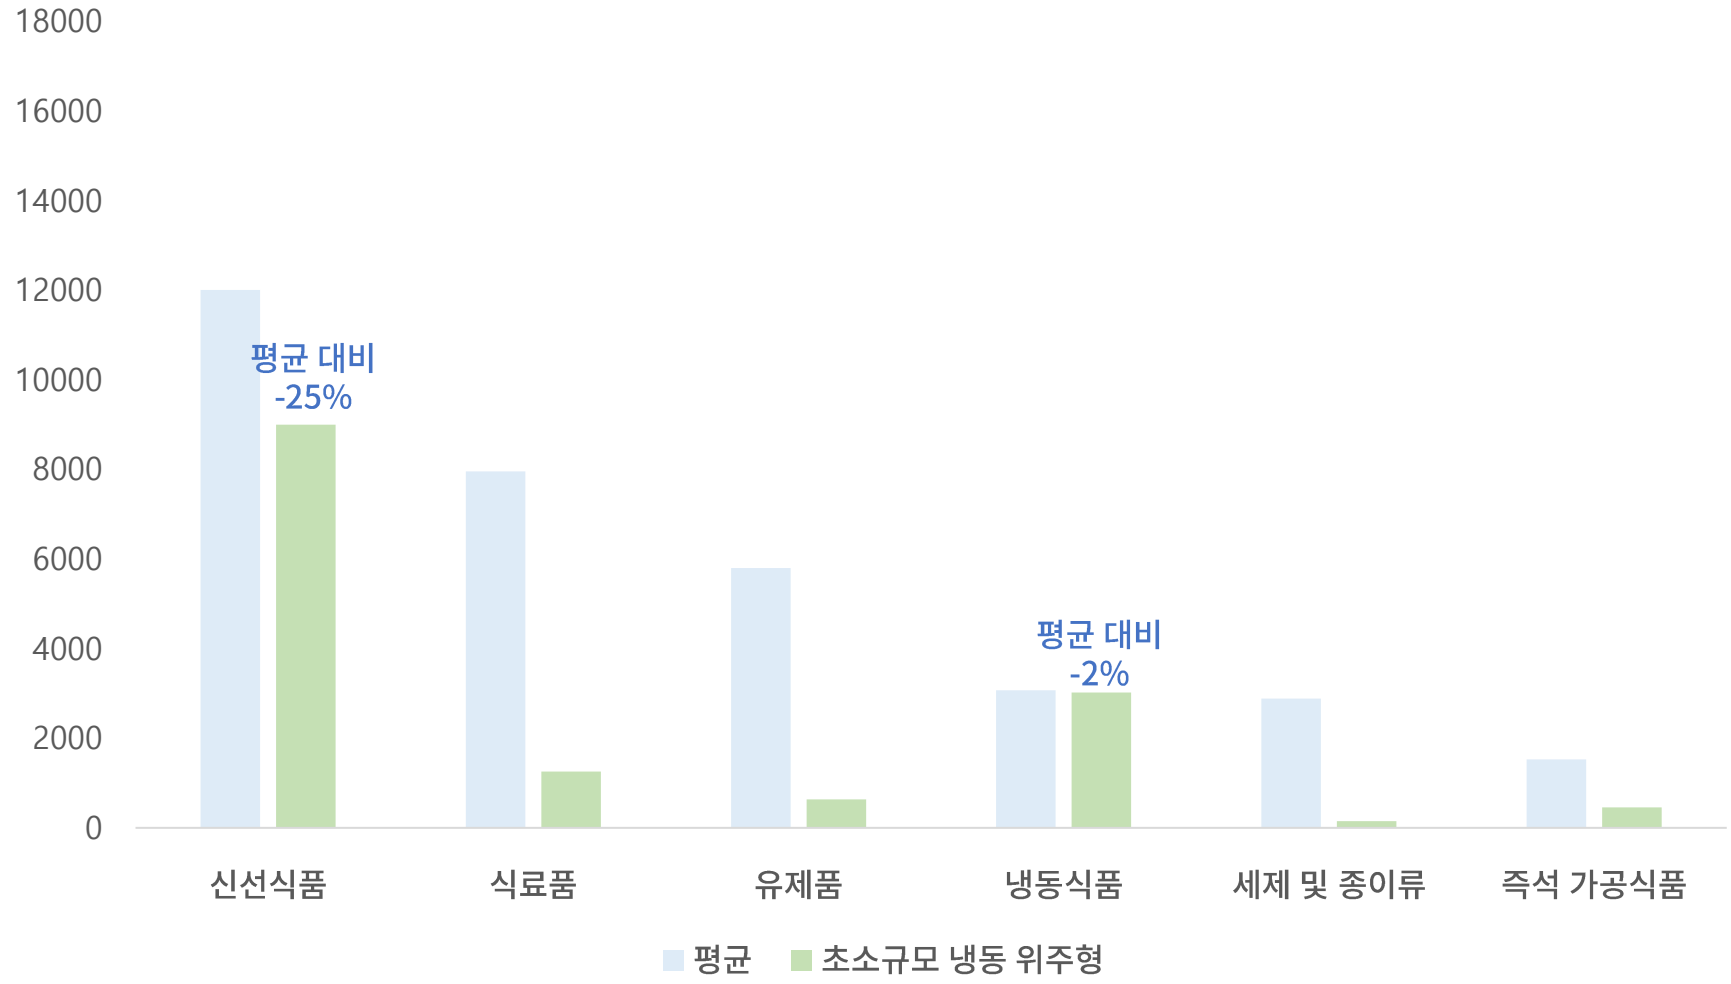
고객 비중	매출 기여
9%	4%

핵심 패턴

- 대부분 품목이 평균 이하 수준이나 냉동식품은 전체 평균과 비슷한 구매량
- 소규모지만 냉동식품을 특화해서 취급하는 냉동 전문 소형 소매점으로 예상

전략 | 특화 품목 집중 마케팅

- 냉동 특화 패키지를 기획하여 구매 편의성 제공
- 웰컴 프로모션을 강화하여 잠재력 있는 소형 점포 초기 확보



3. 머신러닝 기반 분석

- Prediction

머신러닝 기반 분석 | 고객 채널 예측 | 모델 학습/채택

예측 목적

신규 고객의 초기 구매 패턴 기반 마케팅 / 영업 리소스 최적화

데이터 및 전처리

- **타겟 변수(y):** Channel (0: Horeca / 1: Retail)
- **입력 변수(X):** 6개 품목의 구매액 + 지역(Region) 정보

- **주요 전처리:**
  - **Log Transformation:**
    데이터 간의 편차를 줄여 균형된 모델 학습 유도
  - **Standard Scaling:**
    모든 품목의 단위를 통일하여 '공정한 영향력' 부여
  - **One-Hot Encoding:**
    '지역' 같은 범주형 데이터를 컴퓨터가 인식하는 형태로 변환

분류	모델명	Train AUC (학습 데이터 성능)	CV AUC (검증 데이터 성능)	Gap(격차)	결과
선형 모델	Logistic Regression	0.942	0.916	0.026	채택
	SGD Classifier	0.940	0.908	0.032	채택
앙상블	XGBoost	0.999	0.905	0.094	채택
	Random Forest	1.000	0.919	0.081	채택
	CatBoost	0.998	0.892	0.106	제외 (낮은 효율)
	Gradient Boosting	1.000	0.881	0.119	제외 (과적합 경향)
의사결정 나무	Decision Tree	1.000	0.741	0.259	제외 (과적합 경향)

» **임계값에 상관없이 모델의 분류 능력을 종합적으로 보여주는 AUC 지표 기준 선정**

» **과적합 모델을 제외하고 일반화 성능 우선시**

머신러닝 기반 분석 | 고객 채널 예측 | 모델 성능

모델	정확도 (Accuracy)	정밀도 (Precision)	재현율 (Recall)	Test AUC	유형	세부 목적
Logistic Regression	0.90	0.90	0.77	0.95	[균형형]	설명력이 가장 좋고 성능이 안정적 '얼마나 많이 맞힐 수 있는가?'
XGBoost	0.89	0.93	0.71	0.93	[신중형]	Retail 오탐을 최소화해야 할 때 유리 'Retail 로 분류한 고객 중 진짜 Retail 은 몇 명인가?'
SGDClassifier	0.91	0.86	0.86	0.93	[적극형]	잠재 고객을 놓치지 않고 다 찾아낼 때 유리 '실제 Retail 고객들을 하나도 놓치지 않고 다 찾아냈는가?'

3. 머신러닝 기반 분석

- 성능 지표 해석

머신러닝 기반 분석 | 고객 채널 예측 | 모델 해석 | Feature Importance

모델의 판단 근거

Feature Importance : 어떤 변수가 가장 강력 큰 영향을 끼쳤는가 **(모델의 전체적 경향성 판단)**

모델	1순위 변수 (가중치)	2순위 변수 (가중치)	3순위 변수 (가중치)	유형	해석
Logistic Regression	세제·종이류 (1.39)	식료품 (0.88)	유제품 (0.58)	[균형형]	가중치가 계층적으로 고르게 분포함. 가장 표준적인 판단을 내림.
XGBoost	세제·종이류 (0.64)	유제품 (0.09)	식료품 (0.07)	[신중형]	세제(0.64) 가중치가 2위(0.09)보다 7배 이상 압도적임. 확실한 신호(세제류 대량구매)가 포착될 때만 날카롭게 반응함.
SGDClassifier	세제·종이류 (7.50)	식료품 (2.54)	신선식품 (2.04)	[적극형]	세제(7.50) 가중치가 매우 높고 모든 변수의 절댓값이 큼. 작은 구매 변화도 크게 확대 해석하여 타겟을 넓게 포착함.

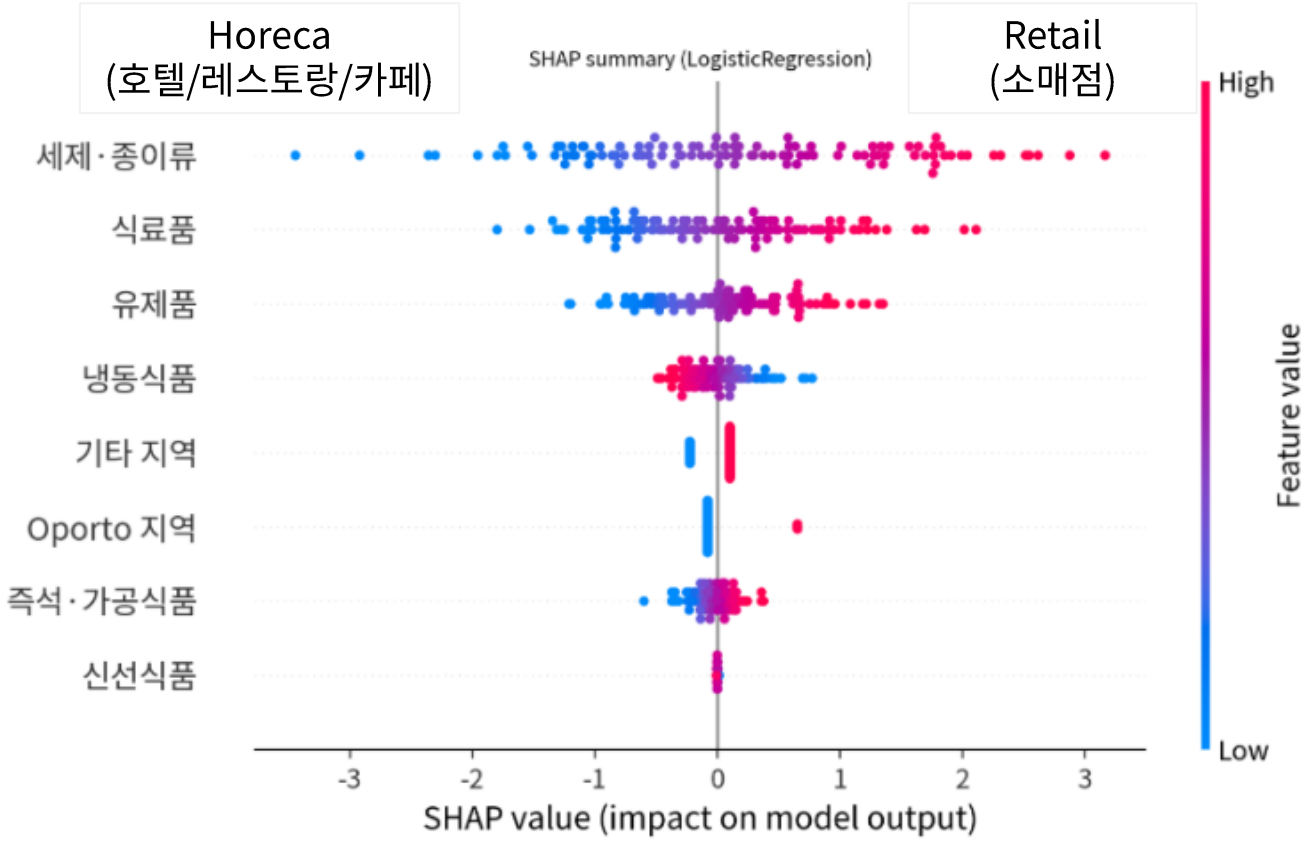
» **모든 알고리즘에서 세제·종이류가 도매 유통 고객 채널 분류에 있어 가장 큰 영향을 끼치는 변수로 확인**

» **도매 시장에서 유제품 , 식료품은 Horeca (호텔/레스토랑/카페) 와 Retail (소매점) 모두에서 구매가 발생하지만,**
세제·종이류는 가정 위주의 소모품으로서 Retail (소매점) 에서 더 큰 비중으로 구매가 발생하는 것으로 해석할 수 있음

머신러닝 기반 분석 | 고객 채널 예측 | 모델 해석 | SHAP Value

모델의 판단 근거

SHAP Value: 특정 고객을 예측할 때 각 변수가 확률에 어떻게 영향을 주었는가 **(각 데이터의 개별적 근거 제시)**



✓ [점의 위치]

오른쪽에 위치 → Retail 일 확률 높힘
왼쪽에 위치 → Horeca 일 확률 높힘

✓ [점의 색상]

빨간색 → 해당 품목의 구매액 높음
파란색 → 해당 품목의 구매액 낮음

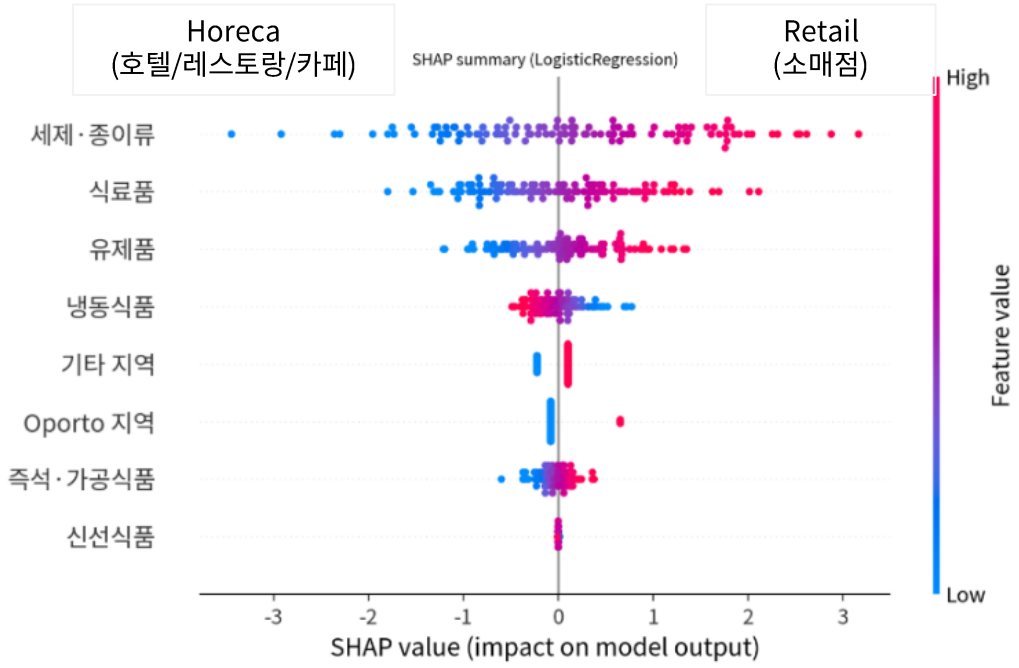
✓ [점의 분포]

점이 수직으로 두껍게 쌓인 형태
→ 비슷한 특성의 고객 다수 존재

머신러닝 기반 분석 | 고객 채널 예측 | 모델 해석 | SHAP Value

1.로지스틱 회귀(Logistic Regression)

데이터의 변화에 따라 예측 확률을 0%에서 100%까지 부드럽게 연결하여 계산하여 끊기지 않고 넓게 퍼진 패턴 보임



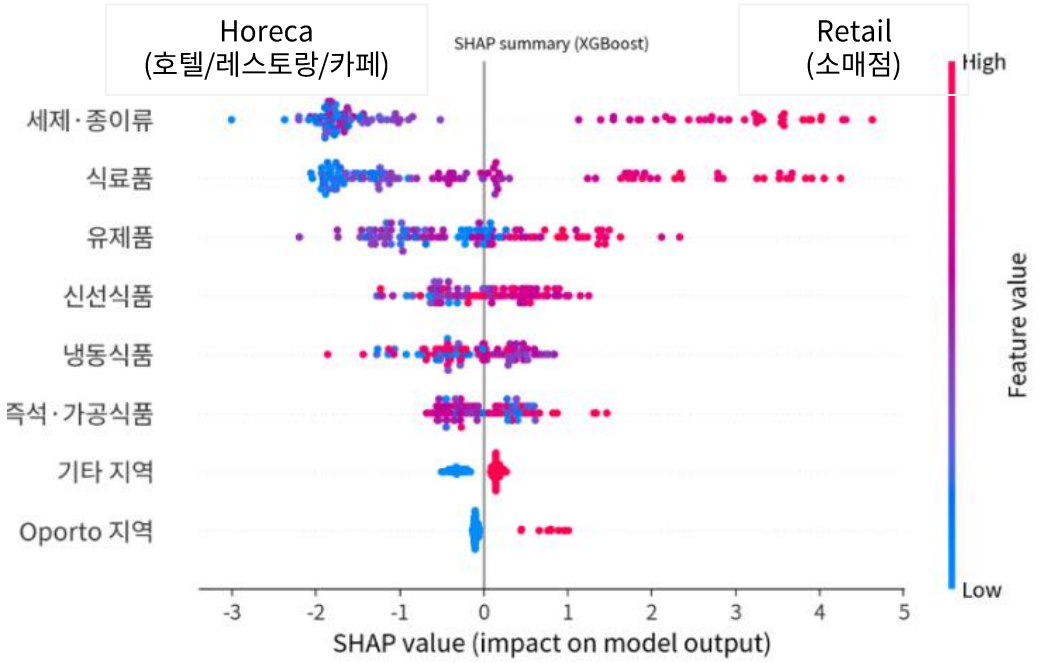
구분	주요 현상	모델 특성 반영	비즈니스 해석
세제·종이류	파랑→빨강으로 가장 넓게 확산	구매량이 늘어날수록 비례해서 확신을 가짐	소매점(Retail) 여부를 가르는 가장 중요한 품목
식료품	세제류와 유사한 넓은 그라데이션	세제와 함께 움직이며 확률을 탄탄하게 받쳐줌	리테일 채널임을 확신하게 만드는 강력한 보조 엔진
유제품	중앙 근처에서 촘촘하게 색이 섞임	크게 휘두르지 않고 미세하게 확률을 조정함	판단을 급하게 바꾸지 않는 신중한 보조 지표
냉동식품	역방향 그라데이션 (빨강이 왼쪽)	이 품목이 많아질수록 리테일과는 거리가 멀어짐	식재료 비중이 높은 호레카(Horeca)만의 시그니처
기타 지역 / Oporto 지역	색은 나뉘나 좌우 폭이 매우 좁음	참고는 하되 대세를 바꿀 힘은 주지 않음	"어디 사느냐"보다 "무엇을 사느냐"가 핵심임을 방증
즉석·가공식품	중앙에서 미세한 색상의 파동 보임	아주 미묘한 차이가 있을 때만 확률 끝자리를 만짐	단독 영향력은 작으나 패턴의 디테일을 완성함
신선식품	점들이 완전히 수직으로 고착됨	이 데이터는 채널 구분엔 아무런 도움이 안 된다고 무시함	모든 업종의 필수품이라 변별력이 없는 공통 품목

» **예측 안정성이 뛰어나 대시보드 시뮬레이션 시 사용자가 수치를 조절할 때 확률 게이지가 부드럽게 변화하여 데이터 변화에 따른 결과 추이가 가장 직관적**

머신러닝 기반 분석 | 고객 채널 예측 | 모델 해석 | SHAP Value

2. XGBoost

앞서 발생한 오차를 계속 보완하며 정답을 찾아가는 정교한 방식으로 학습, 확실한 단서가 있을 때 날카롭게 반응하여 특정 구간이 텅 비어있기도 함



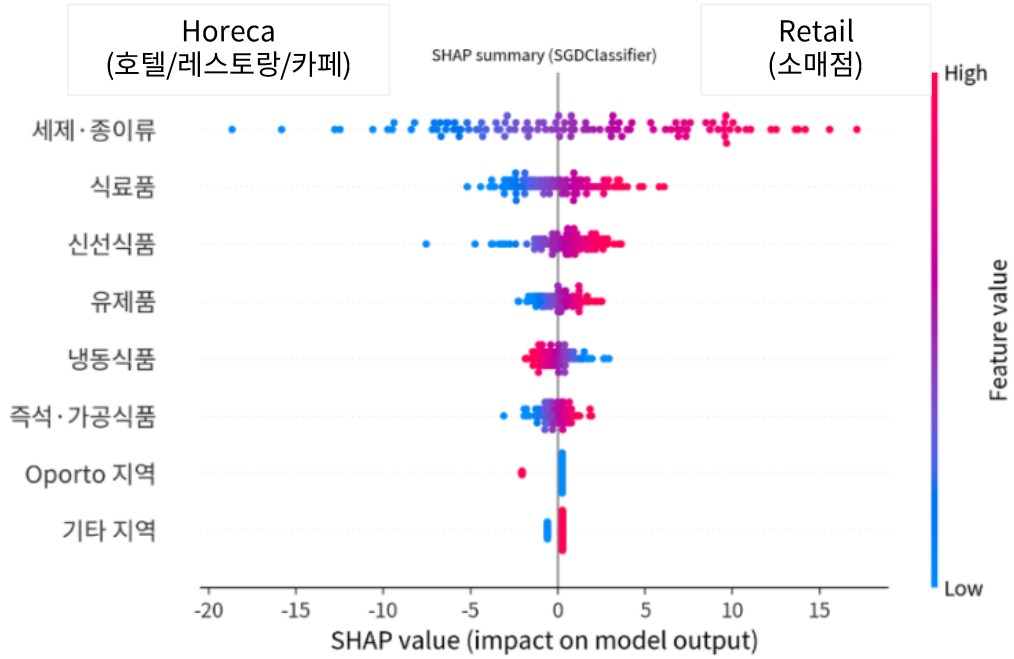
구분	주요 현상	모델 특성 반영	비즈니스 해석
세제·종이류	좌우로 완전히 갈라짐	채널을 가르는 '스위치' 같은 변수로 인식하며 가장 높은 비중 부여	이 품목의 구매액이 기준을 넘는 순간 무조건 소매점(Retail)으로 확신
식료품	좌우로 완전히 갈라짐	세제류의 판단을 보강하는 최종 확인 사격용 변수로 활용	세제와 식료품이 동시에 높으면 오탐률 0%에 가까운 신뢰도 확보
유제품	좌우로 넓게 퍼지나 중앙 밀도도 높음	세제/식료품이 애매할 때 확률을 미세하게 보정하는 역할	리테일 판단의 완성도를 높여주는 정밀한 보조 지표
신선식품	점들이 중앙에 뭉쳐 있으나 좌우 폭 존재	채널 분류의 메인 근거는 아니지만 조합에 따라 가점을 부여	다른 모델보다 신선식품의 구매 패턴을 조금 더 예민하게 관찰함
냉동식품	역방향 분포가 뚜렷하며 상단에 위치	식자재 중심 고객(Horeca)을 걸러내는 강력한 '마이너스' 필터	냉동식품 구매량이 일정 선을 넘으면 즉시 리테일 후보에서 제외
즉석·가공식품	중앙(0) 근처에 점들이 수직 밀집	아주 확실한 데이터가 아니면 판단 근거로 삼지 않는 신중함	틈새 구매 패턴이 명확한 고객에게만 제한적으로 영향력 발휘
지역 변수 (기타/Oporto)	색상은 갈리나 중앙(0)에 완벽히 고정	지역적 요인은 채널 예측에 아무런 도움이 안 된다고 단정함	고객의 지역적 위치 보다는 '구매 품목'에 집중

» **확실한 신호가 있을 때 Retail 로 분류하는 신중한 모델로, 틀린 예측으로 인한 비용 낭비를 줄여야 하거나 고효율 마케팅을 집행해야 하는 상황에 최적화**

머신러닝 기반 분석 | 고객 채널 예측 | 모델 해석 | SHAP Value

3. SGDClassifier

작은 특성 변화도 예측 결과에 반영되므로, 초기 신호를 빠르게 감지하는 데 유리한 모델 구조

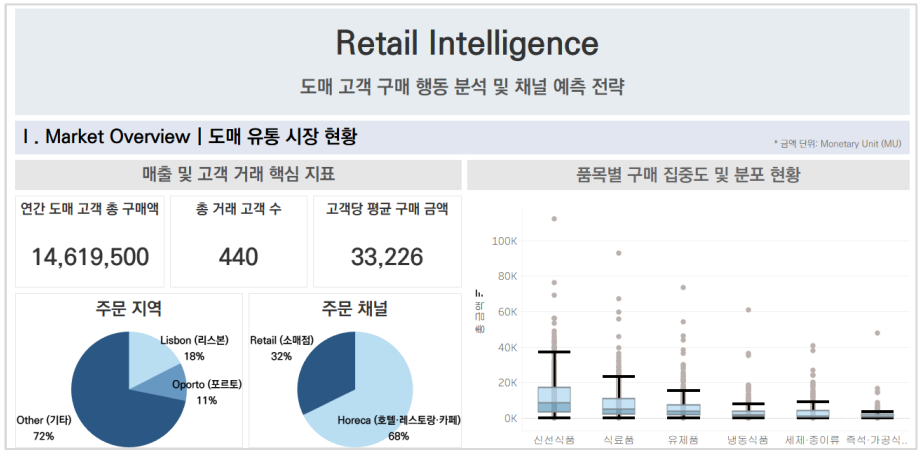


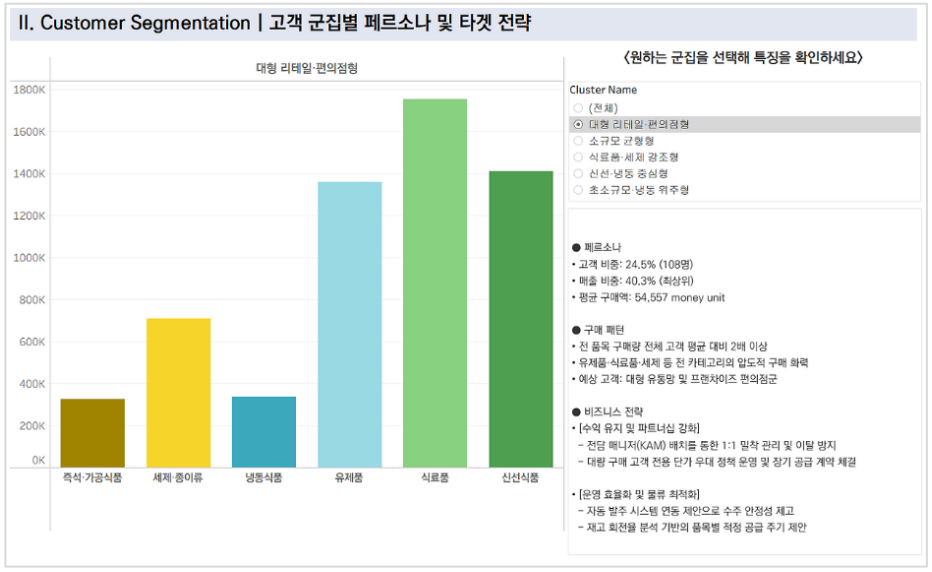
구분	주요 현상	모델 특성 반영	비즈니스 해석
세제·종이류	SHAP 수치가 ±20까지 넓게 뻗음	확실한 변수에 압도적인 가중치(7.50)를 부여해 판단의 기점으로 삼음	소매점(Retail)을 발굴하는 데 있어 가장 강력한 확성기 역할
식료품	중앙에 밀집해 있으나 색 분리가 선명	세제류 다음으로 중요한 신호로 인식하며 빠르게 가중치를 부여함	채널의 정체성을 확정 짓는 핵심적인 보조 지표
신선식품	다른 모델보다 상위권에 위치하며 확산됨	미세한 데이터 노이즈도 판단 근거로적극 활용하려는 성향	신선식품 구매가 적은 고객군을 매우 예민하게 걸러냄
유제품	중앙 부근에서 색상 그라데이션 뚜렷함	유제품 구매액 변화에 따라 기민하게 확률을 조정함	채널 예측의 정밀도를 높여주는 섬세한 안테나 역할
냉동식품	역방향 (빨간 점이 왼쪽) 흐름 뚜렷함	냉동식품 비중이 높을 때 Horeca로 강하게 밀어붙임	식자재 중심 고객을 선별하는 강력하고 날카로운 필터
즉석·가공식품	점들이 좌우로 고르게 퍼져 있음	작은 구매 비중도 판단 근거에 적극 포함시키는 모델 성향	패턴의 디테일을 끝까지 추적하여 분류 성능을 보강함
지역 변수 (Oporto/기타)	색상이 나뉘나 영향력은 매우 미미	지리적 요인보다 구매 행동에만 집중하도록 학습됨	위치 정보에 휘둘리지 않는 객관적인 판단 유지

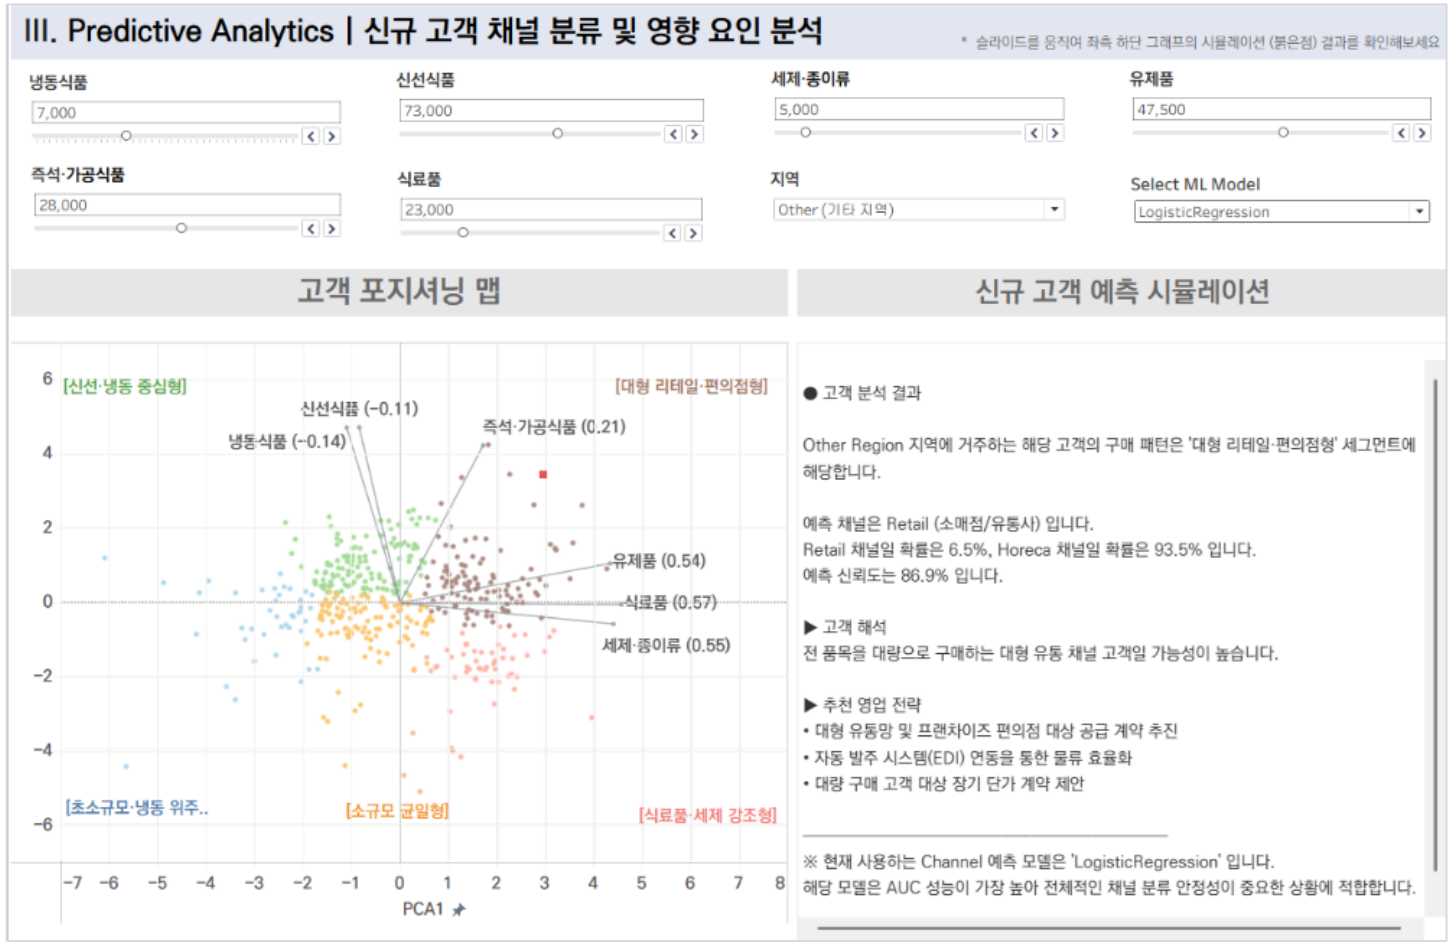
» **높은 수치 반응성으로 값이 조금만 바뀌어도 예측 결과가 크게 변할 수 있음, 즉 Retail 특성이 조금이라도 보이면 놓치지 않는 적극적인 필터링 전략을 취하여 마케팅 초기에 잠재고객군을 넓게 확보해야하는 전략에 적합**

4. 태블로 대시보드 시각화

태블로 대시보드 구현


Retail Intelligence
도매 고객 구매 행동 분석 및 채널 예측 전략
Ⅰ. Market Overview | 도매 유통 시장 현황
* 금액 단위: Monetary Unit (MU)
매출 및 고객 거래 핵심 지표
품목별 구매 집중도 및 분포 현황
연간 도매 고객 총 구매액
14,619,500
총 거래 고객 수
440
고객당 평균 구매 금액
33,226
주문 지역
Lisbon (리스본) 18%
Oporto (포르토) 11%
Other (기타) 72%
주문 채널
Retail (소매점) 32%
Horeca (호텔·레스토랑·카페) 68%
100K
80K
60K
40K
20K
0K
신선식품
식료품
유제품
냉동식품
세제·종이류
즉석·가공식..


Ⅱ. Customer Segmentation | 고객 군집별 페르소나 및 타겟 전략
대형 리테일·편의점형
1800K
1600K
1400K
1200K
1000K
800K
600K
400K
200K
0K
즉석·가공식품
세제·종이류
냉동식품
유제품
식료품
신선식품
〈원하는 군집을 선택해 특징을 확인하세요〉
Cluster Name
(전체)
대형 리테일·편의점형
소규모 균형형
식료품·세제 강조형
신선·냉동 중심형
초소규모·냉동 위주형
● 페르소나
• 고객 비중: 24.5% (108명)
• 매출 비중: 40.3% (최상위)
• 평균 구매액: 54,557 money unit
● 구매 패턴
• 전 품목 구매량 전체 고객 평균 대비 2배 이상
• 유제품·식료품·세제 등 전 카테고리의 압도적 구매 화력
• 예상 고객: 대형 유통망 및 프랜차이즈 편의점군
● 비즈니스 전략
• [수익 유지 및 파트너십 강화]
- 전담 매니저(KAM) 배치를 통한 1:1 밀착 관리 및 이탈 방지
- 대량 구매 고객 전용 단가 우대 정책 운영 및 장기 공급 계약 체결
• [운영 효율화 및 물류 최적화]
- 자동 발주 시스템 연동 제안으로 수주 안정성 제고
- 재고 회전율 분석 기반의 품목별 적정 공급 주기 제안


Ⅲ. Predictive Analytics | 신규 고객 채널 분류 및 영향 요인 분석
* 슬라이드를 움직여 좌측 하단 그래프의 시뮬레이션 (붉은점) 결과를 확인해보세요
냉동식품
7,000
신선식품
73,000
세제·종이류
5,000
유제품
47,500
즉석·가공식품
28,000
식료품
23,000
지역
Other (기타 지역)
Select ML Model
LogisticRegression
고객 포지셔닝 맵
신규 고객 예측 시뮬레이션
[신선·냉동 중심형]
[대형 리테일·편의점형]
[초소규모·냉동 위주..
[소규모 균일형]
[식료품·세제 강조형]
신선식품 (-0.11)
냉동식품 (-0.14)
즉석·가공식품 (0.21)
유제품 (0.54)
식료품 (0.57)
세제·종이류 (0.55)
PCA1
● 고객 분석 결과
Other Region 지역에 거주하는 해당 고객의 구매 패턴은 '대형 리테일·편의점형' 세그먼트에 해당합니다.
예측 채널은 Retail (소매점/유통사) 입니다.
Retail 채널일 확률은 6.5%, Horeca 채널일 확률은 93.5% 입니다.
예측 신뢰도는 86.9% 입니다.
▶ 고객 해석
전 품목을 대량으로 구매하는 대형 유통 채널 고객일 가능성이 높습니다.
▶ 추천 영업 전략
• 대형 유통망 및 프랜차이즈 편의점 대상 공급 계약 추진
• 자동 발주 시스템(EDI) 연동을 통한 물류 효율화
• 대량 구매 고객 대상 장기 단가 계약 제안
※ 현재 사용하는 Channel 예측 모델은 'LogisticRegression' 입니다.
해당 모델은 AUC 성능이 가장 높아 전체적인 채널 분류 안정성이 중요한 상황에 적합합니다.

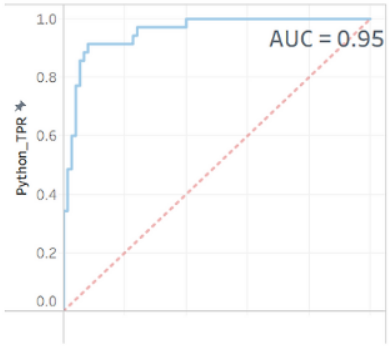
태블로 대시보드 구현

IV. Model Evaluation | 예측 모델 신뢰도 및 주요 변수 기여도(SHAP)

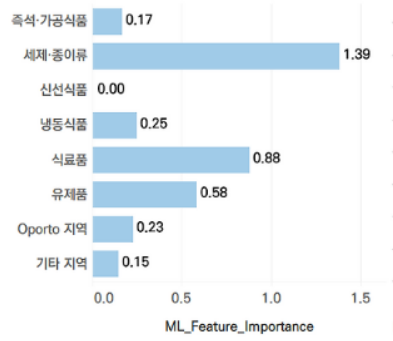
모델	추천 목적	정확도	정밀도	재현율	F1	AUC
LogisticRegression	AUC 최고 → 전반적인 채널 분류 성능이 중요한 상황	90%	90%	77%	83%	95%
XGBoost	정밀도 최고 → Retail 고객 오탐을 최소화해야 하는 상황	89%	93%	71%	81%	93%
RandomForest	정확도·정밀도 균형 → 안정적인 고객 채널 분류 분석	90%	90%	77%	83%	95%
SGDClassifier	재현율 최고 → Horeca 고객을 놓치지 않는 것이 중요한 상황	91%	86%	86%	86%	93%

LogisticRegression 모델 성능 요약

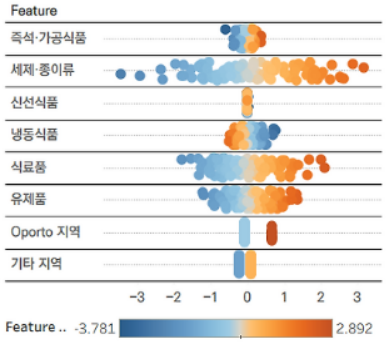
모델 분류 성능



모델 결정 핵심 변수



변수별 상세 영향도



Machine Learning Insights

[요약]
Logistic Regression 모델은 전체 모델 중 종합적인 분류 성능(AUC)이 가장 뛰어난 최적 모델입니다.

[모델 분류 성능 (AUC)]
분석 결과 AUC 약 0.95로 가장 높은 수치를 기록하며, 전반적인 채널 분류 예측의 안정성이 가장 높음을 입증했습니다.

[모델 결정 핵심 변수 (Feature Importance)]
핵심 변수 분석 결과 '세제·종이류(1.39)'가 가장 큰 비중을 차지하며, '식료품(0.88)', '유제품(0.58)'이 그 뒤를 이었습니다. 구매 규모에 따른 채널 구분이 명확하게 이루어지고 있습니다.

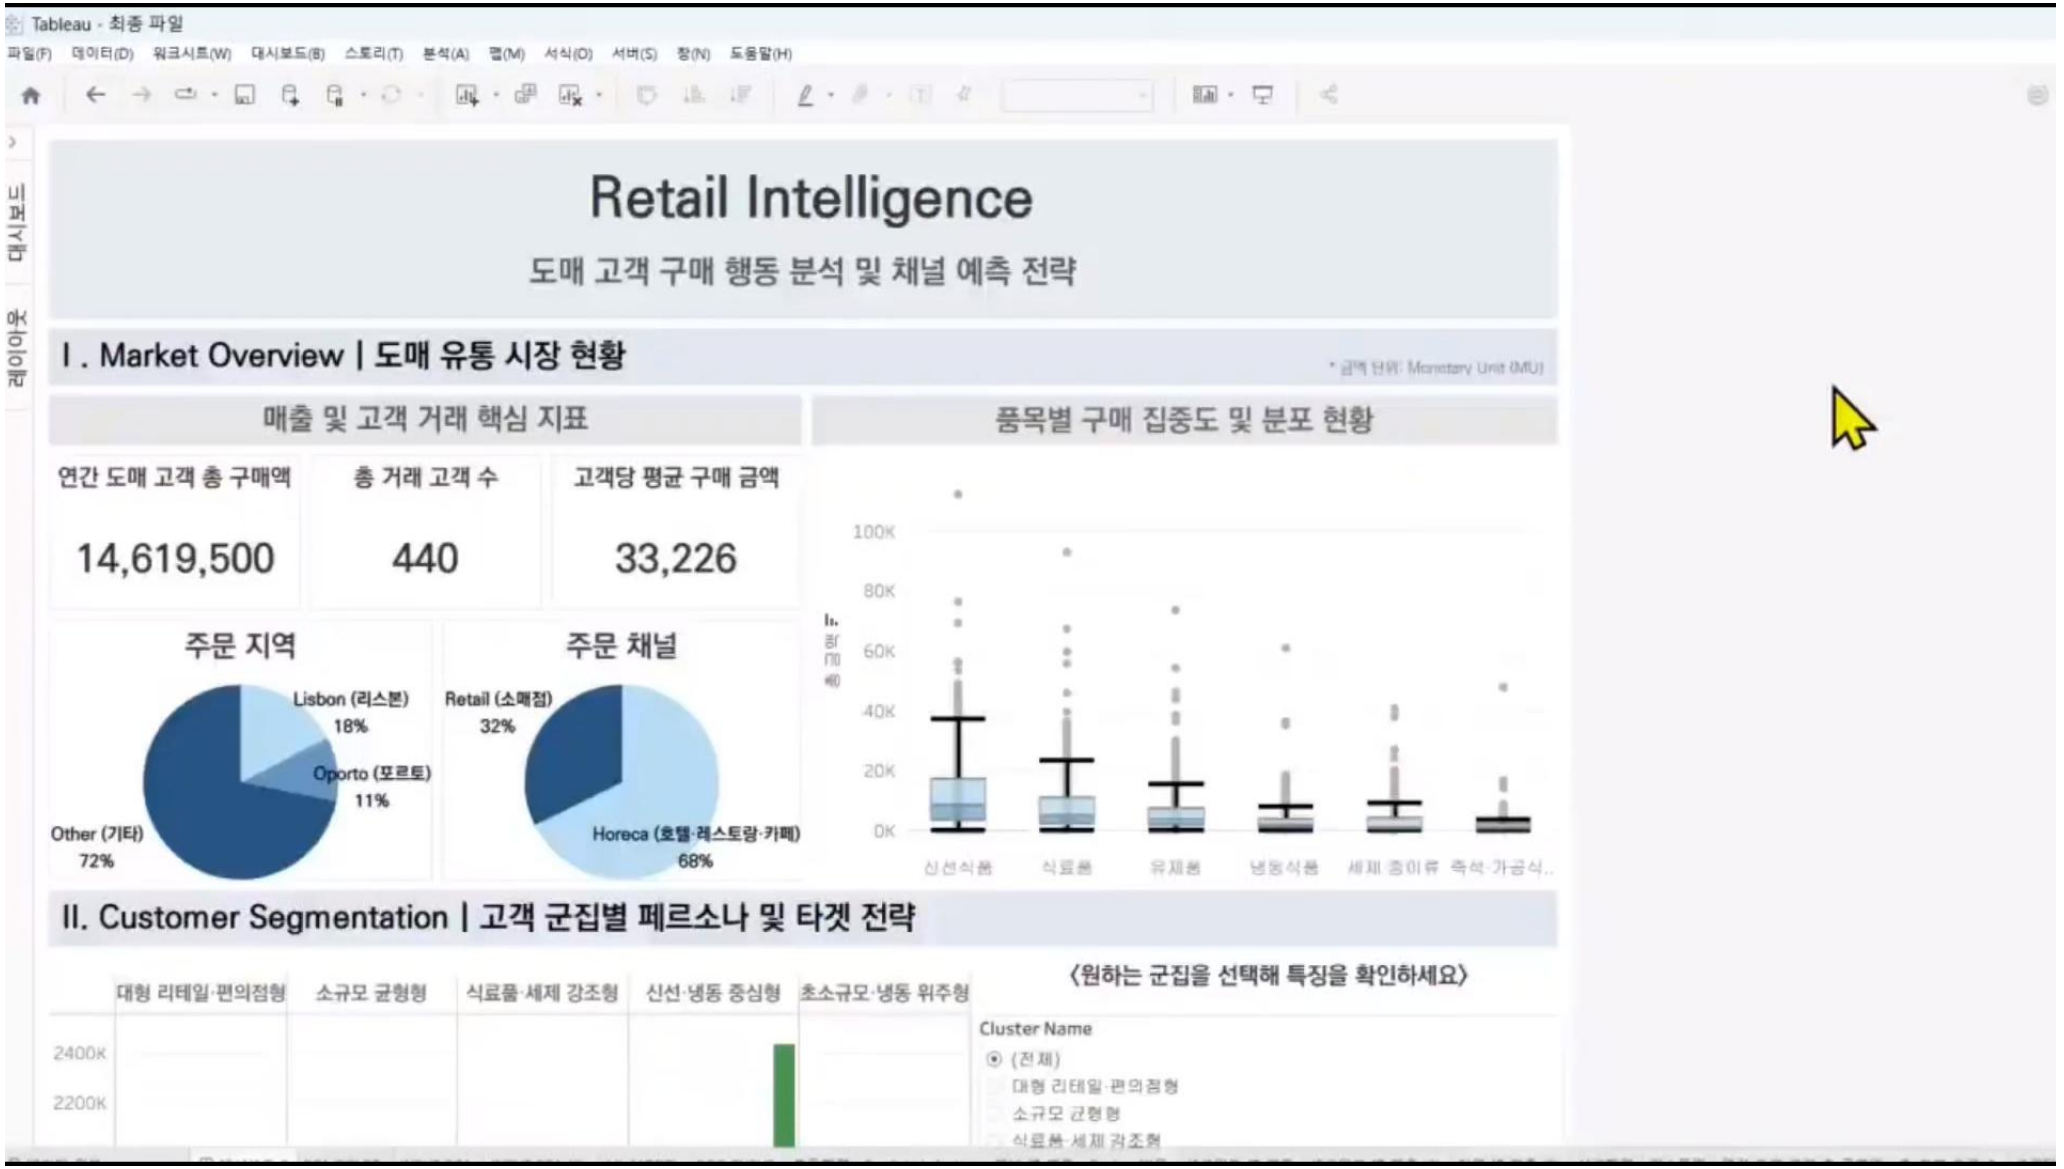
[변수별 상세 영향도 (SHAP Analysis)]
'세제·종이류'의 높은 구매량이 Retail 예측의 핵심 동력으로 작용하고 있습니다. 식료품과 유제품 또한 유사한 분포 패턴을 보이며 분류 결과의 신뢰도를 높여줍니다.

[활용 시사점]
전체 채널 분류 성능이 가장 우수함 뿐만 아니라, 변수의 영향력 해석이 직관적이어서 비즈니스 의사결정 근거로 활용하기 가장 유리한 모델입니다.

V. 머신러닝 모델 및 분석 지표 설명

구분	지표	설명
머신러닝 모델	Logistic Regression	• 변수와 결과 사이 관계를 기반으로 고객 채널을 예측하는 분류 모델 • 구조가 단순하고 변수 영향 해석이 쉬운 특징 • 고객 구매 패턴이 채널 분류에 어떻게 작용하는지 이해하기 쉬움
	Random Forest	• 여러 개의 의사결정 트리를 결합해 예측 성능을 높인 모델 • 다양한 변수 조합을 동시에 고려하는 특징 • 복잡한 구매 패턴 데이터 분석에 안정적인 예측 성능 제공
	SGDClassifier	• 확률적 경사 하강법 기반 선형 분류 모델 • 계산 속도가 빠르고 대규모 데이터에 효율적인 특징 • 고객 탐지율이 중요한 상황에서 활용 가능
	XGBoost	• Gradient Boosting 기반의 고성능 머신러닝 모델 • 여러 모델을 반복적으로 개선하며 예측 정확도를 높이는 구조 • 고객 분류나 예측 문제에서 높은 성능을 보이는 모델

태블로 대시보드 구현

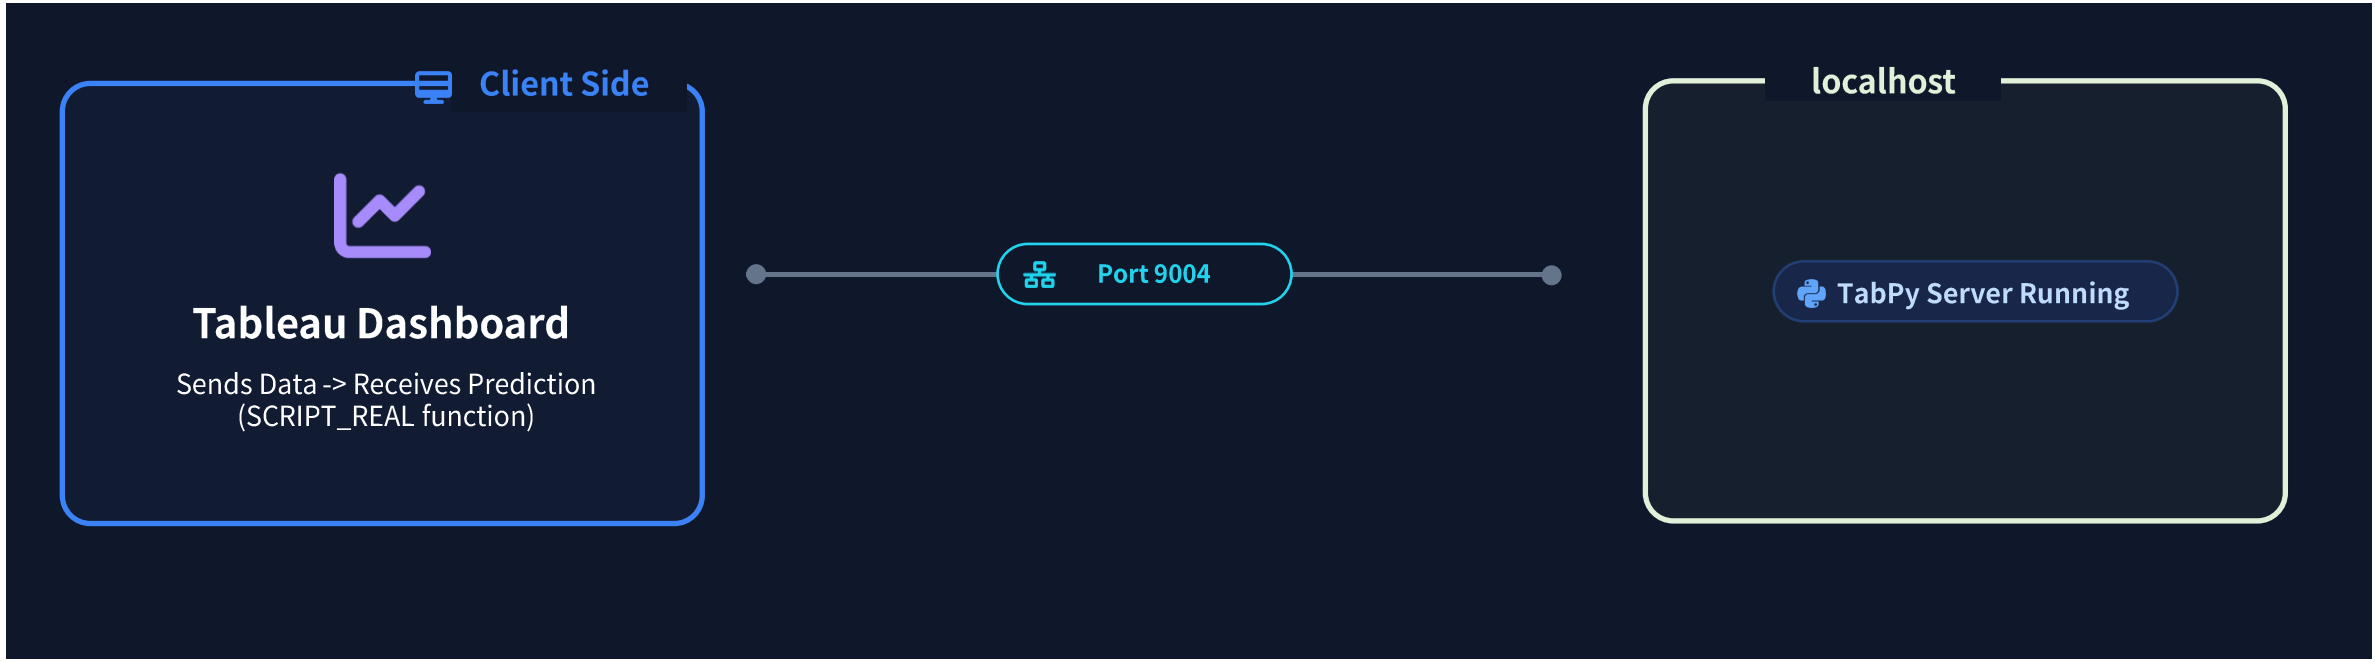

Tableau - 최종 파일
파일(F) 데이터(D) 워크시트(W) 대시보드(B) 스토리(T) 분석(A) 맵(M) 서식(O) 서버(S) 창(N) 도움말(H)
대시보드
레이아웃
Retail Intelligence
도매 고객 구매 행동 분석 및 채널 예측 전략
I . Market Overview | 도매 유통 시장 현황
* 금액 단위: Monetary Unit (MU)
매출 및 고객 거래 핵심 지표
연간 도매 고객 총 구매액
14,619,500
총 거래 고객 수
440
고객당 평균 구매 금액
33,226
주문 지역
Lisbon (리스본) 18%
Oporto (포르토) 11%
Other (기타) 72%
주문 채널
Retail (소매점) 32%
Horeca (호텔·레스토랑·카페) 68%
품목별 구매 집중도 및 분포 현황
100K
80K
60K
40K
20K
0K
신선식품
식료품
유제품
냉동식품
세제·종이류
축산·가금식..
II. Customer Segmentation | 고객 군집별 페르소나 및 타겟 전략
대형 리테일·편의점형
소규모 균형형
식료품·세제 강조형
신선·냉동 중심형
초소규모·냉동 위주형
2400K
2200K
〈원하는 군집을 선택해 특징을 확인하세요〉
Cluster Name
(전체)
대형 리테일·편의점형
소규모 균형형
식료품·세제 강조형

5. TabPy& AWS EC2 인프라 구축

TabPy 기반 태블로 대시보드 시각화

TabPy 란?

태블로에서 파이썬 스크립트나 머신러닝 모델을 실행할 수 있게 해주는 전용 엔진(API 서버) , 머신러닝 예측 결과 실시간 시각화 가능



[localhost 방식의 한계]
개인 컴퓨터에서만 TabPy 가 켜지는 구조는 PC 가 꺼지는 순간 대시보드의 실시간 예측 기능이 사용할 수 없게 되고, 태블로 서버는 기업용 솔루션으로 비용 부담 발생

TabPy& AWS EC2 인프라 구축

AWS EC2 (Elastic Compute Cloud)

아마존 웹 서비스에서 제공하는 클라우드 컴퓨팅으로 독립된 컴퓨터를 임대해주는 서비스



[클라우드 기반 해결]
AWS EC2 는 사용한 만큼만 서버 비용을 지불하여 저렴하게 서버를 구축할 수 있고, AWS 24시간 무중단 서버를 통해 PC 가 꺼져도 대시보드 접속이 가능하도록 구현

6. 비즈니스 내 대시보드 활용

비즈니스 내 예측 대시보드 활용

» 본 대시보드는 도매 매출 데이터를 기반으로 신규 고객의 성향을 즉각 예측하여, 영업 성공률을 높이고 운영 비용을 절감하는 '비즈니스 나침반' 역할

활용 예시

신규 고객 온보딩	**상황:** 새로운 도매 가입자가 첫 구매로 '신선식품'과 '냉동식품' 위주로 주문 **활용:** 대시보드 예측 결과 [신선·냉동 중심형] 군집으로 분류 **액션:** 자동으로 이 고객에게 '콜드체인 배송 시간표'와 '대용량 식자재 할인권'을 발송하여 안정적인 온보딩 진행
영업 타겟팅	**상황:** 매출액 데이터 입력 시 [대형 리테일] 군집으로 예측되는 고객 발견 **활용:** 이 고객은 매출 기여도가 40%에 달할 핵심 VIP 후보 **액션:** 경쟁사에 뺏기지 않도록 즉시 전담 매니저를 배정하고, 대량 구매 (캐시백) 혜택 조건을 안내하여 이탈 방지
채널별 맞춤형 물류 전략	**상황:** 대시보드에서 특정 지역의 신규 고객들이 [Retail(소매)] 채널로 집중 예측 **활용:** 소매 채널은 '식료품'과 '세제류' 수요가 높다는 것을 이미 파악하고 있음 **액션:** 해당 지역 물류 창고에 신선식품보다는 세제와 공산품 재고를 미리 확보하고, 차량 배차 간격 재조정

7. 개인 회고

개인 회고

» 다양한 머신러닝 모델을 비교·분석하며 데이터의 패턴을 이해하고, 이를 비즈니스 관점에서 해석하는 경험을 쌓을 수 있었습니다.
특히 TabPy와 Tableau를 연동하여 예측 결과를 실시간으로 시각화함으로써, 단순 분석을 넘어 의사결정을 지원하는 구조를 구현한 점이 의미 있었습니다.
향후에는 고객 생애 가치(LTV) 및 행동 예측 모델로 확장하여 보다 정교한 고객 전략 수립에 기여하고자 합니다.

좋았던 점 / 아쉬웠던 점 / 추후 보완

Achievements	› 실제 비즈니스 가치와 데이터의 연결 : 클러스터링 결과를 도매 데이터 특성에 맞게 정의하여 각 군집별 차별화된 전략 도출 › 다양한 모델 활용 및 성능 비교 : 여러 알고리즘을 사용하고 SHAP 분석을 통해 AI 를 설명가능한 형태로 해석할 수 있었음 › 태블로 시각화 : 태블로 도구에서 머신러닝 결과를 실시간으로 시각화 해보는 경험이었음
Weaknesses	› 데이터의 시계성 부족 : 현재 데이터는 연간 총액 중심이라 시간의 흐름에 따른 고객의 변화를 반영하지 못함 › 군집 간 경계의 모호성 : 소규모 균형형과 초속규모 군집 처럼 구매액 차이가 크지 않은 경우 군집을 더 명확히 구분할 수 있는 추가 변수가 있었다면 더 정교했을 것 같음
Future Roadmap	› RFM 분석 결합 : 구매 품목 뿐 아니라 최근 구매일 , 구매 빈도, 총 구매 금액 을 결합하여 고객의 충성도를 입체적으로 분석 › 이탈 예측 모델 추가 : 특정 군집 고객의 구매 주기가 길어질 때, 이를 감지하고 경고를 보내는 이탈 징후 › 추천 엔진 구현 : 각 고객에게 구체적으로 어떤 카테고리의 품목이 더 매력적일지 개인화된 상품 추천 시스템으로 확장

감사합니다.