Statistics Basic

LAB 08 - [PBT] 탐색적 데이터 분석

1. EDA 시작하기

실습량이 적습니다.
LAB-05의 PBT 과정을 다시 되짚어 보기 위한 단원 입니다.

ITWILL 이광호 강사

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



탐색적 데이터 분석 개요 (1)

□ 품질 점검이 끝난 데이터에서 패턴을 찾고, 통계로 검증하고, 가설로 정리 과정

STAGE 1
시각화

목적

패턴을 '눈으로' 발견

하는 일

- 단변량으로 분포 확인
- 이변량으로 관계 탐색
- 다변량으로 상호작용 힌트

산출물 → 후보 패턴 목록

STAGE 2
추론통계

목적

패턴을 '숫자로' 검증

하는 일

- 변수 유형 조합 → 검정 선택
- 전제조건 점검
- 4종 검정 (순서 무관)

산출물 → 유의성 + 효과크기

STAGE 3
가설 도출

목적

검증된 패턴을 '가설로' 승격

하는 일

- 관계형 / 차이형 / 연관형
- 효과크기와 도메인 상식
- 상관≠인과 / 교란 점검

산출물 → 연구 가설
(전처리·모델링 입력)

3단계 큰 틀의 **순서는 지켜야** 하지만, **추론통계의 4종 검정은 어떤 순서로 해도 무방**하다

ITWILL 이광호강사

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



탐색적 데이터 분석 개요 (2)

□ 지금까지 학습한 추론통계 기법을 하나의 흐름으로 연결하여 연습합니다.

문제정의	데이터 수집	데이터 품질 점검 및 기본 전처리	탐색적 데이터 분석	모델링용 데이터 전처리	모델 구축	모델 평가 및 개선	결과 해석 및 활용
분석 배경 및 동기 사회적·학문적 필요성 선행연구 검토	**데이터 확보** 내부 데이터, 외부 데이터 데이터 출처 확인	**데이터 구조 점검** 데이터 재점검 (크기, 내용) 데이터 타입 점검 중복값 점검 행·열 이름 점검 행·열 재배치 행·열 추가/삭제	**시각화** 분포·패턴·관계 확인				
분석 목표 설정 문제 확인 분석 질문 구체화 의사결정지원범위	**데이터 구조 확인** 행·열 크기 변수명 확인 데이터 타입 확인	**데이터 품질 점검** 형식·표기 · 단위 점검 **결측치 점검 (삭제만 수행)**	**추론통계** 상관분석(연속형) 교차분석(명목형) 차이 검토 (T-Test) 관계 검토 (ANOVA)				
문제 유형 결정 예측, 분류 군집화, 추천 패턴 탐지	**데이터 이해** 데이터 의미 파악 데이터 단위 파악	**기술통계량 확인** 중심수준 파악 퍼짐과 안정성 판단 비대칭 신호 확인 **이상치 점검 (삭제만 수행)** 기술 통계량 해석	**가설 생성** 패턴 기반 연구 가설 도출				
분석 범위 설정 시간적 범위 공간적 범위	**데이터 한계 인지** 표본 편향 수집 범위 제한						
변수 정의 목표/설명 변수 가설 수립							

01 품질 점검은 '준비'

결측·중복·이상치를 정리해 '분석 가능한 데이터'를 만드는 단계.아직 패턴은 보지 않습니다.

02 EDA는 '질문 만들기'

데이터에 무엇이 들어 있는지, 어떤 패턴이 유의한지, 다음 단계에서 무엇을 할지를 정의하는 단계.

03 전처리는 '설계 반영'

EDA가 만든 가설을 받아 변환·파생변수·인코딩을 수행합니다.
EDA가 없으면 '감'으로 전처리하게 됩니다.

WILL 이광호강사

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



EDA의 목적

□ EDA의 산출물은 가설이자, “이 변수를 모델에 넣을 근거”

모든 검정이 답하는 하나의 질문

“이 변수가 종속변수와 관련 있는가?”

관련 있으면 → **독립변수 후보.**

채택 근거 4요소

① 관련성

목표변수와 통계적으로 유의한 관계 ($p < \alpha$)

② 효과크기

실질 기여 가능성

p값만으론 부족

③ 비중복성

다른 후보와 중복 아님

— 상관 · VIF '관찰'

④ 데이터 적격성

결측 · 이상치 · 분포 · 스케일이 투입 가능한 상태

EDA = SCREENING

모델링 전
1차 변수 스크리닝

검정 4종을 거쳐
“근거 있는 후보군”을 선정한다.

PIPELINE

전체 변수(품질 점검 완료)

▼

EDA — 1차 스크리닝

▼

근거 있는 후보군
→ 모델링 단계로 인계

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



종속변수 유형에 따른 EDA 기법 분류

□ 연속형 종속변수 → 회귀 분석 / 명목형 종속변수 → 분류 분석

	종속: 연속형 회귀 문제	**종속: 명목형** 분류 문제
독립: 연속형 Continuous X	**상관분석**(r) Pearson / Spearman으로 방향·강도 검증	**T·ANOVA**— *역할 전환*[1] Y를 그룹, X를 측정값으로 두고 적용
독립: 명목형 Nominal X	**T검정 · ANOVA**(d · η^2) 2집단 → T검정 / 3+ → ANOVA 그룹 간 평균 차이 검증	**교차분석**(χ^2 · Cramér's V) 두 범주 변수의 셀 빈도로 연관성 검증
✕ **쓰지 않는 것**	✕ **교차분석**— 명목↔명목 전용 *연속 종속에는 정보가 없음*	✕ **상관분석**— 연속↔연속 전용 *명목 종속의 그룹 분리력 못 잼*

▸ 같은 T·ANOVA라도 **종속이 연속이면 '그룹 차이'**를, **종속이 명목이면 'X의 그룹 분리력'**을 본다.

여기서는 회귀 분석에 대한 EDA 과정을 다룹니다. 분류 분석에 대한 EDA는 로지스틱 회귀 파트에서 다룹니다.

ITWILL 이광호강사

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



#01. 준비작업

1. 라이브러리 참조

```python
from hossam import load_data
from helpers import *
```

Python

📦 아이티윌 이광호 강사가 제작한 라이브러리를 사용중입니다.
📚 자세한 사용 방법은 https://py.hossam.kr 을 참고하세요.
📧 Email: leekh4232@gmail.com
🎬 Youtube: https://www.youtube.com/@hossam-codingclub
📝 Blog: https://blog.hossam.kr/
🔖 Version: develop

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



#01. 준비작업

2. 품질 점검 완료 데이터 가져오기

◎ **LAB-05**에서 저장해 둔 데이터 셋을 불러온다.

```python
origin = load_data("boston_qtcheck")
origin.head()
```

Python

📚 보스턴 주택 가격 데이터셋의 품질 검사 완료 버전 (출처: 자체 정제)

	field	description
0	CRIM	타운별 1인당 범죄율 (Per capita crime rate by town)
1	ZN	25,000 sqft 이상 주거용 대지 비율 (Proportion of residential land zoned for large lots)
2	INDUS	비소매 상업구역 비율 (Proportion of non-retail business acres per town)
3	CHAS	명목형, 찰스강 인접 여부 (Charles River dummy variable: 1 if tract bounds river; 0 otherwise)
4	NOX	대기 오염 정도 (Nitric oxides concentration, parts per 10 million)
5	RM	주택당 평균 방(Room) 수 (Average number of rooms per dwelling)
6	AGE	1940년 이전 건축 비율 (Proportion of owner-occupied units built prior to 1940)
7	DIS	5개 주요 고용센터까지의 거리 (Weighted distances to five Boston employment centers)
8	RAD	고속도로 접근성 지수 (Index of accessibility to radial highways)
9	TAX	재산세율 (Full-value property-tax rate per $10,000)
10	PTRATIO	교육구 학생-교사 비율 (Pupil-teacher ratio by town)
11	B	흑인 비율 지수 (1000(Bk - 0.63)²; Bk = proportion of Black residents)
12	LSTAT	저소득층 비율 (%) (Percentage of lower status population)
13	MEDV	주택 가격 중앙값(단위: $1,000) (Median value of owner-occupied homes in $1000s)

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.006	18.000	2.310	0	0.538	6.575	65.200	4.090	1	296	15.300	396.900	4.980	24.000
1	0.027	0.000	7.070	0	0.469	6.421	78.900	4.967	2	242	17.800	396.900	9.140	21.600
2	0.027	0.000	7.070	0	0.469	7.185	61.100	4.967	2	242	17.800	392.830	4.030	34.700
3	0.032	0.000	2.180	0	0.458	6.998	45.800	6.062	3	222	18.700	394.630	2.940	33.400
4	0.069	0.000	2.180	0	0.458	7.147	54.200	6.062	3	222	18.700	396.900	5.330	36.200

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



#01. 준비작업

3. 연속형 변수의 기초 통계량 가져오기

◎ **LAB-05**에서 저장해 둔 기초 통계량 표를 불러온다.

○ 실제 데이터 분석 프로젝트에서는 엑셀 파일로 저장해 두고 필요할 때 마다 열람하자.

```
1 desc = load_data("boston_qtcheck_desc")
2 desc.T
```

✓ 마지막 실행: 오후 12:39:44, 기간: 0.2s Python

📚 보스턴 주택 가격 데이터셋의 품질 검사 완료 버전에 대한 기술통계량 표

	CRIM	ZN	INDUS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
count	506.000	506.000	506.000	506.000	506.000	506.000	506.000	506.000	506.000	506.000	506.000	506.000	506.000
mean	3.614	11.364	11.137	0.555	6.285	68.575	3.795	9.549	408.237	18.456	356.674	12.653	22.533
std	8.602	23.322	6.860	0.116	0.703	28.149	2.106	8.707	168.537	2.165	91.295	7.141	9.197
min	0.006	0.000	0.460	0.385	3.561	2.900	1.130	1.000	187.000	12.600	0.320	1.730	5.000
25%	0.082	0.000	5.190	0.449	5.885	45.025	2.100	4.000	279.000	17.400	375.377	6.950	17.025
50%	0.257	0.000	9.690	0.538	6.208	77.500	3.207	5.000	330.000	19.050	391.440	11.360	21.200
75%	3.677	12.500	18.100	0.624	6.623	94.075	5.188	24.000	666.000	20.200	396.225	16.955	25.000
max	88.976	100.000	27.740	0.871	8.780	100.000	12.127	24.000	711.000	22.000	396.900	37.970	50.000
rel_diff	13.087	inf	0.149	0.031	0.012	0.115	0.183	0.910	0.237	0.031	0.089	0.114	0.063
rdiff_flag	large_diff	large_diff	diff	similar	similar	diff	diff	large_diff	diff	similar	similar	diff	similar
iqr	3.595	12.500	12.910	0.175	0.738	49.050	3.088	20.000	387.000	2.800	20.848	10.005	7.975
upper_bound	9.070	31.250	37.465	0.886	7.731	167.650	9.821	54.000	1246.500	24.400	427.496	31.963	36.963
lower_bound	-5.311	-18.750	-14.175	0.187	4.778	-28.550	-2.532	-26.000	-301.500	13.200	344.106	-8.058	5.062
upper_outliers	66	68	0	0	22	0	5	0	0	0	0	7	38
upper_outliers_ratio	0.130	0.134	0.000	0.000	0.043	0.000	0.010	0.000	0.000	0.000	0.000	0.014	0.075
lower_outliers	0	0	0	0	8	0	0	0	0	15	77	0	2
lower_outliers_ratio	0.000	0.000	0.000	0.000	0.016	0.000	0.000	0.000	0.000	0.030	0.152	0.000	0.004
outliers	66	68	0	0	30	0	5	0	0	15	77	7	40
outliers_ratio	0.130	0.134	0.000	0.000	0.059	0.000	0.010	0.000	0.000	0.030	0.152	0.014	0.079
skew	5.223	2.226	0.295	0.729	0.404	-0.599	1.012	1.005	0.670	-0.802	-2.890	0.906	1.108
skew_interpret	right tail	right tail	symmetric	right tail	symmetric	left tail	right tail	right tail	right tail	left tail	left tail	right tail	right tail
kurt	37.131	4.032	-1.234	-0.065	1.892	-0.968	0.488	-0.867	-1.142	-0.285	7.227	0.493	1.495
kurt_interpret	leptokurtic	leptokurtic	platykurtic	platykurtic	leptokurtic	platykurtic	leptokurtic	platykurtic	platykurtic	platykurtic	leptokurtic	leptokurtic	leptokurtic
log_need	log1p	log1p	none	none	none	none	log1p	log1p	none	none	reverse_log1p	log1p	log1p

- **로그변환을 고려해야 할 변수**: CRIM, ZN, DIS, RAD, LSTAT, MEDV
- **역 로그변환을 고려해야 할 변수**: B

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



#01. 준비작업

4. 명목형 변수의 기초 통계량 가져오기

◎ **LAB-05**에서 저장해 둔 기초 통계량 표를 불러온다.

○ 실제 데이터 분석 프로젝트에서는 엑셀 파일로 저장해 두고 필요할 때 마다 열람하자.

```python
cat_desc = load_data("boston_qtcheck_category_desc")
cat_desc
```

✓ 마지막 실행: 오후 12:39:44, 기간: 0.2s Python

📚 보스턴 주택 가격 데이터셋의 품질 검사 완료 버전에 대한 범주형 변수 기술통계량 표

	CHAS
count	506
unique	2
top	0
freq	471

- **분포**: 명목형 변수 중 유일한 이항 변수이며 **심한 불균형**.
- **분석 시 유의점**:
  - 두 집단에 대한 비교인 **T검정**을 쓰되,
    표본 불균형으로 검정력(power)이 낮아질 수 있음에 유의
  - 모델 투입 시 한쪽 범주(소수 집단)의 영향이 과소·과대 추정될 수 있어 해석에 주의
- **활용**: 소수 집단이라도 강변 인접이 가격에 유의미한 프리미엄을 주는지 확인하면
  해석 가치가 큰 변수가 될 수 있음(버리지 말고 검정으로 확인).



#01. 준비작업

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인

5. 타입 변환 (명목형 확정)

◎ 명목형 기술 통계량 표에 의하면 명목형 변수는 **CHAS** 하나이다.

```
1 df = my_qtcheck.set_type(origin, as_category=["CHAS"])
```

✓ 마지막 실행: 오후 1:05:52, 기간: 0.0s Python

```
<class 'pandas.DataFrame'>
RangeIndex: 506 entries, 0 to 505
Data columns (total 14 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   CRIM     506 non-null    float64
 1   ZN       506 non-null    float64
 2   INDUS    506 non-null    float64
 3   CHAS     506 non-null    category
 4   NOX      506 non-null    float64
 5   RM       506 non-null    float64
 6   AGE      506 non-null    float64
 7   DIS      506 non-null    float64
 8   RAD      506 non-null    int64
 9   TAX      506 non-null    int64
 10  PTRATIO  506 non-null    float64
 11  B        506 non-null    float64
 12  LSTAT    506 non-null    float64
 13  MEDV     506 non-null    float64
dtypes: category(1), float64(11), int64(2)
memory usage: 52.0 KB
```

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 변수간의 상관성 분석
5. 그룹간의 차이 분석
6. 변수 선별
7. EDA 파이프라인



연습문제 의료보험 청구 비용 데이터셋의 EDA 시작하기

□ 보험사 데이터 분석가가 되어, 청구 비용을 예측하는 선형회귀 모델에 넣을 독립변수를 골라야 합니다.

◎ 정제와 기초 통계는 끝나 있다. 첫 임무는 본격 EDA를 시작하기 위한 "기본 준비"를 수행하세요.

- **insurance_qtcheck** : 보험 비용 데이터셋의 품질 검사 완료 버전
- **insurance_qtcheck_desc** : 보험 비용 데이터셋의 연속형 변수에 대한 기술 통계량
- **insurance_qtcheck_category_desc** : 보험 비용 데이터셋의 범주형 변수에 대한 기술 통계량

1 품질 점검이 완료된 데이터셋을 불러와 **행·열 수와 목표변수**를 확인하라.

2 **연속형 변수**의 기초 통계량 표를 불러와, 분포가 **치우친 변수(로그 변환 후보)**를 찾아라.

3 **명목형 변수**의 기초 통계량 표를 불러와, **한쪽으로 쏠린(불균형) 변수**를 찾아라.

4 각 변수의 **데이터 타입을 점검**하고, 명목형 변수의 **변환이 필요한지** 판단하라.

5 **목표변수와 변수 유형 지도**(연속형 설명변수 / 명목형 설명변수)를 확정하라.