[LAB-08] 2. 데이터 시각화

#01. 준비작업

1. 이전 분석 내용 가져오기

- 데이터 로드, 기초 통계량 가져오기 등의 반복적인 작업은 별도의 ipynb 파일에 구현해 두고 **Jupyter Magic Command**로 불러올 수 있다.
  - 다른 ipynb 파일의 소스코드를 이 위치에 복붙 하는 효과가 있다.
  - 가져온 ipynb 파일의 import 내용이나 변수들이 모두 유지된다.

```
%%capture cap
%run "./[LAB-08] PBT - EDA | 1-EDA 시작하기(실습코드).ipynb"
```

2. 불러온 내용 확인

- 이전 분석 내역이 잘 로드 되었는지 확인한다.

```
print("목표변수 :", target)
print("연속형(종속변수 포함) :", continuous_cols)
print("독립변수(명목형) :", nominal_cols)
print("독립변수(연속형) :", feature_continuous)

display(df.head())          # 품질점검 완료 후 타입변환 데이터 프레임
display(desc.head())        # 기술통계량 데이터 프레임
display(cat_desc.head())    # 범주형 데이터 기술통계량 데이터 프레임
```

```
목표변수 : MEDV
연속형(종속변수 포함) : ['CRIM', 'ZN', 'INDUS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX',
'PTRATIO', 'B', 'LSTAT', 'MEDV']
독립변수(명목형) : ['CHAS']
독립변수(연속형) : ['CRIM', 'ZN', 'INDUS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX', 'PTRATIO',
'B', 'LSTAT']
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.006	18.000	2.310	0	0.538	6.575	65.200	4.090	1	296	15.300	396.900	4.980	24.000
1	0.027	0.000	7.070	0	0.469	6.421	78.900	4.967	2	242	17.800	396.900	9.140	21.600
2	0.027	0.000	7.070	0	0.469	7.185	61.100	4.967	2	242	17.800	392.830	4.030	34.700
3	0.032	0.000	2.180	0	0.458	6.998	45.800	6.062	3	222	18.700	394.630	2.940	33.400
4	0.069	0.000	2.180	0	0.458	7.147	54.200	6.062	3	222	18.700	396.900	5.330	36.200

	count	mean	std	min	25%	50%	75%	max	rel_diff	rdiff_flag	iqr	upper_bound	lo
CRIM	506.000	3.614	8.602	0.006	0.082	0.257	3.677	88.976	13.087	large_diff	3.595	9.070	-5

ZN	506.000	11.364	23.322	0.000	0.000	0.000	12.500	100.000	inf	large_diff	12.500	31.250	-1
INDUS	506.000	11.137	6.860	0.460	5.190	9.690	18.100	27.740	0.149	diff	12.910	37.465	-1
NOX	506.000	0.555	0.116	0.385	0.449	0.538	0.624	0.871	0.031	similar	0.175	0.886	0.
RM	506.000	6.285	0.703	3.561	5.885	6.208	6.623	8.780	0.012	similar	0.738	7.731	4.

	CHAS
count	506
unique	2
top	0
freq	471

3. 라이브러리 참조하기

- 불러온 ipynb 파일에서 참조하지 않는 라이브러리중 필요한 것을 참조한다.
  - 여기서는 새로운 라이브러리 참조는 불필요하지만 실습을 위해 이전 ipynb 파일과 중복 참조함

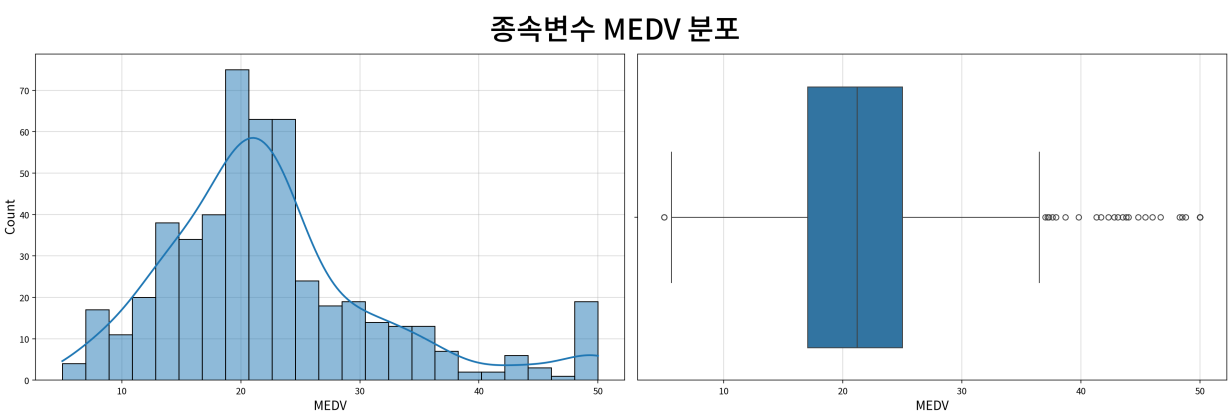
```
from helpers import *
```

#02. 단변량 데이터 시각화

1. 종속변수

- 종속변수는 예측 대상이 되는 값이므로 가장 먼저 따로 시각화 한다.

```
# 1행 2열 서브플롯 구성
# -> 그래프 크기는 서브플롯 중 하나의 크기(전체 크기는 가로 960 x 2가 됨)
fig, ax = my_plot.init(rows=1, cols=2, title=f"종속변수 {target} 분포", width=960,
        height=640)
my_plot.histplot(data=df, x=target, kde=True, ax=ax[0])
my_plot.boxplot(data=df, x=target, ax=ax[1])
my_plot.show()
```



💡 인사이트

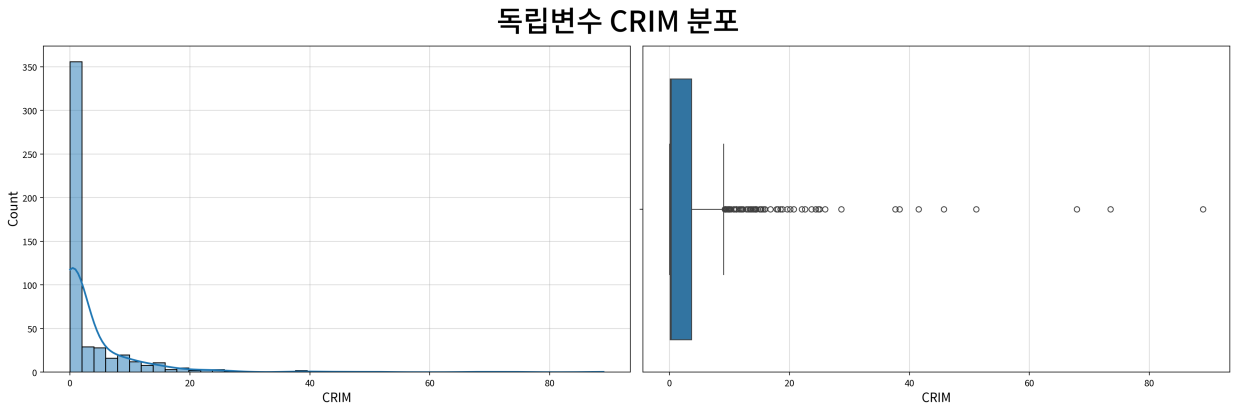
> **단변량 점검의 목적**: “이 변수를 그대로 검정/모델에 넣어도 되는가?”를 판단한다.

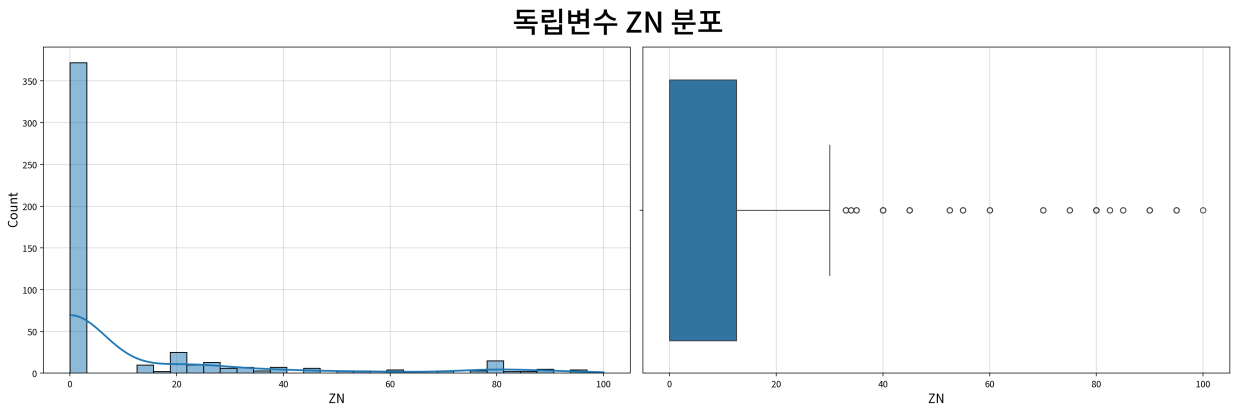
점검 항목	`MEDV` 관찰 내용
분포 모양(왜도)	오른쪽으로 치우침(우편향, skew ≈ 1.1)
봉우리 수	단봉 — 단, 오른쪽 끝(50)에 인위적 군집
이상치(박스플롯)	위쪽 수염 밖에 점 존재(상위 약 8%)
이산점(군집)	50에 값이 뭉침 = 상한 처리(천장효과)

판단·조치: 우편향 + 50 천장효과가 있어 그대로 쓰기엔 부담스럽다. → **로그 변환**으로 분포를 좌우 대칭에 가깝게 펴고, 50에 잘린 값(천장효과)은 높은 가격대 예측의 한계로 인지한다.

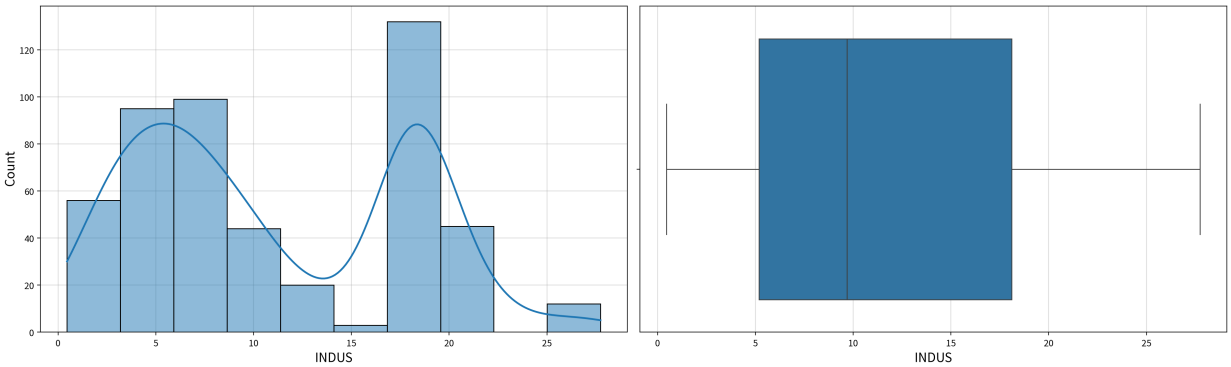
2. 연속형 독립변수 분포 시각화

```
for f in feature_continuous:
    fig, ax = my_plot.init(rows=1, cols=2, title=f"독립변수 {f} 분포", width=960,
        height=640)
    my_plot.histplot(data=df, x=f, kde=True, ax=ax[0])
    my_plot.boxplot(data=df, x=f, ax=ax[1])
    my_plot.show()
```

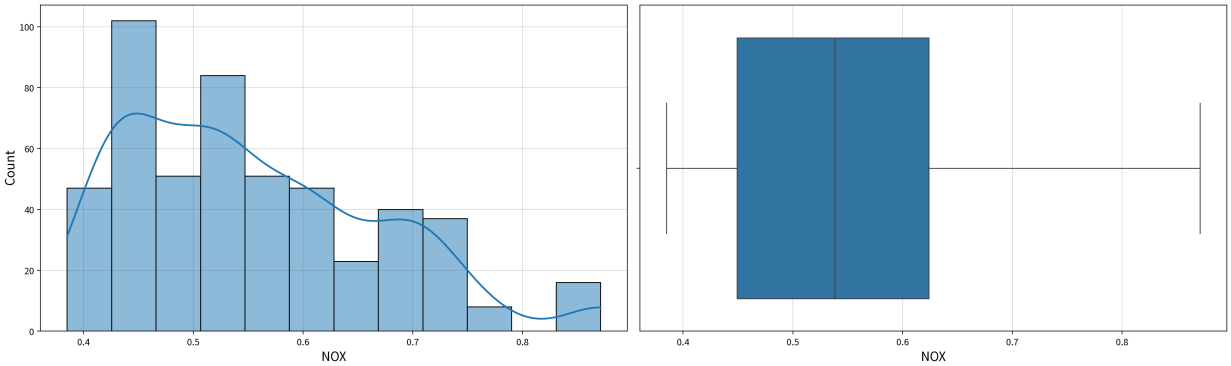




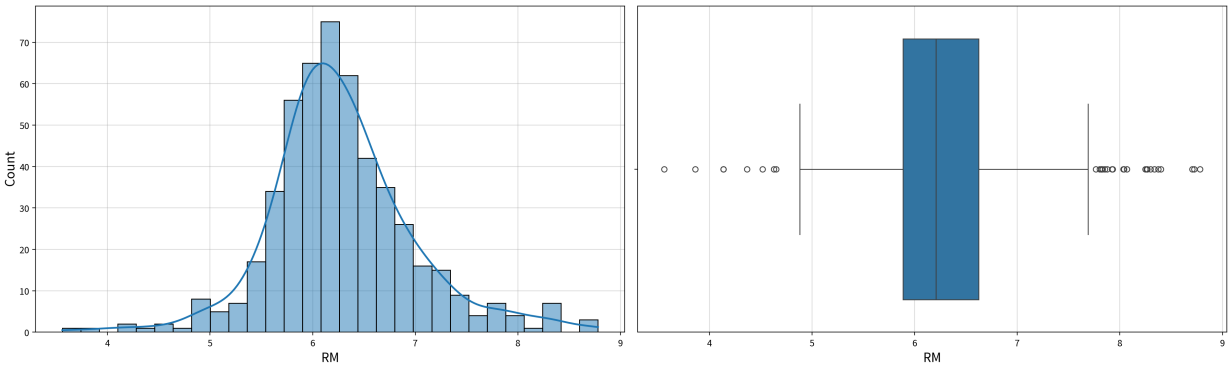
독립변수 INDUS 분포



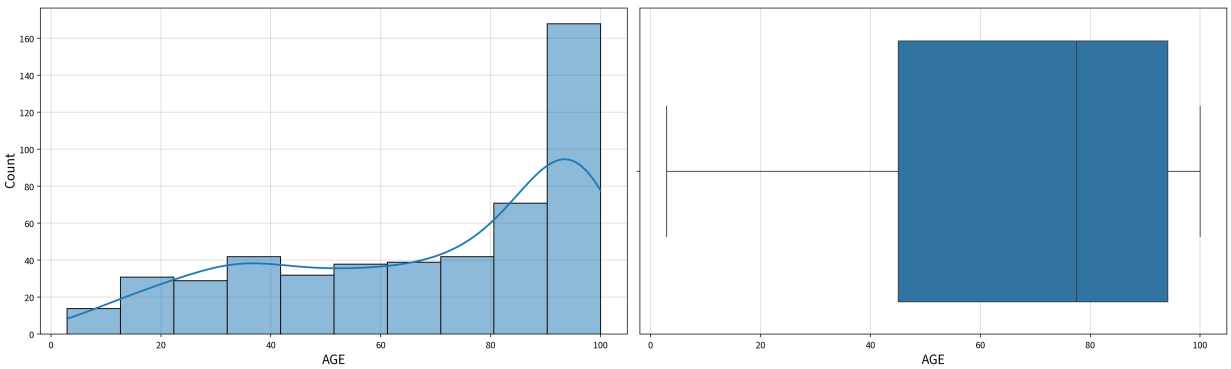
독립변수 NOX 분포



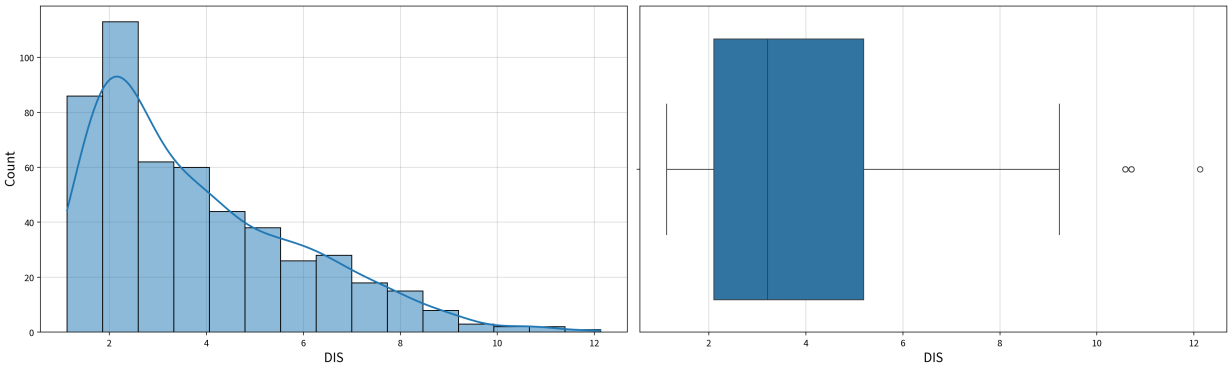
독립변수 RM 분포



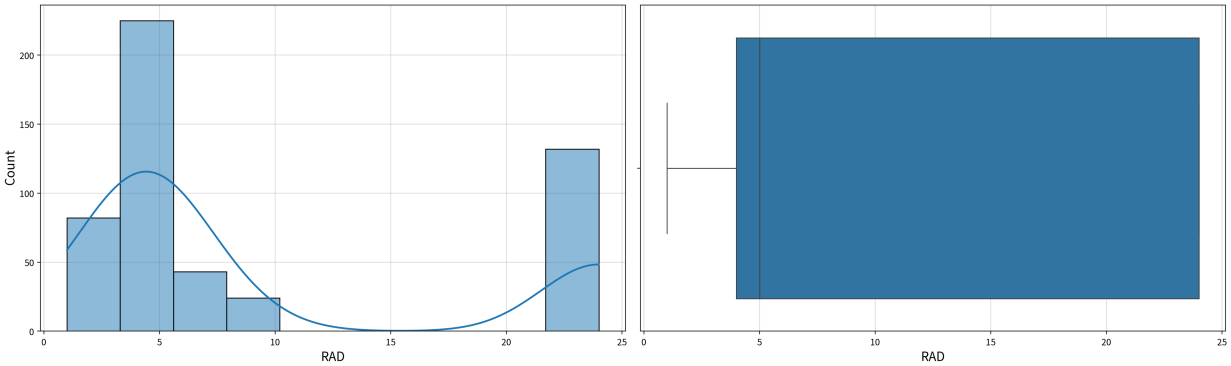
독립변수 AGE 분포



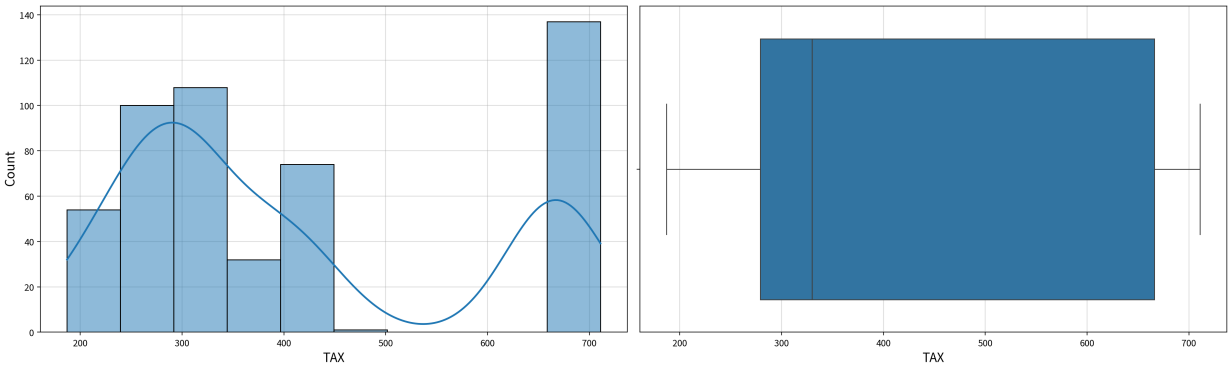
독립변수 DIS 분포



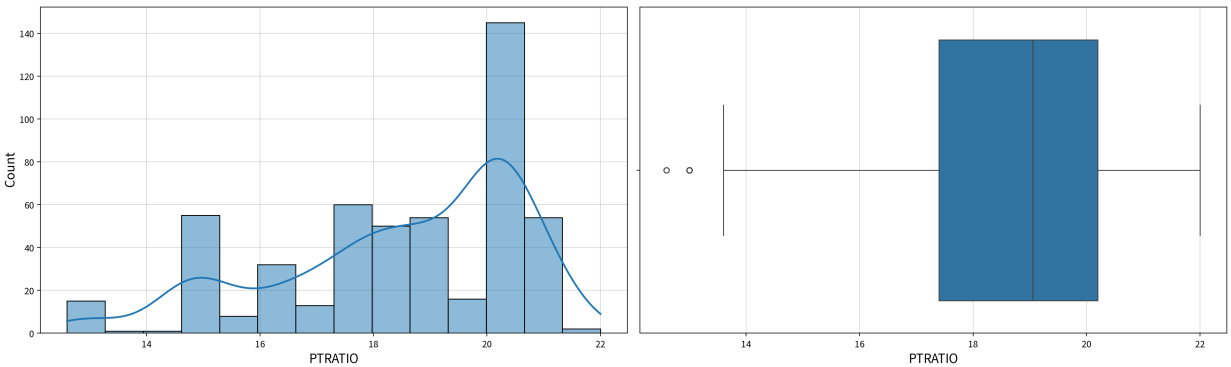
독립변수 RAD 분포



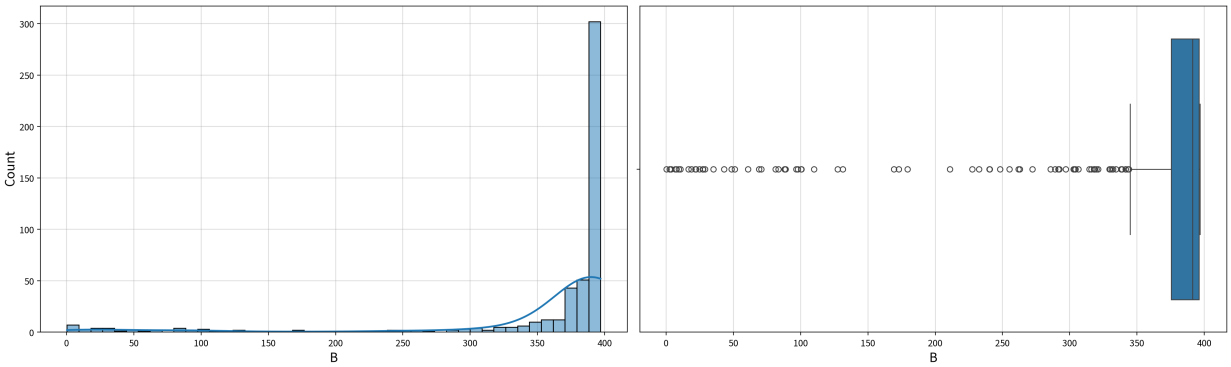
독립변수 TAX 분포



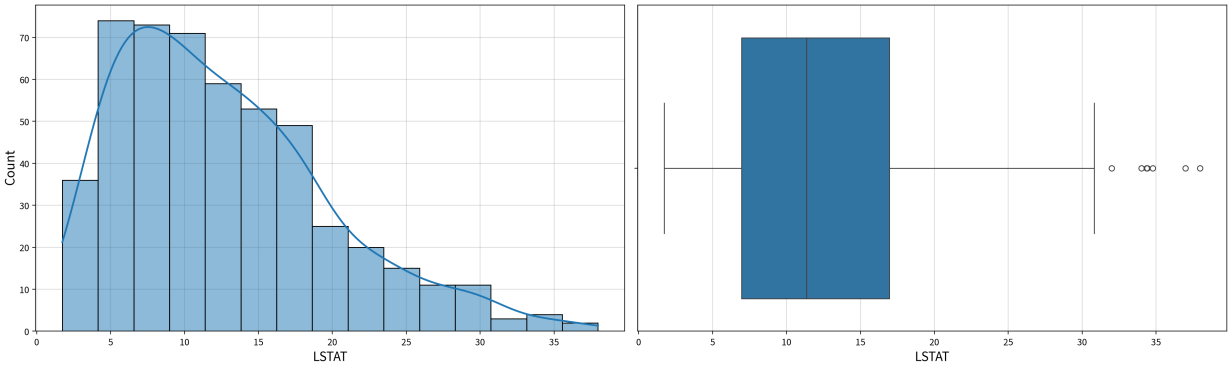
독립변수 PTRATIO 분포



독립변수 B 분포



독립변수 LSTAT 분포



💡 인사이트

> 각 변수를 **분포 모양(왜도) · 봉우리 수 · 이상치(박스플롯 점) · 이산점(군집)** 관점에서 점검하여 “그대로 검정/모델에 넣어도 되는가?”를 판단한다.

변수	분포 모양(왜도)	봉우리	이상치	이산점·군집	판단·조치
CRIM	매우 강한 우편향	단봉(0 근처 집중)	많음(약 13%)	—	로그 변환 + 이상치 처리
ZN	강한 우편향	0에 큰 덩어리	많음(약 13%)	0 값에 집중	로그 변환 + 이상치 처리
INDUS	대칭에 가까움	다봉(쌍봉 경향)	거의 없음	특정 구간 군집	변환 불필요, 다봉만 유의
NOX	약한 우편향	다봉 경향	없음	—	그대로 사용 가능
RM	대칭(정규에 가까움)	단봉	양쪽에 소수	—	그대로 사용 가능
AGE	좌편향	단봉(100 쪽 몰림)	없음	100 부근 집중	그대로 사용 가능
DIS	우편향	단봉	소수	—	로그 변환 고려
RAD	우편향	**뚜렷한 이봉**	없음	**24에 큰 군집**	사실상 범주형 → 선형 가정 주의
TAX	우편향	**이봉**	없음	**666~711에 군집**	사실상 범주형 → 선형 가정 주의
PTRATIO	좌편향	다봉(값 군집)	소수	특정 값에 집중	그대로 사용 가능
B	매우 강한 좌편향	단봉(396 쪽 몰림)	많음(약 15%)	396 부근 집중	역로그 변환 + 이상치 처리

LSTAT	우편향	단봉	소수	—	로그 변환 고려

요약

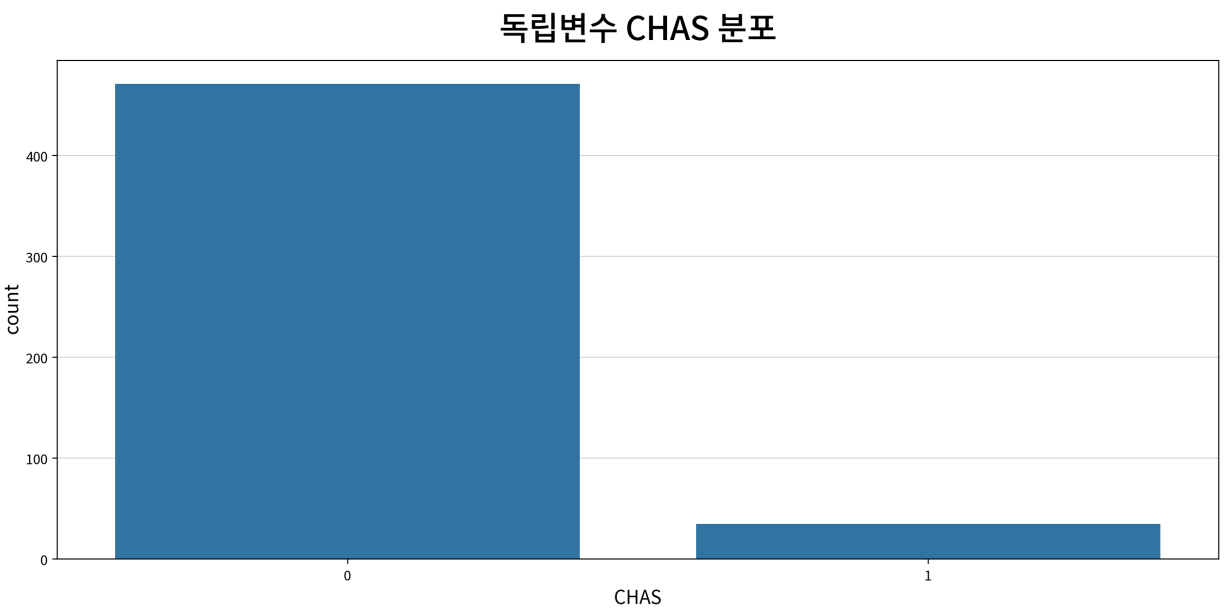
- **로그 변환 후보(치우침 강함)**: `CRIM` , `ZN` , `DIS` , `LSTAT` , `RAD` (우편향) / `B` (좌편향 → 역로그).
- **이상치 처리 우선(비율 10% ↑)**: `CRIM` , `ZN` , `B` .
- **선형 가정 주의(이산점·범주형 성격)**: `RAD` , `TAX` — 특정 값에 군집되어 직선 관계가 아닐 수 있음.
- **그대로 검정 가능(대칭·이상치 적음)**: `INDUS` , `NOX` , `RM` , `AGE` , `PTRATIO` .

3. 명목형 독립변수 분포 시각화

```
for n in nominal_cols:
    # 빈도표 — 명목형 분포를 수치로
    freq = df[n].value_counts().rename("빈도").to_frame()
    freq["비율(%)"] = (df[n].value_counts(normalize=True) * 100).round(1)
    display(freq)

    # 명목형 분포는 카운트 플롯으로 처리한다.
    my_plot.countplot(data=df, x=n, title=f"독립변수 {n} 분포")
```

	빈도	비율(%)
CHAS		
0	471	93.100
1	35	6.900



💡 인사이트

> 명목형은 분포 모양·왜도 대신 **범주의 균형/불균형**을 점검하여 “그대로 검정/모델에 넣어도 되는가?”를 판단한다.

변수	범주 수	빈도(비율)	균형 여부	판단·조치

CHAS	2 (0=강변 아님, 1=강변 인접)	0: 471 (93.1%) / 1: 35 (6.9%)	**심한 불균형**	2집단이므로 MEDV 와의 **T 검정** 대상이나, 소수 집단(35건)이라 **비교·해석 신중**

판단·조치

- CHAS 는 2집단 명목형이므로 종속변수(MEDV)와의 차이는 **T검정**으로 확인한다.
- 다만 강변 인접(1) 집단이 35건(6.9%)뿐이라 **표본 불균형 → 검정력(power)이 낮고**, 모델 투입 시 소수 집단의 효과가 과소·과대 추정될 수 있어 **결과를 단정하지 말고 신중히 해석**한다.
- 소수 집단이라도 강변 인접이 가격에 유의미한 프리미엄을 주는지 검정으로 확인할 가치가 있으므로 **버리지 않고 유지**한다.

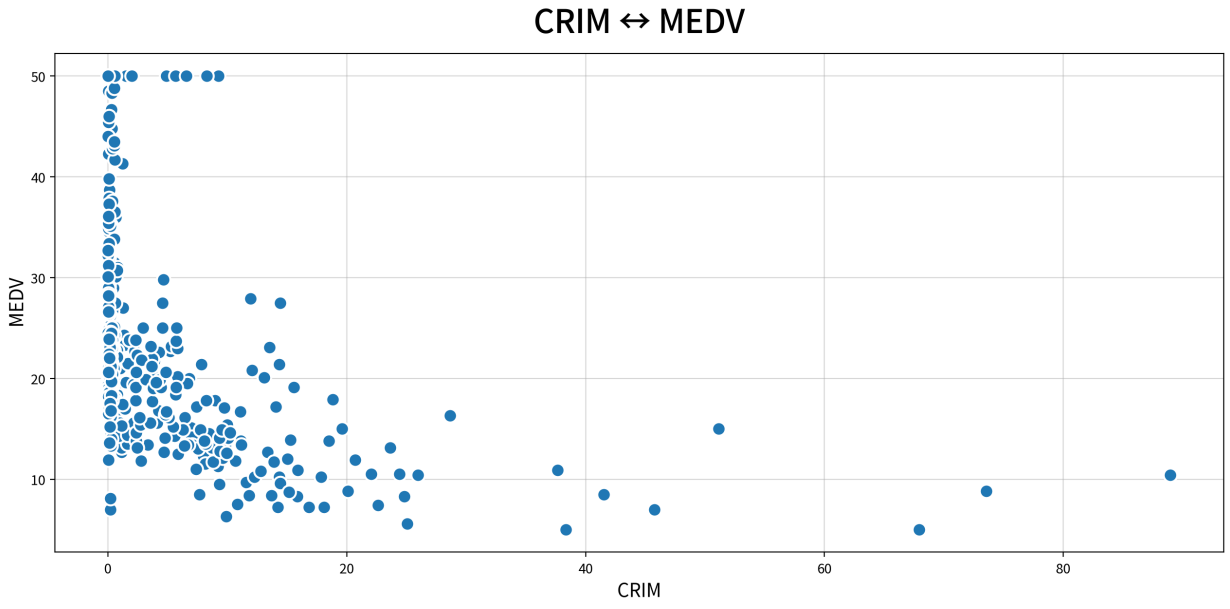
#03. 이변량 데이터 시각화

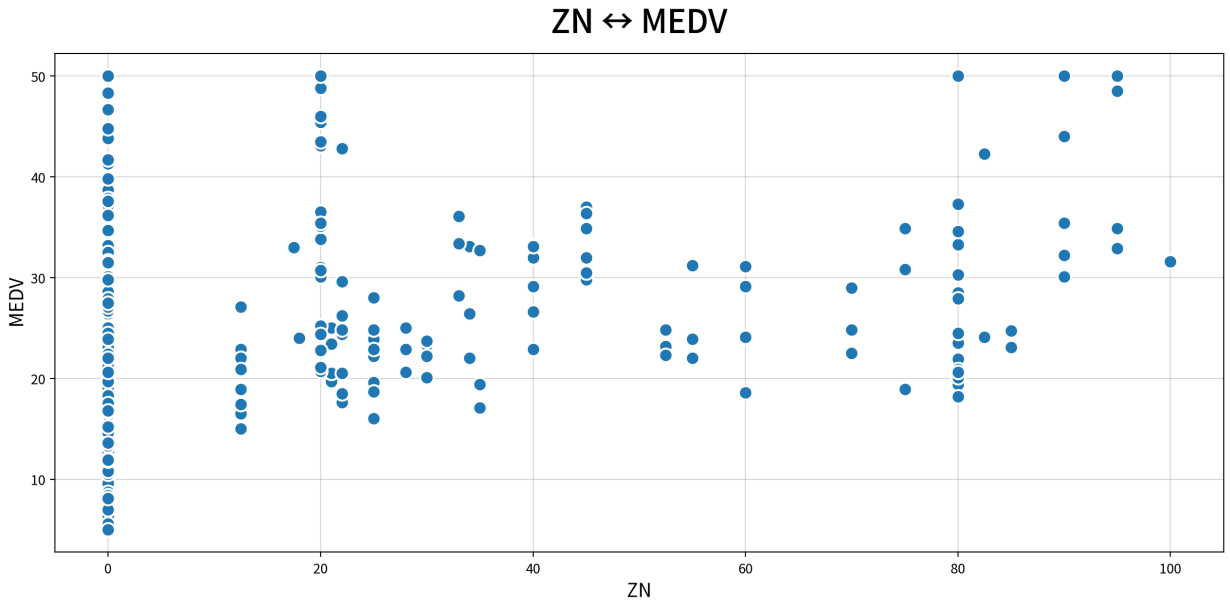
- 목표변수(MEDV)와 각 설명변수의 **관계(패턴)** 를 눈으로 확인하는 단계다. (PDF p.4 — 이변량 시각화 매트릭스)
- 모든 시각화는 **짝이 되는 검정**과 연결된다.
  - 연속형 ? 연속형 → **산점도** → 상관분석
  - 명목형(2집단) ? 연속형 → **박스플롯·바이올린** → T검정
- 여기서 발견한 것은 아직 **"후보 패턴"** 이며, 다음 추론통계 단계에서 숫자로 검증한다.

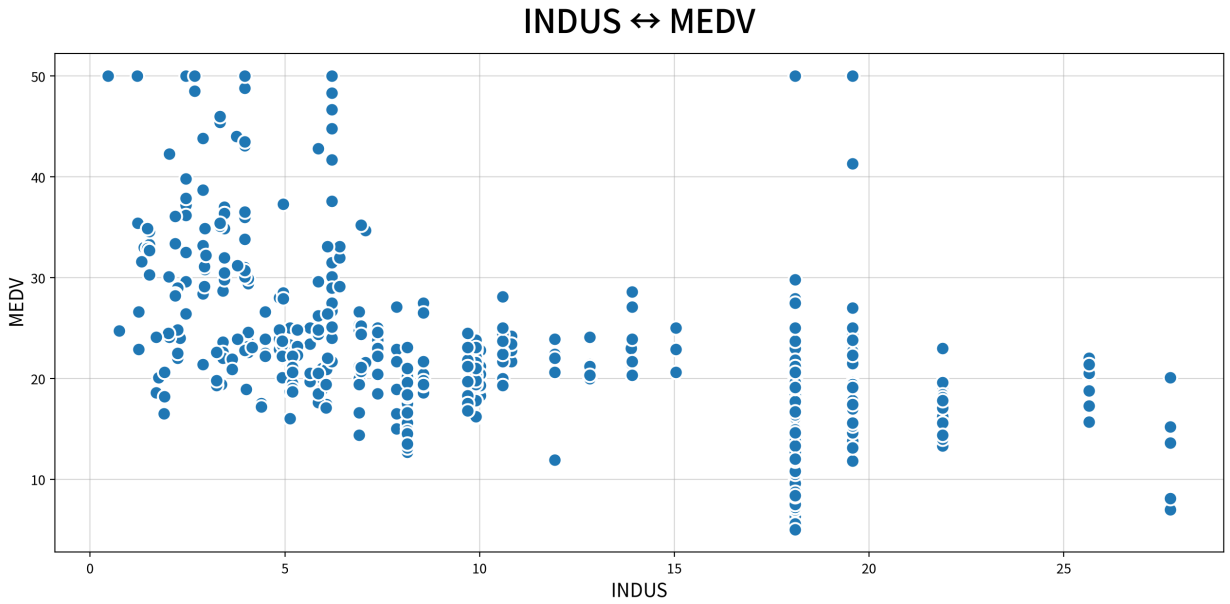
1. 연속형 독립변수 ? 종속변수 (산점도 → 상관분석)

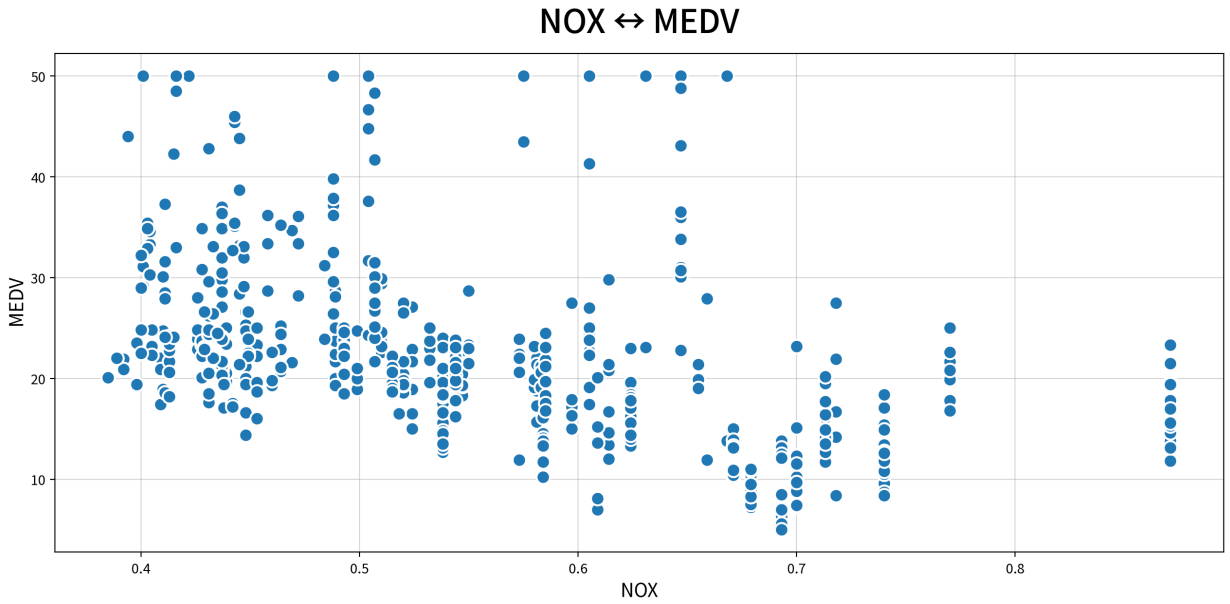
- 연속형 설명변수와 종속변수(MEDV)의 관계는 **산점도**로 본다.
- 관계의 **방향(증가/감소)·모양(선형/곡선)·산포·이상치**를 동시에 확인 → 짝이 되는 검정은 **상관분석**.

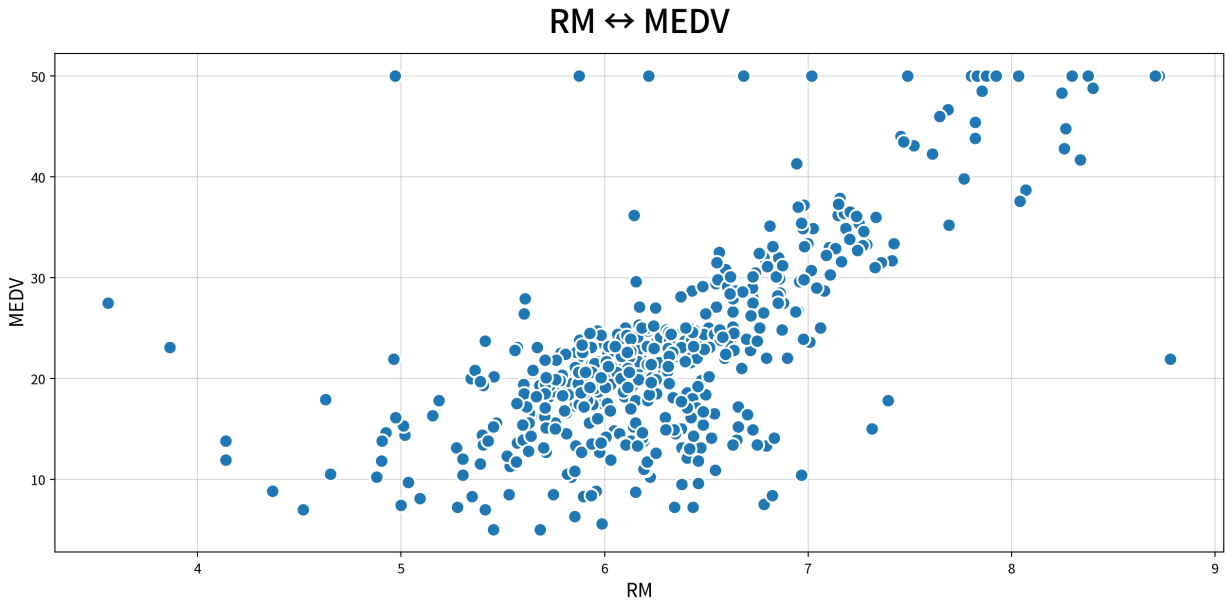
```
for f in feature_continuous:
    # 연속 ↔ 연속: 산점도로 방향·모양·산포를 확인
    my_plot.scatterplot(data=df, x=f, y=target, title=f"{f} ↔ {target}")
```

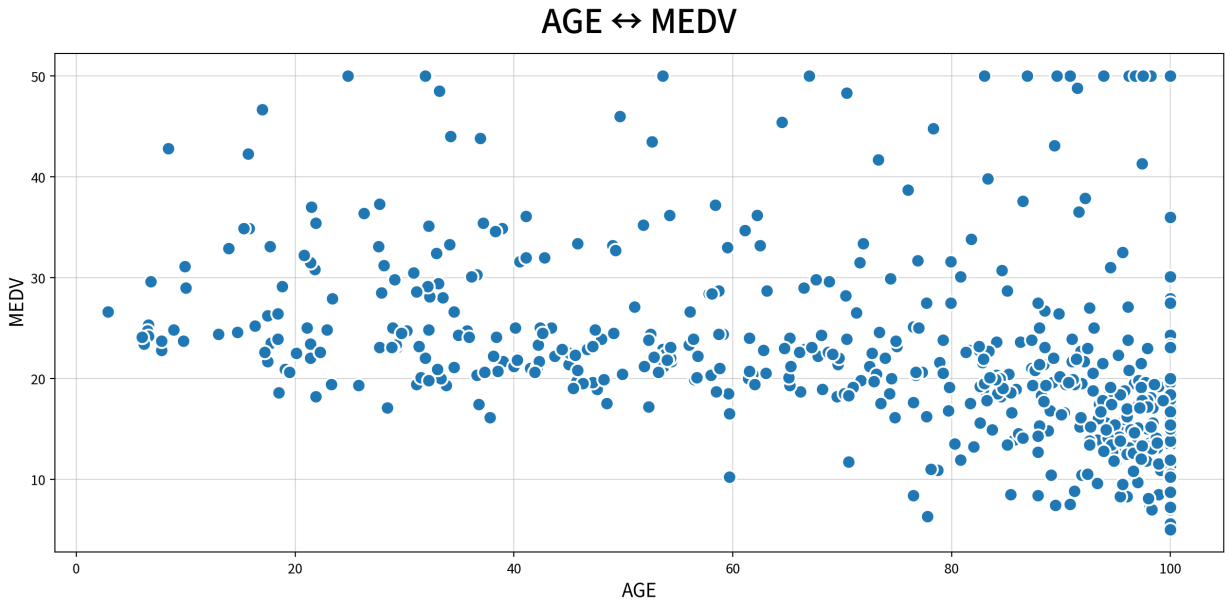


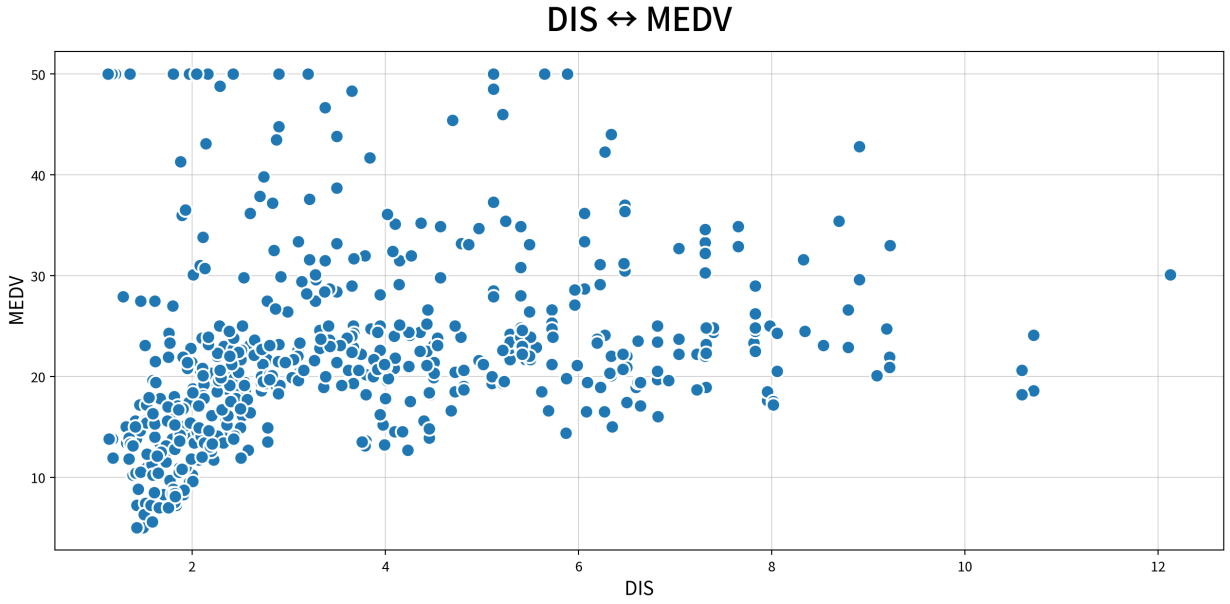

ZN ↔ MEDV
MEDV
ZN
50
40
30
20
10
0
20
40
60
80
100


INDUS ↔ MEDV
MEDV
INDUS
50
40
30
20
10
0
5
10
15
20
25

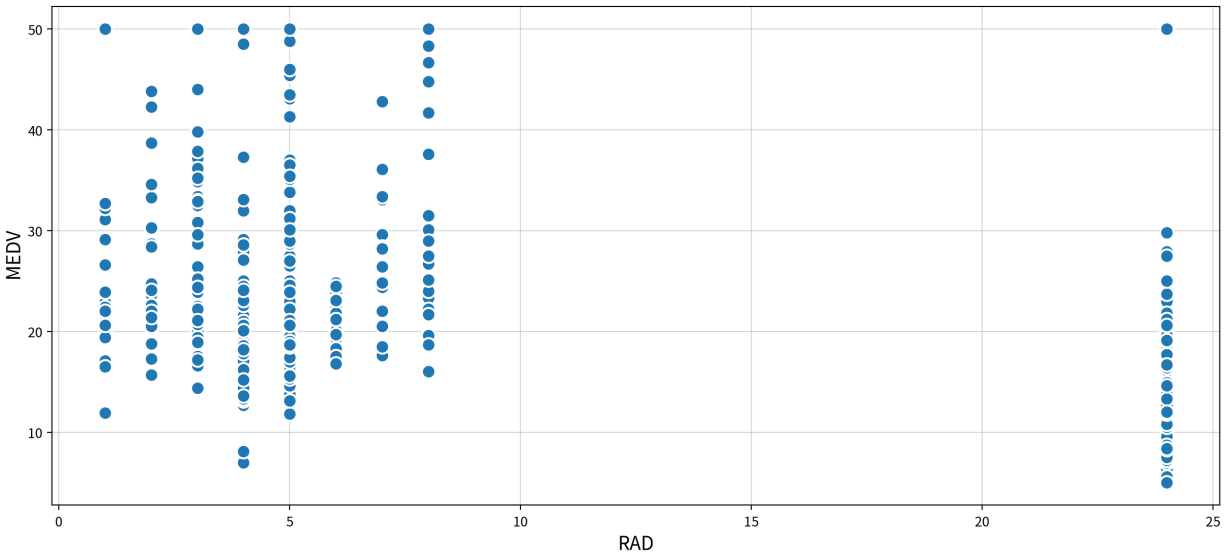

NOX ↔ MEDV
MEDV
NOX
50
40
30
20
10
0.4
0.5
0.6
0.7
0.8


RM ↔ MEDV
MEDV
RM
50
40
30
20
10
4
5
6
7
8
9

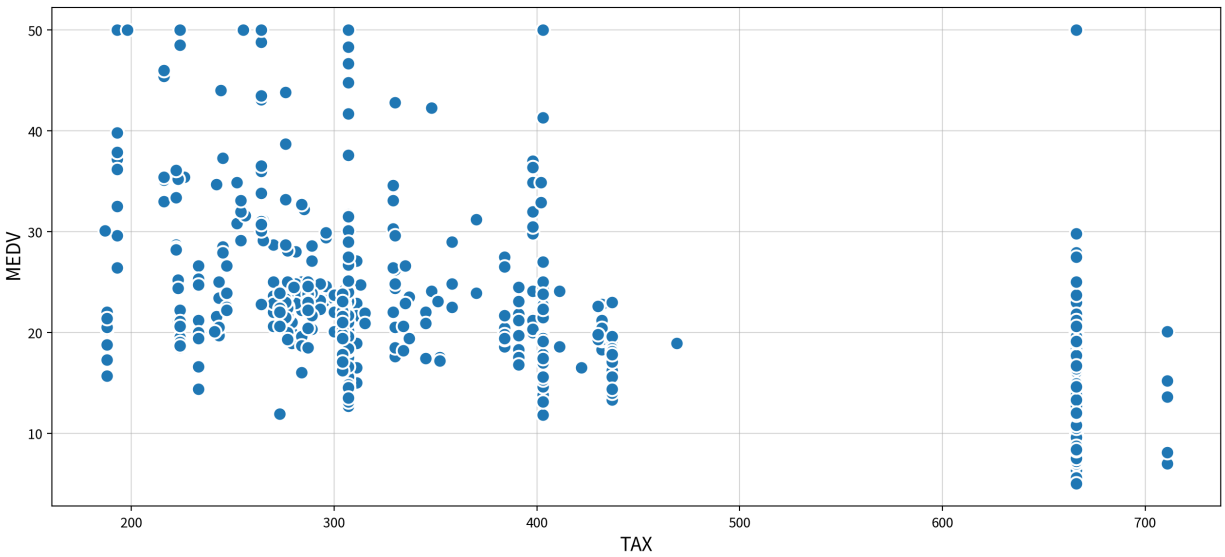

AGE ↔ MEDV
MEDV
AGE
50
40
30
20
10
0
20
40
60
80
100


DIS ↔ MEDV
MEDV
DIS
50
40
30
20
10
2
4
6
8
10
12

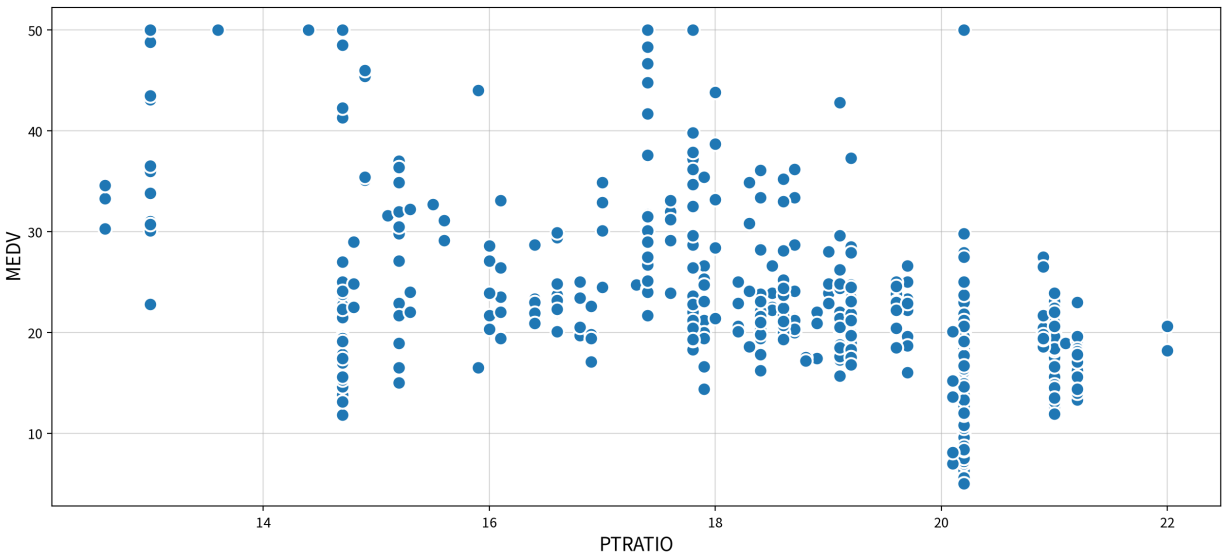
RAD ↔ MEDV



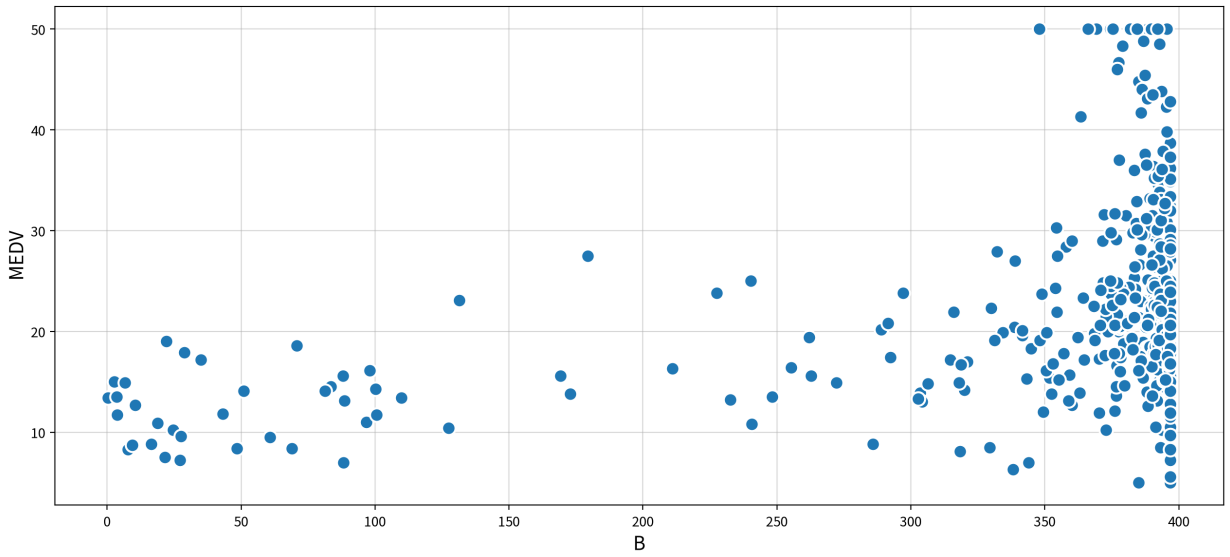
TAX ↔ MEDV



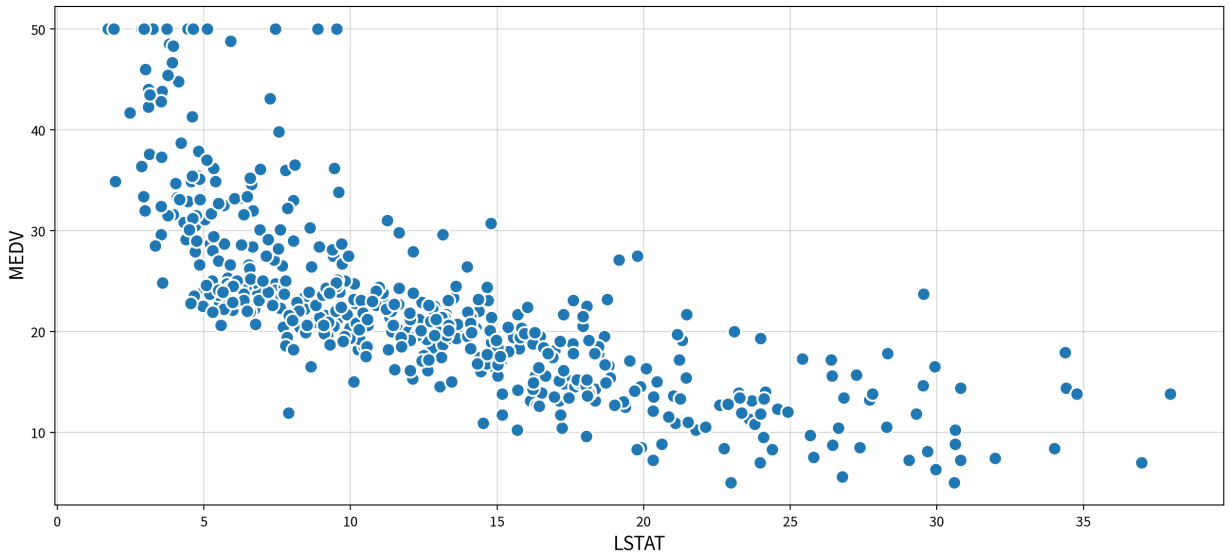
PTRATIO ↔ MEDV



B ↔ MEDV



LSTAT ↔ MEDV



💡 인사이트

> 연속 × 연속 → **산점도,** 짝이 되는 검정은 **상관분석**. (방향·모양·산포를 함께 본다)

변수	관찰된 관계(방향·모양)	→ 검정
LSTAT	강한 **음(−)**, 곡선형 (저소득층 ↑ → 가격↓)	상관분석
RM	뚜렷한 **양(+)**, 약한 곡선 (방 수 ↑ → 가격↑)	상관분석
INDUS · NOX · TAX · PTRATIO · AGE · CRIM · RAD	**음(−)** 경향(산포 큼)	상관분석
ZN · DIS · B	약한 **양(+)** 경향	상관분석

후보 패턴 요약

- 가장 뚜렷한 관계: `LSTAT` (음) · `RM` (양). → 상관분석에서 효과크기 확정 예정.
- `RAD` · `TAX` 는 값이 띄엄띄엄(이산) 모여 있어 직선 관계로 보기 어렵다(앞 단봉/이봉 단서와 일치).

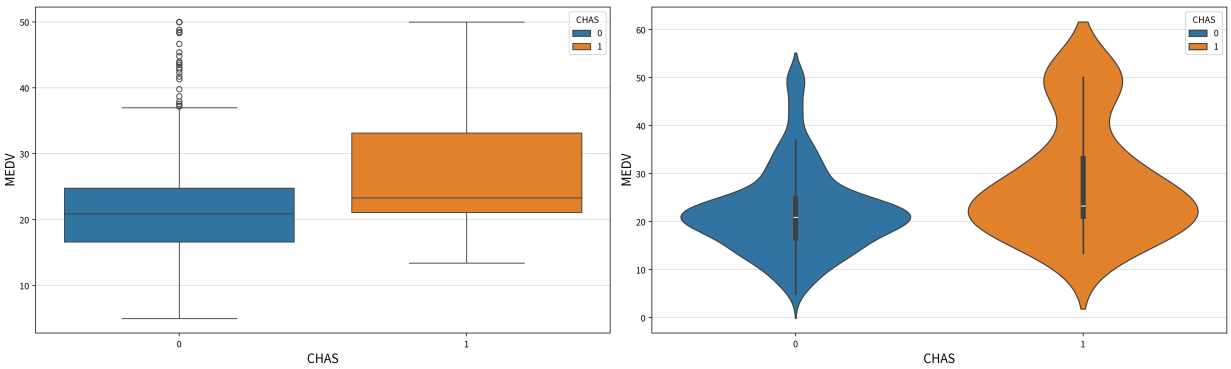
- 아직 **눈으로 본 후보**이며, 실제 유의성·강도는 추론통계 단계의 **상관분석**에서 검증한다.

2. 명목형 독립변수 ? 종속변수 (박스플롯·바이올린 → T검정)

- 명목형(2집단)과 연속형의 관계는 **그룹별 박스플롯·바이올린**으로 본다.
- 두 그룹의 중앙값·산포 차이를 확인 → 짝이 되는 검정은 **T검정**.

```
for n in nominal_cols:
    # 명목(2집단) ↔ 연속: 박스플롯 + 바이올린으로 그룹 간 분포 비교
    fig, ax = my_plot.init(rows=1, cols=2, title=f"{n} ↔ {target}", width=960,
        height=640)
    my_plot.boxplot(data=df, x=n, y=target, hue=n, ax=ax[0])
    my_plot.violinplot(data=df, x=n, y=target, hue=n, ax=ax[1])
    my_plot.show()
```

CHAS ↔ MEDV



💡 인사이트

> 명목(2집단) × 연속 → **박스플롯/바이올린**, 짝이 되는 검정은 **T검정**.

변수(2집단)	관찰된 관계(방향)	→ 검정
CHAS	인접(1)의 MEDV 중앙값이 높고 분포가 위쪽 → **인접 > 비인접**	T검정

후보 패턴: "강에 인접한 지역(CHAS=1)의 주택 가격이 더 높다."

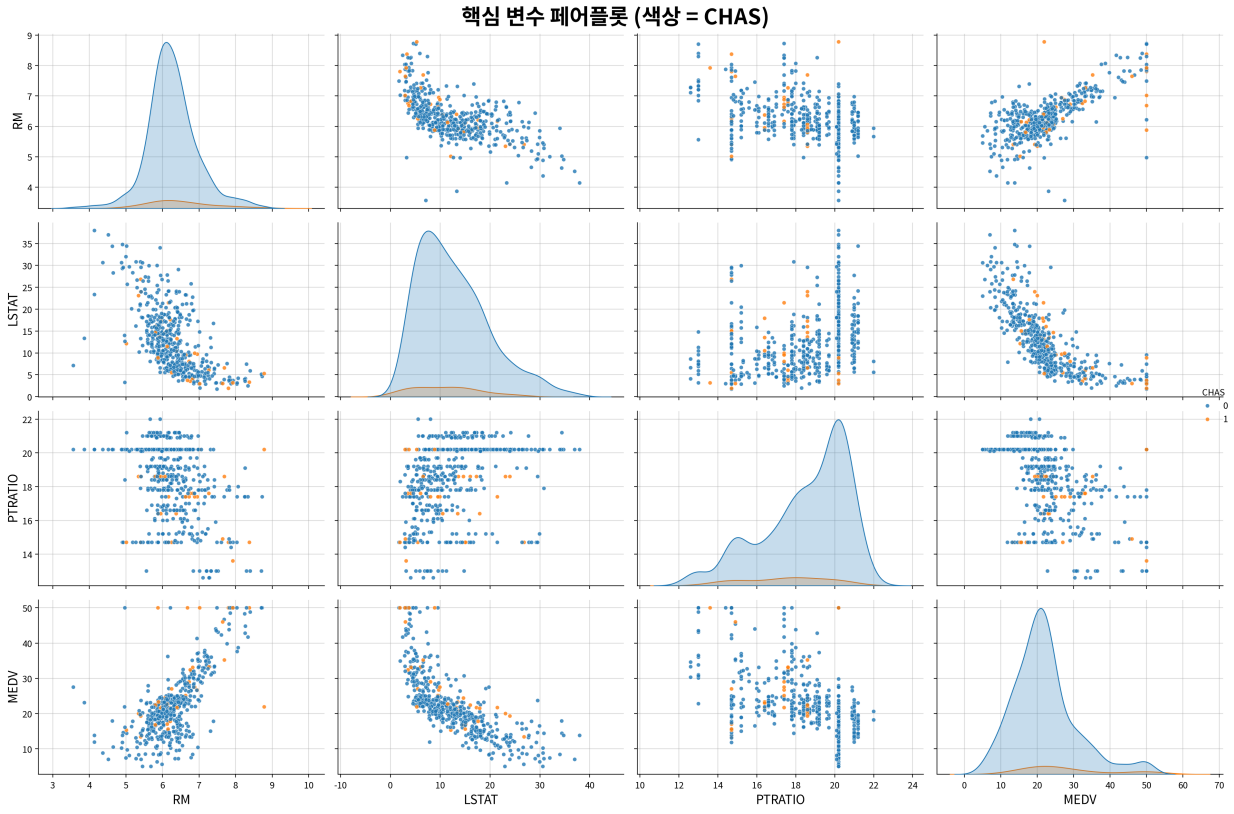
- 단, 인접 집단 표본이 35건(6.9%)으로 적어 검정·해석은 신중히 한다.
- 아직 **눈으로 본 후보**이므로, 실제 유의성·효과크기는 추론통계 단계의 **T검정**에서 확정한다.

#04. 다변량 데이터 시각화

- 두 변수만으로 보이지 않는 **여러 변수의 관계·군집**을 한 번에 보는 단계다. (PDF p.5 — 다변량 시각화)
- 아직 상관분석(상관계수 산출) 전이므로, 숫자 대신 **페어플롯**으로 분포(대각)와 산점도(비대각)를 **눈으로** 확인한다.
- ⚠️ **필요할 때만** 사용한다. 연속형 12개를 모두 그리면 정보 과부하 → 이변량에서 관계가 뚜렷했던 **핵심 변수만** 골라 그린다.

1. 핵심 변수 페어플롯

```
# 핵심 변수 페어플롯 — 대각=분포(KDE), 비대각=산점도, 색상=명목형(CHAS)
# 이변량에서 관계가 뚜렷했던 변수 + 종속변수만 선택 (12개 전부는 정보 과부하)
core_cols = ["RM", "LSTAT", "PTRATIO", target]
hue_col = nominal_cols[0]
my_plot.pairplot(data=df[core_cols + [hue_col]], hue=hue_col, diag_kind="kde",
                 title=f"핵심 변수 페어플롯 (색상 = {hue_col})",
                 width=480*4, height=320*4)
```



💡 인사이트

> 페어플롯으로 핵심 변수들의 **분포(대각)와 두 변수 관계(비대각)** 를 한 번에 확인한다. (PDF p.5 — TOOL 02)

- **`MEDV` 관계**: `LSTAT` 은 강한 음(곡선), `RM` 은 양, `PTRATIO` 는 음 경향 → 이변량 산점도에서 본 방향과 일치(재확인).
- **색상(`CHAS`)**: 강 인접(1) 점들이 같은 위치에서도 `MEDV` 위쪽(고가)에 분포 → "인접 지역이 비싸다" 후보 패턴 보강.
- **설명변수끼리의 관계**: `LSTAT` ↑일 때 `RM` ↓ 경향 등 → 변수 간 중복(공선성) 가능성의 시각 단서.
- ⚠️ 여기까지는 모두 **눈으로 본 후보**다. 상관계수·유의성 등 숫자 근거는 추론통계의 **상관분석**에서 확정한다.

추론통계 후보 패턴 목록

> 📄 PDF p.6 — 시각화로 '눈으로 본' 패턴을 한 표에 모아 추론통계를 수행할 후보를 도출한다. ⚠️ 아직 **가설이 아니라 "후보"** — 다음 추론통계 단계에서 숫자로 검증한다.

#	변수 조합 (유형)	관찰된 패턴 (방향 · 근거 그래프)	→ 검정
01	`LSTAT` · `MEDV` (연속 × 연속)	`LSTAT` ↑ → `MEDV` ↓, 강한 감소·**곡선형** (산점도·페어플롯)	상관분석
02	`RM` · `MEDV` (연속 × 연속)	`RM` ↑ → `MEDV` ↑, 증가 (산점도·페어플롯)	상관분석
03	`PTRATIO` · `MEDV` (연속 × 연속)	`PTRATIO` ↑ → `MEDV` ↓, 감소 경향 (산점도·페어플롯)	상관분석
04	그 외 연속형 9종 · `MEDV` (연속 × 연속)	음: `INDUS` · `NOX` · `TAX` · `AGE` · `CRIM` · `RAD` / 약한 양: `ZN` · `DIS` · `B` (산점도)	상관분석
05	`CHAS` · `MEDV` (명목 2집단 × 연속)	강 인접(1) 집단의 `MEDV` 중앙값↑ = **인접 > 비인접** (박스·바이올린)	T검정
06	`RAD` · `TAX` (연속 × 연속)	두 변수가 강하게 동반 변화 = **공선성 의심** (페어플롯)	상관분석 / VIF

참고

- ※ '관찰된 패턴'은 느낌이 아니라 **그래프에서 본 사실**(기울기·중앙값 차이·동반 변화)로 적었다.
- ※ **미해당 검정**: ANOVA(원본에 명목 3집단+ 변수 없음), 교차분석(명목 × 명목 조합 없음).