[LAB-08] 2. 데이터 시각화 - 연습문제

#01. 준비작업

1. 이전 분석 내용 가져오기

- 데이터 로드, 기초 통계량 가져오기 등의 반복적인 작업은 별도의 ipynb 파일에 구현해 두고 **Jupyter Magic Command**로 불러올 수 있다.
  - 다른 ipynb 파일의 소스코드를 이 위치에 복붙 하는 효과가 있다.
  - 가져온 ipynb 파일의 import 내용이나 변수들이 모두 유지된다.

```
%%capture cap
%run "./[LAB-08] PBT - EDA | 1-EDA 시작하기(연습문제).ipynb"
```

2. 불러온 내용 확인

- 이전 분석 내역이 잘 로드 되었는지 확인한다.

```
print("목표변수 :", target)
print("연속형(종속변수 포함) :", continuous_cols)
print("독립변수(명목형) :", nominal_cols)
print("독립변수(연속형) :", feature_continuous)

display(df.head())          # 품질점검 완료 후 타입변환 데이터 프레임
display(desc.head())        # 기술통계량 데이터 프레임
display(cat_desc.head())    # 범주형 데이터 기술통계량 데이터 프레임
```

```
목표변수 : charges
연속형(종속변수 포함) : ['age', 'bmi', 'children', 'charges']
독립변수(명목형) : ['sex', 'smoker', 'region']
독립변수(연속형) : ['age', 'bmi', 'children']
```

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.924
1	18	male	33.770	1	no	southeast	1725.552
2	28	male	33.000	3	no	southeast	4449.462
3	33	male	22.705	0	no	northwest	21984.471
4	32	male	28.880	0	no	northwest	3866.855

	count	mean	std	min	25%	50%	75%	max	rel_diff	rdiff_flag	
age	1337.000	39.222	14.044	18.000	27.000	39.000	51.000	64.000	0.006	similar	24
bmi	1337.000	30.663	6.100	15.960	26.290	30.400	34.700	53.130	0.009	similar	8.

children	1337.000	1.096	1.206	0.000	0.000	1.000	2.000	5.000	0.096	similar	2.
charges	1337.000	13279.121	12110.360	1121.874	4746.344	9386.161	16657.717	63770.428	0.415	diff	11

	Unnamed: 0	sex	smoker	region
0	count	1337	1337	1337
1	unique	2	2	4
2	top	male	no	southeast
3	freq	675	1063	364

3. 라이브러리 참조하기

- 불러온 ipynb 파일에서 참조하지 않는 라이브러리중 필요한 것을 참조한다.
  - 여기서는 새로운 라이브러리 참조는 불필요하지만 실습을 위해 이전 ipynb 파일과 중복 참조함

```
from helpers import *
```

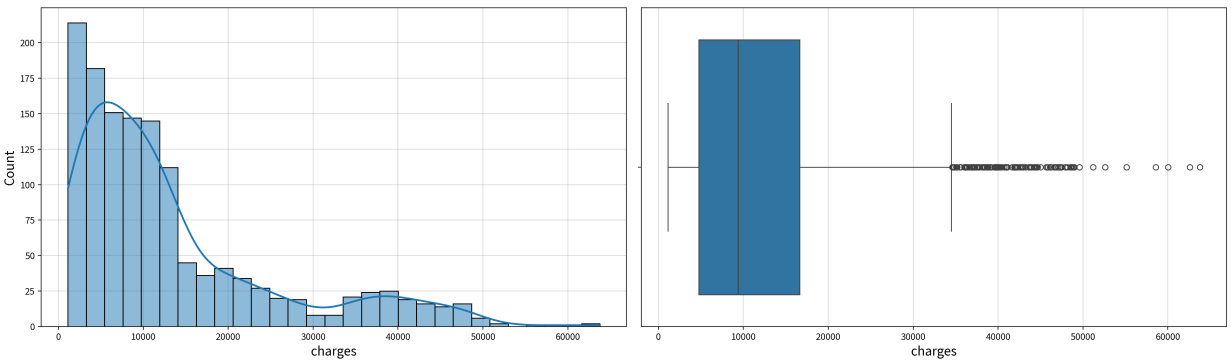
#02. 단변량 데이터 시각화

1. 종속변수

- 종속변수는 예측 대상이 되는 값이므로 가장 먼저 따로 시각화 한다.

```
# 1행 2열 서브플롯 구성
# -> 그래프 크기는 서브플롯 중 하나의 크기(전체 크기는 가로 960 x 2가 됨)
fig, ax = my_plot.init(rows=1, cols=2, title=f"종속변수 {target} 분포", width=960,
        height=640)
my_plot.histplot(data=df, x=target, kde=True, ax=ax[0])
my_plot.boxplot(data=df, x=target, ax=ax[1])
my_plot.show()
```

종속변수 charges 분포



💡 인사이트

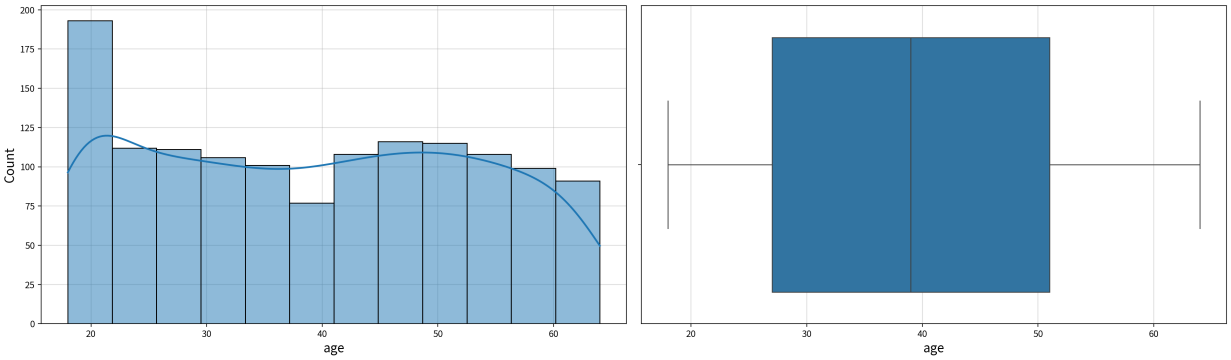
> 종속변수 `charges` 는 예측 대상이므로 **분포 형태와 변환 필요성**을 먼저 확정한다. (아래 정확한 수치는 그래프가 아니라 **기술통계량(`desc`) 표 기준**이며, 그래프로는 모양을 확인한다.)

- **강한 우편향**: 히스토그램·박스플롯이 오른쪽으로 길게 늘어짐. 평균 > 중앙값 → 소수 고액 청구가 평균을 끌어올린다. (기술통계 기준 skew ≈ 1.52, 평균 ≈ 13,279 > 중앙값 ≈ 9,386)
- **상단 이상치가 눈에 띄게 많음**: 박스플롯 오른쪽으로 점이 길게 늘어짐 → 오류가 아니라 **정상 범주의 고액 집단**으로 보이므로 단순 제거 대상이 아니다. (기술통계 기준 상단 이상치 10.4%)
- **KDE 2차 봉우리 힌트(그래프에서 확인)**: 저비용 주봉 외에 35,000~45,000 부근에 작은 봉우리 → **별도 고비용 하위집단**(뒤에서 `smoker` 로 설명될 후보) 존재 암시.
- **조치**: 회귀 모델 투입 시 `log1p(charges)` 변환으로 왜도 완화(`desc` 의 `log_need = log1p` 와 일치). 고액 꼬리가 이상치가 아니라 **설명변수로 갈라지는 구조**인지 이변량 단계에서 확인한다.

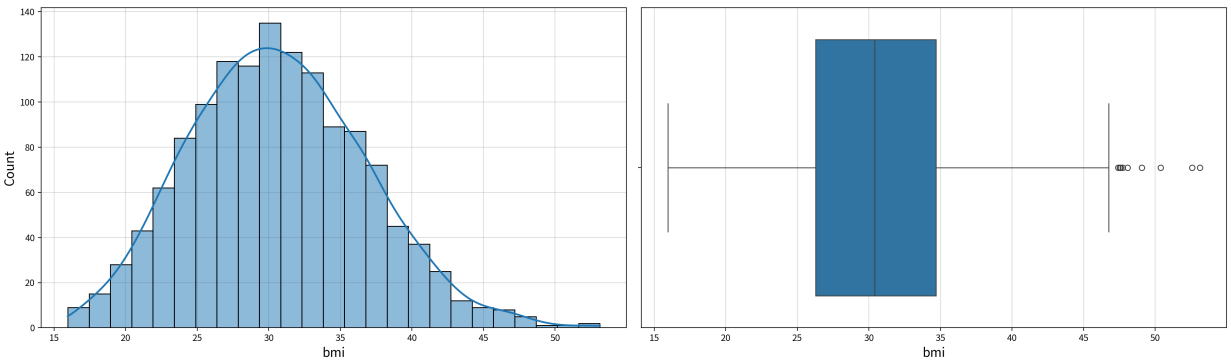
2. 연속형 독립변수 분포 시각화

```
for f in feature_continuous:
    fig, ax = my_plot.init(rows=1, cols=2, title=f"독립변수 {f} 분포", width=960,
        height=640)
    my_plot.histplot(data=df, x=f, kde=True, ax=ax[0])
    my_plot.boxplot(data=df, x=f, ax=ax[1])
    my_plot.show()
```

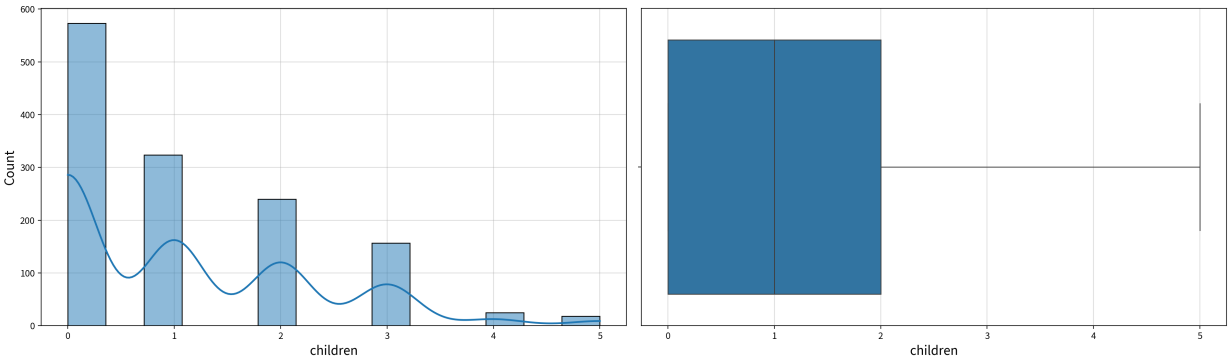
독립변수 age 분포



독립변수 bmi 분포



독립변수 children 분포



💡 인사이트

> 각 연속형 변수를 **분포 모양 · 봉우리 · 이상치 · 이산성**으로 점검하여 "그대로 검정/모델에 넣어도 되는가?"를 판단한다. (모양은 그래프로, **정확한 왜도·이상치 수치는 기술통계량(`desc`) 표 기준**이다.)

변수	분포 모양(그래프)	봉우리	이상치	이산·특징	판단·조치
`age`	좌우 대칭, **평탄**(넓게 퍼짐)	뚜렷한 단봉 없음	없음	18~64 고르게 분포	그대로 사용 가능
`bmi`	거의 대칭, 종 모양(정규에 가까움)	단봉	소수(상단 소량)	—	그대로 사용 가능 (정규 가정 양호)
`children`	우편향, 0에 몰림	0에 최빈	없음	**이산(0~5), 사실상 count**	연속 취급 주의

요약 (왜도·이상치 비율은 *`desc`* 기준)

- 세 변수 모두 **심한 치우침·과다 이상치 없음 → 로그 변환 불필요**(`age` skew≈0.06, `bmi` ≈0.28은 대칭권 / `children` skew≈0.94는 이산 count라 `log1p` 실효 낮음).
- `age` · `bmi` 는 정규 가정이 양호해 **모수 검정(상관·회귀)에 바로 투입 가능**.
- `children` 은 값이 6종(0~5)뿐 → 연속으로 다루되 관계가 약할 수 있어 이변량에서 재확인.

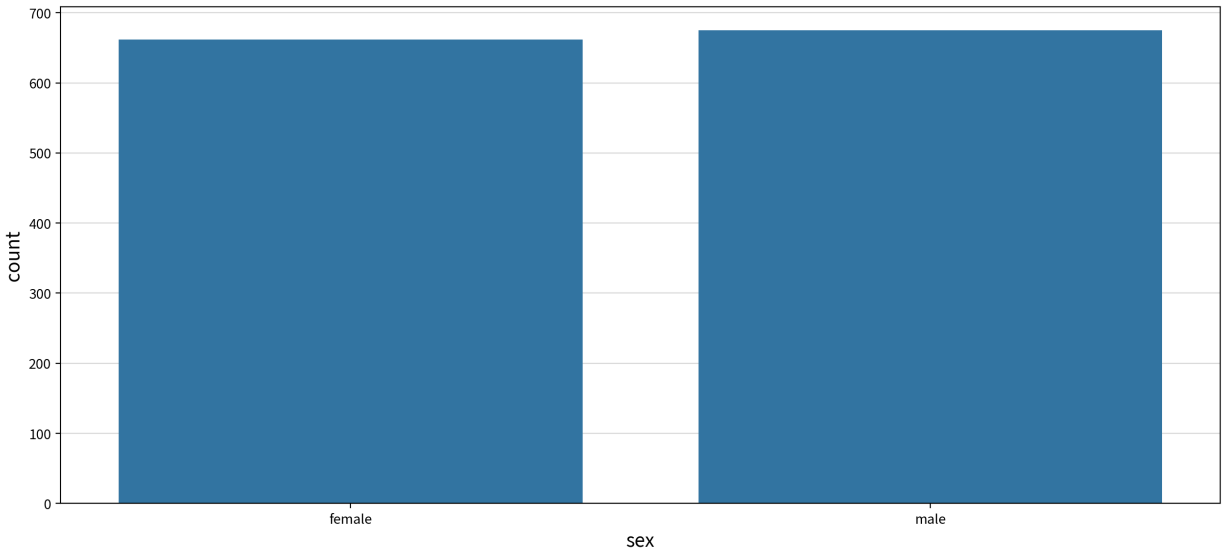
3. 명목형 독립변수 분포 시각화

```
for n in nominal_cols:
    # 빈도표 — 명목형 분포를 수치로
    freq = df[n].value_counts().rename("빈도").to_frame()
    freq["비율(%)"] = (df[n].value_counts(normalize=True) * 100).round(1)
    display(freq)

    # 명목형 분포는 카운트 플롯으로 처리한다.
    my_plot.countplot(data=df, x=n, title=f"독립변수 {n} 분포")
```

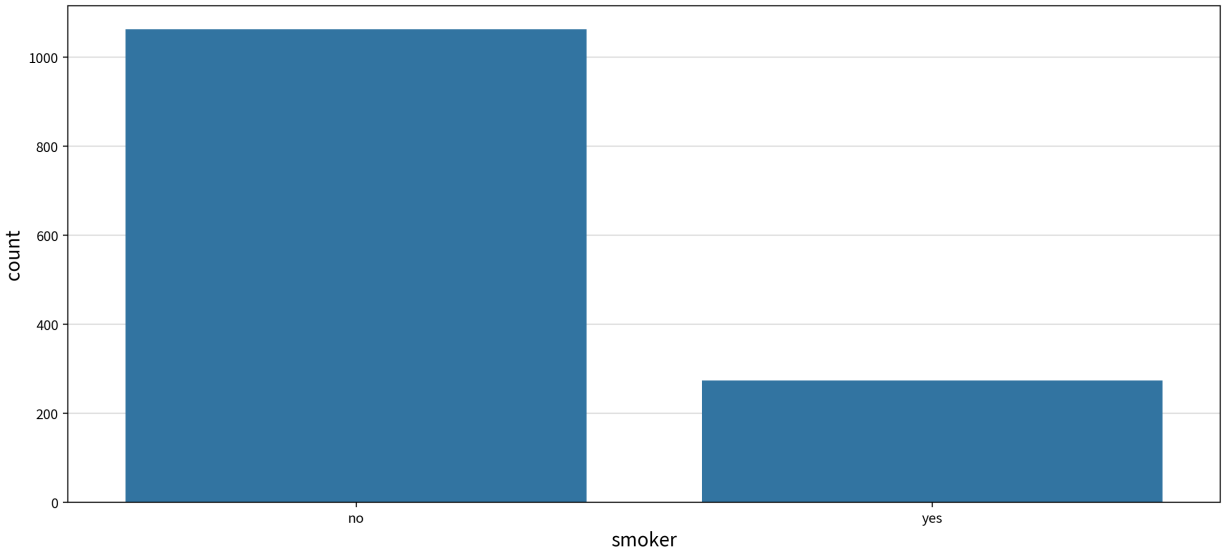
	빈도	비율(%)
sex		
male	675	50.500
female	662	49.500

독립변수 sex 분포

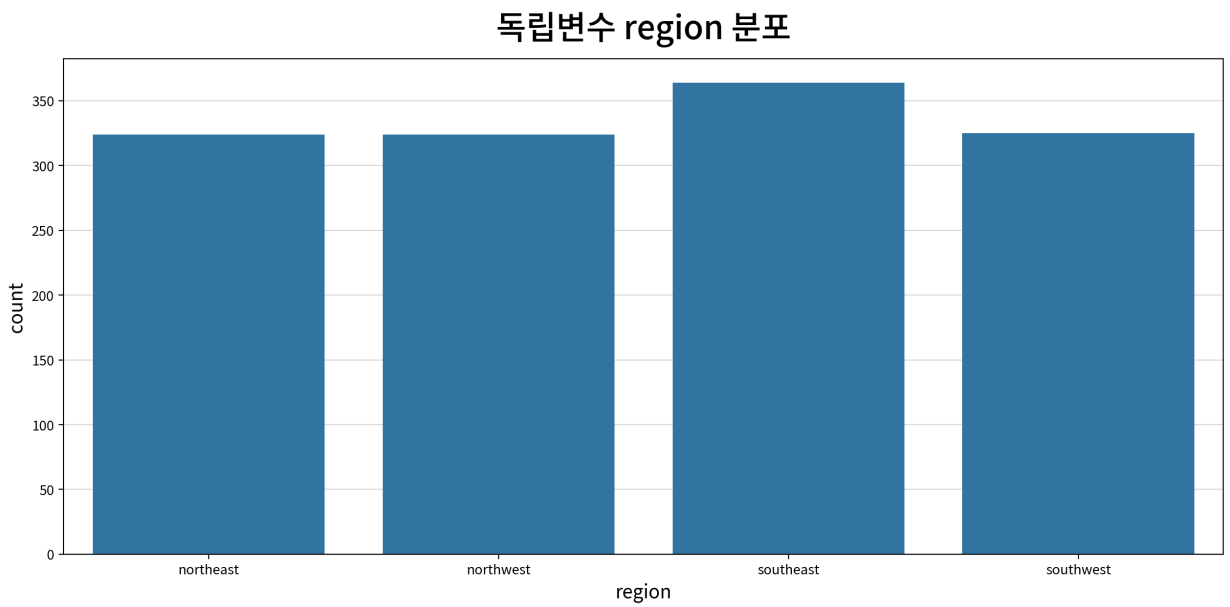


	빈도	비율(%)
smoker		
no	1063	79.500
yes	274	20.500

독립변수 smoker 분포



	빈도	비율(%)
region		
southeast	364	27.200
southwest	325	24.300
northeast	324	24.200
northwest	324	24.200



💡 인사이트

> 명목형은 분포 왜도 대신 **범주의 균형/불균형**과 **범주 수(→ 짝이 되는 검정)**를 점검한다. (아래 빈도·비율은 위 카운트플롯과 함께 출력된 **빈도표 기준**이다.)

변수	범주 수	빈도(비율)	균형 여부	판단·짝 검정
`sex`	2	male 675(50.5%) / female 662(49.5%)	**균형**	2집단 → `charges` 와 **T검정**
`smoker`	2	no 1063(79.5%) / yes 274(20.5%)	불균형(흡연 소수)	2집단 → **T검정** (흡연 274건으로 검정력은 충분)
`region`	4	southeast 364(27.2%) / 나머지 ≈ 24%	대체로 균형	**4집단 → ANOVA** (T검정 아님)

판단·조치

- 2집단(`sex` , `smoker`)은 `charges` 와의 차이를 **T검정**, 4집단(`region`)은 **ANOVA**로 짝짓는다. (원본 Boston과 달리 **다집단 명목변수가 존재**해 ANOVA 대상이 생김.)
- 모든 범주가 검정 가능한 표본을 확보 → **버릴 변수 없음**. 특히 `smoker` 는 불균형이지만 소수집단(흡연)이 가격에 큰 영향을 줄 가능성이 커 반드시 유지한다.

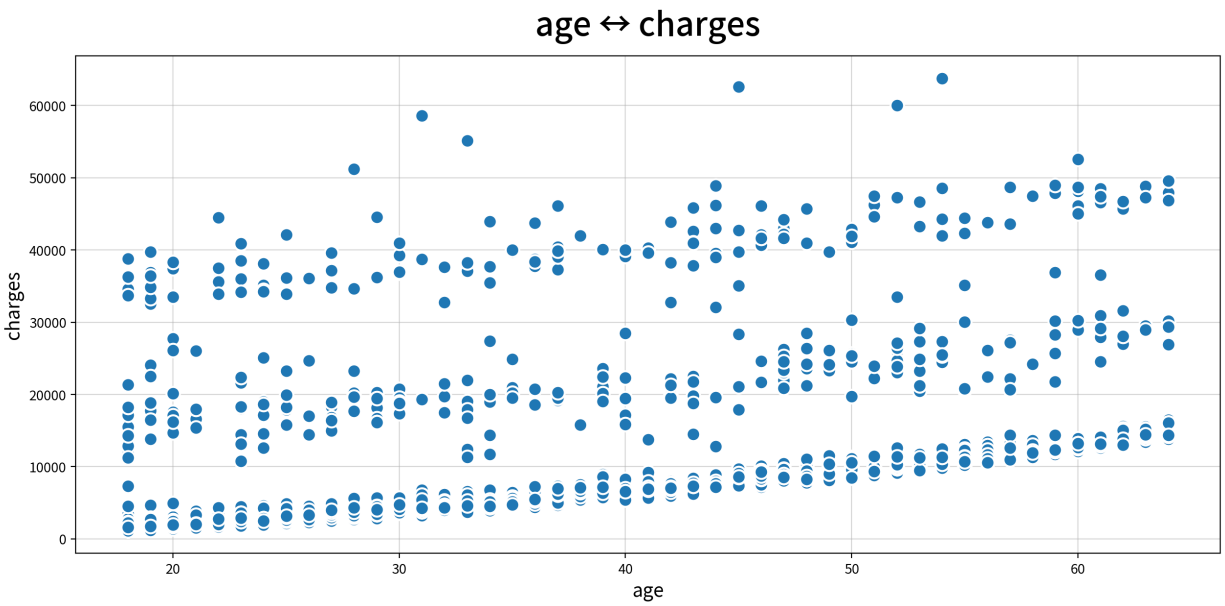
#03. 이변량 데이터 시각화

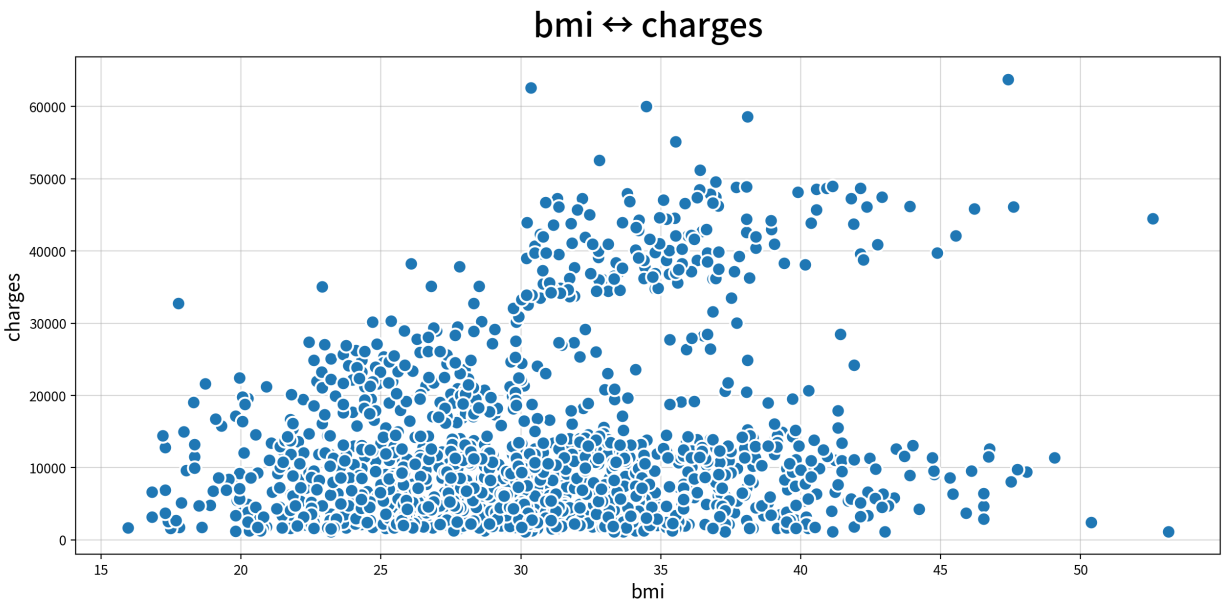
- 목표변수(`MEDV`)와 각 설명변수의 **관계(패턴)** 를 눈으로 확인하는 단계다. (PDF p.4 — 이변량 시각화 매트릭스)
- 모든 시각화는 **짝이 되는 검정**과 연결된다.
  - 연속형 ? 연속형 → **산점도** → 상관분석
  - 명목형(2집단) ? 연속형 → **박스플롯·바이올린** → T검정
- 여기서 발견한 것은 아직 **"후보 패턴"** 이며, 다음 추론통계 단계에서 숫자로 검증한다.

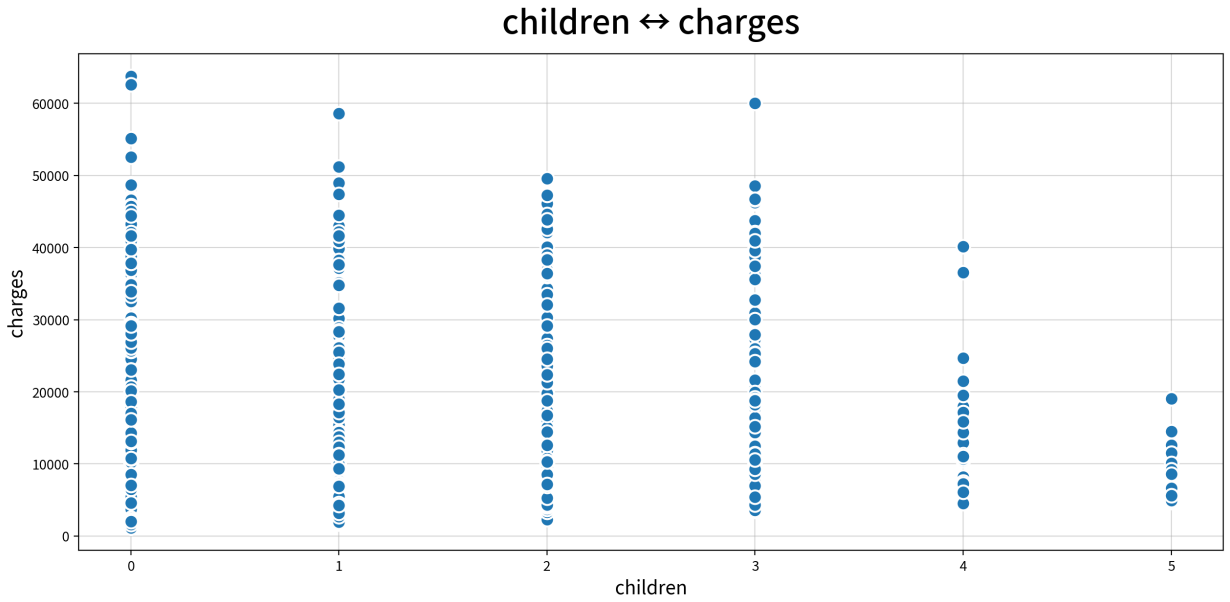
1. 연속형 독립변수 ? 종속변수 (산점도 → 상관분석)

- 연속형 설명변수와 종속변수(MEDV)의 관계는 **산점도**로 본다.
- 관계의 **방향(증가/감소)·모양(선형/곡선)·산포·이상치**를 동시에 확인 → 짝이 되는 검정은 **상관분석**.

```
for f in feature_continuous:
    # 연속 ↔ 연속: 산점도로 방향·모양·산포를 확인
    my_plot.scatterplot(data=df, x=f, y=target, title=f"{f} ↔ {target}")
```







💡 인사이트

> 연속형 설명변수와 `charges` 의 **관계 방향·모양**을 산점도로 확인한다.

- **`age`** : 우상향 경향이나 **세 개의 수평 밴드(하·중·상)**로 갈라진다. 밴드 안에서는 나이가 많을수록 `charges` ↑가 뚜렷 → 하나의 직선이라기보다 **잠재 그룹(흡연 등)이 밴드를 만드는 구조**로 보인다.
- **`bmi`** : 전체적으로 약한 양의 경향이나, **`bmi` 가 대략 30을 넘으면 고비용(상단) 점들이 새로 나타난다** → 특정 조건(흡연)과 결합해 급증하는 **상호작용 신호**.
- **`children`** : 0~5의 이산 세로열로 **방향성이 뚜렷하지 않고**, 4~5는 점이 희박

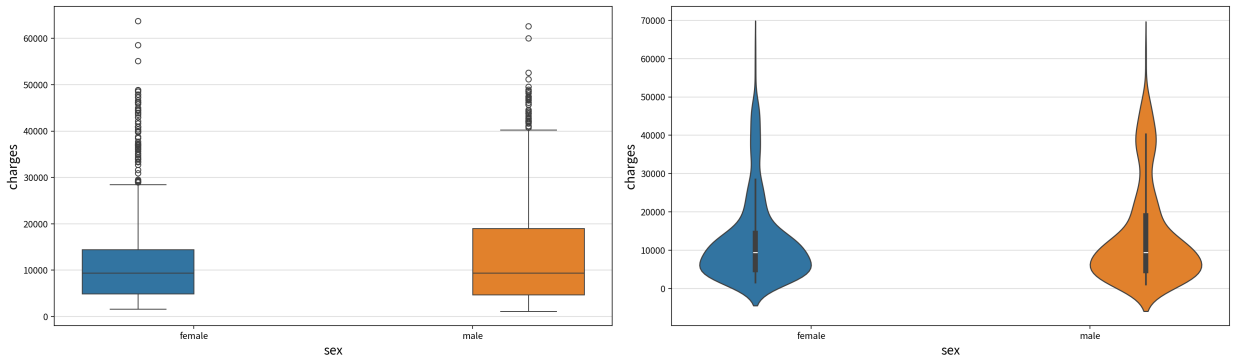
후보 정리: `age` · `bmi` 는 상관분석 대상(양의 관계로 보임). 밴드·상단 군집은 명목변수(`smoker`)와의 결합으로 다변량에서 재확인한다. (관계의 강도·유의성은 상관분석에서 수치로 확정)

2. 명목형 독립변수 ? 종속변수 (박스플롯·바이올린 → T검정)

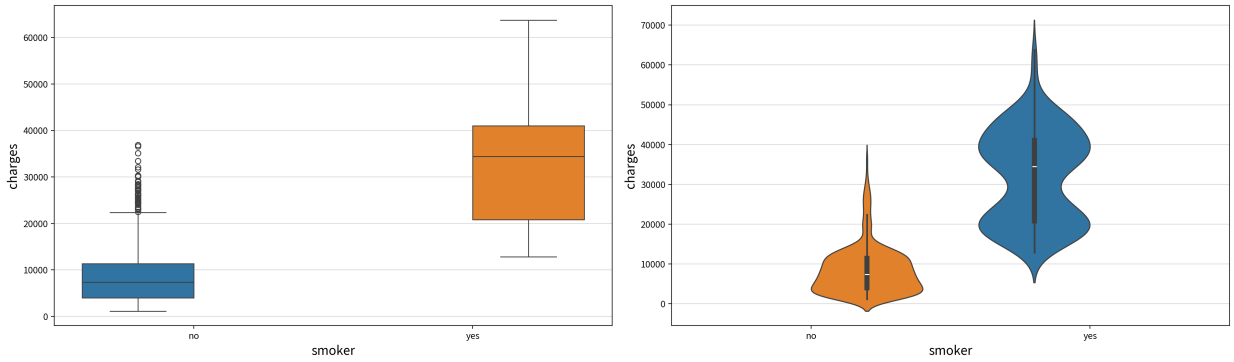
- 명목형(2집단)과 연속형의 관계는 **그룹별 박스플롯·바이올린**으로 본다.
- 두 그룹의 중앙값·산포 차이를 확인 → 짝이 되는 검정은 **T검정**.

```
for n in nominal_cols:
    # 명목(2집단) ↔ 연속: 박스플롯 + 바이올린으로 그룹 간 분포 비교
    fig, ax = my_plot.init(rows=1, cols=2, title=f"{n} ↔ {target}", width=960,
        height=640)
    my_plot.boxplot(data=df, x=n, y=target, hue=n, ax=ax[0])
    my_plot.violinplot(data=df, x=n, y=target, hue=n, ax=ax[1])
    my_plot.show()
```

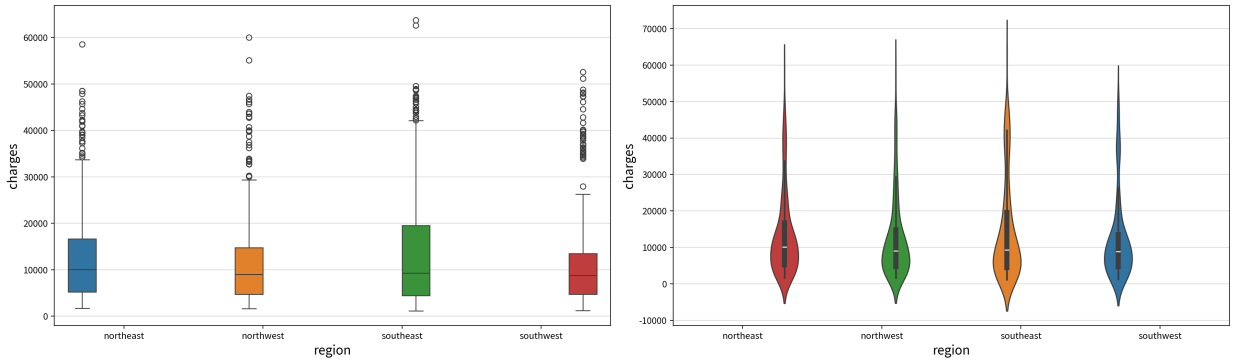
sex ↔ charges



smoker ↔ charges



region ↔ charges



💡 인사이트

> 명목형과 `charges` 의 그룹 차이를 박스·바이올린으로 확인한다. (짝: 2집단 → **T검정**, 다집단 → **ANOVA**) (중앙값 수치는 **박스 중앙선을 눈으로 읽은 대략값**이며, 정확한 차이·유의성은 검정에서 확인한다.)

- **`smoker` (2집단)**: **압도적 차이**. 비흡연 중앙값(대략 7천대) vs 흡연(대략 3만대 중반)으로 **두 박스가 거의 겹치지 않는다**. 흡연 바이올린은 **이중 봉우리** → `charges` 의 **가장 강력한 설명변수 후보**. → T검정
- **`sex` (2집단)**: 두 박스의 **중앙선이 거의 같은 높이**. 남성의 상위 IQR·고액 사례가 다소 많으나 분포가 크게 겹침 → 차이가 있어도 **약함**. → T검정
- **`region` (4집단)**: 네 지역 중앙선 높이 비슷, `southeast` 가 산포·고액 이상치가 가장 큼. 전반적으로 **차이 미미·중첩 큼**. → **ANOVA**

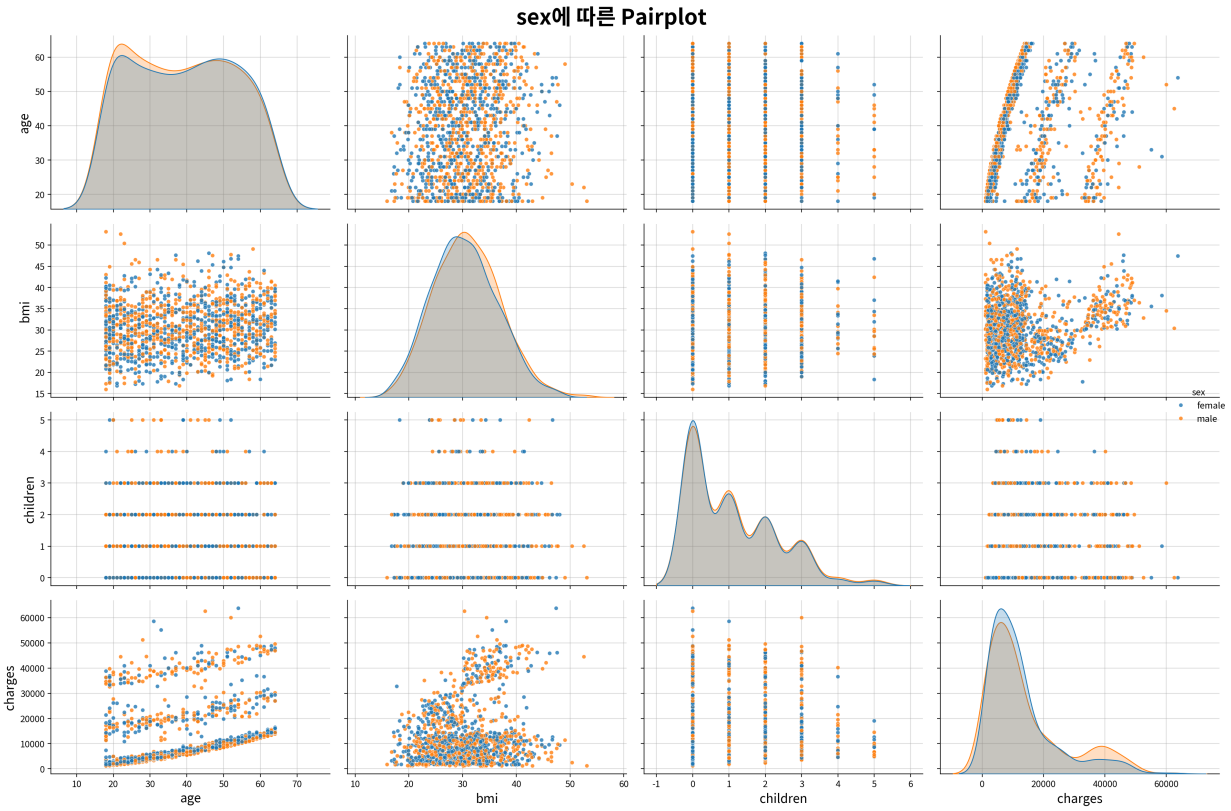
후보 우선순위: `smoker` (강함) ≫ `sex` · `region` (약함). 유의성은 추론통계에서 확정한다.

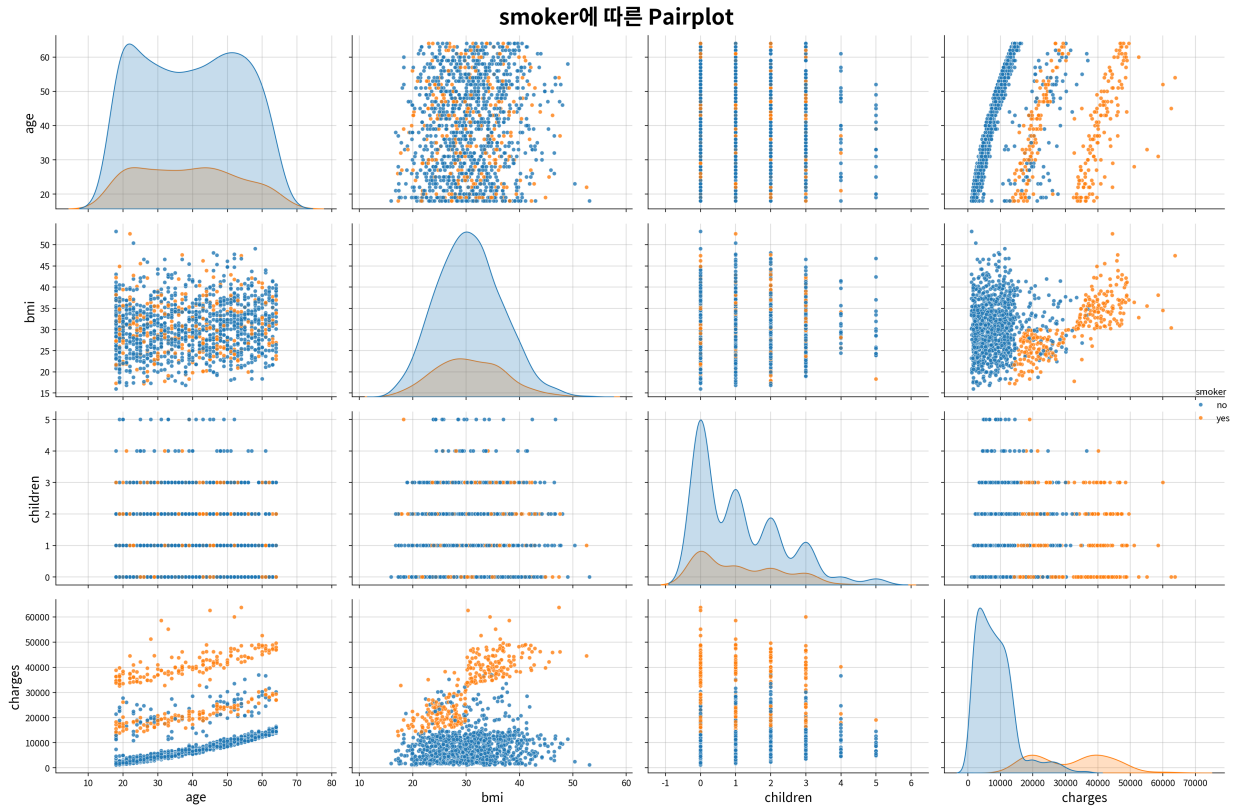
#04. 다변량 데이터 시각화

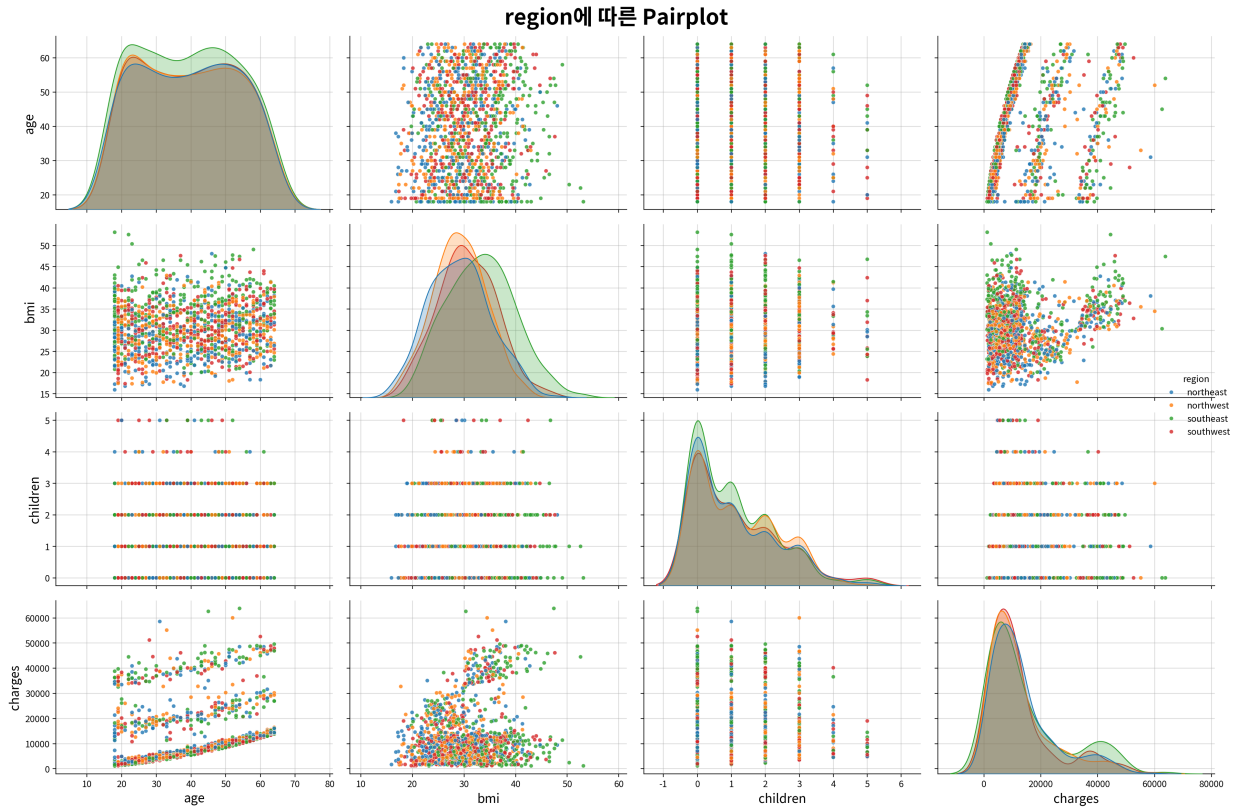
1. 범주별로 구분한 PairPlot

- 모든 쌍에 대한 비교

```
size = len(continuous_cols)
for n in nominal_cols:
    my_plot.pairplot(df[continuous_cols + [n]], hue=n, title=f"{n}에 따른 Pairplot",
        width=480*size, height=320*size)
```







💡 인사이트

> 세 명목형(`sex` · `smoker` · `region`)을 각각 색상으로 준 페어플롯 **3장을 비교**해 ① 어떤 범주가 `charges` 의 층(밴드)을 가장 잘 가르는지, ② 연속형끼리의 관계(공선성)를 함께 확인한다.

① 가장 영향력 있는 명목형 → `smoker` (색 분리가 압도적)

- **`smoker`** : `charges` 가 걸린 모든 칸에서 **비흡연(파랑, 저비용)·흡연(주황, 고비용) 색이 뚜렷이 갈린다.** `charges` 대각 KDE도 파랑(저)·주황(고)으로 봉우리가 분리 → `age`⍰`charges` 의 **3밴드**와 `bmi`⍰`charges` 의 **상단 군집**이 모두 **흡연 여부로 설명**된다.
- **`sex`** : 모든 칸에서 남녀 색이 **거의 완전히 섞임**, `charges` KDE도 겹침(남성 상단 꼬리만 약간 두꺼움) → 층을 가르지 못함.
- **`region`** : 4색이 대체로 섞이고 `charges` KDE도 겹침 → 약함. 유일한 소소한 신호는 `southeast` (초록)의 **`bmi` 분포가 살짝 오른쪽(고 `bmi`)** 이라 고비용 꼬리가 조금 두꺼운 정도.
- ⇒ **`charges` 를 가르는 핵심 명목변수는 `smoker`** , `sex` · `region` 은 분리력이 약하다.

② 연속형끼리의 관계 (색상과 무관)

- `age`↑ → `charges`↑ (밴드형), `bmi`↑ → `charges`↑ (특히 흡연자에서 급증) 재확인. `children` 은 세로열로 방향 없음.
- `age` · `bmi` · `children` 은 서로 **무작위로 흩어져 공선성이 낮다** → 회귀 투입 시 다중공선성 우려가 작다.

③ 상호작용 신호

- `bmi`⍰`charges` 칸에서 **흡연자(주황)만 `bmi` 가 커질수록 `charges` 가 급상승**하고 비흡연자(파랑)는 완만 → **`smoker` × `bmi` 상호작용** 후보.
- ⚠️ 색 분리·군집·기울기는 모두 **눈으로 본 후보**다. 유의성·계수는 다음 추론통계(상관분석·T검정·ANOVA·회귀)에서 확정한다.

추론통계 후보 패턴 목록

> 시각화로 '눈으로 본' 패턴을 한 표에 모아 추론통계를 수행할 후보를 도출한다. ⚠️ 아직 **가설이 아니라 "후보"** — '관찰된 패턴'은 **그래프에서 읽은 방향·모양·색 분리**이며, 상관계수·평균차 등 정확한 수치는 다음 단계에서 산출한다.

#	변수 조합 (유형)	관찰된 패턴 (그래프에서 읽은 방향·모양)	→ 검정
01	`smoker` · `charges` (명목 2집단 × 연속)	흡연 중앙선 ≫ 비흡연, **박스 거의 안 겹침 / 페어플롯 색이 저·고비용으로 뚜렷이 분리** (박스·바이올린·페어플롯)	**T검정**
02	`age` · `charges` (연속 × 연속)	`age` ↑ → `charges` ↑, **3개 밴드 구조**(밴드는 흡연색으로 갈림) (산점도·페어플롯)	상관분석
03	`bmi` · `charges` (연속 × 연속)	약한 양의 경향, **`bmi` ≈30↑에서 고비용 군집(대부분 흡연자)** (산점도·페어플롯)	상관분석
04	`children` · `charges` (연속 × 연속)	세로열, 방향 뚜렷치 않음 → 관계 미약 (산점도·페어플롯)	상관분석(유의성 낮을 것으로 예상)
05	`sex` · `charges` (명목 2집단 × 연속)	중앙선 거의 동일, **페어플롯 색 섞임 = 분리력 약함**(남성 고액 사례만 다소↑) (박스·바이올린·페어플롯)	**T검정**
06	`region` · `charges` (명목 4집단 × 연속)	지역 중앙선 유사, **페어플롯 색 섞임**, `southeast` 만 `bmi` ·상단 꼬리 약간↑ (박스·바이올린·페어플롯)	**ANOVA**

07	`smoker` × `bmi` · `charges` (상호작용)	`bmi`□`charges` 에서 **흡연자만 `bmi` ↑에 따라 급상승**, 비흡연자는 완만 (페어플롯)	회귀 상호작용 / 그룹별 상관

참고

- ※ **영향력 우선순위(시각적 분리 기준)**: 명목형은 `smoker` ≫ `sex` ≈ `region` (거의 없음), 연속형은 `age` ≳ `bmi` > `children` .
- ※ '관찰된 패턴'은 느낌이 아니라 **그래프에서 본 사실**(중앙선 높이 차·기울기·군집·밴드·색 분리)로 적었고, **정확한 상관계수·평균차·유의성은 추론통계에서 확정**한다.
- ※ **검정 짝**: 2집단 명목(`smoker` , `sex`) → **T검정**, 4집단 명목(`region`) → **ANOVA**, 연속 × 연속 → **상관분석**, 상호작용 → **회귀**.
- ※ **교차분석(명목 × 명목)**: 목표변수와 직접 관련은 아니나 `smoker` × `region` 등 범주 간 분포 확인 시 옵션으로 활용 가능.