Statistics Basic

LAB 08 - [PBT] 탐색적 데이터 분석

2. 데이터 시각화

IT WILL 이광호 강사

1. EDA 시작하기
2. 데이터 시각화
3. 추론통계
4. 변수 선별
5. EDA 파이프라인



데이터의 패턴을 눈으로 발견하는 과정

□ 분포를 다시 확인하고, 검정에 입력할 후보 패턴 목록을 만드는 단계

시각화의 3가지 목적

1 분포의 모양 재확인

왜도·첨도, 봉우리 수, 이상치, 결측 분포 등
기술통계로는 놓치는 모양을 찾는다

2 목표변수와의 관계 탐색

설명변수와 목표변수의 짝을
변수 유형 조합별로 패턴의 단서를 찾는다

3 상호작용·교란 힌트 발견

범주형을 3번째 변수로 추가하여(hue)
두 변수만으로 보이지 않는 구조를 짚어낸다

시각화 3단계 진행

① 단변량 — 변수 하나씩 분포

연속/명목별 매트릭스

② 이변량 — 목표변수와의 관계 (★ 핵심)

변수 조합 ↔ 그래프 ↔ 짝이 되는 검정
여기서 만들어진 후보 패턴이 추론통계의 입력값

③ 다변량 — 3개 이상 동시에

히트맵 · 페어플롯 · 색상 구분 (필요 시)

OUTPUT — 1단계 산출물

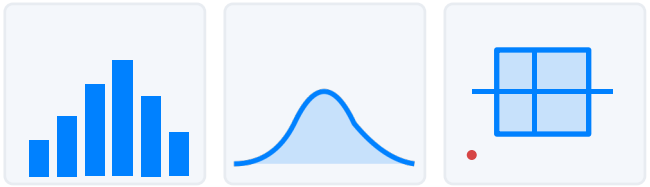
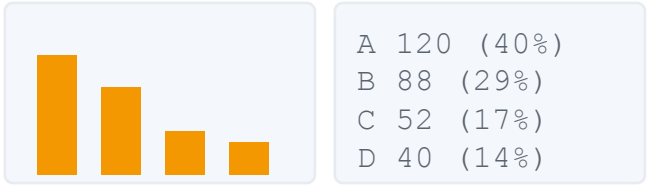
후보 패턴 목록

“A가 클수록 B가 큰 듯”, “그룹별 C 평균이 달라 보임”

ITWILL 이광호강사

변수 유형별 단변량 시각화

□ 변수 하나씩 분포의 모양을 확인하는 시각화 유형

변수 유형	대표 시각화	무엇을 보는가
연속형 Continuous 예: 나이, 가격, 점수, 거리	 히스토그램 / KDE (밀도) / 박스플롯	· **분포의 모양** — 정규/치우침(왜도) · **봉우리 수** — 단봉/다봉 · **이상치** — 박스플롯의 점 · **이산점** — 군집 여부
명목형 Nominal 예: 성별, 지역, 카테고리	 막대그래프 / 빈도표 A 120 (40%) B 88 (29%) C 52 (17%) D 40 (14%)	· **범주별 빈도** — 어떤 값이 많은가 · **불균형** — 모델링 시 보정 필요? · **희소 범주** — 묶기·제거 후보 · **결측 카테고리** — 처리 전략

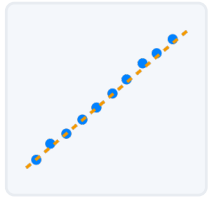
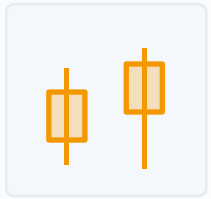
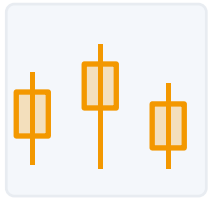
단변량 단계의 목적은 '이 변수를 그대로 검정에 넣어도 되는가?'를 판단하는 것

치우침이 강하면 → 로그 변환 / 이상치가 많으면 → 처리 고려 / 불균형 명목형이면 → 비교 및 해석 신중

ITWILL 이광호강사

변수 유형별 이변량 시각화

□ 모든 시각화는 그에 대응하는 검정과 짝지어진다.

변수 조합	시각화 (모식도 + 명칭)	짝이 되는 검정	무엇을 보는가?
연속 × 연속 예: 나이 X 와 가격 Y의 관계	 **산점도**	**상관분석** Pearson · Spearman	선형/비선형, 단조성, 산포·이상치 동시 확인.
명목(2) × 연속 예: 성별(2개) 별 점수 Y	 **그룹별 박스플롯 혹은 바이올린 플롯**	**T검정** 독립표본 t / Welch / Mann-Whitney	두 그룹의 중앙값· 산포 차이를 동시에.
명목(3+) × 연속 예: 지역(3개+)별 점수 Y	 **그룹별 박스플롯 혹은 바이올린 플롯**	**ANOVA** 일원분산분석 + 사후검정	3개 이상 그룹의 중심·분산을 비교.
명목 × 명목 예: 지역 × 결제수단	**교차표 히트맵 누적 막대 그래프**	**교차분석** 카이제곱 · Fisher 정확검정	셀 빈도의 편향(연관 여부) 확인.

ITWILL 이광호강사

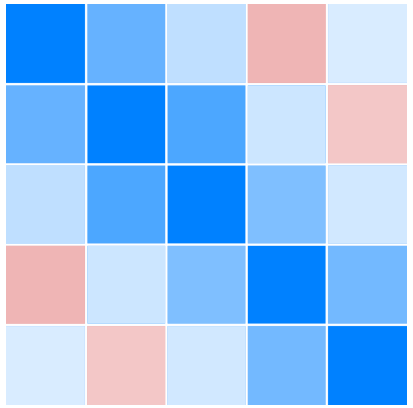
1. EDA 시작하기
2. 데이터 시각화
3. 추론통계
4. 변수 선별
5. EDA 파이프라인

다변량 시각화

□ 두 변수만으로 보이지 않는 상호작용·교란 후보가 의심될 때 확인

TOOL 01

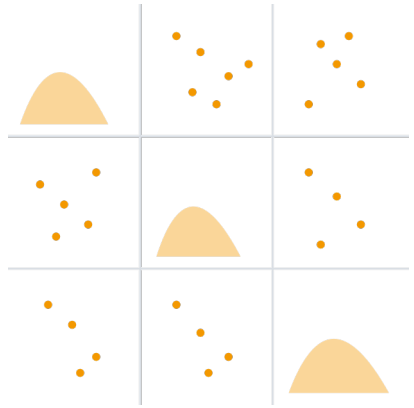
상관 히트맵



연속형 변수쌍의 상관계수를 한눈에
→ 강한 상관쌍과 군집을 빠르게 찾기.

TOOL 02

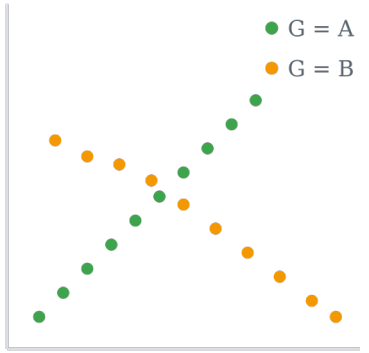
페어플롯 (pairplot)



대각선엔 분포, 비대각엔 산점도.
연속형 그룹 전체를 한 번에 스캔.

TOOL 03

범주별 색상 구분



하나의 그래프 안에서 3번째 명목변수를
색상으로 구분
→ 상호작용·교란 후보 식별.

⚠ WHEN NOT TO USE 다변량은 '필요할 때만' 사용

- 단변량/이변량으로 충분히 설명되는데 다변량을 덧대면 가독성·해석력이 모두 떨어집니다.
- 변수가 10개 이상이면 페어플롯은 정보 과부하 → 상관 히트맵으로 후보 변수를 먼저 줄입니다.
- 다변량으로 본 '패턴'은 어디까지나 후보일 뿐 → 검증은 반드시 2단계 추론통계에서 수행합니다.

ITWILL 이광호강사



후보 패턴 목록 도출

□ 시각화로 '눈으로 본' 패턴을 한 표에 모아 추론통계를 수행할 후보를 도출한다.

후보 패턴 표

예시 문장 입니다.

#	변수 조합	관찰된 패턴	→ 검정
01	연속 X · 연속 Y 예: 나이 × 가격	X가 클수록 Y도 커 보임 (정의 선형)	상관분석
02	명목(2) G · 연속 Y 예: 성별 × 점수	그룹 A 평균이 그룹 B보다 높아 보임	T검정
03	명목(3+) G · 연속 Y 예: 지역 × 점수	3개 지역의 점수 분포가 서로 다름	ANOVA
04	명목 A · 명목 B 예: 지역 × 결제수단	특정 셀에 빈도가 몰림	교차분석

※ **'관찰된 패턴'**은 **'느낌'이 아니라 그래프에서 본 사실**
(기울기, 평균 차이, 셀 빈도 편향) 등으로 적습니다.

※ 한 변수쌍에 패턴이 여러 개 보이면 행을 나누어 별도로 적습니다.

DO / DON'T

✓ DO — 검증 가능한 형식

- 변수 이름·유형을 함께 표기
- 방향 포함 (증가/감소/차이/연관)
- 어떤 그래프에서 본 것인지 명시

✗ DON'T — 결론으로 도약 금지

- "X가 Y의 원인"이라 단정 ✗
- 통계 검정 없이 "유의함" 판단 ✗
- 수치(평균/상관)를 임의 기재 ✗
- 그래프 없이 머릿속 가정 서술 ✗

근거 없는 일반 상식이나 추측 금지

ITWILL 이광호강사