[LAB-08] 3. 추론통계

#01. 준비작업

1. 이전 분석 내용 가져오기

```
%%capture cap
%run "./[LAB-08] PBT - EDA | 1-EDA 시작하기(실습코드).ipynb"
```

2. 불러온 내용 확인

- 이전 분석 내역이 잘 로드 되었는지 확인한다.

```
print("목표변수 :", target)
print("연속형(종속변수 포함) :", continuous_cols)
print("독립변수(명목형) :", nominal_cols)
print("독립변수(연속형) :", feature_continuous)

display(df.head())          # 품질점검 완료 후 타입변환 데이터 프레임
display(desc.head())        # 기술통계량 데이터 프레임
display(cat_desc.head())    # 범주형 데이터 기술통계량 데이터 프레임
```

```
목표변수 : MEDV
연속형(종속변수 포함) : ['CRIM', 'ZN', 'INDUS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX',
'PTRATIO', 'B', 'LSTAT', 'MEDV']
독립변수(명목형) : ['CHAS']
독립변수(연속형) : ['CRIM', 'ZN', 'INDUS', 'NOX', 'RM', 'AGE', 'DIS', 'RAD', 'TAX', 'PTRATIO',
'B', 'LSTAT']
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	MEDV
0	0.006	18.000	2.310	0	0.538	6.575	65.200	4.090	1	296	15.300	396.900	4.980	24.000
1	0.027	0.000	7.070	0	0.469	6.421	78.900	4.967	2	242	17.800	396.900	9.140	21.600
2	0.027	0.000	7.070	0	0.469	7.185	61.100	4.967	2	242	17.800	392.830	4.030	34.700
3	0.032	0.000	2.180	0	0.458	6.998	45.800	6.062	3	222	18.700	394.630	2.940	33.400
4	0.069	0.000	2.180	0	0.458	7.147	54.200	6.062	3	222	18.700	396.900	5.330	36.200

	count	mean	std	min	25%	50%	75%	max	rel_diff	rdiff_flag	iqr	upper_bound	lo
CRIM	506.000	3.614	8.602	0.006	0.082	0.257	3.677	88.976	13.087	large_diff	3.595	9.070	-5
ZN	506.000	11.364	23.322	0.000	0.000	0.000	12.500	100.000	inf	large_diff	12.500	31.250	-1
INDUS	506.000	11.137	6.860	0.460	5.190	9.690	18.100	27.740	0.149	diff	12.910	37.465	-1
NOX	506.000	0.555	0.116	0.385	0.449	0.538	0.624	0.871	0.031	similar	0.175	0.886	0.

RM	506.000	6.285	0.703	3.561	5.885	6.208	6.623	8.780	0.012	similar	0.738	7.731	4.

	CHAS
count	506
unique	2
top	0
freq	471

3. 라이브러리 참조

```
from pandas import DataFrame, cut
```

#02. 상관분석

1. (연속형 종속변수 ? 연속형 독립변수

```
for f in feature_continuous:
    result = my_stats.correlation(df, x=f, y= target, plot=False)
    print(f"\n독립변수 : {f}")
    display(result)
```

```
독립변수 : CRIM
```

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlie
x	**y**									
CRIM	**MEDV**	Spearman	-0.559	0.000	Moderate	True	False	False	False	False

```
독립변수 : ZN
```

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier
x	**y**									
ZN	**MEDV**	Spearman	0.438	0.000	Moderate	True	False	False	False	False

```
독립변수 : INDUS
```

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outli

x	y									
INDUS	**MEDV**	Spearman	-0.578	0.000	Moderate	True	False	False	False	True

독립변수 : NOX

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier
x	**y**									
NOX	**MEDV**	Spearman	-0.563	0.000	Moderate	True	False	False	True	True

독립변수 : RM

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier
x	**y**									
RM	**MEDV**	Spearman	0.634	0.000	Moderate	True	False	False	False	False

독립변수 : AGE

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier
x	**y**									
AGE	**MEDV**	Spearman	-0.548	0.000	Moderate	True	False	False	False	True

독립변수 : DIS

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier
x	**y**									
DIS	**MEDV**	Spearman	0.446	0.000	Moderate	True	False	False	False	True

독립변수 : RAD

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier
x	**y**									
RAD	**MEDV**	Spearman	-0.347	0.000	Moderate	True	False	False	False	True

독립변수 : TAX

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier
x	y									
TAX	MEDV	Spearman	-0.562	0.000	Moderate	True	False	False	True	True

독립변수 : PTRATIO

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_ou
x	y									
PTRATIO	MEDV	Spearman	-0.556	0.000	Moderate	True	False	False	True	False

독립변수 : B

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlier	h
x	y										
B	MEDV	Spearman	0.186	0.000	Weak	True	False	False	True	True	T

독립변수 : LSTAT

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_outlie
x	y									
LSTAT	MEDV	Spearman	-0.853	0.000	Strong	True	False	False	False	False

💡 인사이트

검정 선택 : 모든 쌍에서 정규성 위배(normality=False) → **Spearman ρ** 자동 적용(비모수). 12개 변수 모두 p<0.001로 유의.

채택 기준(PDF) : `p<0.05 & |r|≥0.3` → 독립변수 후보로 채택

변수	ρ	방향	강도(PDF)	채택
LSTAT	-0.853	부(−)	강함	✅
RM	0.634	정(+)	강함	✅
INDUS	-0.578	부(−)	강함	✅
NOX	-0.563	부(−)	강함	✅

TAX	-0.562	부(−)	강함	✅
CRIM	-0.559	부(−)	강함	✅
PTRATIO	-0.556	부(−)	강함	✅
AGE	-0.548	부(−)	강함	✅
DIS	0.446	정(+)	중간	✅
ZN	0.438	정(+)	중간	✅
RAD	-0.347	부(−)	중간	✅
B	0.186	정(+)	약함	❌

- **핵심 :** `LSTAT` (하위계층 비율)이 |ρ|=0.85로 MEDV와 가장 강한 **음(−)의 상관**, `RM` (방 개수)이 가장 강한 **양(+)의 상관** → 두 변수가 집값 설명력의 핵심 후보.
- `B` 만 |ρ|<0.3(약함)이라 유일하게 후보에서 **제외**, 나머지 11개는 채택.
- ⚠ 상관 ≠ 인과 : 강한 ρ라도 원인으로 단정 금지.

2. 연속형 독립변수간의 상관분석

- 다중공선성 신호를 감지한다.

```
my_stats.multi_correlation(df, columns=feature_continuous, plot=False)
```

	CRIM	ZN	INDUS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT
CRIM	1.000	-0.572	0.736	0.822	-0.309	0.704	-0.745	0.728	0.729	0.465	-0.361	0.635
ZN	-0.572	1.000	-0.643	-0.635	0.361	-0.544	0.615	-0.279	-0.371	-0.449	0.163	-0.490
INDUS	0.736	-0.643	1.000	0.791	-0.415	0.679	-0.757	0.456	0.664	0.434	-0.286	0.639
NOX	0.822	-0.635	0.791	1.000	-0.310	0.795	-0.880	0.586	0.649	0.391	-0.297	0.637
RM	-0.309	0.361	-0.415	-0.310	1.000	-0.278	0.263	-0.107	-0.272	-0.313	0.054	-0.641
AGE	0.704	-0.544	0.679	0.795	-0.278	1.000	-0.802	0.418	0.526	0.355	-0.228	0.657
DIS	-0.745	0.615	-0.757	-0.880	0.263	-0.802	1.000	-0.496	-0.574	-0.322	0.250	-0.564
RAD	0.728	-0.279	0.456	0.586	-0.107	0.418	-0.496	1.000	0.705	0.318	-0.282	0.394
TAX	0.729	-0.371	0.664	0.649	-0.272	0.526	-0.574	0.705	1.000	0.453	-0.330	0.534
PTRATIO	0.465	-0.449	0.434	0.391	-0.313	0.355	-0.322	0.318	0.453	1.000	-0.072	0.467
B	-0.361	0.163	-0.286	-0.297	0.054	-0.228	0.250	-0.282	-0.330	-0.072	1.000	-0.211
LSTAT	0.635	-0.490	0.639	0.637	-0.641	0.657	-0.564	0.394	0.534	0.467	-0.211	1.000

		method	coef	p-value	strength	significant	normality_x	normality_y	linearity	influential_
x	**y**									
CRIM	**ZN**	Spearman	-0.572	0.000	Moderate	True	False	False	False	False

	INDUS	Spearman	0.736	0.000	Strong	True	False	False	False	True
	NOX	Spearman	0.822	0.000	Strong	True	False	False	False	True
	RM	Spearman	-0.309	0.000	Moderate	True	False	False	False	False
	AGE	Spearman	0.704	0.000	Strong	True	False	False	False	False
	DIS	Spearman	-0.745	0.000	Strong	True	False	False	False	False
	RAD	Spearman	0.728	0.000	Strong	True	False	False	False	True
	TAX	Spearman	0.729	0.000	Strong	True	False	False	False	True
	PTRATIO	Spearman	0.465	0.000	Moderate	True	False	False	False	False
	B	Spearman	-0.361	0.000	Moderate	True	False	False	False	True
	LSTAT	Spearman	0.635	0.000	Moderate	True	False	False	False	False
ZN	**INDUS**	Spearman	-0.643	0.000	Moderate	True	False	False	False	True
	NOX	Spearman	-0.635	0.000	Moderate	True	False	False	False	True
	RM	Spearman	0.361	0.000	Moderate	True	False	False	False	False
	AGE	Spearman	-0.544	0.000	Moderate	True	False	False	False	True
	DIS	Spearman	0.615	0.000	Moderate	True	False	False	False	True
	RAD	Spearman	-0.279	0.000	Weak	True	False	False	False	False
	TAX	Spearman	-0.371	0.000	Moderate	True	False	False	False	False
	PTRATIO	Spearman	-0.449	0.000	Moderate	True	False	False	False	True
	B	Spearman	0.163	0.000	Weak	True	False	False	False	True
	LSTAT	Spearman	-0.490	0.000	Moderate	True	False	False	False	True
INDUS	**NOX**	Spearman	0.791	0.000	Strong	True	False	False	False	False
	RM	Spearman	-0.415	0.000	Moderate	True	False	False	False	False
	AGE	Spearman	0.679	0.000	Moderate	True	False	False	False	False
	DIS	Spearman	-0.757	0.000	Strong	True	False	False	False	False
	RAD	Spearman	0.456	0.000	Moderate	True	False	False	False	False
	TAX	Spearman	0.664	0.000	Moderate	True	False	False	False	False
	PTRATIO	Spearman	0.434	0.000	Moderate	True	False	False	False	False
	B	Spearman	-0.286	0.000	Weak	True	False	False	True	True
	LSTAT	Spearman	0.639	0.000	Moderate	True	False	False	False	False
NOX	**RM**	Spearman	-0.310	0.000	Moderate	True	False	False	True	False
	AGE	Spearman	0.795	0.000	Strong	True	False	False	False	False
	DIS	Spearman	-0.880	0.000	Strong	True	False	False	False	False
	RAD	Spearman	0.586	0.000	Moderate	True	False	False	False	False
	TAX	Spearman	0.649	0.000	Moderate	True	False	False	False	False
	PTRATIO	Spearman	0.391	0.000	Moderate	True	False	False	False	False
	B	Spearman	-0.297	0.000	Weak	True	False	False	True	True
	LSTAT	Spearman	0.637	0.000	Moderate	True	False	False	False	False

RM	**AGE**	Spearman	-0.278	0.000	Weak	True	False	False	False	False
	DIS	Spearman	0.263	0.000	Weak	True	False	False	False	False
	RAD	Spearman	-0.107	0.016	Weak	True	False	False	False	False
	TAX	Spearman	-0.272	0.000	Weak	True	False	False	False	False
	PTRATIO	Spearman	-0.313	0.000	Moderate	True	False	False	False	True
	B	Spearman	0.054	0.228	Weak	False	False	False	True	False
	LSTAT	Spearman	-0.641	0.000	Moderate	True	False	False	False	False
AGE	**DIS**	Spearman	-0.802	0.000	Strong	True	False	False	False	False
	RAD	Spearman	0.418	0.000	Moderate	True	False	False	False	False
	TAX	Spearman	0.526	0.000	Moderate	True	False	False	False	False
	PTRATIO	Spearman	0.355	0.000	Moderate	True	False	False	True	False
	B	Spearman	-0.228	0.000	Weak	True	False	False	False	True
	LSTAT	Spearman	0.657	0.000	Moderate	True	False	False	False	False
DIS	**RAD**	Spearman	-0.496	0.000	Moderate	True	False	False	False	False
	TAX	Spearman	-0.574	0.000	Moderate	True	False	False	False	False
	PTRATIO	Spearman	-0.322	0.000	Moderate	True	False	False	False	False
	B	Spearman	0.250	0.000	Weak	True	False	False	False	True
	LSTAT	Spearman	-0.564	0.000	Moderate	True	False	False	False	False
RAD	**TAX**	Spearman	0.705	0.000	Strong	True	False	False	False	False
	PTRATIO	Spearman	0.318	0.000	Moderate	True	False	False	False	False
	B	Spearman	-0.282	0.000	Weak	True	False	False	True	True
	LSTAT	Spearman	0.394	0.000	Moderate	True	False	False	True	False
TAX	**PTRATIO**	Spearman	0.453	0.000	Moderate	True	False	False	False	False
	B	Spearman	-0.330	0.000	Moderate	True	False	False	True	True
	LSTAT	Spearman	0.534	0.000	Moderate	True	False	False	True	False
PTRATIO	**B**	Spearman	-0.072	0.106	Weak	False	False	False	False	True
	LSTAT	Spearman	0.467	0.000	Moderate	True	False	False	False	False
B	**LSTAT**	Spearman	-0.211	0.000	Weak	True	False	False	False	True

💡 인사이트

독립변수끼리의 상관을 보고 **다중공선성(변수 중복)** 신호를 점검. |ρ|≥0.7을 위험 신호로 간주.

강한 상관 변수쌍(|ρ|≥0.7) — 다중공선성 위험

변수쌍	ρ	해석
NOX ? DIS	-0.880	오염↑일수록 도심거리↓ (가장 강함)
AGE ? DIS	-0.802	노후 주택일수록 도심 근접
NOX ? AGE	0.795	오염·노후 동반

INDUS ? NOX	0.791	산업지역·오염 동반
INDUS ? DIS	-0.757	산업지역일수록 도심 근접
INDUS ? CRIM	0.736	산업지역·범죄 동반
CRIM ? TAX	0.729	범죄·세율 동반
CRIM ? RAD	0.728	범죄·도로접근 동반
RAD ? TAX	**0.705**	도로접근성·재산세 동반
CRIM ? NOX	0.822	범죄·오염 동반

- **군집 발견** : `NOX·DIS·AGE·INDUS·CRIM` 이 서로 강하게 얽힌 **환경·입지 군집** → 회귀에 함께 넣으면 계수 왜곡 위험.
- **거의 무관(독립)** : `RM?B` (ρ=0.05, p=0.228), `PTRATIO?B` (ρ=-0.07, p=0.106)만 유의하지 않음.
- **시사점** : 강상관 쌍은 **하나만 선택하거나 VIF로 추가 점검** 후 회귀에 투입.

#03. T검정

1. 이진 명목형 변수 ? 연속

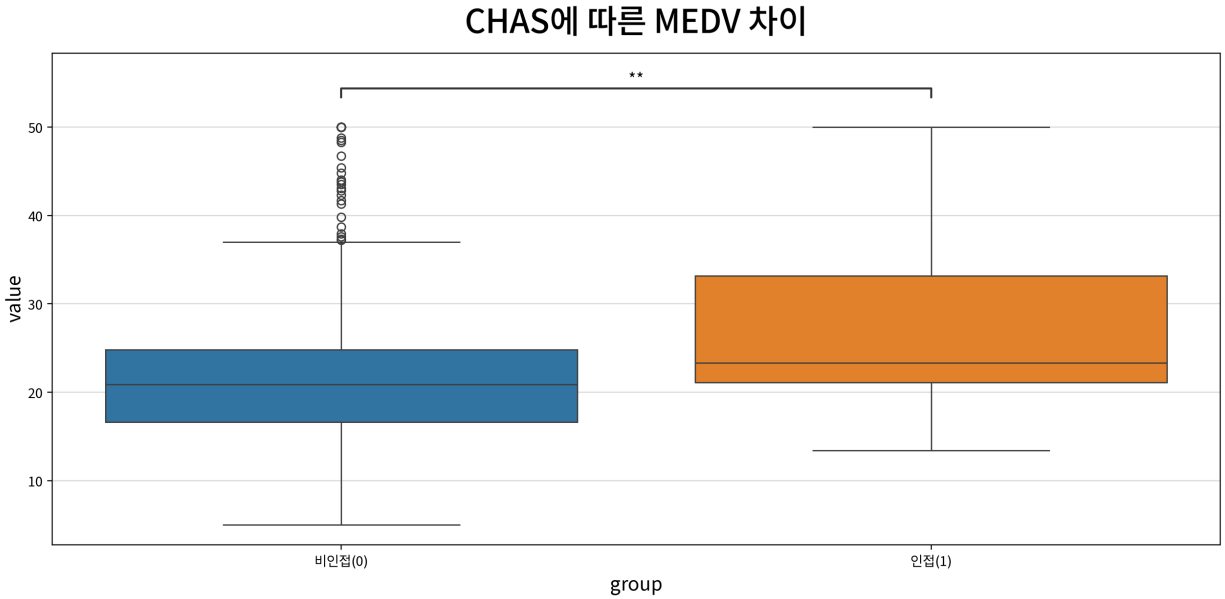
- `CHAS` (강 인접)에 따른 `MEDV` 차이
  - 검정값을 wide 포맷(두 컬럼)으로 분리해 전달한다.

```
chas_medv = DataFrame({
    "비인접(0)": df.loc[df["CHAS"] == 0, target].reset_index(drop=True),
    "인접(1)":   df.loc[df["CHAS"] == 1, target].reset_index(drop=True),
})

my_stats.test_independent(chas_medv, "비인접(0)", "인접(1)",
                          title="CHAS에 따른 MEDV 차이")
```

```
p-value annotation legend:
      ns: 5.00e-02 < p <= 1.00e+00
       *: 1.00e-02 < p <= 5.00e-02
      **: 1.00e-03 < p <= 1.00e-02
     ***: 1.00e-04 < p <= 1.00e-03
    ****: p <= 1.00e-04

비인접(0) vs. 인접(1): Mann-Whitney-Wilcoxon test two-sided, P_val:1.582e-03 U_stat=5.606e+03
```



		statistic	p-value	significant	result
test	**alternative**				
Mann-Whitney U test	**two-sided**	5605.500	0.002	True	비인접(0) ≠ 인접(1)
	less	5605.500	0.001	True	비인접(0) < 인접(1)
	greater	5605.500	0.999	False	비인접(0) ≤ 인접(1)

💡 인사이트

명목(2) × 연속 → T검정 계열. 정규성 위배 → **Mann-Whitney U**(비모수) 자동 적용.

항목	결과
검정	Mann-Whitney U (비모수)
U 통계량	5605.5
p-value (양측)	0.002 () → 유의**
방향 (단측)	비인접(0) < 인접(1), p=0.001
결론	강에 **인접한 지역(CHAS=1)의 MEDV가 더 높다**

- **해석** : 찰스강 인접 여부에 따라 집값이 통계적으로 유의하게 다르며, **인접 지역이 더 비쌈**.
- p<0.05 유의 → `CHAS` 를 **독립변수 후보로 채택**.
- ⚠ 비모수 검정이라 Cohen's d가 출력되지 않음 → 실질 크기는 박스플롯의 중앙값 차이로 보완 판단.

#04. ANOVA

1. 3개 이상의 그룹을 갖는 명목형 파생변수 생성

- 원본엔 3집단+ 명목형이 없기 때문에 가상의 파생변수를 생성해서 진행한다.
- 이 검정의 결과는 최종 변수 선별에는 포함되지 않는다.

```
df["RM_grp"] = cut(df["RM"], 3, labels=["방적음", "방보통", "방많음"])
df["RM_grp"].value_counts().sort_index()
```

```
RM_grp
방적음     24
방보통    422
방많음     60
Name: count, dtype: int64
```

2. 일원분산분석

```
my_stats.anova_oneway(df, y="MEDV", between="RM_grp")
```

	test	Source	ddof1	ddof2	F	p_unc	np2	effect_size
0	welch_anova	RM_grp	2	47.875	125.757	0.000	0.428	Large

💡 인사이트

명목(3+) × 연속 → ANOVA. RM을 3구간(방적음/방보통/방많음)으로 나눈 **파생변수**로 검정. 등분산 위배 → **Welch ANOVA** 자동 적용.

항목	결과
검정	Welch ANOVA (등분산 위배)
F	125.757
p-value	<0.001 → **유의**
효과크기 η^2(np2)	0.428 → **Large** (≥0.14)
그룹 크기	방적음 24 / 방보통 422 / 방많음 60 (불균형)

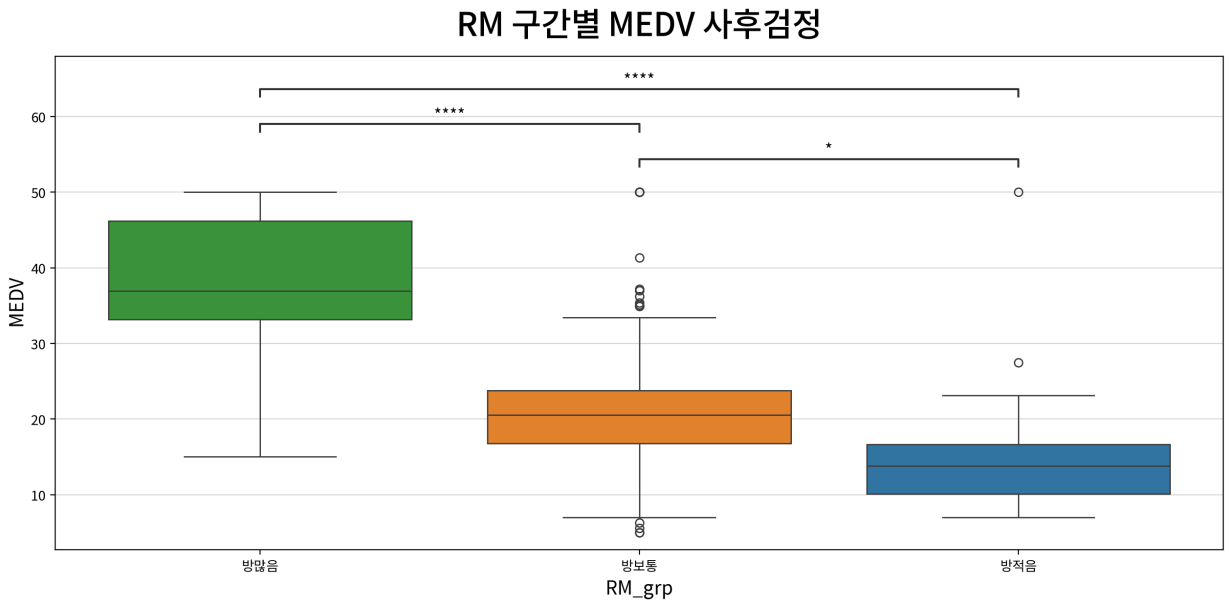
- **해석** : 방 개수 구간에 따라 MEDV가 통계적으로 유의하게 다르며, 효과크기도 **매우 큼**.
- F만으로는 “어느 쌍이” 다른지 알 수 없음 → **사후검정 필요**(다음 셀).
- ⚠ RM_grp는 실습용 파생변수 → **최종 변수 선별에는 미포함**.

2. 사후검정

```
my_stats.posthoc_oneway(df, y="MEDV", between="RM_grp",
                        title="RM 구간별 MEDV 사후검정")
```

```
p-value annotation legend:
      ns: 5.00e-02 < p <= 1.00e+00
       *: 1.00e-02 < p <= 5.00e-02
      **: 1.00e-03 < p <= 1.00e-02
     ***: 1.00e-04 < p <= 1.00e-03
    ****: p <= 1.00e-04
```

```
방보통 vs. 방적음: Custom statistical test, P_val:2.365e-02
방많음 vs. 방보통: Custom statistical test, P_val:0.000e+00
방많음 vs. 방적음: Custom statistical test, P_val:4.676e-13
```



	test	A	B	mean_A	mean_B	diff	se	T	df	pval	hedges	significant	effect_size
0	Games-Howell	방적음	방보통	15.342	20.652	-5.310	1.872	-2.837	24.403	0.024	-0.789	True	Medium
1	Games-Howell	방적음	방많음	15.342	38.637	-23.295	2.153	-10.820	40.614	0.000	-2.645	True	Large
2	Games-Howell	방보통	방많음	20.652	38.637	-17.985	1.156	-15.563	69.133	0.000	-2.620	True	Large

💡 인사이트

정규성·등분산 위배 → 사후검정은 **Games-Howell** 적용. 세 쌍 모두 유의.

비교 쌍	평균 A → B	차이	p	효과크기(hedges)
방적음 vs 방보통	15.34 → 20.65	-5.31	0.024 (*)	-0.79 (Medium)
방적음 vs 방많음	15.34 → 38.64	-23.30	<0.001	-2.65 (Large)
방보통 vs 방많음	20.65 → 38.64	-17.99	<0.001	-2.62 (Large)

- **방향** : 방적음(15.3) < 방보통(20.7) < 방많음(38.6) → **방이 많을수록 집값이 뚜렷하게 상승**.
- **모든 쌍이 유의**하며, 특히 방많음 그룹이 다른 두 그룹과 **매우 큰(Large) 차이**를 보임.
- 방 개수(RM)가 집값을 단조 증가시키는 강한 요인임을 사후검정이 재확인.