Statistics Basic

LAB 08 - [PBT] 탐색적 데이터 분석

4. 변수간의 상관성 분석

ITWILL 이광호 강사

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인



추론통계 - 패턴을 '숫자로' 검증

□ 1단계의 후보 패턴을 받아 통계적 유의성과 효과크기로 확정한다

CORE PRINCIPLE 2단계의 두 가지 원칙

원칙 ①

변수 유형이 검정을 결정

- 독립·종속변수의 유형 조합이 곧 검정 종류
- 연속 × 연속 → 상관
- 명목 × 연속 → T·ANOVA
- 명목 × 명목 → 교차.

원칙 ②

4종 검정은 순서 무관

- 상관/T/ANOVA/교차 검정은 어떤 순서로 해도 결과가 같음
- 다만 큰 틀 시각화 → 추론통계 → 가설의 순서는 반드시 지켜야 함

4 TESTS 2단계에서 사용할 4종 검정

TEST 01

상관분석

연속 × 연속

Pearson · Spearman
관계의 방향·강도 검증

TEST 02

T검정

명목(2) × 연속

독립표본 t
두 그룹 평균 차이 검증

TEST 03

ANOVA

명목(3+) × 연속

일원분산분석 + 사후
3집단+ 평균 차이 검증

TEST 04

교차분석

명목 × 명목

카이제곱 · Fisher
두 범주의 연관성 검증

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인



변수 유형별 검정 방법

로지스틱 회귀 PBT에서 다룹니다.

□ ↓ 독립변수 | 종속변수 →

	종속변수: 연속형 Continuous Y	종속변수: 명목형 Nominal Y
독립: 연속형 Continuous X	CELL 1·1연속 × 연속 **상관분석** **전제 충족** Pearson (선형·정규) **전제 위배** Spearman (단조·비정규·순서형) **효과크기:** 상관계수 **r** (방향 + 강도) — |r| ≥ 0.3 중간 / 0.5 강함	CELL 1·2연속 × 명목 **T·ANOVA — 역할 전환** *Y를 그룹, X를 측정값으로 두고 적용* **EDA 스크리닝** 이진 Y → **T검정** (≡ 점이중상관) · 3범주+ → **ANOVA** **모델링 단계** **로지스틱 회귀**로 이어짐
독립: 명목형 Nominal X	2 집단 **T검정** **전제 충족** 독립표본 t **전제 위배** 등분산 위배 → Welch's t 정규성 위배 → Mann-Whitney U 3+ 집단 **ANOVA** **전제 충족** 일원분산분석 + Tukey **전제 위배** 등분산 위배 → Welch ANOVA 정규성 위배 → Games-Howell	CELL 2·2명목 × 명목 **교차분석** **전제 충족** 카이제곱 검정 χ^2 **전제 위배** Fisher 정확검정 (기대빈도 < 5) 효과크기: Cramér's V (0–1, 값이 클수록 강한 연관)

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인

추론통계의 가정 확인

□ 모수/비모수 검정 분기를 결정

CHECK 01 정규성 (Normality)

무엇

관찰값(또는 잔차)이 정규분포에 가까운가

도구

시각: Q-Q plot, 히스토그램
검정: D'Agostino / Shapiro-Wilk

위배 시

→ 비모수 검정
(Spearman / Mann-Whitney)

CHECK 02 등분산성

무엇

비교하려는 그룹들의 분산이 비슷한가

도구

시각: 그룹별 박스플롯의 폭
검정: Levene / Bartlett

위배 시

→ Welch 계열 (Welch's t /
Welch ANOVA + Games-Howell)

CHECK 03 독립성

무엇

관측치들이 서로 독립적으로 추출되었는가

도구

통계 검정보다 **설계·추출 구조 확인**이 핵심

위배 시

→ 짝(대응) 데이터면 paired t / 반복측정 /
혼합효과 모형 등으로 재구성



helpers 패키지의 **my_stats.py**가
모수/비모수 검정 분기를 자동으로 처리합니다.

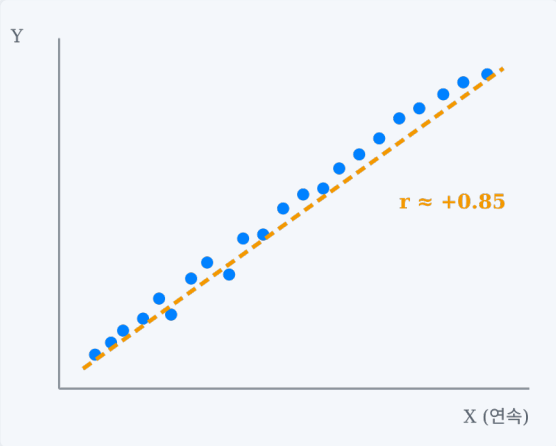


상관분석

□ 두 연속형 변수 사이의 방향과 강도를 상관계수로 검증

① 시각화

산점도 (+ 추세선)



무엇을 보는가

- 선형? 비선형? 단조?
- 산포 — 점들이 추세선 주변에 얼마나 몰려 있나
- 이상치 — 추세에서 크게 벗어난 점

② 검정

Pearson r

✓ 가정 충족

선형 관계 · 정규분포

Spearman ρ

가정 불충족시 대안

단조 관계 · 비정규 · 순서형

효과크기: |r| 기준

- $|r| \geq 0.5$ — **강한** 관계
- $0.3 \leq |r| < 0.5$ — **중간**
- $0.1 \leq |r| < 0.3$ — **약한**
- $|r| < 0.1$ — 무시할 만한 수준

③ 해석INTERPRETATION

한 줄 해석 형식

"X와 Y는 + 강한 상관"
(r=0.85, p<0.01)"

결론에 포함할 3가지

① **방향** — 정(+) / 부(−)
② **강도** — |r| 절댓값 + 등급
③ **유의성** — p값

⚠ **상관 ≠ 인과**

강한 r이라도 'X가 Y의 원인'이라 단정 금지.

전제 위배 시 대안 정규성 위배 / 순서형 → **Spearman**

p-value < 0.05 & |r| ≥ 0.3 → 해당 연속변수를 독립변수 후보로 채택할 근거

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인

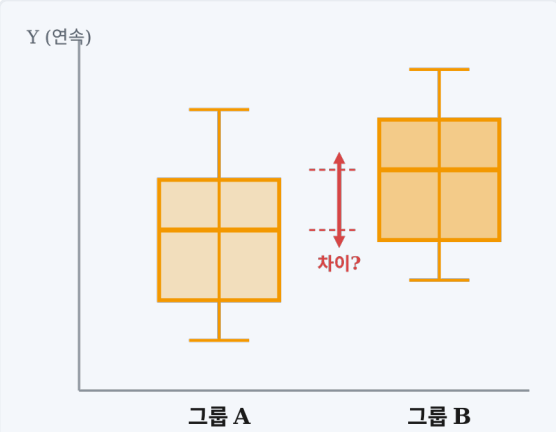
T검정 Independent Samples T-Test

● 명목(2) × ● 연속

두 그룹의 연속형 변수 평균이 통계적으로 다른지 검증합니다.

① 시각화 VISUALIZATION

그룹별 박스플롯



무엇을 보는가
- 두 그룹의 **중앙값·평균 위치**
- 박스의 폭(분산) — 등분산 점검 단서
- 이상치 — 평균 왜곡 가능

② 검정 STATISTICAL TEST

독립표본 t-test ✓ 충족

정규성 · 등분산 · 독립

```
scipy.stats.ttest_ind(a, b)
→ t, p
```

가설 (귀무 vs 대립)

H_0: μ_A = μ_B (평균이 같다)

H_1: μ_A ≠ μ_B (다르다)

p < 유의수준(α, 보통 0.05) → H_0 기각

효과크기: Cohen's d

d ≥ 0.8 큼 / 0.5 중간 / 0.2 작음
(두 그룹 평균 차를 분산으로 표준화)

③ 해석 INTERPRETATION

한 줄 해석 형식

"그룹 A의 평균 점수가 B보다 **통계적으로 유의하게 높다** (t=3.42, p=0.001, d=0.62)" *(예시)*

결론에 포함할 3가지

① **방향** — 어느 그룹이 큰가
② **유의성** — p값
③ **실질 크기** — Cohen's d

⚠ p값만 보지 말 것
표본이 크면 작은 차이도 유의해짐 — Cohen's d로 실질성 확인.

전제 위배 시 대안 등분산 위배 → **Welch's t** · 정규성 위배 → **Mann-Whitney U** ttest_ind(equal_var=False) · mannwhitneyu

→ 변수 채택 근거 유의 + **|d| ≥ 0.5** → 해당 **명목변수(2집단)**를 **독립변수 후보로**

ITWILL 이광호강사

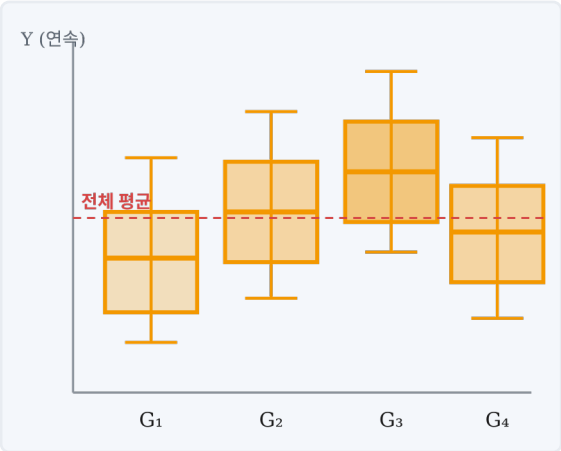
ANOVA One-way Analysis of Variance

● 명목(3+) × ● 연속

3개 이상 그룹의 평균이 모두 같은지 한 번에 검정하고, 다르면 어느 쌍이 다른지 사후검정으로 확인합니다.

① 시각화 VISUALIZATION

그룹별 박스플롯 (3+)



무엇을 보는가
- 그룹 간 **중심 위치 차이**
- 박스 폭(분산) — 등분산 점검
- 전체 평균에서 어느 그룹이 크게 벗어났는가

② 검정 STATISTICAL TEST

일원분산분석 ✓ 충족

F = 그룹간 분산 / 그룹내 분산

```
pingouin.anova(data, dv, between)
→ F, p, np2
```

사후검정 (Post-hoc)

F-검정이 유의하면 **어느 쌍이 다른지**는 별도로 확인해야 합니다.
(다중비교 보정 포함)

```
pingouin.pairwise_tukey(
data, dv, between)
```

효과크기: η^2 (eta-squared)

$\eta^2 \geq 0.14$ 큼 / 0.06 중간 / 0.01 작음

③ 해석 INTERPRETATION

한 줄 해석 형식

"지역 G에 따라 점수 Y가 **유의하게 다름** ($F=5.21$, $p<0.01$, $\eta^2=0.09$). Tukey 결과 $G_2 < G_3$" *(예시)*

결론에 포함할 4가지

① **전체 유의성** — F, p
② **효과크기** — η^2
③ **어느 쌍이 다른가** — Tukey
④ **방향** — 어느 그룹이 큰가

⚠ **사후검정 없이 결론 금지**
F만으로는 '어느 쌍이' 다른지 알 수 없음.

전제 위배 시 대안 등분산 위배 → **Welch ANOVA** · 정규성 위배 → **Kruskal-Wallis** (+ Games-Howell)

→ **변수 채택 근거** 유의 + **$\eta^2 \geq 0.06$** → 해당 **명목변수(3+집단)**를 **독립변수 후보로**

ITWILL 이광호강사

교차분석 Chi-square Test of Independence

● 명목×● 명목

두 명목형 변수가 서로 **연관되어 있는지(독립인지)**를 교차표의 셀 빈도로 검증합니다.

① 시각화VISUALIZATION

모자이크 / 교차표 히트맵

변수 B (행)

	A₁	A₂	A₃
B₁	120	28	15
B₂	35	98	42
B₃	12	22	105

변수 A (열)

무엇을 보는가

- 셀이 **대각선 쪽으로 몰림** → 연관 있음
- 셀이 **균등하게 분포** → 독립
- 기대빈도 < 5인 셀의 존재 여부

② 검정STATISTICAL TEST

카이제곱 검정 χ^2 ✓ 충족

$\chi^2 = \Sigma$ (관측빈도 − 기대빈도)^2 / 기대빈도

```
scipy.stats.chi2_contingency(tab)
→ chi2, p, dof, expected
```

가설

H_0: A와 B는 독립이다

H_1: A와 B는 연관되어 있다

$p < \alpha \rightarrow H_0$ 기각 (연관 있음)

효과크기: Cramér's V

0 ~ 1 — 값이 클수록 강한 연관
(자유도 보정된 표준화 지표)

③ 해석INTERPRETATION

한 줄 해석 형식

"변수 A와 B는 **유의하게 연관됨** (χ^2=42.1, p<0.01, V=0.23) — A_1이 B_1에, A_3가 B_3에 몰림" *(예시)*

결론에 포함할 4가지

① **유의성** — χ^2, p
② **강도** — Cramér's V
③ **패턴** — 어느 셀이 몰렸나
④ **표본 크기** — N 명시

⚠ 기대빈도 점검 필수
expected 행렬에 5 미만 셀이 있으면 χ^2 결과를 신뢰하지 말 것.

전제 위배 시 대안기대빈도 < 5인 셀이 있으면 → **Fisher 정확검정**scipy.stats.fisher_exact (2×2)

boston 실습 생략종속 MEDV가 연속형이라 명목×명목 실습 없음 — **분류 과제면 로지스틱 회귀(추후 수업)**로 이어집니다.

ITWILL 이광호강사님

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인



결과 해석법 — p값만 보지 말 것

올바른 결론은 **유의확률 + 효과크기 + 방향** 세 가지를 함께 진술합니다.

① 유의확률 (p값)

무엇을 답하나

관측된 패턴이 **우연일 확률** — H_0가 맞다고 가정했을 때 이런 결과가 나올 확률.

관행적 기준

· $p < 0.05$ → 유의
· $p < 0.01$ → 매우 유의
· $p \geq 0.05$ → 유의하지 않음

② 효과크기 ★

무엇을 답하나

차이/관계의 **실질적 크기** — 표본 크기에 의존하지 않는 표준화 지표.

검정별 지표

· 상관 — **r**
· T검정 — **Cohen's d**
· ANOVA — **η^2** · 교차 — **Cramér's V**

③ 방향 / 패턴

무엇을 답하나

차이의 **어느 쪽**인가, 연관의 **어디가** 몰렸는가.

예시

· "G_A > G_B"
· "양(+)의 상관"
· "A_1-B_1 셀에 몰림"

✗ 잘못된 진술

"그룹 A와 B 사이에 유의한 차이가 있다 (p<0.05)" *(예시)*

· 어느 쪽이 큰지(방향)가 없음
· 효과크기 없음 — 실질 의미 불명
· 표본이 크면 미세한 차이도 유의해짐

✓ 올바른 진술

"그룹 A가 B보다 평균 점수가 높음 (p=0.001, d=0.62 중간 크기)" *(예시)*

· 방향이 명확 (A > B)
· 효과크기로 실질 의미 명시
· 가설 진술 형식으로 그대로 이어짐 (슬20)

ITWILL 이광호강사