# Statistics Basic

## LAB 08 - [PBT] 탐색적 데이터 분석

### 5. 변수 선별

코드 실습이 없는 단원입니다.

ITWILL 이광호 강사

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인



# 탐색적 데이터 분석 프로세스

## □ 통합 의사결정 흐름도 — 시각화에서 가설까지

**목표변수 정의 + 변수 [ ] 분류 — (모든 분기의 1차 기준)**

▼

**데이터 시각화 (패턴 발견)**

단변량 분포 확인 → 목표변수와의 이변량 관계 탐색 → (필요 시) 다변량

산출물: **후보 패턴 목록** (변수 조합 + 관찰된 패턴)

▼

**추론통계 4종 : 변수 유형 조합으로 검정**

**전제조건 점검** 정규성 · 등분산 · 독립성 → 충족: 모수 검정 · 위배: 비모수 / Welch 계열 대안

| 연속 × 연속 | 명목(2)×연속 | 명목(3+)×연속 | 명목×명목 |
|---|---|---|---|
| [ ] | [ ] | [ ] | [ ] |

결과 진술: **유의확률(p) + 효과크기 + 방향** 3가지를 함께

▼

OUTPUT A · 현상 기술 관점
**연구 가설**
관계형 / 차이형 / 연관형 진술 — 상관≠인과 검토

=

OUTPUT B · 모델 입력 관점
**독립변수 후보 + 근거**
스코어카드 (관련성 + 효과 + 비중복 + 적격성)

▼

**NEXT▶ 전처리·모델링 단계로 연결 (슬26)** 로그 변환 · 파생변수 · VIF 점검 · 인코딩이 EDA 산출물로부터 설계


ITWILL 이광호강사

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인



# 탐색적 데이터 분석의 가설 유형

## □ 검정 결과 + 효과크기 + 도메인 상식을 종합해 연구 가설로 정리한다.

### 가설 진술 형식 3종

**관계형** [ ] 결과 → 가설
"X가 증가할수록 Y가 (증가/감소)하는 경향이 있다."
**EXAMPLE** "나이가 많을수록 가격이 증가하는 경향"

**차이형** [ ] 결과 → 가설
"집단 G에 따라 Y의 (평균/분포)에 차이가 있다."
**EXAMPLE** "지역에 따라 점수의 평균에 차이가 있다"

**연관형** [ ] 결과 → 가설
"범주 A와 범주 B는 서로 연관되어 있다."
**EXAMPLE** "지역과 결제수단은 연관되어 있다"

### 가설로 승격되는 3가지 조건

✓ **통계적으로 유의함**
p값이 사전에 정한 유의수준(α) 미만

✓ **효과크기가 의미 있음**
효과 크기를 의미하는 값이 기준치 이상

✓ **도메인 상식에 부합**
관련 분야 지식 / 선행 연구와 모순되지 않음

✗ **기각 조건**
- 통계적으로 유의하지 않음 ($p \geq \alpha$)

✗ **보류 조건**
- 유의해도 효과크기가 미미함 (예: $|r| < 0.1$)
- 교란변수 의심 / 도메인 상식과 모순
- 표본 편향·추출 구조에 문제

➡ 모든 가설은 곧 **"이 변수를 모델 독립변수 후보로 본다"**는 뜻



# 단변량 스크리닝의 한계

**스크리닝**: 특정한 기준을 바탕으로 많은 대상 중에서 필요한 것만 골라내거나 불필요한 것을 걸러내는 작업

**⚠ EDA의 변수 판정은 1차 후보 선별일 뿐 — 다변량(모델) 안에서는 달라질 수 있다.**

### TRAP 01
### 억제 · 상호작용

단독으론 약해도 다른 변수와 결합하면 종속변수에 대한 기여도가 달라질 수 있음

예: **운동시간 단독**으로는 체중과 무관해 보이지만, **성별과 함께** 보면 남녀의 효과 방향이 반대로 나타날 수 있다.
(상호작용 · 심슨의 역설)

→ 성급한 제외 금지

### TRAP 02
### 다중 공선성

단독 유의해도 다른 변수와 중복이면 일부만 채택.

예: **아파트 평수 · 방 개수** 둘 다 집값과 유의하지만 둘 사이 상관 0.9 → **평수 1개만** 대표로 채택

→ 대표변수만 채택

### TRAP 03
### 단변량 한계

상호작용·비선형 효과는 1:1 검정에서 확인되지 않음

예: **기온 ↔ 전력 사용량**은 U자형(난방·냉방) → 선형 상관 r ≈ 0
→ 단변량 검정은 “비유의” 처리, 그러나 2차항 모델에서는 유의

→ 모델에서 재검증 필요

➡ **보류 대상 변수를 제거한 경우와 그렇지 않은 경우의 모델링을 시도하고 예측 성능 비교 필요**

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인



# EDA에서 가장 자주 마주치는 6가지 실수 패턴

## 01 정규성 미점검 채 T검정

**왜 위험한가**

정규성·등분산을 무시하면 p값 자체가 잘못 추정된다.

**대처**

정규성을 충족하지 않을 경우 Welch's t / Mann-Whitney로 대체.

## 02 다중비교 보정 누락

**왜 위험한가**

변수 조합을 마구 검정하면 위양성이 누적되어 '우연'이 '유의'로 보입니다.

**대처**

Bonferroni / Tukey · Games-Howell 등의 보정 절차 적용.

## 03 이상치 미확인 채 평균 비교

**왜 위험한가**

평균은 이상치에 크게 끌려가 "평균이 다르다"는 잘못된 신호를 줍니다.

**대처**

박스플롯으로 이상치 확인
→ 이상치 비율에 따라 평균과 중앙값 선택

## 04 가정 확인 없이 Pearson 강행

**왜 위험한가**

Pearson은 선형 관계만 잡습니다.
U자/지수형은 **상관계수 ≈ 0**으로 보인다.

**대처**

산점도 먼저 → 단조면 Spearman, 비선형이면 변환·다항회귀 고려.

## 05 기대빈도<5 인데 카이제곱

**왜 위험한가**

희소 셀에서 $\chi^2$ 근사가 무너져 p값이 부정확해진다.

**대처**

기대값이 5이하인 경우 Fisher 정확검정

## 06 p값만 보고 효과크기 무시

**왜 위험한가**

표본이 크면 미세한 차이도 $p<0.05$가 되어 '유의=중요'로 오해됩니다.

**대처**

효과 크기를 항상 같이 보고 '실질 크기'로 결론을 내려야 함



# boston 데이터셋의 독립변수 선별표

✅ 채택 5 · 🟡 후보 7 · ❌ 제외 1

## □ EDA 결과에 따른 결론

| 결과 | 변수 | 검정방법 | 유의수준(p) | 효과크기 | 가정점검 | 비대칭신호 | 공선성신호 | 근거 |
|---|---|---|---|---|---|---|---|---|
| ✅ 채택 | LSTAT | Spearman | <0.001 | ρ=−0.853 (강함) | 정규성 위배 / 이상치 영향 없음 | 우편향 / log1p 필요 | X | 최강 반비례 + 중복 없음 → 핵심 변수 |
| ✅ 채택 | RM | Spearman | <0.001 | ρ=+0.634 (중간) | 정규성 위배 / 이상치 영향 없음 | 대칭 / 불필요 | X | 양(+)의 최강 상관 + 중복 없음 |
| ✅ 채택 | PTRATIO | Spearman | <0.001 | ρ=−0.556 (중간) | 정규성 위배 / 선형성 충족 | 좌편향 / 불필요 | X | 유의미한 관계 + 중복 없음 |
| ✅ 채택 | ZN | Spearman | <0.001 | ρ=+0.438 (중간) | 정규성 위배 | 우편향 / log1p 필요 | X | 유의미한 관계 + 중복 없음 |
| ✅ 채택 | CHAS | Mann-Whitney U | 0.002 | 미제공 (U=5605.5) | 정규성 위배 | 해당 없음 | X | 강 인접(CHAS=1) 집값 유의하게 높음 *(표본 불균형 471:35 주의)* |
| 🟡 후보 | INDUS | Spearman | <0.001 | ρ=−0.578 (중간) | 정규성 위배 / 이상치 영향 있음 | 대칭 / 불필요 | O | 유의하나 오염·거리 변수와 중복 → 택1 |
| 🟡 후보 | NOX | Spearman | <0.001 | ρ=−0.563 (중간) | 정규성 위배 / 선형성 충족 · 이상치 영향 있음 | 우편향 / 불필요 | O | 유의하나 가장 심한 중복 → VIF 점검 |
| 🟡 후보 | TAX | Spearman | <0.001 | ρ=−0.562 (중간) | 정규성 위배 / 선형성 충족 · 이상치 영향 있음 | 우편향 / 불필요 | O | 유의하나 RAD와 거의 동일 정보 → 둘 중 하나 |
| 🟡 후보 | CRIM | Spearman | <0.001 | ρ=−0.559 (중간) | 정규성 위배 / 이상치 영향 없음 | 우편향 / log1p 필요 | O | 유의하나 다수 변수와 중복 → 조건부 |
| 🟡 후보 | AGE | Spearman | <0.001 | ρ=−0.548 (중간) | 정규성 위배 / 이상치 영향 있음 | 좌편향 / 불필요 | O | 유의하나 거리·오염과 중복 → 조건부 |
| 🟡 후보 | DIS | Spearman | <0.001 | ρ=+0.446 (중간) | 정규성 위배 / 이상치 영향 있음 | 우편향 / log1p 필요 | O | 유의하나 중복 많음 → 조건부 |
| 🟡 후보 | RAD | Spearman | <0.001 | ρ=−0.347 (중간) | 정규성 위배 / 이상치 영향 있음 | 우편향 / log1p 필요 | O | 상관 가장 약 + TAX와 중복 → 조건부 |
| 🟡 후보 | B | Spearman | <0.001 | ρ=+0.186 (약함) | 정규성 위배 / 선형성 충족 · 이상치 영향 있음 | 좌편향 / reverse_log1p 필요 | X | 유의하지만 관계가 너무 약함 (\|ρ\|<0.3) |

1. EDA 시작하기
2. 단변량 시각화
3. 이변량 시각화
4. 추론통계
5. 변수 선별
6. EDA 파이프라인




# 연습문제 의료보험 청구 비용 데이터셋의 변수 선별

## □ 보험사 데이터 분석가가 되어, 청구 비용(charges) 예측 모델의 최종 독립변수를 채택해야 합니다.

◎ 사전 연습(준비·시각화·검정)을 마쳤습니다. 이제 **결과를 종합해 변수 선별표를 완성하세요.**

- **insurance_qtcheck** : 보험 비용 데이터셋의 품질 검사 완료 버전
- **insurance_qtcheck_desc** : 보험 비용 데이터셋의 연속형 변수에 대한 기술 통계량
- **insurance_qtcheck_category_desc** : 보험 비용 데이터셋의 범주형 변수에 대한 기술 통계량

**1** **앞선 검정 결과**(유의수준 p·효과크기)를 변수별로 한 표에 정리하세요.

**2** 독립변수끼리의 상관·연관 분석으로 **공선성 신호**를 표시하세요.

**3** 분포의 비대칭·이상치 신호를 반영해 **변환(log 등)이 필요한 변수**를 표시하세요.

**4** 변수별로 **채택 / 후보 / 제외를 판정**하고, 판정 **근거를 한 줄로 기록**하세요.

**5** 완성된 스코어카드를 바탕으로 모델링에 투입할 **최종 독립변수 목록을 확정**하세요.


ITWILL 이광호강사