Statistics Basic

LAB 10 - [PBT] 선형회귀

2. 회귀모형 평가와 진단

ITWILL 이광호 강사



전처리는 성능을 보장하지 않는다

□ 전처리를 많이 할수록 모델이 좋아진다?

◎ 이건 검증 대상이지 전제가 아니다.

데이터: **보스턴 주택 가격 (n = 506)** · 전처리를 하나씩 누적한 **5개 체크포인트**에 동일 방식으로 회귀 적합

체크포인트 0	+	체크포인트 1	+	체크포인트 2	+	체크포인트 3	+	체크포인트 4
기준선 라벨링·더미변수		로그변환 치우침 완화		이상치 대체 경계값 대체		공선성 제거 VIF 임계		스케일링 정규화

이 강의를 관통하는 두 가지 질문

Q1. **어느 단계**에서 성능이 실제로 올라갔는가?

Q2. 성능이 올라가지 **않은 단계**는 왜 그런가?



#01. 준비작업

실습

1. 라이브러리 참조

```
1 from hossam import load_data
2 from helpers import *
3
4 import numpy as np
5 from pandas import DataFrame, concat
6 from IPython.display import Markdown
7
8 # 성능 평가 지표 (직접 계산하지 않고 sklearn 의 함수를 사용한다)
9 from sklearn.metrics import r2_score, root_mean_squared_error,
  mean_absolute_error
```

✓ 마지막 실행: 오전 8:25:03, 기간: 2.1s Python

📦 아이티윌 이광호 강사가 제작한 라이브러리를 사용중입니다.
📚 자세한 사용 방법은 https://py.hossam.kr 을 참고하세요.
📧 Email: leekh4232@gmail.com
🎬 Youtube: https://www.youtube.com/@hossam-codingclub
📝 Blog: https://blog.hossam.kr/
🔖 Version: develop



#01. 준비작업

2. 체크포인트 데이터 로드

◎ 전처리 단계가 하나씩 누적된 5개의 데이터셋을 불러온다.

```python
df0 = load_data("boston_checkpoint_0")
df1 = load_data("boston_checkpoint_1")
df2 = load_data("boston_checkpoint_2")
df3 = load_data("boston_checkpoint_3")
df4 = load_data("boston_checkpoint_4")
```

✓ 마지막 실행: 오전 8:25:05, 기간: 1.9s Python

```
📚 보스턴 주택 가격 데이터셋의 전처리 체크포인트 0 - 기준선 역할을 위해 라벨링과 더미변수 처리만 적용됨
📚 보스턴 주택 가격 데이터셋의 전처리 체크포인트 1 - 라벨링 + 더미변수 + 로그변환
📚 보스턴 주택 가격 데이터셋의 전처리 체크포인트 2 - 라벨링 + 더미변수 + 로그변환 + 이상치 대체
📚 보스턴 주택 가격 데이터셋의 전처리 체크포인트 3 - 라벨링 + 더미변수 + 로그변환 + 이상치 대체 + 다중공선성제거
📚 보스턴 주택 가격 데이터셋의 전처리 체크포인트 4 - 라벨링 + 더미변수 + 로그변환 + 이상치 대체 + 다중공선성제거 + 스케일링
```



#01. 준비작업

3. 분석 대상 정리

◎ 5개 체크포인트를 딕셔너리로 묶고, 체크포인트별로 **종속변수에 log1p가 적용되었는지 여부**를 함께 기록한다.

```python
# 종속변수
target = "MEDV"

# 비교 대상 체크포인트 (아래로 갈수록 전처리가 하나씩 누적된다)
checkpoints = { "0_기준선": df0, "1_로그변환": df1, "2_이상치대체": df2,
    "3_공선성제거": df3, "4_스케일링": df4 }

# 종속변수(MEDV)에 log1p 가 적용되었는지 여부 (체크포인트 1부터 적용됨)
log_y = { "0_기준선": False, "1_로그변환": True, "2_이상치대체": True,
    "3_공선성제거": True, "4_스케일링": True }

# 로그변환(log1p)이 적용된 독립변수 → 최종 모델의 회귀계수 해석에 사용한다
log1p_x = ["CRIM", "ZN", "DIS", "RAD", "LSTAT"]
```

✓ 마지막 실행: 오전 8:25:05, 기간: 0.0s Python



종속변수의 로그 변환 여부에 따른 모델의 변형

□ 로그변환 대상에 종속변수도 포함되었다.

◎ 체크포인트 1부터는 사실상 다른 문제를 푸는 모델이다.

체크포인트별 종속변수 기술통계

체크포인트	종속변수	평균	표준편차	분산
0 (기준선)	MEDV (천 달러)	**22.500**	9.197	**84.59**
1~4 (로그 이후)	log1p(MEDV) (로그 척도)	**3.085**	0.387	**0.150**

왜 문제인가

· 종속변수가 다르면 **분산의 기준(분모)**이 달라진다 → R^2의 분모가 다르다.

· **우도(likelihood)**의 기준도 달라진다 → AIC·BIC의 절대값 비교가 무의미해진다.

⇒ 0과 1~4의 성능 숫자를 그냥 나란히 놓고 비교하면 틀린 결론이 나온다.

성능표의 숫자를 아무거나 골라 1등을 뽑기 전에, 지표별 비교 가능 범위부터 먼저 확인해야 한다.



#01. 준비작업

4. 종속변수 척도 확인

◎ 체크포인트 1 이후부터 종속변수의 척도가 다름을 확인

```python
medv_scale = DataFrame()

for name in checkpoints:
    data = checkpoints[name]
    medv_scale[name] = data[target].describe()

medv_scale.round(3)
```

✓ 마지막 실행: 오전 8:25:05, 기간: 0.0s Python

	0_기준선	1_로그변환	2_이상치대체	3_공선성제거	4_스케일링
count	506.000	506.000	506.000	506.000	506.000
mean	22.533	3.085	3.085	3.085	3.085
std	9.197	0.387	0.387	0.387	0.387
min	5.000	1.792	1.792	1.792	1.792
25%	17.025	2.892	2.892	2.892	2.892
50%	21.200	3.100	3.100	3.100	3.100
75%	25.000	3.258	3.258	3.258	3.258
max	50.000	3.932	3.932	3.932	3.932



지표마다 '비교할 수 있는 범위'가 다르다

□ MEDV 분산 84.59 vs log1p(MEDV) 분산 0.150

◎ 이만큼 다르면 AIC·BIC 절대값을 나란히 놓는 것 자체가 무의미하다.

지표군	비교 가능 범위	이유
R^2(모델척도) **Adj.R^2** **AIC · BIC**	**종속변수가 같은 모델끼리만** 비교 가능 (체크포인트 1~4 내부, 또는 0 자체 확인)	분산의 분모와 우도의 기준이 종속변수 척도에 종속됨
R^2(원본척도) **RMSE · MAE**	**모든 체크포인트** 비교 가능 (0 ↔ 1 ↔ 2 ↔ 3 ↔ 4 모두)	예측값을 원래 척도(천 달러)로 되돌린 뒤 계산 → 공통 기준

흔한 오독 — AIC 3021 → -301 은 성능 향상이 아니다

체크포인트 0의 AIC 3021.7과 1~4의 AIC -301.5 부호 반전은 척도 차이일 뿐, 모델이 극적으로 좋아진 것이 아니다.
로그를 취하면 log 우도의 기저가 바뀌어 AIC·BIC의 절대값 자체가 다른 세계의 숫자가 된다.

» 여기 등장한 **R^2(원본척도) · RMSE · MAE**의 정확한 정의는 다음 두 슬라이드에서 다룬다.

주의 — 로그 R^2의 자동 상승 편향

로그를 취하면 **큰 값이 눌려 분산이 줄어들기 때문에** R^2는 저절로 올라가는 경향이 있다.
따라서 **로그 모델의 R^2 상승 = 성능 향상이라고 단정할 수 없다**. 진짜 개선은 원본 척도 지표로 확인해야 한다.

ITWILL 이광호강사



R^2 → 모델척도 vs 원본척도

□ 어느 척도에서 계산했느냐에 따라 다른 값이 되고, 다른 질문에 답한다.

R^2의 정의 — 종속변수 전체 분산 중 모델이 설명해낸 비율

$$R^2 = 1 - \frac{SSE}{SST}$$

· **SSE**(못 맞힌 부분) / **SST**(전체 변동) — 1에 가까울수록 설명력이 높다

▶ 위 식의 y가 무엇이냐에 따라 R^2가 달라진다

R^2(모델척도) → y = log1p(MEDV)

모델이 실제로 최소화한 척도 — 통계 SW 기본 출력값.

"로그 척도 집값 분산의 몇 %를 설명하는가"

R^2(원본척도) → y = MEDV (천 달러)

원래 단위(천 달러)로 되돌려 계산 — 비즈니스 기준.

"실제 집값(천 달러) 분산의 몇 %를 설명하는가"

▶ 5개 체크포인트 — 두 R^2의 비교

모델	R^2(모델척도)	R^2(원본척도)	차이
0_기준선	0.741	0.741	동일
1_로그변환	0.792	0.789	갈라짐
2_이상치대체	0.791	0.787	갈라짐

보고할 값은?
R^2(원본척도)
모델척도는 내부 진단용

ITWILL 이광호강사

RMSE와 MAE — 오차를 재는 두 가지 방법

□ R^2는 단위가 없다 — RMSE · MAE는 "평균 몇 달러 빗나가나"를 답한다.

MAE — 평균절대오차

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

오차의 **절대값**을 그냥 평균낸다.

· "평균 몇 달러 빗나가나" — 가장 직관적
· 오차를 **똑같은 무게**로 → 이상치에 덜 민감

RMSE — 평균제곱근오차

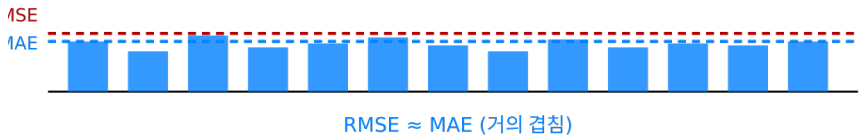
$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

오차를 **제곱해 평균**낸 뒤 **제곱근**을 씌운다.

· **큰 오차에 무거운 벌점** — 2배 틀리면 4배
· √로 단위를 원래대로(천 달러) 되돌림

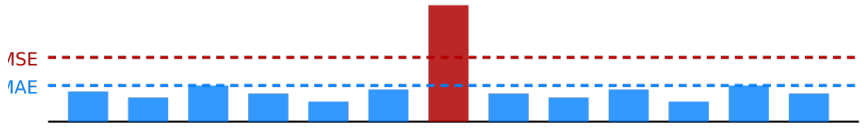
▶ 둘의 관계 — 항상 $RMSE \geq MAE$

오차가 고를 때 — 두 값이 근접



RMSE ≈ MAE (거의 겹침)

이상치가 섞이면 — RMSE만 치솟음



RMSE ≫ MAE (격차가 벌어짐)

최종 모델 — RMSE 4.215 / MAE 2.973 → 비율 약 1.42배

평균 약 **2,973달러** 빗나가지만, 크게 빗나가는 소수 지역이 RMSE를 **4,215달러**로 끌어올린다.
» 후반의 **정규성 두꺼운 꼬리 · MEDV 50 상한 절단**의 다른 얼굴이다.

세 지표의 역할

- **R^2(원본)** — 비율, 데이터셋 간 비교
- **RMSE** — 금액, 큰 오차 민감 (대표)
- **MAE** — 금액, 체감 오차 (보조)

ITWILL 이광호강사



최종 모델 채택 기준

□ 기준을 먼저 정하고 표를 본다.

◎ 일반적으로 RMSE를 가장 우선적으로 확인한다.

1순위 RMSE

원본 척도 RMSE가 가장 작은 모델을 채택한다

- 5개 후보를 가로질러 공정하게 비교 가능한 유일한 지표군이기 때문
- 오차가 **천 달러 단위로 그대로 해석**된다
- **큰 오차에 벌점** → RMSE, MAE를 참고하여 오차가 큰 모델을 걸러낸다

2순위 간명성

RMSE가 사실상 같다면(5% 내외) 변수가 적은 모델을 채택해야 함

- **오컴의 면도날** — 같은 성능이면 단순한 모델이 낫다
- 종속변수가 같은 **체크포인트 1~4 사이**에서는 **AIC · BIC**로 간명성을 정량 확인할 수 있다

» 실무에선 RMSE·MAE 둘 다 보고하되 **대표 지표는 RMSE**.



#02. 체크포인트별 모델 적합 및 성능 비교

1. 체크포인트마다 모델을 적합(후진소거 포함) (1/3)

◎ 예측값을 **원본 척도(천 달러)로 되돌려** 성능을 계산한다.

```python
fits = {}
result = []

for c in checkpoints:
    data = checkpoints[c]        # 체크포인트 데이터프레임
    log = log_y[c]               # 종속변수에 log1p 가 적용되었는지 여부

    # --- 1) 모델 적합 (후진제거 포함) ---

    # --- 2) 실제값과 예측값을 원본 척도(천 달러)로 되돌린다 ---

    # --- 3) 지표를 한 행으로 정리해 저장 ---

rdf = DataFrame(result).set_index("모델")
rdf.round(4)
```

✓ 마지막 실행: 오전 8:25:05, 기간: 0.1s Python



#02. 체크포인트별 모델 적합 및 성능 비교

1. 체크포인트마다 모델을 적합(후진소거 포함) (2/3)

```
    # --- 1) 모델 적합 (후진제거 포함) ---
    fit = my_ols.auto_ols(data, target,
                          log1p_y=log, log1p_x=log1p_x,
                          backward=True, report=False, test=False)

    fits[c] = fit

    # --- 2) 실제값과 예측값을 원본 척도(천 달러)로 되돌린다 ---
    if log:
        y_true = np.expm1(data[target])          # 종속변수 역변환
        y_pred = np.expm1(fit.fittedvalues)      # 예측값 역변환
    else:
        y_true = data[target]                    # 체크포인트 0 은 이미 원본 척도
        y_pred = fit.fittedvalues
```



#02. 체크포인트별 모델 적합 및 성능 비교

1. 체크포인트마다 모델을 적합(후진소거 포함) (3/3)

```python
    # --- 3) 지표를 한 행으로 정리해 저장 ---
    result.append({
        "모델": c,
        "변수수": int(fit.df_model),          # 상수항을 제외한 독립변수 개수
        "R2(모델척도)": fit.rsquared,         # 체크포인트간 비교 불가 (참고용)
        "Adj.R2": fit.rsquared_adj,           # 같은 종속변수끼리만 비교
        "AIC": fit.aic,                       # 같은 종속변수끼리만 비교 (작을수록 좋음)
        "BIC": fit.bic,                       # 같은 종속변수끼리만 비교 (작을수록 좋음)
        # 아래 세 지표는 원본 척도에서 계산하므로 체크포인트간 비교가 가능하다
        "R2(원본척도)": r2_score(y_true, y_pred),
        "RMSE": root_mean_squared_error(y_true, y_pred),      # 최종 선택 기준
        "MAE": mean_absolute_error(y_true, y_pred),
    })
```

모델	변수수	R2(모델척도)	Adj.R2	AIC	BIC	R2(원본척도)	RMSE	MAE
0_기준선	11	0.741	0.735	3021.726	3072.445	0.741	4.680	3.272
1_로그변환	9	0.792	0.789	-301.461	-259.196	0.789	4.215	2.973
2_이상치대체	9	0.791	0.787	-297.591	-255.326	0.787	4.237	2.982
3_공선성제거	9	0.791	0.787	-297.591	-255.326	0.787	4.237	2.982
4_스케일링	9	0.791	0.787	-297.591	-255.326	0.787	4.237	2.982



성능 향상은 '로그변환'에서 거의 전부 나왔다

□ 5개 체크포인트 성능 비교표 (n = 506)

모델	변수수	R^2(모델)	Adj.R^2	AIC	BIC	R^2(원본)	RMSE	MAE
0_기준선	11	0.741	0.735	3021.7	3072.4	0.741	4.680	3.272
1_로그변환 ★	**9**	**0.792**	**0.789**	**-301.5**	**-259.2**	**0.789**	**4.215**	**2.973**
2_이상치대체	9	0.791	0.787	-297.6	-255.3	0.787	4.237	2.982
3_공선성제거	9	0.791	0.787	-297.6	-255.3	0.787	4.237	2.982
4_스케일링	9	0.791	0.787	-297.6	-255.3	0.787	4.237	2.982

① 1위는 명확

1_로그변환

- **RMSE** : 4.215
- **MAE** : 2.973
- **원본 R^2** : 0.789

✓세 지표 모두 같은 방향으로 1위
✓지표를 바꿔도 순위가 뒤집히지 않음
✓채택 근거 명확

② 이상치 대체는 오히려 역효과

RMSE 4.215 → 4.237
미세하게 **악화**.

로그변환으로 이미 꼬리가 눌린 상태에서 경계값으로 대체하니
설명력이 미세하게 줄어들고
에러율이 높아졌다.

③ 2·3·4는 완전 동일

RMSE · R^2 · AIC 모두 **소수점까지** 완전히 일치.

사실상 같은 모형
전처리 효과가 없음

ITWILL 이광호강사



#02. 체크포인트별 모델 적합 및 성능 비교

2. 최종 모델 채택 → 1_로그변환

◎ 성능표를 슬라이드의 채택 기준(**1순위 원본 척도 RMSE, 2순위 간명성**)으로 읽으면 `1_로그변환` 이 선택된다.

항목	값
전처리	라벨링 + 더미변수 + **로그변환**
독립변수	**9개** (전체 13개 중 `ZN` · `B` · `INDUS` · `AGE` 제거)
RMSE (원본 척도)	**4.215** (천 달러)
MAE / R^2 (원본 척도)	2.973 / 0.789

```python
final_fit = fits["1_로그변환"]
```



왜 체크포인트 2·3·4는 완전히 같은가

□ 공선성 제거와 스케일링이 모델 성능을 높이지 못한 이유

① 공선성 제거(3)가 아무것도 하지 않은 이유

VIF가 이미 전부 임계값 아래였다.

→ **제거된 변수가 0개**

→ 체크포인트 2와 **완전히 동일한 데이터**

실무 교훈 — 공선성 진단은 "결과가 바뀌었는지"가 아니라 "제거된 변수가 있는지"로 확인한다.

② 스케일링(4)이 성능을 못 바꾸는 이유

정규화는 선형변환일 뿐이다.

각 변수에 상수를 더하고 곱하는 조작

→ 선형회귀에서의 정규화는
회귀계수가 **반대 방향으로 상쇄**되며 예측값을 그대로 유지

→ 사실상 정규화 효과 없음 (하는 것과 안하는 것의 차이 없음)

"정규화하면 회귀 성능이 오른다"는 OLS에서는 틀린 명제다.
스케일링은 규제 모델(Ridge·Lasso)이나 계수 크기 비교를 위한 준비 작업일 뿐이다.



후진소거법 — 왜 한 번에 하나씩만 지우는가

□ 유의하지 않은 변수를 한꺼번에 지우면 안 된다.

절차 (반복)

1) 유의확률이 가장 큰(가장 유의하지 않은) 변수 **하나**를 제거
2) 남은 변수로 모델을 재적합
3) 모든 변수가 유의해질 때까지 **반복**

기준 통계량: **HC3** 유의확률
(등분산성 가정을 충족하지 않음)

하나씩 순차적으로 제거하는 이유

변수들 사이에 상관이 있기 때문

어떤 변수의 "안 유의함"은 다른 변수가 함께 있을 때만 성립

한꺼번에 삭제할 경우,
원래는 유의해졌을 변수까지 잘못 소거할 가능성
→ 종속변수에 영향을 주는 변수를 잘못 제거할 수 있음

▶ 최종 모델의 제거 순서 (13개 → 9개)

STEP 1	→	STEP 2	→	STEP 3	→	STEP 4
ZN		**B**		**INDUS**		**AGE**
p = .997		p = .788		p = .552		p = .272

총 4개 제거 → 최종 독립변수 9개



모형 적합도 보고 — 개별 계수 이전에 '전체'를 판정

□ F 검정 → R^2 → Adj.R^2 순으로 확인

◎ 최종 모델(1_로그변환)의 결과 예시

① F 검정

F(9, 496) = 210.41

p < .001

H_0 (모든 회귀계수 = 0) 을 기각 → **모형은 유의**하다

② R^2 (결정계수)

0.792

종속변수 분산의 79.2% 설명

주의: log1p(MEDV) 척도의 R^2

③ Adj.R^2 (조정)

0.789

변수 개수 벌점 반영

변수 개수가 다른 모델 비교 시 사용

두 개의 R^2를 구분한다

· **R^2(모델척도) 0.792** — log1p(MEDV) 척도의 설명력. 변수 개수 비교(Adj.R^2)의 기준.
· **R^2(원본척도) 0.789** — 예측값을 천 달러로 되돌린 뒤 계산. 비즈니스 커뮤니케이션에서 사용.

▶ 보고 문장 형식 — n · F(df1, df2) · p · R^2 · Adj.R^2 를 함께

"보스턴 주택가격을 종속변수로 한 다중회귀 분석 결과, 모형은 통계적으로 유의하였다
(**n = 506, F(9, 496) = 210.41, p < .001, R^2 = .792, Adj.R^2 = .789**).
9개의 독립변수는 log1p(MEDV) 분산의 약 79%를 설명하였다."

ITWILL 이광호강사



#03. 최종 모델 분석 결과 보고

1. 모형 적합도

```python
display(Markdown(
    my_ols.report_fitness(final_fit, log1p_y=True,
    log1p_x=final_log1p_x)
))
```

✓ 마지막 실행: 오전 8:46:01, 기간: 0.0s Python

Note. n = 506. F(9, 496) = 210.41, p < 0.001, R^2 = 0.792, Adj.R^2 = 0.789, Durbin-Watson = 1.037

log1p(MEDV)를 종속변수로, log1p(CRIM), CHAS, NOX, RM, log1p(DIS), log1p(RAD), TAX, PTRATIO, log1p(LSTAT)(을)를 독립변수로한 다중선형회귀분석 결과, 모형은 통계적으로 유의하였다.

> F(9, 496) = 210.41, p < 0.001, R^2 = 0.792.

즉, log1p(CRIM), CHAS, NOX, RM, log1p(DIS), log1p(RAD), TAX, PTRATIO, log1p(LSTAT)는 log1p(MEDV)의 약 79.24%를 설명하는 것으로 나타났다.

B(계수)와 β(표준화 계수)는 '다른 질문'에 답한다

□ 계수는 모형의 해석, 표준화 계수는 독립변수 간의 비교

B (비표준화) — 해석용

"x가 1 증가하면 y가 얼마나 변하는가"

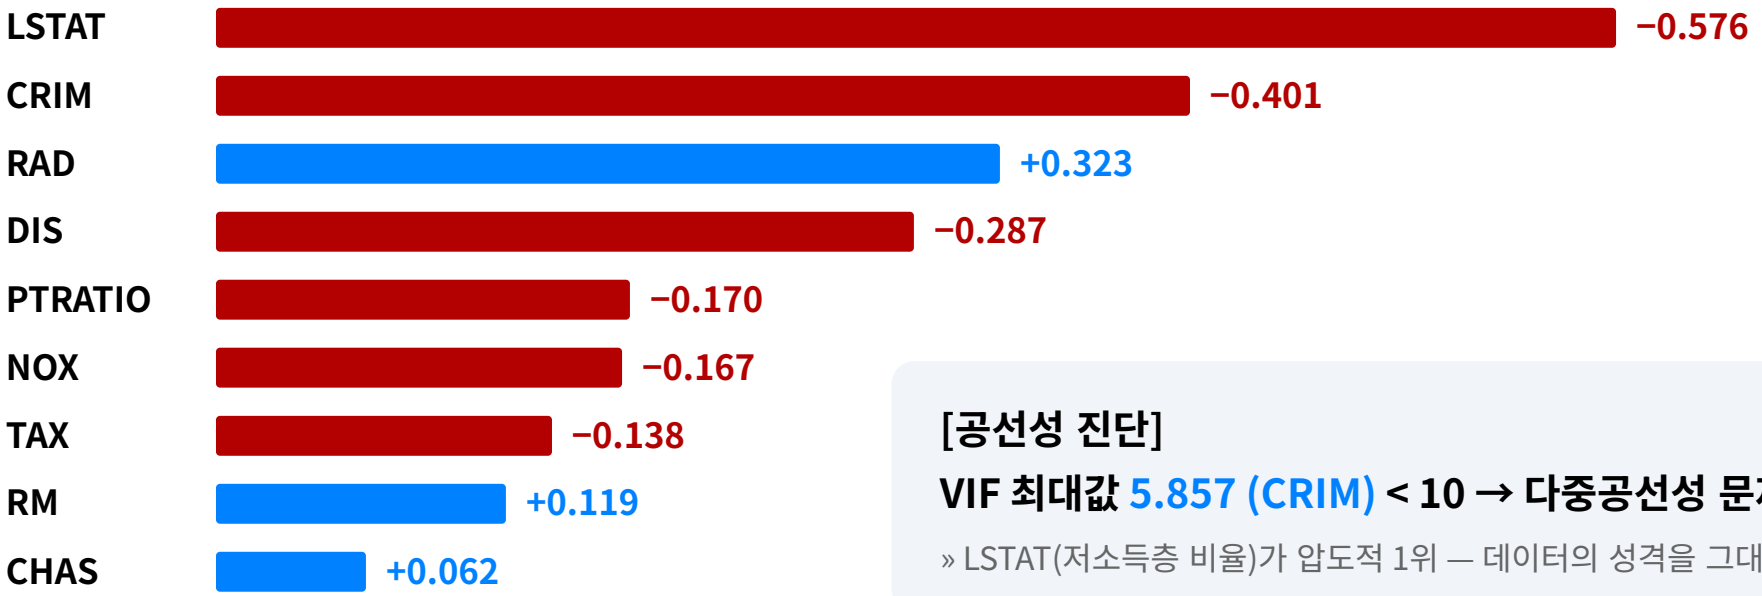
변수마다 단위가 달라 크기 비교 불가
(예: TAX는 수백 단위, CHAS는 0/1)

β (표준화) — 비교용

단위를 지운 계수 → 영향력 순위 비교

순위는 비교 가능하되 **절대적 크기**는 아님
공차·VIF와 함께 다중공선성도 함께 본다

▶ **표준화계수 |β| 크기순 — 파란 = 정(+) · 빨간 = 부(−)**



[공선성 진단]

VIF 최대값 5.857 (CRIM) < 10 → 다중공선성 문제 없음

» LSTAT(저소득층 비율)가 압도적 1위 — 데이터의 성격을 그대로 말해준다.



#03. 최종 모델 분석 결과 보고

2. 회귀계수 보고

```
1 my_ols.report_variables(final_fit, final_data, hc3=use_hc3)
```

✓ 마지막 실행: 오전 8:46:01, 기간: 0.0s Python

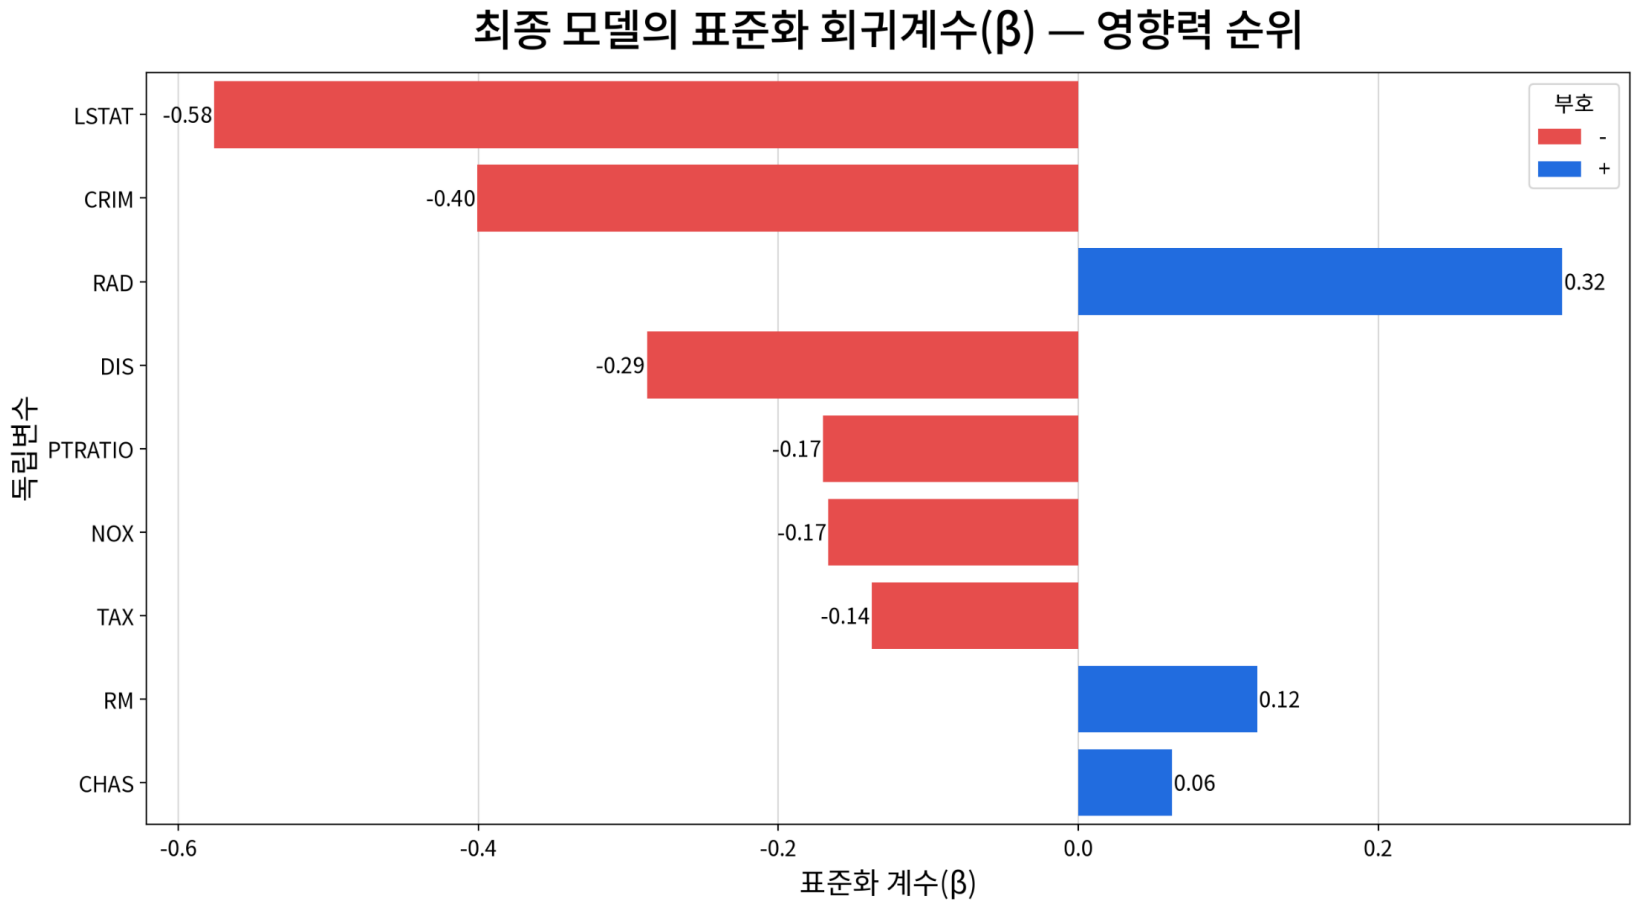
	종속변수	독립변수	B	표준오차	표준오차(HC3)	β	t	t(HC3)	유의확률	유의확률(HC3)	공차	VIF
0	MEDV	LSTAT	-0.414	0.024	0.036	-0.576	-16.903	-11.433	0.000	0.000	0.360	2.777
1	MEDV	CRIM	-0.152	0.019	0.025	-0.401	-8.094	-6.083	0.000	0.000	0.171	5.857
2	MEDV	RAD	0.166	0.025	0.025	0.323	6.678	6.553	0.000	0.000	0.179	5.585
3	MEDV	DIS	-0.269	0.035	0.040	-0.288	-7.675	-6.799	0.000	0.000	0.298	3.353
4	MEDV	PTRATIO	-0.030	0.005	0.004	-0.170	-6.718	-7.687	0.000	0.000	0.653	1.532
5	MEDV	NOX	-0.556	0.141	0.159	-0.167	-3.954	-3.502	0.000	0.001	0.236	4.239
6	MEDV	TAX	-0.000	0.000	0.000	-0.138	-2.799	-2.270	0.005	0.024	0.173	5.774
7	MEDV	RM	0.066	0.016	0.024	0.119	4.230	2.753	0.000	0.006	0.526	1.900
8	MEDV	CHAS	0.095	0.032	0.038	0.063	2.969	2.533	0.003	0.012	0.944	1.060

#03. 최종 모델 분석 결과 보고

3. 영향력 순위 시각화 (표준화 계수 β)

```
1 my_ols.plot_beta(final_fit, final_data,
2                  title="최종 모델의 표준화 회귀계수(β) – 영향력 순위")
```

✓ 마지막 실행: 오전 8:46:02, 기간: 0.1s Python





로그 모델의 계수 해석 — '로그가 붙으면 %가 된다'

□ 변수에 로그가 걸리면 해석의 단위가 절대량에서 %로 바뀐다.

	y = 원본	y = log(y)
x = 원본	**기본 형태** x 1↑ → y가 **B**만큼 ↑ (절대량 → 절대량)	**준탄력 (semi-elastic)** x 1↑ → y가 약 **(e^B − 1) × 100 %** ↑ (절대량 → %)
x = log(x)	**준탄력 (semi-elastic)** x 1 % ↑ → y가 약 **B × ln(1.01)** ↑ (% → 절대량)	**완전탄력 (log-log)** x 1 % ↑ → y가 약 **B %** ↑ **= 탄력성**

▶ 최종 모델 적용 — 종속변수가 log1p(MEDV)이므로 결과는 항상 % 변화

· **로그가 걸린 독립변수** (CRIM · DIS · RAD · LSTAT) → "1 % 증가할 때 몇 % 변화" (탄력성)

· **원본 그대로인 독립변수** (CHAS · NOX · RM · TAX · PTRATIO) → "1 증가할 때 몇 % 변화"

log1p의 함정 — % 해석의 대상은 x가 아니라 (1+x)

log1p(x) = ln(1 + x). 값이 클 때만 "1 % ↑ → B %" **근사가 성립. 0 근처의 작은 값에서는 부정확.**

예: **CRIM**(범죄율) — 중앙값 0.257, 전체의 **65.6 %**가 1 미만, 최솟값 0.006 → 데이터가 "0 근처"에 몰림.

⇒ CRIM의 계수는 부호·유의성 중심으로 해석하고, 탄력성 수치를 액면 그대로 읽지 않는다.



#03. 최종 모델 분석 결과 보고

4. 회귀계수 해석 문장

```python
display(Markdown(
    my_ols.report_variables_text(final_fit,
                                 log1p_y=True, log1p_x=final_log1p_x,
                                 hc3=use_hc3)
))
```

✓ 마지막 실행: 오전 8:46:01, 기간: 0.0s Python

- **CRIM**의 회귀계수는 **B = -0.15**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = -6.08**, **p < .001**) 즉, **(1+CRIM)가 1% 증가**할 때 **(1+MEDV)**는 평균적으로 약 **0.15% 감소**하는 것으로 해석된다.
- **CHAS**의 회귀계수는 **B = 0.1**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = 2.53**, **p = .012**) 즉, CHAS가 **1 증가**할 때 **(1+MEDV)**는 평균적으로 약 **9.99% 증가**하는 것으로 해석된다.
- **NOX**의 회귀계수는 **B = -0.56**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = -3.5**, **p < .001**) 즉, NOX가 **1 증가**할 때 **(1+MEDV)**는 평균적으로 약 **42.66% 감소**하는 것으로 해석된다.
- **RM**의 회귀계수는 **B = 0.07**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = 2.75**, **p = .006**) 즉, RM가 **1 증가**할 때 **(1+MEDV)**는 평균적으로 약 **6.79% 증가**하는 것으로 해석된다.
- **DIS**의 회귀계수는 **B = -0.27**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = -6.8**, **p < .001**) 즉, **(1+DIS)가 1% 증가**할 때 **(1+MEDV)**는 평균적으로 약 **0.27% 감소**하는 것으로 해석된다.
- **RAD**의 회귀계수는 **B = 0.17**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = 6.55**, **p < .001**) 즉, **(1+RAD)가 1% 증가**할 때 **(1+MEDV)**는 평균적으로 약 **0.17% 증가**하는 것으로 해석된다.
- **TAX**의 회귀계수는 **B = -0.0**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = -2.27**, **p = .024**) 즉, TAX가 **1 증가**할 때 **(1+MEDV)**는 평균적으로 약 **0.03% 감소**하는 것으로 해석된다.
- **PTRATIO**의 회귀계수는 **B = -0.03**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = -7.69**, **p < .001**) 즉, PTRATIO가 **1 증가**할 때 **(1+MEDV)**는 평균적으로 약 **2.99% 감소**하는 것으로 해석된다.
- **LSTAT**의 회귀계수는 **B = -0.41**으로 나타났으며, 이는 **MEDV**에 유의한 요인임을 의미한다. (**t(496) = -11.43**, **p < .001**) 즉, **(1+LSTAT)가 1% 증가**할 때 **(1+MEDV)**는 평균적으로 약 **0.41% 감소**하는 것으로 해석된다.

> ※ 위 **t**와 **유의확률**은 등분산 가정이 충족되지 않은 경우를 대비해 **HC3 로버스트 표준오차**로 계산한 값이다. 회귀계수(B)와 효과 크기 해석은 일반 OLS와 동일하며, 표준오차만 이분산에 강건하게 보정되어 유의성 판정이 달라질 수 있다.

> ※ **log1p**(=ln(1+·))의 % 해석은 변수 자체가 아니라 **(1+변수)** 기준이며, 값이 클 때만 위 근사가 성립한다(0·작은 값 구간에서는 원본처럼 동작해 부정확). 이 구간에서는 부호·유의성 중심으로 해석하거나 예측값을 expm1로 원 척도에서 비교한다.



회귀분석의 4가지 가정 — 깨지면 무엇이 망가지나

□ 가정이 깨지면 모형을 믿을 수 없을까?

· 앞의 **계수 해석은 가정이 지켜졌을 때**만 액면 그대로 **믿을 수 있다**.
· 가정이 깨져도 계수(B)는 대체로 불편추정량으로 남는다. 무너지는 것은 **SE → t → p → 신뢰구간**.
· **단, 선형성만은 예외 — 선형성이 깨지면 계수 자체가 편향된다. 선형회귀가 성립되지 않는다.**

가정	검정 방법	귀무가설 H_0	깨지면 무엇이 망가지나
선형성	Ramsey RESET	선형모형이 적절하다	**계수 자체가 편향됨 — 가장 치명적**
정규성	K-S (n ≥ 30) + √MSE 구간	잔차가 정규분포를 따른다	소표본에서 t·F 검정의 근거가 흔들림
등분산성	Breusch-Pagan	잔차의 분산이 일정하다	표준오차 편향 → 유의성 오판
독립성	Durbin-Watson	잔차가 서로 독립이다	표준오차 과소추정 → 유의성 과대평가

선형이 유지되는 구간만 채택, 2차항 추가, 머신러닝(트리계열)로 전환 등 고려

망함

한계점 명시 해석유의

가정이 지키는 것

- 계수 B의 **불편성**
- 표준오차 SE의 **정확성**
- 유의성 판정(t · p)의 **타당성**
- 신뢰구간·예측구간의 **정확성**

깨질 때 잃는 것 (심각도 순)

- **선형성** → 계수 편향 (해석 자체 무너짐)
- **독립성** → SE 과소 → 유의성 과대
- **등분산성** → SE 편향 → 유의성 오판
- **정규성** → 소표본 t · F의 신뢰성 저하

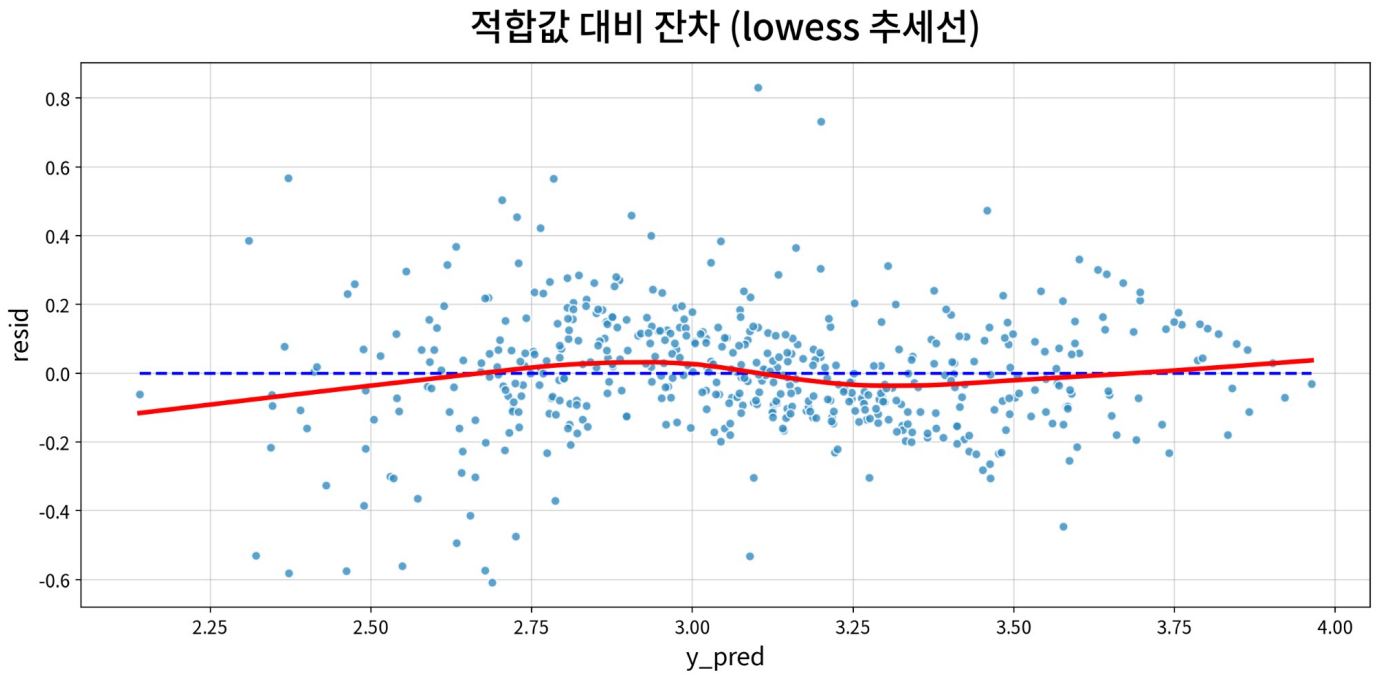
#04. 최종 모델의 회귀분석 가정 검정

1. 선형성 검정

```
1 my_ols.test_linear(final_fit, plot=True,
2                    title="적합값 대비 잔차 (lowess 추세선)")
```

✓ 마지막 실행: 오전 8:46:02, 기간: 0.1s Python

	statistic	p-value	linearity	result
Ramsey RESET	5.635	0.018	False	대립가설 채택 → 선형성 위배(곡선 관계 존재)



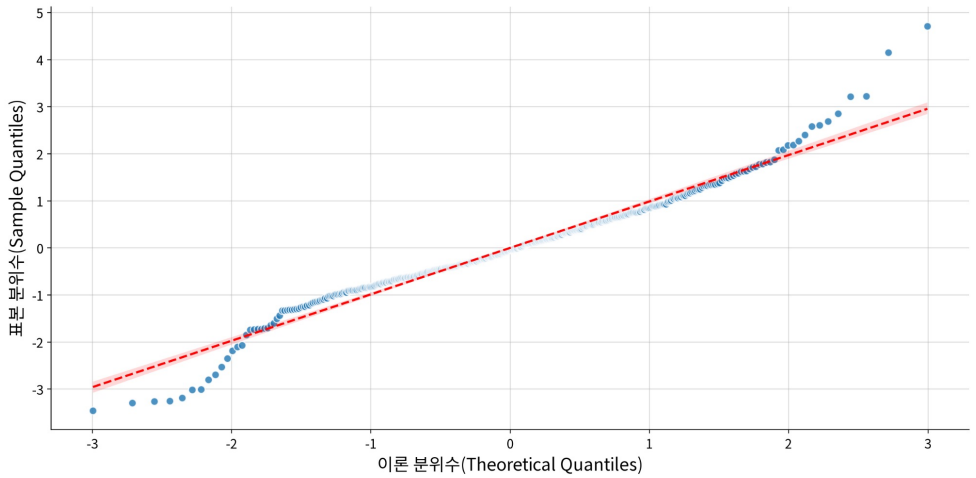
#04. 최종 모델의 회귀분석 가정 검정

2. 정규성 검정

```
1 my_ols.test_normal(final_fit, plot=True)
```

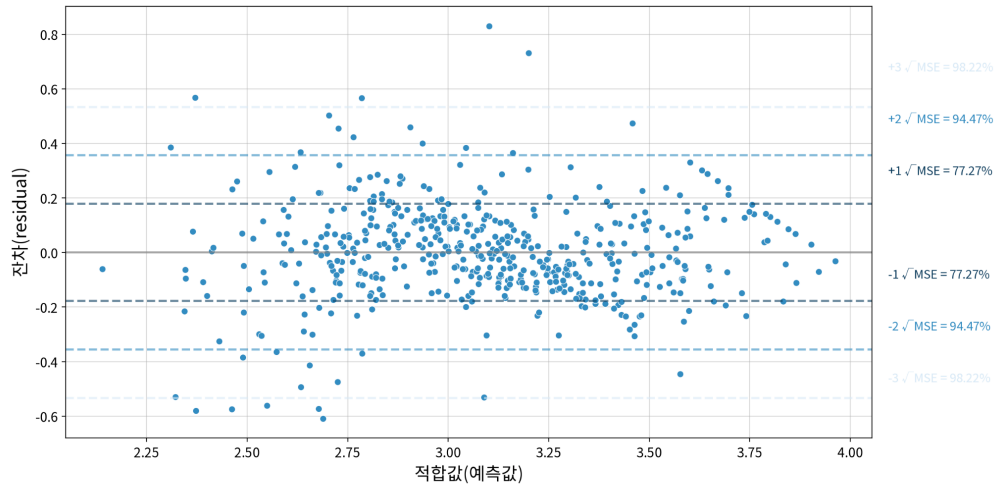
✓ 마지막 실행: 오전 8:46:02, 기간: 0.2s Python

	statistic	p-value	normality	result
Kolmogorov-Smirnov	0.060	0.049	False	대립가설 채택 → 정규성 위배



구간	기대(%)	허용범위(%)	실제(%)	판정
±1√MSE	68.000	64~72	77.270	위배
±2√MSE	95.000	93~97	94.470	충족
±3√MSE	99.700	99~100	98.220	위배

√MSE = 0.18 · 구간 규칙 판정: 정규성 위배



ITWILL 이광호강사



#04. 최종 모델의 회귀분석 가정 검정

3. 등분산성 검정

```
1 my_ols.test_equalvar(final_fit)
```

✓ 마지막 실행: 오전 8:46:02, 기간: 0.0s Python

	LM statistic	LM p-value	F statistic	F p-value	homoscedasticity	result
Breusch-Pagan	77.414	0.000	9.954	0.000	False	대립가설 채택 → 등분산 아님

4. 독립성 검정

```
1 my_ols.test_independent(final_fit)
```

✓ 마지막 실행: 오전 8:46:02, 기간: 0.0s Python

	statistic	independence	result
Durbin-Watson	1.037	False	독립성 위반 (양(+)의 자기상관)



가정 검정 종합 — 4개 모두 위배

□ 이 모델은 4가지 가정을 모두 충족하지 못했다.

◎ 그래도 버리는 게 아니라 어디까지 믿을지를 정한다.

가정	검정	통계량	p	판정
선형성	Ramsey RESET	**F = 5.635**	.018	위배
정규성	Kolmogorov-Smirnov	**D = 0.060**	.049	위배 (경계선)
등분산성	Breusch-Pagan	**F = 9.954**	< .001	위배
독립성	Durbin-Watson	**DW = 1.037**	—	위배

그래도 예측 성능은 준수하다

원본 척도 **RMSE = 4.215** (천 달러)
원본 척도 **R^2 = 0.789**

따라서 이 모델의 위치

"쓸 수 없는 모델"이 아니라
"예측엔 유효하지만 **추론**은 조심해야 하는 모델"

한계점 명시는 '분석 보고서의 의무'

가정 위배는 실패가 아니다 — **무엇을 얼마나 신뢰할지 결정하는 근거**다.
숨기면 그때부터 결과가 거짓말이 된다.

한계점 - ① 선형성 · ② 등분산성 위배

□ 선형성 위배는 계수 자체를, 등분산성 위배는 예측구간을 망가뜨린다.

① 선형성 위배 (p = .018)

다른 가정이 깨져도 계수는 불편추정량으로 남지만,
선형성이 깨지면 **계수 자체가 편향**된다.

→ "RM이 1 증가하면 몇 % 오른다"는 해석의 크기 자체가 틀어질 수 있다.

원인 추정

- RM(방 개수)-집값, LSTAT(저소득층 비율)
  → 집값은 **알려진 대로 비선형** 관계
- MEDV = 50에서 **상한 절단** (16건)
  → 고가 구간이 직선으로 설명 안 됨

보완 방향

· 다항항 추가 (RM^2 · $LSTAT^2$)
· 비선형 모델(트리 계열)로 확장

② 등분산성 위배 (p < .001)

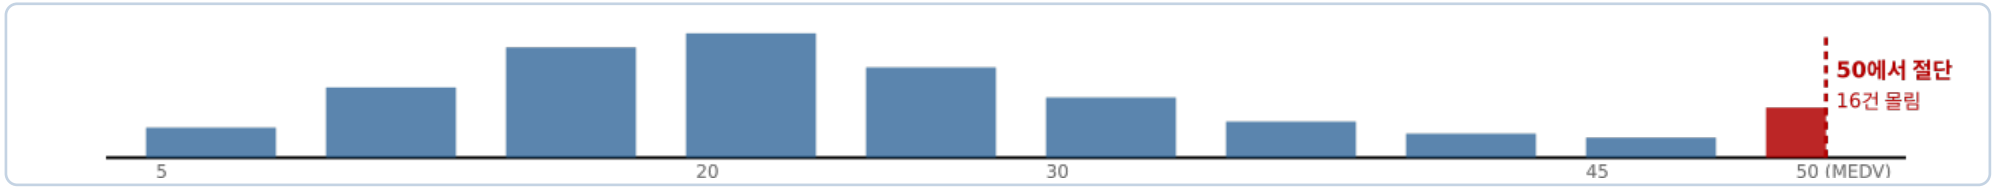
이미 취한 조치

모든 계수를 **HC3 로버스트 표준오차** 채택
→ 유의성 판정은 방어되어 있다.

그럼에도 남는 한계

HC3는 표준오차를 보정할 뿐 이분산 자체를 없애지 않는다.
→ 계수 유의성은 믿을 수 있어도
개별 예측값의 신뢰구간·예측구간은 여전히 부정확.

▶ MEDV = 50 상한 절단 — 오른쪽 끝에 16건이 쌓여 있다 (수집 단계의 결함)



ITWILL 이광호강사



HC3 로버스트 표준오차 — 등분산 위배의 처방

□ 계수(B)는 그대로 두고 표준오차만 보정한다. 그러면 t와 p가 함께 바뀐다.

- 유의성 판정(t, p)은 **표준오차에서 나온다**.
- **등분산이 깨지면** 일반 OLS의 SE는 편향된 값이라 **유의성 판정 자체를 믿을 수 없다**.
- HC3는 **이분산에 강건한(robust)** 표준오차다.

▶ HC3 적용 시 — 무엇이 바뀌고 무엇이 그대로인가

유지 / 변경	B	β	공차 · VIF	SE	t	p
HC3 적용	그대로	그대로	그대로	바뀜	바뀜	바뀜

▶ 최종 모델에서 실제로 유의확률이 커진 변수들

TAX
일반 OLS.005 → HC3.024
약 5배 커짐

RM
일반 OLS< .001 → HC3.006
1자리 → 3자리 뒤 유의

CHAS
일반 OLS.003 → HC3.012
약 4배 커짐

일반 OLS만 봤다면 세 변수의 유의성을 과대평가했을 것이다.
등분산성 가정이 깨진 경우 변수 선택 기준과 보고 기준을 일치시킨다 → 후진소거도 HC3, 최종 보고도 HC3



한계점 - ③ 독립성 · ④ 정규성 위배

□ 독립성 위배는 교정할 수단이 없고, 정규성 위배는 표본이 커서 완충된다.

③ 독립성 위배 (DW = 1.037) — 교정 불가

연쇄 효과

공간 자기상관
→ 유효 표본 수 **과대평가**
→ SE 과소추정
→ **유의성 과대평가**

HC3가 왜 못 잡나

HC3는 **이분산은 잡지만 자기상관은 못 잡는다.**

보완 방향과 현실적 제약

· 공간 회귀 / HAC(Newey-West) 표준오차
· 위도·경도 컬럼이 데이터셋에 없어 **이 실습에서는 교정 불가**
→ 계수 유의성은 **다소 낙관적**임을 감안

④ 정규성 위배 (p = .049) — 실질 영향 최소

왜 완충되는가

- p = .049는 **경계선** — 강한 위배가 아님
- n = 506으로 충분히 크다
- **중심극한정리**에 의해 계수 추정량의 표집분포는 정규에 근사
- t · F 검정의 타당성이 크게 훼손되지 않는다

그래도 남는 신호

두꺼운 꼬리(leptokurtic) — **큰 잔차(이상치)**가 정규 이상으로 남아 있다.

» 체크포인트 2의 이상치 대체가 성능을 못 올린 것과 같은 맥락.

▶ 4가지 위배의 심각도 순위 · 교정 가능 여부

1st — 선형성	2nd — 독립성	3rd — 등분산성	4th — 정규성
계수 편향 — 치명	유의성 과대 — 낙관적	SE 편향 — 유의성 오판	t·F 신뢰성 — 저하
✓ 다항항·비선형으로 교정 가능	✗ 좌표 없어 교정 불가	✓ HC3로 방어 (완결 아님)	✓ CLT로 완충 (n = 506)

ITWILL 이광호강사



결론 — 신뢰할 수 있는 것 / 없는 것

□ 최종 모델의 기능

◎ **예측 도구로는 유효** → 원본 척도 $R^2 = 0.789$, RMSE = 4.215 (천 달러)

◎ **인과 해석의 근거로는 부적합**

✓ 신뢰할 수 있는 것

① 계수의 방향 (부호)
LSTAT · CRIM · DIS · PTRATIO · NOX · TAX가 (−), RAD · RM · CHAS가 (+)라는 사실

② 대략적인 영향력 순위
LSTAT > CRIM > RAD > DIS > PTRATIO > NOX > …

③ 원본 척도의 예측 오차 규모
평균 ±4.2천 달러 — 예측 도구로의 실용성

✗ 신뢰하면 안 되는 것

① 계수의 정확한 크기
선형성 위배로 편향되었을 수 있음 → “몇 %”를 액면 그대로 인용 금지

② 유의성의 강도
공간 자기상관으로 과대평가된 상태

③ 개별 예측값의 신뢰구간
이분산 잔존 → 예측구간은 여전히 부정확

▶ 다음 단계 로드맵

1st — 다항항 추가
RM^2 · $LSTAT^2$ 등—
계수의 편향부터 잡는다

→

2nd — 규제 모델
Ridge · Lasso—
과적합 억제 · 계수 안정화

→

3rd — 교차검증
K-fold—
일반화 성능의 실제 측정

머신러닝을 해 봐야 한다는 의미

ITWILL 이광호강사



연습문제 보험료 가격 결정 구조 분석

□ 아래는 insurance 데이터셋에 대한 품질 검사 완료 버전이다.
분석하라!!!!

- **insurance_qtcheck** : 보험 비용 데이터셋의 품질 검사 완료 버전
- **insurance_qtcheck_desc** : 보험 비용 데이터셋의 연속형 변수에 대한 기술 통계량
- **insurance_qtcheck_category_desc** : 보험 비용 데이터셋의 범주형 변수에 대한 기술 통계량