[LAB-10] 06. [PBT] 로지스틱 회귀 파이프라인 - 연습문제

1. 작업 개요 (2문항)

문제 1

데이터를 불러왔을 때, 원본 데이터의 관측치(행)는 몇 개인가요? (정수 1개)

정답. `4000`

해설. 불러온 직후 가장 먼저 할 일은 **크기를 눈으로 확인하는 것**임. 사과 4,000개에 대한 기록이며, 이 숫자가 이후 모든 단계의 기준점이 됨. 중복이나 결측을 제거해 행이 줄면 곧바로 알아챌 수 있어야 함.

문제 2

원본 데이터는 몇 개의 컬럼으로 이루어져 있나요? (정수 1개)

정답. `9`

해설. 식별자 1개(`A_id`) + 연속형 측정값 7개 + 종속변수 1개(`Quality`) = **9열**임.

이 9라는 숫자가 중요한 이유는 다음 섹션에서 식별자를 빼면서 **8열로 줄어들기 때문**임. 열 개수가 언제 왜 바뀌었는지 추적하지 못하면 분석 중간에 변수가 사라지거나 남아 있어도 알아채지 못함.

2. 데이터 품질 점검 (3문항)

문제 3

분석 대상이 아닌 컬럼을 제거하고 나면, 남은 데이터는 몇 개의 컬럼이 되나요? (정수 1개)

정답. `8`

해설. `A_id` 는 **행마다 값이 모두 다른 식별자**라 분석 대상이 아님. 9열에서 이것 하나를 빼 **8열**이 됨.

숫자로 저장되어 있다는 점이 함정임. 그대로 두면 연속형 독립변수로 잘못 투입되어, 아무 의미 없는 일련번호가 모델에 들어감. 자료형만 보고 판단하지 말고 **값의 성격**을 봐야 함.

문제 4

7가지 연속형 측정 항목 중 이상치가 가장 많이 섞여 있는 항목은 무엇인가요? (변수명 1개)

정답. `Weight`

해설. 사분위수로 계산한 경계를 벗어난 관측치는 `Weight` **54건(1.3%)** 으로 가장 많고, `Crunchiness` 47건, `Sweetness` · `Juiciness` 32건 순임.

이 단계에서는 세어서 기록만 하고 지우거나 대체하지 않음. 여기서 손대면 "대체하는 편이 나았는지"를 나중에 비교할 수단이 사라지기 때문임.

문제 5

반대로, 이상치가 가장 적게 섞여 있는 항목은 무엇인가요? (변수명 1개)

정답. `Acidity`

해설. `Acidity` **20건(0.5%)** 으로 가장 적고, `Size` 22건이 근소한 차이로 뒤를 이음.

최대와 최소의 차이가 54건 대 20건에 불과함. 즉 **7종 모두 1.3% 이하로 고르게 미미한 수준**이라, 어느 하나가 유독 지저분하다고 볼 근거가 없음.

> 참고 — 중복 0건, 결측 0건임. 캐글 데이터셋 중에서는 드물게 정제가 이미 끝난 상태임.

3. 탐색적 데이터 분석 (3문항)

문제 6

종속변수를 제외하고 나면, 탐색적 분석의 대상이 되는 연속형 독립변수는 몇 개인가요? (정수 1개)

정답. `7`

해설. `Size` · `Weight` · `Sweetness` · `Crunchiness` · `Juiciness` · `Ripeness` · `Acidity` **7개**임. 종속변수 `Quality` 는 명목형이라 연속형 목록에 들어가지 않음.

코드에서 `target_is_continuous` 를 `False` 로 두었기 때문에, 종속변수를 **명목형 목록에서** 제거하는 분기를 탐. 선형회귀였다면 반대쪽 분기를 타서 연속형 목록에서 제거했을 것임.

문제 7

종속변수를 제외하고 나면, 명목형 독립변수는 몇 개인가요? (정수 1개)

정답. `0`

해설. 명목형 변수는 종속변수 `Quality` 하나뿐이므로, 이것을 빼면 **0개**임.

이 0이 이후 절차를 결정함. 교차분석은 **대상이 없어 출력이 비고**, 더미변수 인코딩도 할 일이 없음. **"해당 없음"도 판단 결과이므로 절차상 그대로 기록함.** 비어 있는 출력을 보고 코드가 잘못됐다고 오해하지 말 것.

문제 8

척도 조합표의 아홉 가지 경우 중, 이 데이터에서 실제로 수행되는 분석 유형은 무엇인가요? (분석 기법 이름 1개)

정답. T검정

해설. 종속변수가 **명목형 2집단**이므로 후보는 세 줄(명목형 2집단 × 연속형 / × 명목형 2집단 / × 명목형 3집단+)로 좁혀지고, 그중 독립변수가 실제로 존재하는 것은 **연속형** 한 줄뿐임. 따라서 **T검정**만 수행됨.

핵심은 종속변수가 명목형이면 상관분석을 쓸 수 없다는 점임. 상관계수는 두 변수가 모두 연속형일 때 정의되는 지표이기 때문임. “이 변수가 품질과 관련이 있는가”라는 **같은 질문**에 답하는 도구가 상관분석에서 T검정으로 바뀜.

문제 9

종속변수의 두 범주 중 더 많이 나타나는 쪽은 무엇인가요? (범주값 1개)

정답. `good`

해설. `good` 2,004건, `bad` 1,996건으로 **`good` 이 8건 더 많음.**

종속변수가 명목형이 되면 단변량 분석의 관심사가 바뀜. 선형회귀에서는 분포 모양(왜도·이상치)을 봤지만, 로지스틱 회귀에서는 **범주 비율(균형 여부)** 을 봄.

문제 10

그 최빈 범주가 전체에서 차지하는 비율은 얼마인가요? (소수 셋째 자리)

정답. `0.501`

해설. 2,004 ÷ 4,000 = **0.501**, 차이는 0.2%p에 불과한 **거의 완벽한 균형**임.

이 값이 곧 **모형이 넘어야 할 바닥값(baseline)** 임. 무조건 `good` 이라고만 답하는 게으른 모형의 정확도가 50.1%이므로, 모형은 그보다 얼마나 올라가는지로 평가함.

불균형 데이터였다면 이 숫자가 훨씬 커짐. 예를 들어 사건이 5%인 데이터라면 게으른 모형의 정확도가 95%가 되어, 정확도를 그대로 믿으면 안 됨. 이 데이터는 **정확도를 신뢰해도 되는 드문 경우**임.

문제 11

7가지 연속형 독립변수 중 분포의 비대칭이 가장 큰(왜도의 절댓값이 가장 큰) 항목은 무엇인가요? (변수명 1개)

정답. `Juiciness`

해설. 왜도의 절댓값은 `Juiciness` **0.113** 이 가장 크고, `Sweetness` 0.084, `Acidity` 0.056 순임. 가장 작은 `Crunchiness` 는 0.000임.

가장 크다는 0.113조차 판정은 `symmetric` (대칭) 이며, 7종 모두 평균 0 부근의 대칭 단봉 분포로 로그변환 대상이 하나도 없음.

여기서 중요한 것은 로지스틱 회귀가 독립변수의 정규성을 가정하지 않는다는 점임. 왜도가 크다는 이유만으로 로그변환을 하지 않음. 변환이 필요한 경우는 로짓 선형성이 깨졌을 때임.

문제 12

각 측정 항목이 `good` / `bad` 판정과 관련이 있는지 하나씩 검정했을 때, 두 집단 사이에 차이가 가장 없다고 나온 항목은 무엇인가요? (변수명 1개)

정답. `Crunchiness`

해설. 유의확률이 `Crunchiness` **0.985** 로 가장 크고, `Weight` 0.928, `Acidity` 0.797 순임. 0.985는 “두 집단의 아삭함 평균이 거의 완벽하게 같다”는 뜻임.

그렇다고 여기서 버리면 안 됨. 이 검정은 다른 변수를 통제하지 않은 **단독 비교**임.

문제 13

유의수준 5% 기준으로, 두 집단 사이에 차이가 유의하다고 판정된 항목은 몇 개인가요? (정수 1개)

정답. `4`

해설. `Size` · `Sweetness` · `Juiciness` · `Ripeness` **4종**이 모두 0.001 미만으로 유의함. 나머지 3종 (`Weight` · `Acidity` · `Crunchiness`)은 유의확률이 0.79를 넘음.

7종이 4 대 3으로 갈림. 이 3종을 어떻게 처리할지가 다음 섹션(#07)의 쟁점임.

문제 14

유의하다고 판정된 4개 항목 중, 유일하게 `bad` 집단의 평균이 더 큰 항목은 무엇인가요? (변수명 1개)

정답. `Ripeness`

해설. 유의한 4종의 방향을 보면 `Size` · `Sweetness` · `Juiciness` 는 `bad < good` 인데, **`Ripeness` 만 `bad > good`** (bad 0.995 / good 0.004)임.

즉 익은 정도가 낮을수록 좋은 사과임. 지나치게 익은 사과는 품질이 떨어진다는 상식과 맞아떨어짐. 유의성만 보지 말고 **방향까지 확인해야** 결과를 도메인 언어로 옮길 수 있음.

문제 15

검정 전에 정규성·등분산성을 먼저 확인하기 때문에, 항목마다 적용되는 검정 방법이 달라집니다. 정규성 가정을 만족하지 못해 **순위 기반 비모수 검정**으로 판정된 항목은 몇 개인가요? (정수 1개)

정답. `4`

해설. `Size` · `Sweetness` · `Crunchiness` · `Acidity` **4종**이 비모수 검정(Mann-Whitney U)으로, 나머지 3종 (`Weight` · `Juiciness` · `Ripeness`)이 Welch t-검정으로 판정됨.

검정 방법은 분석자가 고르는 것이 아님. 정규성·등분산성을 먼저 검정한 뒤 함수가 자동으로 선택함. 분석자가 할 일은 **어떤 검정이 선택됐는지 확인하고 결과표에 기록**하는 것임.

문제 16

연속형 독립변수끼리 상관관계를 확인했을 때, 강한 상관($|r| \geq 0.7$)으로 분류된 조합은 몇 개인가요? (정수 1개)

정답. `0`

해설. Strong으로 분류된 조합이 **하나도 없음.** → **다중공선성 문제 없음.** 7개 변수를 모두 투입해도 계수가 불안정해지지 않음.

같은 상관분석이라도 여기서는 목적이 다름. 종속변수와의 관계를 볼 때는 설명력 확인이지만, 독립변수끼리 볼 때는 **다중공선성 점검**임. 그래서 이 결과는 변수 해석에 쓰지 않음.

문제 17

독립변수 조합 중 상관계수의 절댓값이 가장 큰 값은 얼마인가요? (부호를 포함해 소수 셋째 자리)

정답. `-0.325`

해설. `Size – Sweetness` 조합의 **−0.325**가 가장 강함. 그다음이 `Ripeness – Sweetness` −0.255, `Weight – Ripeness` −0.244임.

가장 강한 것이 0.325인데 기준선은 0.7임. **기준의 절반에도 못 미침.**

보고서에 "공선성 문제 없음"이라고만 쓰면 안 됨. **무슨 기준으로 몇이었는지를 남겨야** 검토가 가능함.

문제 18

이변량 분석 결과만으로 곧바로 채택할 수 있는 변수는 몇 개인가요? (정수 1개)

정답. `4`

해설. 집단 간 차이가 유의한 `Size` · `Sweetness` · `Juiciness` · `Ripeness` **4종**임. 공선성 신호도 없어 그대로 투입하면 됨.

문제 19

단독 비교에서는 차이가 없었지만, 제거하지 않고 **보류**로 두는 변수는 몇 개인가요? (정수 1개)

정답. `3`

해설. `Weight` · `Acidity` · `Crunchiness` **3종**임. 유의확률이 0.79를 넘어 "차이가 전혀 없다"에 가까운데도 버리지 않음.

이유는 두 가지임. ① 공선성이 없어 다 넣어도 부작용이 없고, ② **다른 변수를 통제하면 숨어 있던 효과가 드러날 수 있기 때문**임(억제효과).

이변량 분석의 유의성만으로 변수를 버리면 안 됨. 이 검정은 다른 변수를 통제하지 않은 단독 비교이므로, 여기서 자르면 되살아날 변수를 놓침.

문제 20

결국 모델에 투입되는 독립변수는 모두 몇 개인가요? (정수 1개)

정답. `7`

해설. 채택 4종 + 보류 3종 = **7종 전부**임. 실제로 제외되는 것은 식별자 `A_id` 하나뿐이며, 그것도 이변량 분석 결과 때문이 아니라 **애초에 분석 대상이 아니어서** 빠진 것임.

변수 제거의 판정 시점은 탐색적 분석이 아니라 모델 적합 이후임. 7종을 모두 넣은 뒤 후진소거법으로 판정함.