Statistics Basic

LAB 10 - 로지스틱 회귀

6. [PBT] Apple Quality

ITWILL 이광호 강사

1. 작업 개요

모든 실습이 하나의 노트북 파일에서 이어서 진행됩니다.

ITWILL 이광호 강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



로지스틱 회위 분석의 전체 작업 흐름

□ 이 파이프라인은 8개 단계를 순서대로 지나간다.

단계 1 데이터 품질 점검 ▶ **단계 2** 변수 유형 분류· EDA 범위 확정 ▶ **단계 3** EDA 단변량·이변량·다변량 ▶ **단계 4** 최종 변수 선택 ↘

↳ **단계 5** 기준선 모형 ▶ **단계 6** 가정 검정 ▶ **단계 7** 전처리 파이프라인 비교 ▶ **단계 8** 결과 보고

□ 선형회귀 파이프라인과의 차이

◎ 선형회귀 파이프라인과 같은 순서다. 종속변수가 명목형이라 달라지는 지점은 세 곳이다.

단계 3 이변량 분석 기법
연속형 상관 대신
집단 간 차이 검정 사용

단계 6 가정 검정 항목
점검 대상 가정 자체가 치환된다

단계 8 성능 지표
회귀 적합도 지표 대신
분류 지표를 본다

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#01. 준비작업

실습

1. 라이브러리 참조

```python
from hossam import load_data
from helpers import *
from IPython.display import display, Markdown

from pandas import DataFrame
```

Python

📦 아이티윌 이광호 강사가 제작한 라이브러리를 사용중입니다.
📚 자세한 사용 방법은 https://py.hossam.kr 을 참고하세요.
📧 Email: leekh4232@gmail.com
🎬 Youtube: https://www.youtube.com/@hossam-codingclub
📝 Blog: https://blog.hossam.kr/
🔖 Version: develop

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#01. 준비작업

실습

2. 데이터 불러오기

```python
origin = load_data("apple_quality")
origin.head()
```

Python

📚 이 데이터 세트는 다양한 과일 속성에 대한 정보를 담고 있어 과일의 특성을 파악하는 데 도움이 됩니다. 데이터 세트에는 과일 ID, 크기, 무게, 당도, 아삭함, 과즙량, 숙성도, 산도 및 품질과 같은 세부 정보가 포함되어 있습니다. (출처: https://www.kaggle.com/datasets/nelgiriyewithana/apple-quality)

field	description
A_id	각 과일에 대한 고유 식별자 ← 불필요한 변수
Size	크기
Weight	무게
Sweetness	단맛 정도
Crunchiness	과일의 아삭한 식감을 나타내는 질감
Juiciness	과일의 과즙 함량 정도
Ripeness	과일이 익은 정도
Acidity	과일의 산도 수준
Quality	과일의 전반적인 품질 ← 종속변수

다음페이지에 데이터 프레임 모습이 제시됩니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#01. 준비작업

2. 데이터 불러오기 (결과 확인)

삭제 필요 — 종속변수

	A_id	Size	Weight	Sweetness	Crunchiness	Juiciness	Ripeness	Acidity	Quality
0	0	-3.970	-2.512	5.346	-1.012	1.845	0.330	-0.492	good
1	1	-1.195	-2.839	3.664	1.588	0.853	0.868	-0.723	good
2	2	-0.292	-1.351	-1.738	-0.343	2.839	-0.038	2.622	bad
3	3	-0.657	-2.272	1.325	-0.098	3.638	-3.414	0.791	good
4	4	1.364	-1.297	-0.385	-0.553	3.031	-1.304	0.502	good

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#01. 준비작업

실습

2. 컬럼 의미를 정리한 딕셔너리

```python
column_means = {
    "A_id":         "사과 식별자",
    "Size":         "크기",
    "Weight":       "무게",
    "Sweetness":    "단맛 정도",
    "Crunchiness":  "아삭한 식감",
    "Juiciness":    "과즙 함량",
    "Ripeness":     "익은 정도",
    "Acidity":      "산도",
    "Quality":      "품질 (good / bad)",
}
```

Python

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



연습문제 사과 품질 분류 데이터셋 활용 로지스틱 회귀 #01

□ 데이터를 확인하고 다음 물음에 답하시오.

1. 데이터를 불러왔을 때, 원본 데이터의 관측치(행)는 몇 개인가요? (정수 1개)
2. 원본 데이터는 몇 개의 컬럼으로 이루어져 있나요? (정수 1개)

2. 데이터 품질 점검

모든 실습이 하나의 노트북 파일에서 이어서 진행됩니다.

ITWILL 이광호 강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



단계 1: 데이터 품질 점검

□ 이 단계에서는 점검만 한다. 결측·이상치의 대체는 하지 않고 뒤로 미룬다.

STEP 1
자료형 확인

▶

STEP 2
자료형 변환
식별자 컬럼 제거
종속변수 명목형 변환

▶

STEP 3
중복 점검

▶

STEP 4
결측 점검

▶

STEP 5
기술통계량 확인
명목형 / 연속형
분리하여 확인

실행 규칙

결측·이상치는 **있는지 확인하고 기록**하는 데서 멈춘다.
삭제도, 대체도 이 단계에서는 하지 않는다.
대체를 적용할지는 **단계 7의 전처리 비교**에서 결정한다.

순서를 어기면

여기서 지워 버리면 **"대체가 나았는지" 뒤에서 비교할 수단이 사라진다.**
비교 대상이 없어지므로
단계 7의 체크포인트 설계 자체가 성립하지 않는다.

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

1. 자료형 확인

```python
origin.info()
```

Python

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4000 entries, 0 to 3999
Data columns (total 9 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   A_id         4000 non-null   int64
 1   Size         4000 non-null   float64
 2   Weight       4000 non-null   float64
 3   Sweetness    4000 non-null   float64
 4   Crunchiness  4000 non-null   float64
 5   Juiciness    4000 non-null   float64
 6   Ripeness     4000 non-null   float64
 7   Acidity      4000 non-null   float64
 8   Quality      4000 non-null   object
dtypes: float64(7), int64(1), object(1)
memory usage: 281.4+ KB
```

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

2. 자료형 변환

◎ A_id는 **행마다 값이 모두 다른 식별자**이므로 분석 대상이 아니다. 여기서 제거한다.

○ 숫자로 저장되어 있어 그대로 두면 연속형 독립변수로 잘못 투입된다.

◎ 종속변수 Quality는 문자열이므로 **명목형(category)** 으로 변환한다.

```
1 df0 = origin.drop(columns=["A_id"])
2 df1 = my_qtcheck.set_type(df0, as_category=["Quality"])
```

✓ 마지막 실행: 오후 12:35:44, 기간: 0.0s Python

```
<class 'pandas.DataFrame'>
RangeIndex: 4000 entries, 0 to 3999
Data columns (total 8 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   Size         4000 non-null   float64
 1   Weight       4000 non-null   float64
 2   Sweetness    4000 non-null   float64
 3   Crunchiness  4000 non-null   float64
 4   Juiciness    4000 non-null   float64
 5   Ripeness     4000 non-null   float64
 6   Acidity      4000 non-null   float64
 7   Quality      4000 non-null   category
dtypes: category(1), float64(7)
memory usage: 222.8 KB
```

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

3. 데이터 중복 점검

```python
df2 = my_qtcheck.check_duplicates(df1)
df2.head()
```

Python

중복된 행의 수: 0

	Size	Weight	Sweetness	Crunchiness	Juiciness	Ripeness	Acidity	Quality
0	-3.970	-2.512	5.346	-1.012	1.845	0.330	-0.492	good
1	-1.195	-2.839	3.664	1.588	0.853	0.868	-0.723	good
2	-0.292	-1.351	-1.738	-0.343	2.839	-0.038	2.622	bad
3	-0.657	-2.272	1.325	-0.098	3.638	-3.414	0.791	good
4	1.364	-1.297	-0.385	-0.553	3.031	-1.304	0.502	good

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

4. 결측치 점검

```python
my_qtcheck.check_missing_values(df2)
```

Python

	Missing Count	Missing Ratio (%)
Size	0	0.000
Weight	0	0.000
Sweetness	0	0.000
Crunchiness	0	0.000
Juiciness	0	0.000
Ripeness	0	0.000
Acidity	0	0.000
Quality	0	0.000

중복도 결측치도 없다. 캐글 데이터셋 중에서는 드물게 **정제가 이미 끝난 상태**다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

5. 명목형 변수의 기술 통계량

```python
cat_desc = my_qtcheck.categorical_summary(df2)
cat_desc
```

Python

📊 컬럼 'Quality'의 value_counts():

	count
Quality	
bad	1996
good	2004

	Quality
count	4000
unique	2
top	good
freq	2004

good이 전체 4000건 중에서 2004건 이므로
두 범주간의 데이터 균형이 잘 맞는다고 볼 수 있다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

6. 연속형 변수의 기술 통계량

```python
num_desc = my_qtcheck.numerical_summary(df2)
num_desc.T
```

Python

	Size	Weight	Sweetness	Crunchiness	Juiciness	Ripeness	Acidity
count	4000.000	4000.000	4000.000	4000.000	4000.000	4000.000	4000.000
mean	-0.503	-0.990	-0.470	0.985	0.512	0.498	0.077
std	1.928	1.603	1.943	1.403	1.930	1.874	2.110
min	-7.152	-7.150	-6.894	-6.055	-5.962	-5.865	-7.011
25%	-1.817	-2.012	-1.738	0.063	-0.801	-0.772	-1.377
50%	-0.514	-0.985	-0.505	0.998	0.534	0.503	0.023
75%	0.806	0.031	0.802	1.894	1.836	1.766	1.510
max	6.406	5.791	6.375	7.620	7.364	7.238	7.405
rel_diff	-0.021	-0.005	-0.068	0.013	0.041	0.010	2.400
rdiff_flag	similar	similar	similar	similar	similar	similar	large_diff
iqr	2.622	2.043	2.540	1.831	2.637	2.538	2.888
upper_bound	4.739	3.095	4.612	4.641	5.792	5.573	5.842
lower_bound	-5.750	-5.076	-5.549	-2.684	-4.757	-4.579	-5.709
upper_outliers	11	31	21	24	14	9	13
upper_outliers_ratio	0.003	0.008	0.005	0.006	0.004	0.002	0.003
lower_outliers	11	23	11	23	18	15	7
lower_outliers_ratio	0.003	0.006	0.003	0.006	0.004	0.004	0.002
outliers	22	54	32	47	32	24	20
outliers_ratio	0.005	0.013	0.008	0.012	0.008	0.006	0.005
skew	-0.002	0.003	0.084	0.000	-0.113	-0.009	0.056
skew_interpret	symmetric	symmetric	symmetric	symmetric	symmetric	symmetric	symmetric
kurt	-0.083	0.359	0.014	0.722	0.029	-0.072	-0.093
kurt_interpret	platykurtic	leptokurtic	leptokurtic	leptokurtic	leptokurtic	platykurtic	platykurtic
log_need	none	none	none	none	none	none	none

인사이트 — 품질 점검 결과

점검 항목	결과
관측치 수	4,000건 (중복 0건, 결측 0건)
식별자	A_id 제거
종속변수	Quality — good 2,004건 / bad 1,996건
연속형 변수	7종 (Size ~ Acidity)
왜도	7종 모두 symmetric → 로그변환 대상 없음
이상치	7종 모두 1.3% 이하 → 체크포인트로 비교

- 값의 범위가 −7 ~ +7, 평균은 0 부근
  → **이미 표준화된 지표**로 제공된 데이터다.
- "크기 1 증가"는 mm·g가 아니라 **표준화 점수 1점 증가**로 읽어야 한다.
- 종속변수가 **2,004 : 1,996으로 거의 완벽한 균형**이다.
- 따라서 정확도의 함정(불균형 데이터에서 게으른 모형이 높은 점수를 받는 문제)은 **이 데이터에서는 발생하지 않는다.**

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



단계 2: 변수 유형 분류와 EDA 범위 확정

□ 스위치 하나가 이후 모든 분기를 결정한다.

◎ 이 단계는 데이터셋에 종속된 설정을 한곳에 모아 두는 자리다.

◎ 다른 데이터로 같은 파이프라인을 돌릴 때 **STEP 2**만 수정하면 뒤쪽 단계는 손대지 않는다.

STEP 1	STEP 2	STEP 3	STEP 4	STEP 5
종속변수 지정	종속변수의 연속형 여부 스위치(bool) 지정	명목형 / 연속형 변수 목록 자동 분리	목록에서 종속변수 제거	(필요 시) 서열척도 순서 재지정

스위치가 결정하는 것 — 네 단계

종속변수 연속형 여부 스위치 ▶

이변량 분석 기법 선택	단계 3	적합할 모형 계열	단계 5
점검할 가정 항목	단계 6	성능 지표 구성	단계 8

이 네 가지 중 **단계 3·6·8**은 선형회귀와 달라지는 지점이고, **단계 5**는 모형 계열 자체를 고르는 지점이다.

서열척도 지정 규칙

서열척도의 순서 지정은 **도메인 지식이 필요한 판단**이므로, **준비작업 단계에서만 수정**한다.
뒤쪽 단계에서 순서를 바꾸면 앞서 실행한 분리 결과와 어긋난다.

대상이 없으면 **빈 상태로 둔다** — 비워 두는 것도 확인을 거친 판단 결과이므로 그대로 기록한다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#03. 변수 유형 분류와 EDA 범위

실습

□ 1. 변수 유형 분류

◎ 선형회귀 때와 **코드는 그대로**이고, **target_is_continuous**만 **False**로 바꾼다.

```
target = "Quality"    # 종속변수
target_is_continuous = False    # 종속변수 연속형 여부  --> 로지스틱이므로 False
nominal_cols = my_qtcheck.get_categorical_column_names(df2) # 명목형 변수
continuous_cols = my_qtcheck.get_number_column_names(df2)   # 연속형 변수

if target_is_continuous:
    continuous_cols.remove(target)  # 연속형 변수 이름에서 종속변수 항목 제거
else:
    nominal_cols.remove(target)     # 명목형 변수 이름에서 종속변수 항목 제거

print("종속변수 :", target)
print("종속변수 유형: " + ("연속형" if target_is_continuous else "명목형"))
print("명목형   :", nominal_cols)
print("연속형   :", continuous_cols)
```

```
종속변수 : Quality
종속변수 유형: 명목형
명목형   : []
연속형   : ['Size', 'Weight', 'Sweetness', 'Crunchiness', 'Juiciness', 'Ripeness', 'Acidity']
```

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#03. 변수 유형 분류와 EDA 범위

2. 서열척도 적용 (필요에 따라 수행)

◎ 명목형 범주에 순서가 있다면 순서를 지정한다. (도메인 지식이 필요한 부분)

○ **이 데이터셋에는 서열척도 대상이 없다.** 코드는 다른 데이터셋에 그대로 옮겨 쓸 수 있도록 남겨 둔다.

```python
# 서열척도를 적용할 변수와 순서를 정의한다. (낮은 등급 → 높은 등급)
# -> 도메인 지식이 필요한 부분이다.
# -> 서열척도 대상이 없는 데이터셋이라면 빈 딕셔너리로 둔다.
ordinal_map = {}

# 정의된 내용에 따라 순서를 재지정한다.
# -> 데이터셋에 없는 컬럼은 건너뛰므로 다른 데이터셋에서도 오류가 나지 않는다.
df = df2.copy()

for col, order in ordinal_map.items():
    if col in df.columns:
        print(f"'{col}' 컬럼 순서 재지정 : {order}")
        df[col] = df[col].cat.reorder_categories(order, ordered=True)
```

✓ 마지막 실행: 오후 1:10:51, 기간: 0.0s Python

출력 결과가 없습니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#03. 변수 유형 분류와 EDA 범위

□ EDA 범위 정리

◎ 변수 유형에 따라 어떤 EDA를 수행해야 할지 분류해 놓는다.

종속유형	독립유형	분석 유형	대상 변수	적용 여부	비고
연속형	연속형	상관분석	—	미적용	종속변수 타입이 명목형
연속형	명목형(2집단)	T검정	—	미적용	종속변수 타입이 명목형
연속형	명목형(3집단+)	ANOVA	—	미적용	종속변수 타입이 명목형
명목형(2집단)	**연속형**	**T검정**	**연속형 독립 7종 → Quality**	**적용**	**이 데이터의 핵심**
명목형(2집단)	명목형(2집단)	교차분석	—	미적용	명목형 독립변수 없음
명목형(2집단)	명목형(3집단+)	교차분석	—	미적용	명목형 독립변수 없음
명목형(3집단+)	연속형	ANOVA	—	미적용	종속변수가 2집단
명목형(3집단+)	명목형(2집단)	교차분석	—	미적용	종속변수가 2집단
명목형(3집단+)	명목형(3집단+)	교차분석	—	미적용	종속변수가 2집단

- 종속변수 Quality가 **명목형 2집단**이므로 4~6행만 후보가 되고, 독립변수가 실제로 존재하는 **T검정**만 수행됨
- **주의** — 종속변수가 명목형이면 **상관분석(피어슨·스피어만)을 쓸 수 없다.**
  - 상관계수는 두 변수가 모두 연속형일 때 정의되는 지표이기 때문이다.
  - 같은 질문("이 변수가 품질과 관련이 있는가")에 답하는 도구가 **T검정**으로 바뀐다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



연습문제 사과 품질 분류 데이터셋 활용 로지스틱 회귀 #01

□ 데이터 품질 점검을 수행하고 다음 물음에 답하시오.

3. 분석 대상이 아닌 컬럼을 제거하고 나면, 남은 데이터는 몇 개의 컬럼이 되나요? (정수 1개)
4. 7가지 연속형 측정 항목 중 이상치가 가장 많이 섞여 있는 항목은 무엇인가요? (변수명 1개)
5. 반대로, 이상치가 가장 적게 섞여 있는 항목은 무엇인가요? (변수명 1개)

3. 탐색적 데이터 분석

모든 실습이 하나의 노트북 파일에서 이어서 진행됩니다.

ITWILL 이광호 강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



단계 3: EDA 실행 순서

□ EDA는 단변량 → 이변량 → 다변량 순서로 실행한다.

단변량	이변량	다변량
1) 종속변수(명목형) 먼저 실행 2) 그다음 연속형 독립변수를 반복문으로 일괄 처리	연속형 독립변수 각각에 대해 집단별 시각화 → 검정 순서로 반복	1) 독립변수 간 상관 2) VIF

다변량 분석의 목적

독립변수 간 상관분석의 목적은 **설명력 확인이 아니라 다중공선성 점검**이다.
따라서 이 결과는 변수 해석에 쓰지 않고, **단계 7의 공선성 제거 옵션을 켤지 판단**하는 데 쓴다.

단계 3에서 각 단계가 산출하는 것

단변량	각 변수의 분포 형태를 확인한다
이변량	종속변수 집단 간 차이가 있는 변수를 가려낸다 → 단계 4의 3분류 입력
다변량	공선성 점검 결과를 남긴다 → 단계 7의 옵션 판단 입력

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



단계 3: EDA 코딩 주의점

□ 단계 3의 코딩 주의점 세 가지

주의 1

이변량 검정 전 long → wide 변환

이변량 검정을 실행하기 전에 **long → wide 변환**이 필요하다.
이때 **선형회귀 때와 집단 기준이 뒤바뀐다**
— **종속변수가 집단 기준**이 된다.

주의 2

검정 기법은 직접 고르지 않는다

정규성·등분산성을 **먼저 검정**한 뒤
함수가 자동으로 선택한다.
분석자가 기법을 지정하는 것이 아니라,
선택 결과를 **확인**하는 자리다.

주의 3

비는 출력도 그대로 기록한다

명목형 독립변수가 없으면 **교차분석은 출력이 빈다**.
이것도 **절차상 그대로 기록**한다
— 실행하지 않은 것과 대상이 없는 것은 다르다.

정리

집단 기준이 뒤바뀐다는 것의 실무적 의미

선형회귀에서는 명목형 변수로 집단을 나누고 연속형 종속변수를 비교했다.
여기서는 **종속변수의 두 범주가 집단**이 되고,
연속형 독립변수가 비교 대상이 된다.

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#04. 단변량 분석

실습

1. 명목형 종속변수에 대한 단변량 분석

◎ 선형회귀에서는 종속변수의 **분포 모양(왜도·이상치)** 을 봤지만,
로지스틱 회귀에서는 종속변수의 **범주 비율(균형 여부)** 을 본다.

```python
# 명목형 분포는 카운트 플롯으로 처리한다.
my_plot.countplot(data=df, x=target, hue=target, palette="Set2",
                  title=f"종속변수 {target}({column_means[target]}) 분포")

# 명목형 기술통계량
display(cat_desc[[target]].T)

# 추가적으로 빈도표 생성
freq = df[target].value_counts().rename("빈도").to_frame()
# value_counts(normalize=True)
# --> 전체 고유값의 개수(빈도수) 대신 전체 데이터의 비율을 계산
freq["비율"] = df[target].value_counts(normalize=True)
display(freq)
```

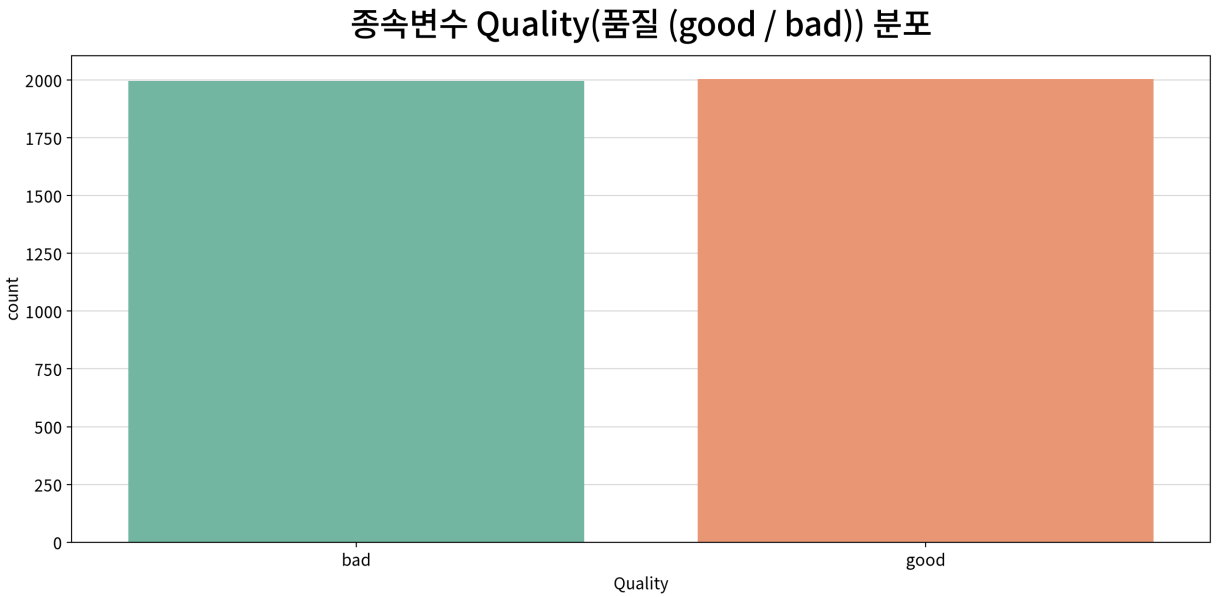
Python

결과는 다음 페이지에 제시합니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

1. 명목형 종속변수에 대한 단변량 분석 (결과 확인)



	count	unique	top	freq
Quality	4000	2	good	2004

	빈도	비율
Quality		
good	2004	0.501
bad	1996	0.499

인사이트

점검 항목	Quality 관찰값
범주 수	2 (good / bad)
최빈 범주	good 2,004건 (50.1%)
최소 범주	bad 1,996건 (49.9%)
균형 여부	거의 완벽한 균형 (차이 8건, 0.2%p)

- 균형 데이터이므로 **정확도(Accuracy)를 그대로 신뢰해도 되는 드문 경우**다.
- 무조건 good이라고만 답하는 게으른 모형의 정확도는 **50.1%**이다.
- 즉 정확도 50%가 이 데이터의 **바닥값 (baseline)**이고, 모형은 그보다 얼마나 올라가는지로 평가한다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#04. 단변량 분석

실습

2. 연속형 독립변수에 대한 단변량 분석

```python
for f in continuous_cols:
    fig, ax = my_plot.init(rows=1, cols=2, width=960, height=640,
                           title=f"독립변수 {f}({column_means[f]}) 분포")
    my_plot.histplot(data=df, x=f, kde=True, ax=ax[0])
    my_plot.boxplot(data=df, x=f, ax=ax[1])
    my_plot.show()

    display(num_desc[num_desc.index == f].T)
```

Python

결과는 다음 페이지에 제시합니다.

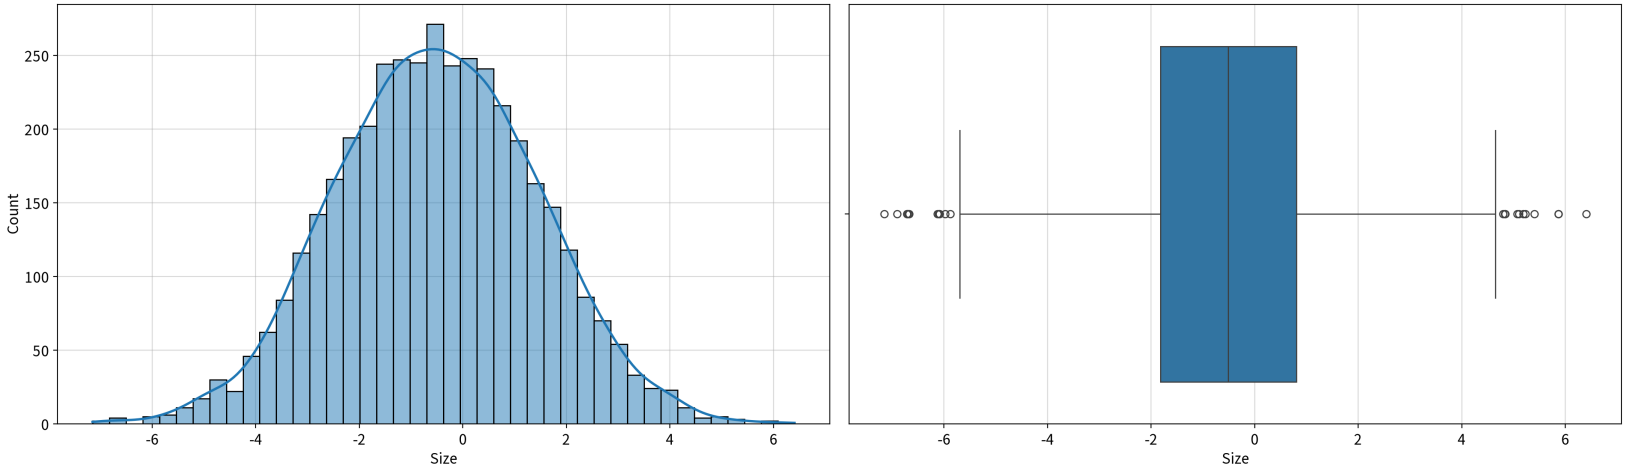
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

2. 연속형 독립변수에 대한 단변량 분석 (결과 확인 1/7) → Size

	Size
count	4000.000
mean	-0.503
std	1.928
min	-7.152
25%	-1.817
50%	-0.514
75%	0.806
max	6.406
rel_diff	-0.021
rdiff_flag	similar
iqr	2.622
upper_bound	4.739
lower_bound	-5.750
upper_outliers	11
upper_outliers_ratio	0.003
lower_outliers	11
lower_outliers_ratio	0.003
outliers	22
outliers_ratio	0.005
skew	-0.002
skew_interpret	symmetric
kurt	-0.083
kurt_interpret	platykurtic
log_need	none

독립변수 Size(크기) 분포



변수	Size
분포 모양(왜도)	대칭 (−0.002)
봉우리 수	단봉
이상치	22건 (0.5%)
판단·조치	변환 불필요

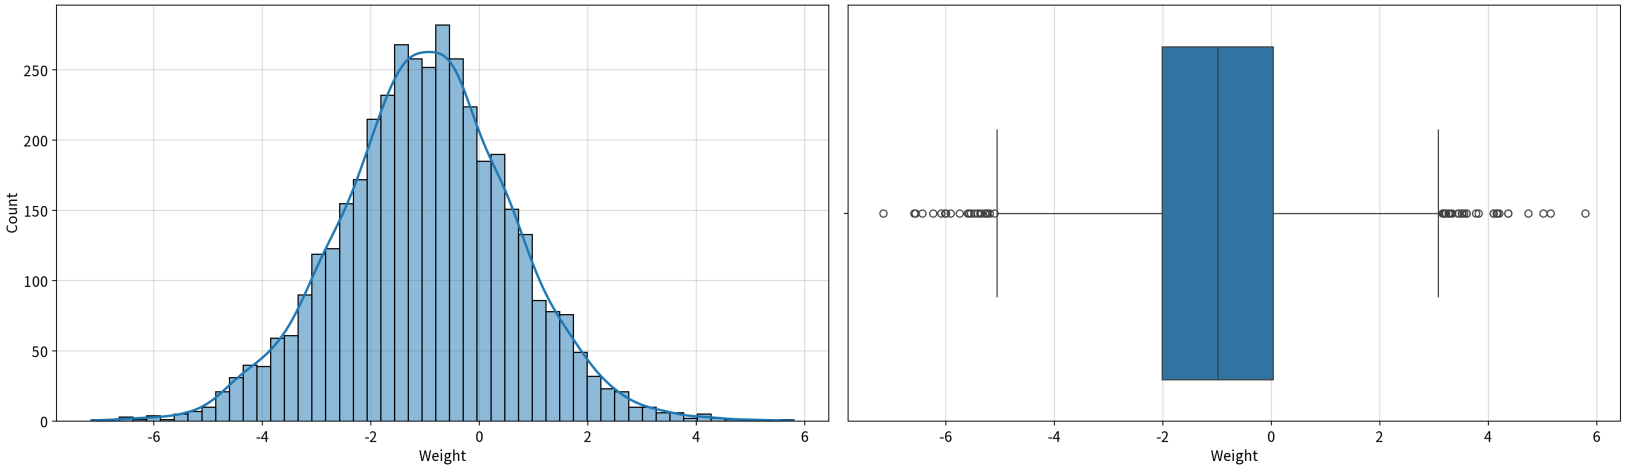
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

2. 연속형 독립변수에 대한 단변량 분석 (결과 확인 2/7) → Weight

	Weight
count	4000.000
mean	-0.990
std	1.603
min	-7.150
25%	-2.012
50%	-0.985
75%	0.031
max	5.791
rel_diff	-0.005
rdiff_flag	similar
iqr	2.043
upper_bound	3.095
lower_bound	-5.076
upper_outliers	31
upper_outliers_ratio	0.008
lower_outliers	23
lower_outliers_ratio	0.006
outliers	54
outliers_ratio	0.013
skew	0.003
skew_interpret	symmetric
kurt	0.359
kurt_interpret	leptokurtic
log_need	none

독립변수 Weight(무게) 분포



변수	Weight
분포 모양(왜도)	대칭 (+0.003)
봉우리 수	단봉
이상치	54건 (1.3%)
판단·조치	변환 불필요

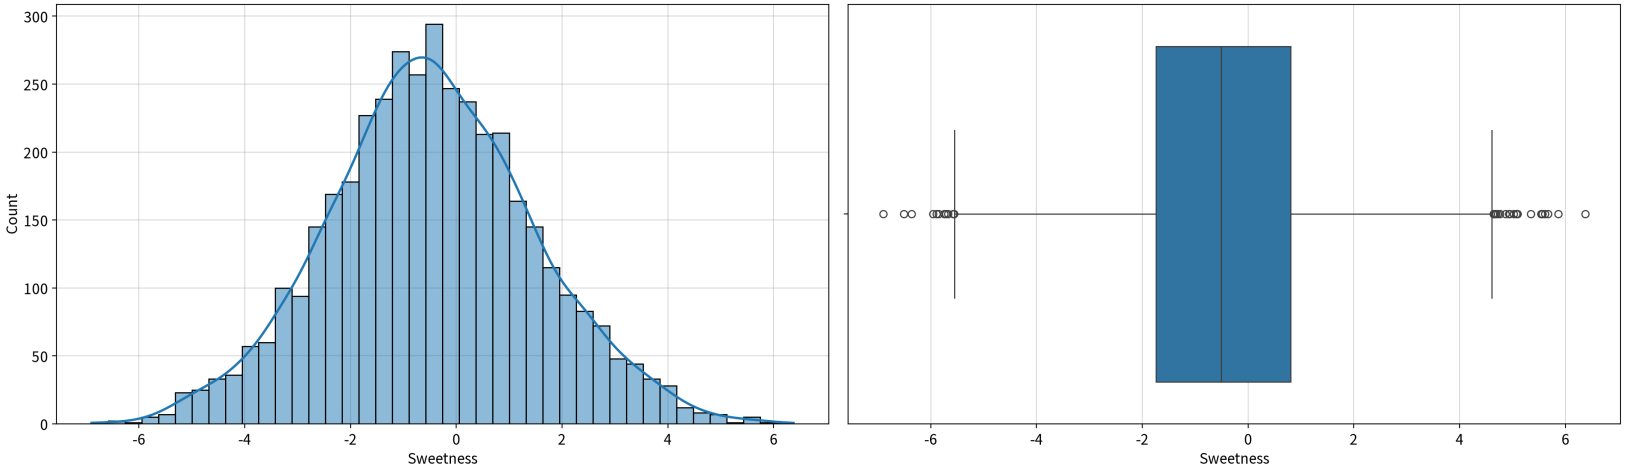
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

2. 연속형 독립변수에 대한 단변량 분석 (결과 확인 3/7) → Sweetness

	Sweetness
count	4000.000
mean	-0.470
std	1.943
min	-6.894
25%	-1.738
50%	-0.505
75%	0.802
max	6.375
rel_diff	-0.068
rdiff_flag	similar
iqr	2.540
upper_bound	4.612
lower_bound	-5.549
upper_outliers	21
upper_outliers_ratio	0.005
lower_outliers	11
lower_outliers_ratio	0.003
outliers	32
outliers_ratio	0.008
skew	0.084
skew_interpret	symmetric
kurt	0.014
kurt_interpret	leptokurtic
log_need	none

독립변수 Sweetness(단맛 정도) 분포



변수	Sweetness
분포 모양(왜도)	대칭 (+0.084)
봉우리 수	단봉
이상치	32건 (0.8%)
판단·조치	변환 불필요

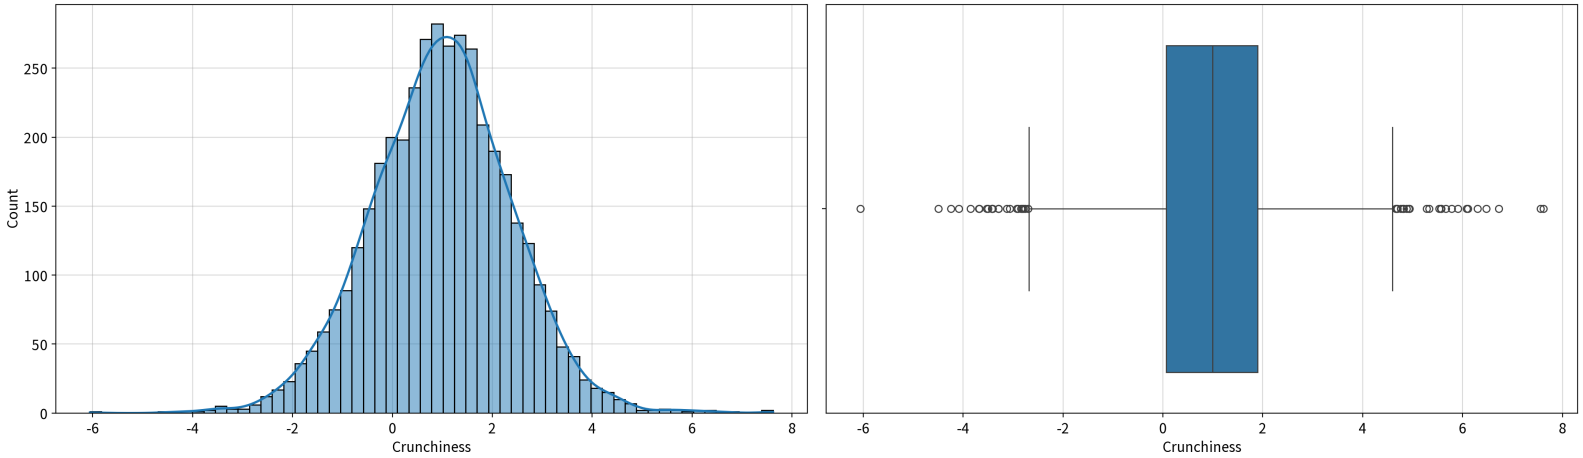
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

2. 연속형 독립변수에 대한 단변량 분석 (결과 확인 4/7) → Crunchiness

	Crunchiness
count	4000.000
mean	0.985
std	1.403
min	-6.055
25%	0.063
50%	0.998
75%	1.894
max	7.620
rel_diff	0.013
rdiff_flag	similar
iqr	1.831
upper_bound	4.641
lower_bound	-2.684
upper_outliers	24
upper_outliers_ratio	0.006
lower_outliers	23
lower_outliers_ratio	0.006
outliers	47
outliers_ratio	0.012
skew	0.000
skew_interpret	symmetric
kurt	0.722
kurt_interpret	leptokurtic
log_need	none

독립변수 Crunchiness(아삭한 식감) 분포



변수	Crunchiness
분포 모양(왜도)	대칭 (0.000)
봉우리 수	단봉
이상치	47건 (1.2%)
판단·조치	변환 불필요

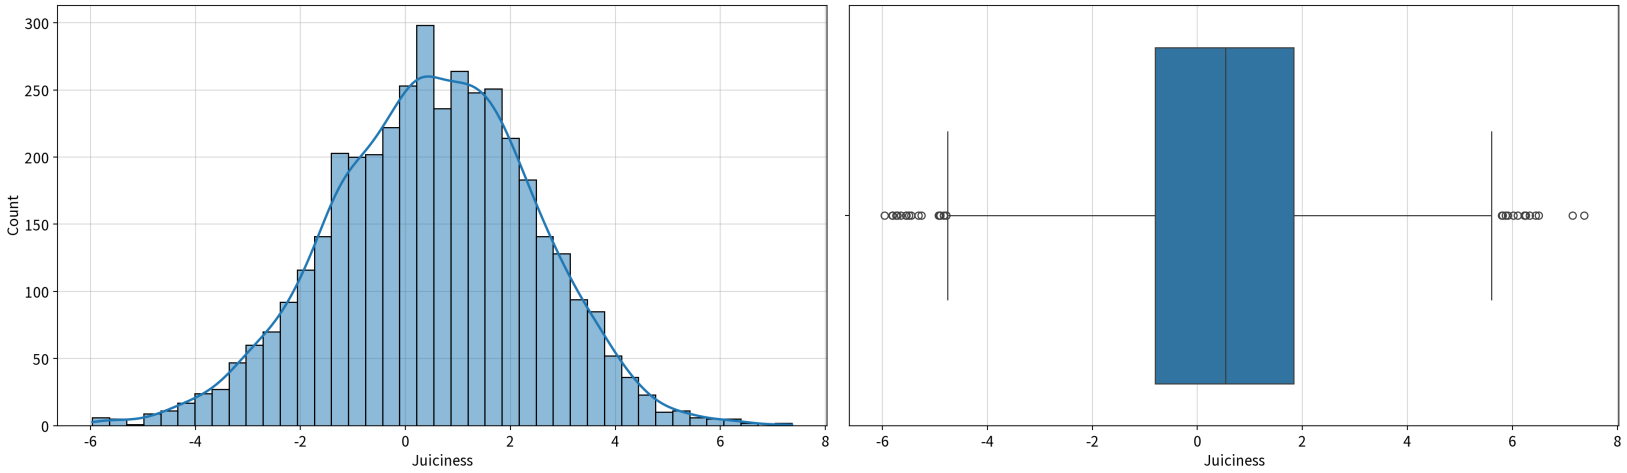
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

2. 연속형 독립변수에 대한 단변량 분석 (결과 확인 5/7) → Juiciness

	Juiciness
count	4000.000
mean	0.512
std	1.930
min	-5.962
25%	-0.801
50%	0.534
75%	1.836
max	7.364
rel_diff	0.041
rdiff_flag	similar
iqr	2.637
upper_bound	5.792
lower_bound	-4.757
upper_outliers	14
upper_outliers_ratio	0.004
lower_outliers	18
lower_outliers_ratio	0.004
outliers	32
outliers_ratio	0.008
skew	-0.113
skew_interpret	symmetric
kurt	0.029
kurt_interpret	leptokurtic
log_need	none

독립변수 Juiciness(과즙 함량) 분포



변수	Juiciness
분포 모양(왜도)	대칭 (−0.113)
봉우리 수	단봉
이상치	32건 (0.8%)
판단·조치	변환 불필요

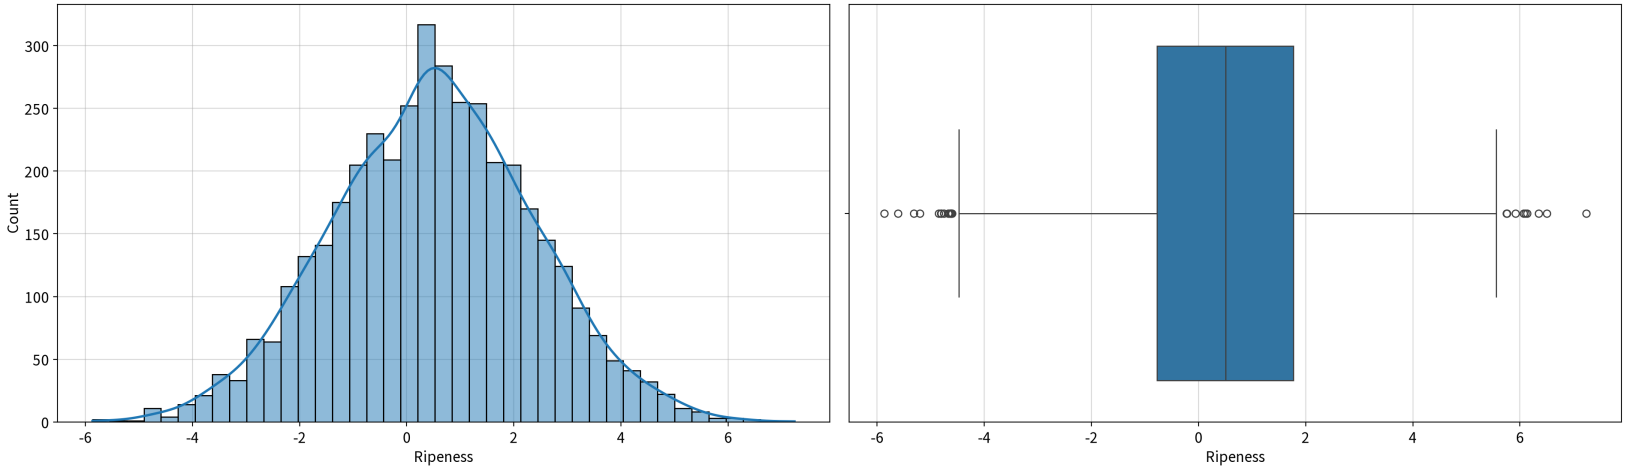
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

2. 연속형 독립변수에 대한 단변량 분석 (결과 확인 6/7) → Ripeness

	Ripeness
count	4000.000
mean	0.498
std	1.874
min	-5.865
25%	-0.772
50%	0.503
75%	1.766
max	7.238
rel_diff	0.010
rdiff_flag	similar
iqr	2.538
upper_bound	5.573
lower_bound	-4.579
upper_outliers	9
upper_outliers_ratio	0.002
lower_outliers	15
lower_outliers_ratio	0.004
outliers	24
outliers_ratio	0.006
skew	-0.009
skew_interpret	symmetric
kurt	-0.072
kurt_interpret	platykurtic
log_need	none

독립변수 Ripeness(익은 정도) 분포



변수	Ripeness
분포 모양(왜도)	대칭 (−0.009)
봉우리 수	단봉
이상치	24건 (0.6%)
판단·조치	변환 불필요

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

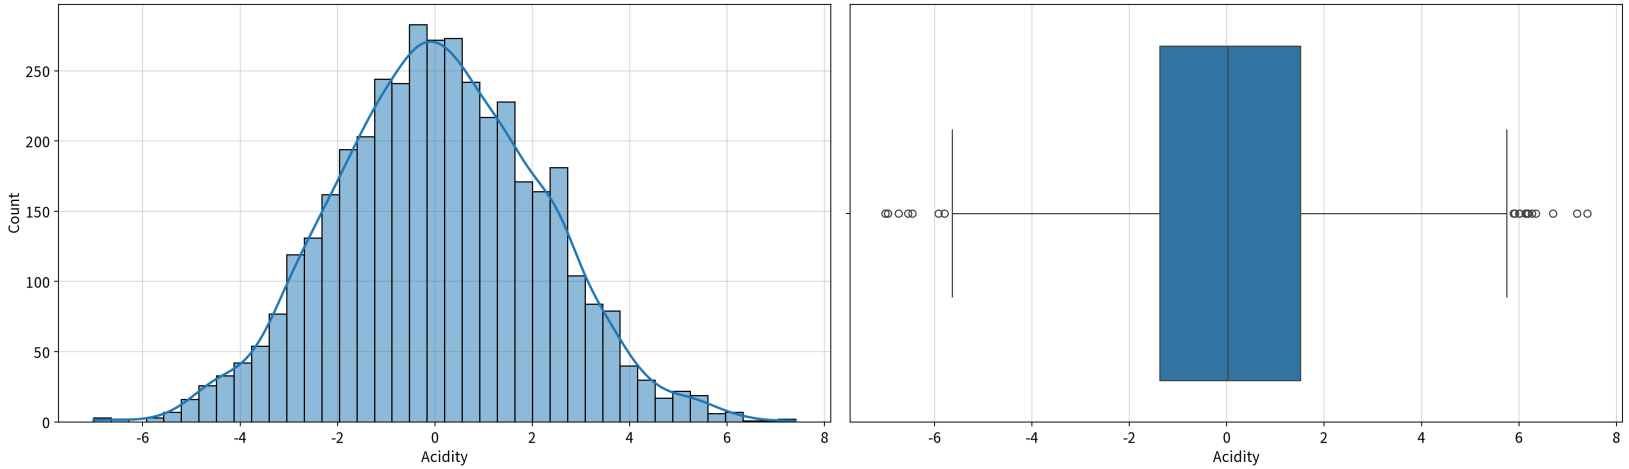


#04. 단변량 분석

2. 연속형 독립변수에 대한 단변량 분석 (결과 확인 7/7) → Acidity

	Acidity
count	4000.000
mean	0.077
std	2.110
min	-7.011
25%	-1.377
50%	0.023
75%	1.510
max	7.405
rel_diff	2.400
rdiff_flag	large_diff
iqr	2.888
upper_bound	5.842
lower_bound	-5.709
upper_outliers	13
upper_outliers_ratio	0.003
lower_outliers	7
lower_outliers_ratio	0.002
outliers	20
outliers_ratio	0.005
skew	0.056
skew_interpret	symmetric
kurt	-0.093
kurt_interpret	platykurtic
log_need	none

독립변수 Acidity(산도) 분포



변수	Acidity
분포 모양(왜도)	대칭 (+0.056)
봉우리 수	단봉
이상치	20건 (0.5%)
판단·조치	변환 불필요

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수)

◎ 선형회귀에서 **상관분석**이 하던 역할(**"이 독립변수가 종속변수와 관련이 있는가"**)을 로지스틱 회귀에서는 **T검정**이 맡는다.

```
# 연속형 독립변수 이름을 탐색하면서 반복
for f in continuous_cols:
    # 빈 줄 출력용
    print()

    # 분석 단위 제목 출력
    display(Markdown(f"#### ▶ {f}({column_means[f]}) → {target}"))

    # 수집된 데이터가 long 타입이므로 검정 대상만 wide 타입으로 변환해야 한다.
    # -> 선형회귀 때와 hue/values 가 서로 뒤바뀐다. (종속변수가 집단 기준이 되므로)
    wide_df = my_prep.long2wide(df, hue=target, values=f)
    display(my_stats.test_independent(wide_df,
                group1=wide_df.columns[0], group2=wide_df.columns[1], plot=False))

    # 시각화: 종속변수 집단별 분포 비교
    my_plot.boxplot(data=df, x=target, y=f, hue=target, palette="Set2",
                    width=720, height=400)
```

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

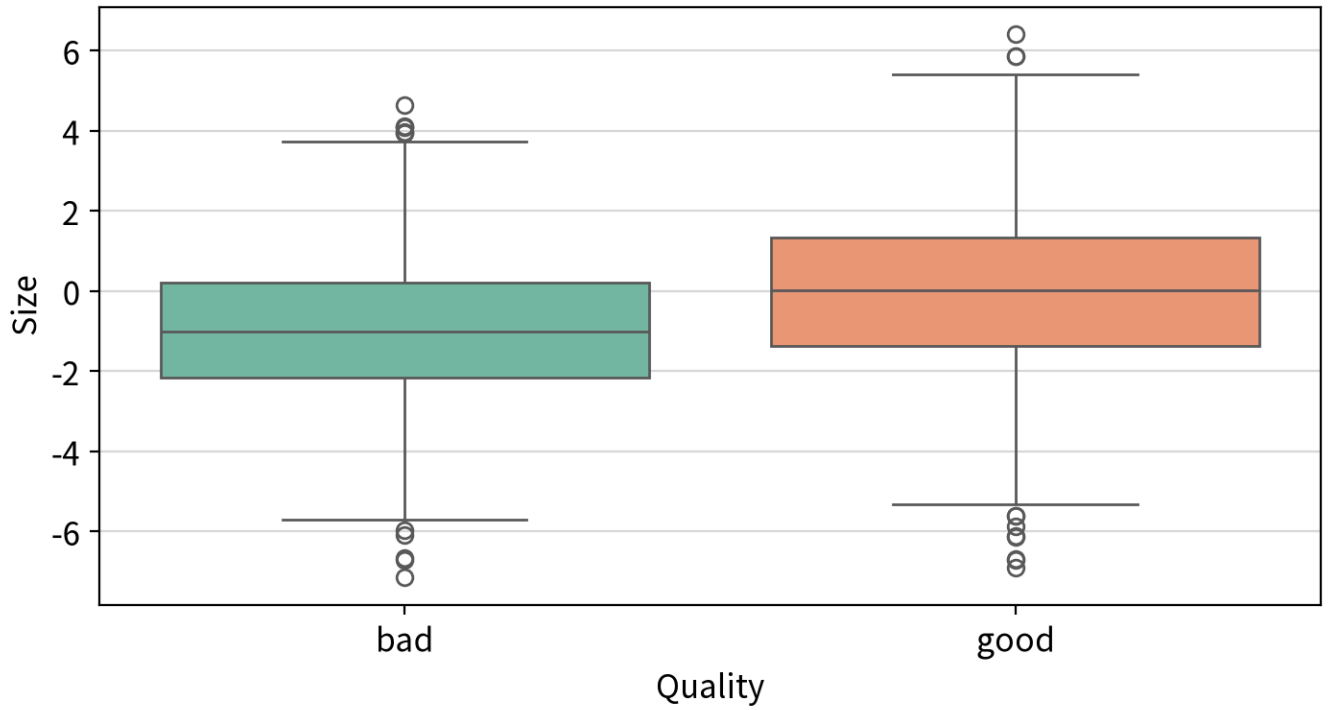
#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과확인 1/7)

▶ Size(크기) → Quality

		statistic	p-value	significant	result
test	alternative				
Mann-Whitney U test	two-sided	1433524.000	0.000	True	bad ≠ good
	less	1433524.000	0.000	True	bad < good
	greater	1433524.000	1.000	False	bad ≤ good



변수	Size
검정 방법	Mann-Whitney U
유의확률	< 0.001
집단 차이	유의
방향	bad < good
단독 채택	채택

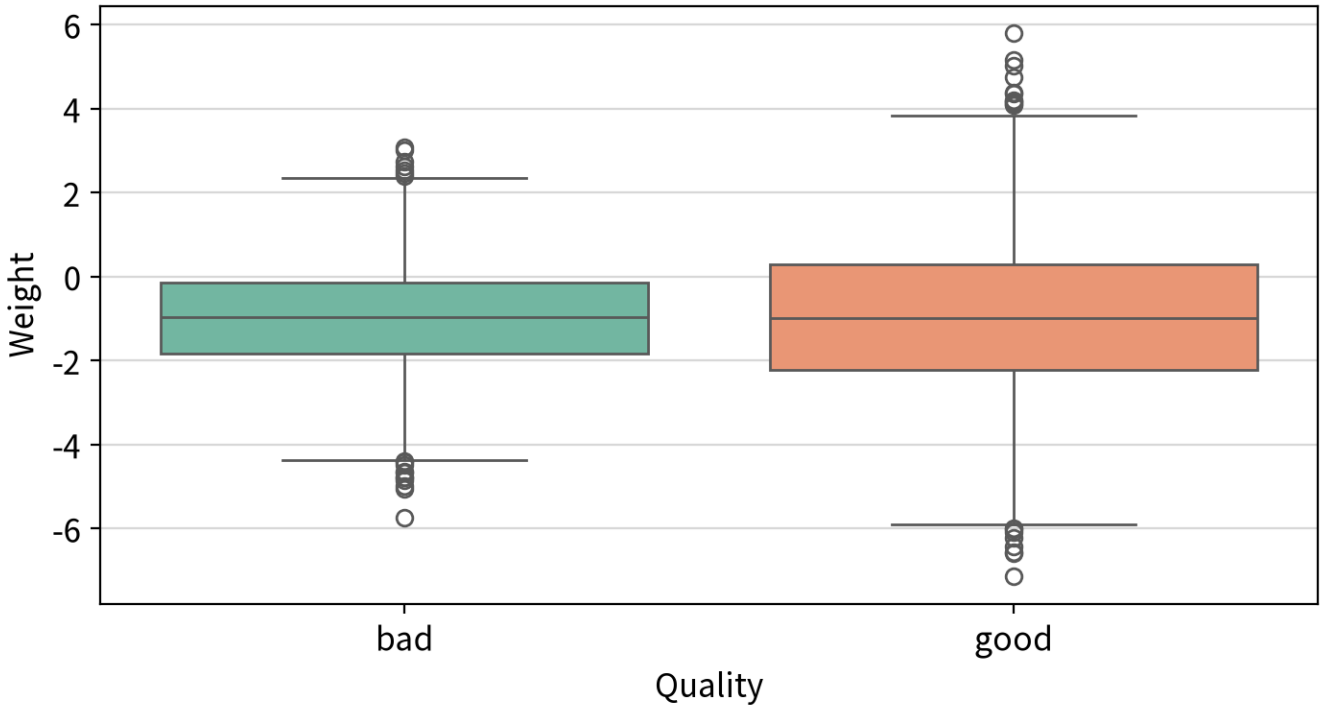
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#05. 이변량 분석

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과확인 2/7)

▶ Weight(무게) → Quality

test	alternative	statistic	p-value	significant	result
Welch t-test	two-sided	-0.090	0.928	False	bad = good
	less	-0.090	0.464	False	bad ≥ good
	greater	-0.090	0.536	False	bad ≤ good



변수	Weight
검정 방법	T검정 (Welch)
유의확률	0.928
집단 차이	차이 없음
방향	—
단독 채택	보류

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

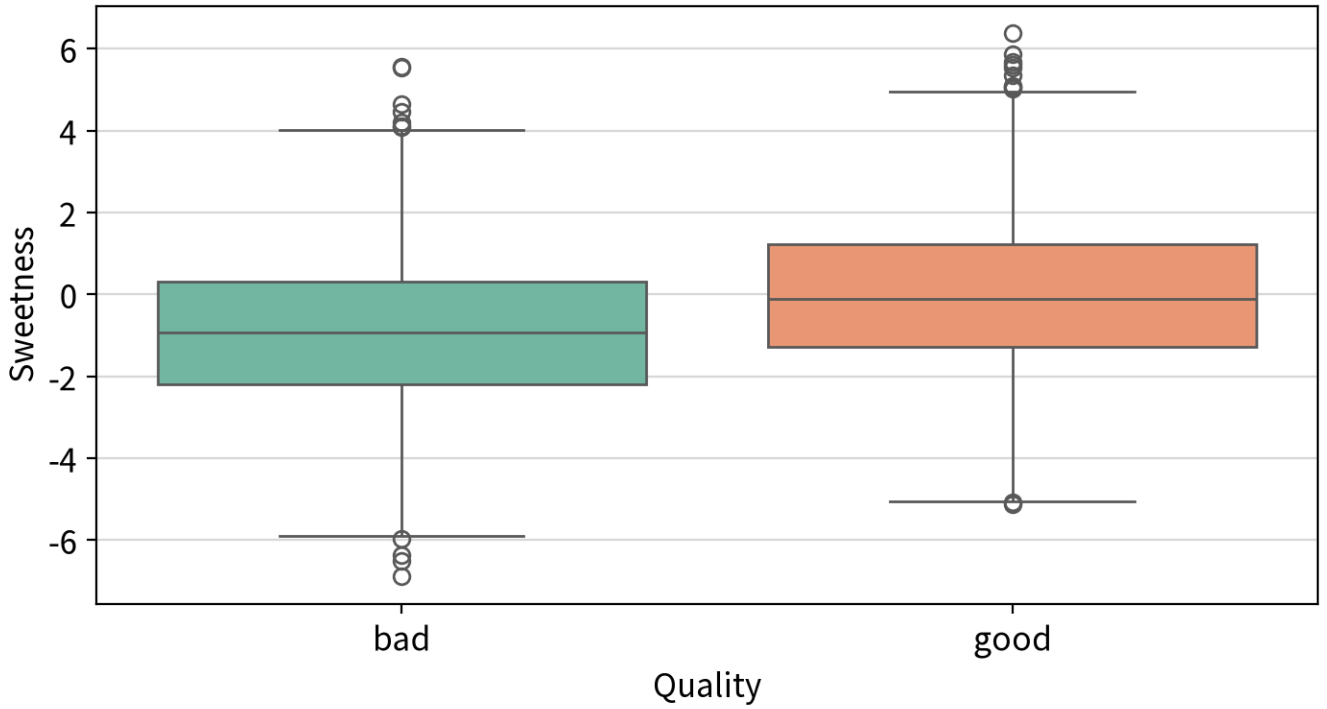
#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과확인 3/7)

▶ Sweetness(단맛 정도) → Quality

		statistic	p-value	significant	result
test	alternative				
Mann-Whitney U test	two-sided	1452149.000	0.000	True	bad ≠ good
	less	1452149.000	0.000	True	bad < good
	greater	1452149.000	1.000	False	bad ≤ good



변수	Sweetness
검정 방법	Mann-Whitney U
유의확률	< 0.001
집단 차이	유의
방향	bad < good
단독 채택	채택

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

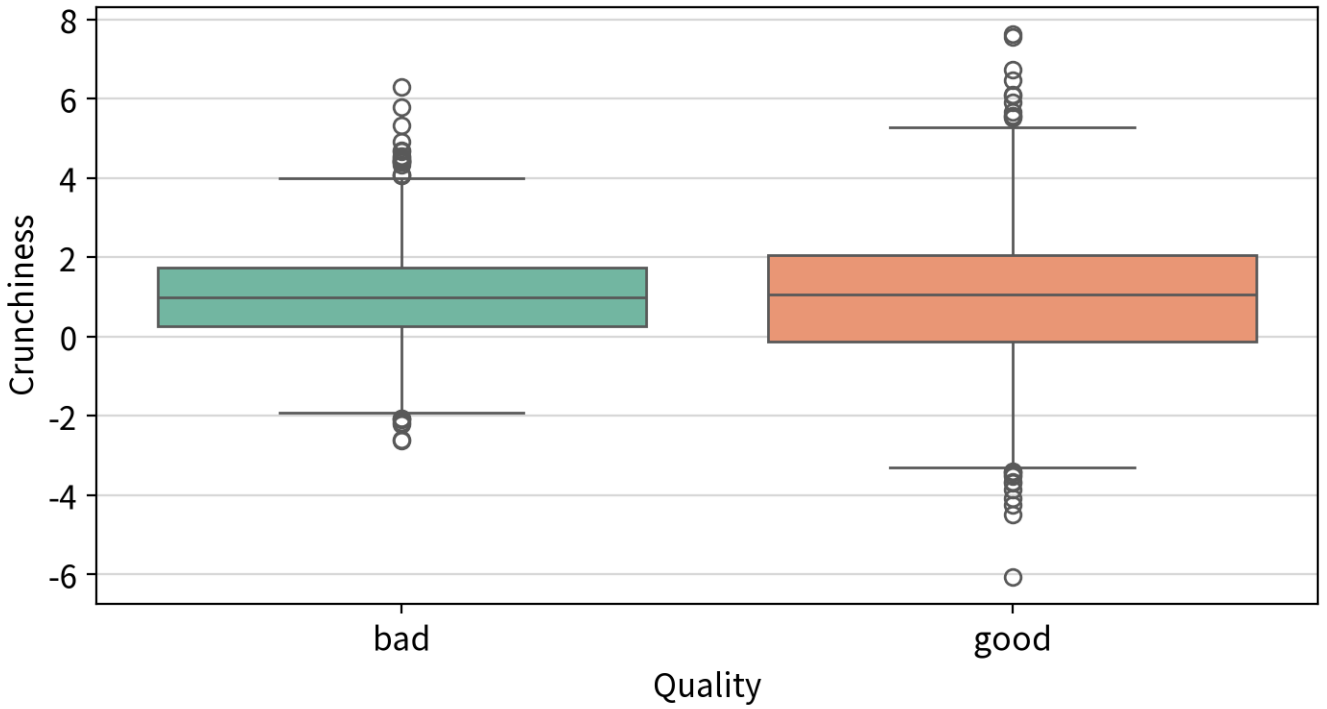
#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과확인 4/7)

▶ Crunchiness(아삭한 식감) → Quality

test	alternative	statistic	p-value	significant	result
Mann-Whitney U test	two-sided	1999316.000	0.985	False	bad = good
	less	1999316.000	0.493	False	bad ≥ good
	greater	1999316.000	0.507	False	bad ≤ good



변수	Crunchiness
검정 방법	Mann-Whitney U
유의확률	0.985
집단 차이	차이 없음
방향	—
단독 채택	보류

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



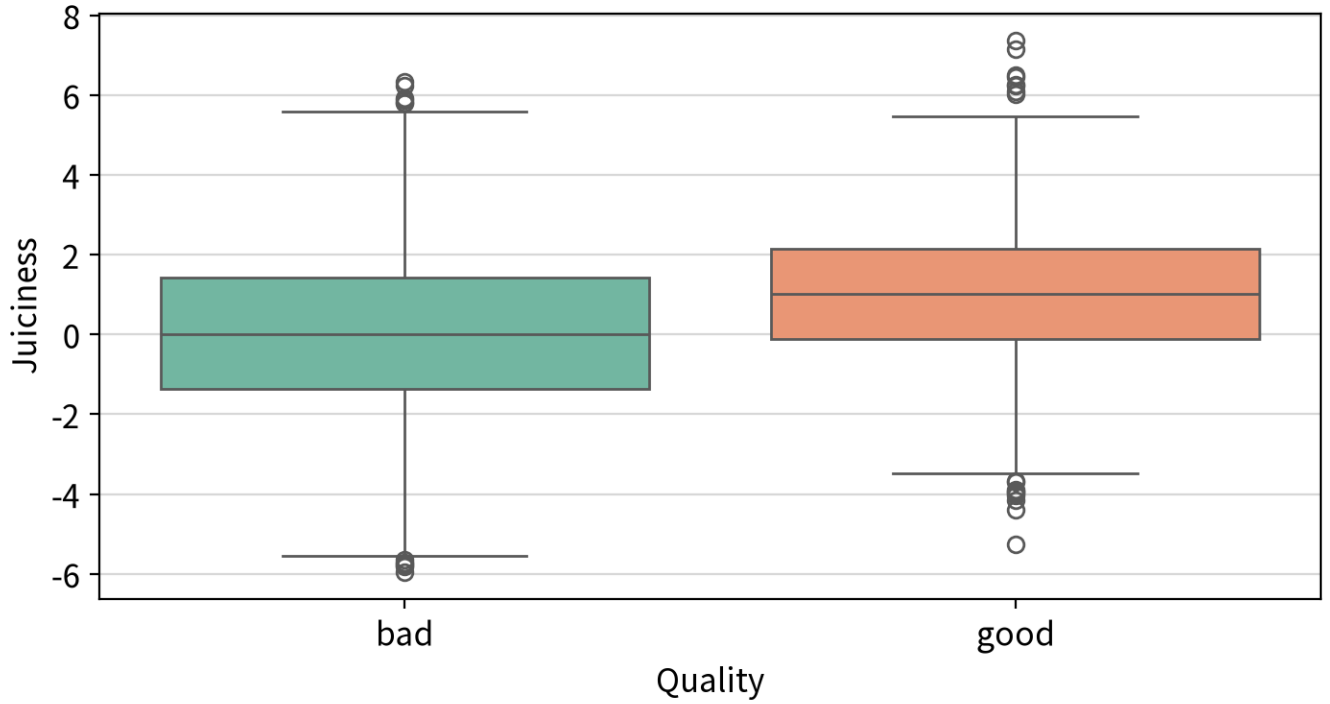
#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과확인 5/7)

▶ Juiciness(과즙 함량) → Quality

test	alternative	statistic	p-value	significant	result
Welch t-test	two-sided	-17.035	0.000	True	bad ≠ good
	less	-17.035	0.000	True	bad < good
	greater	-17.035	1.000	False	bad ≤ good



변수	Juiciness
검정 방법	T검정
유의확률	< 0.001
집단 차이	유의
방향	bad < good
단독 채택	채택

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

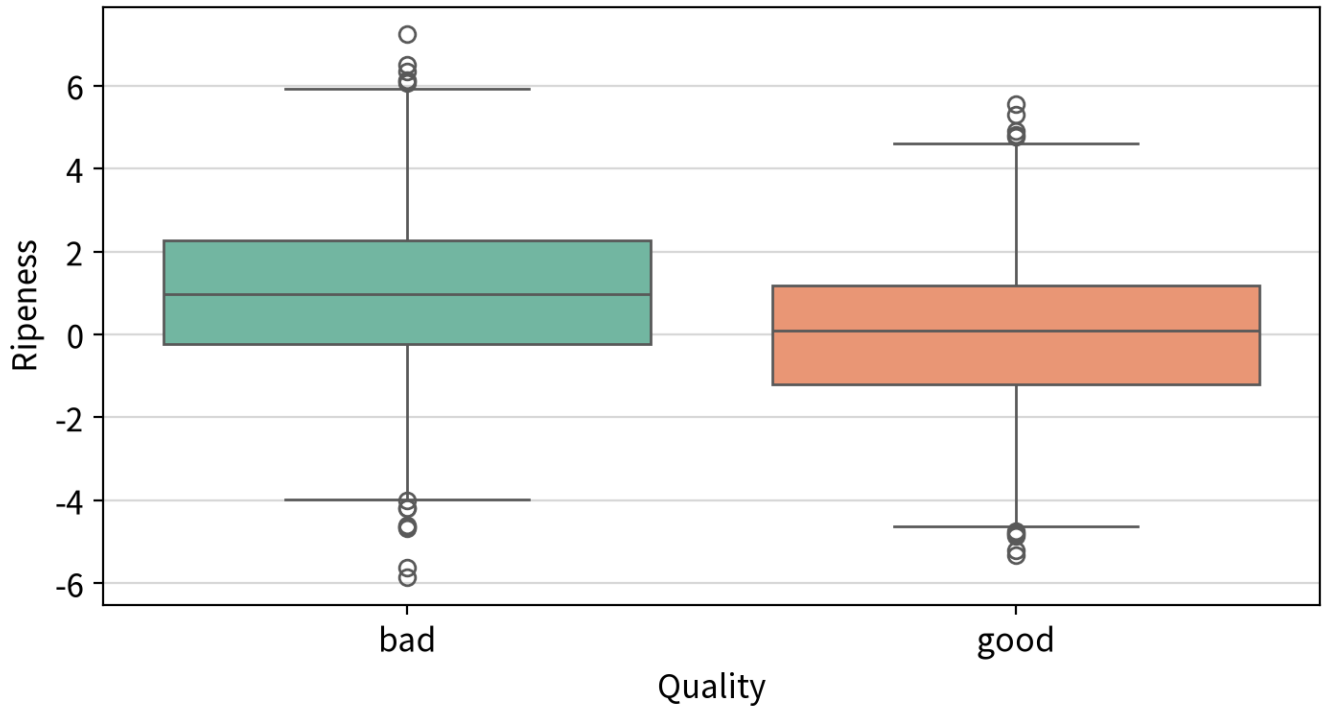
#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과확인 6/7)

▶ Ripeness(익은 정도) → Quality

		statistic	p-value	significant	result
test	alternative				
Welch t-test	two-sided	17.326	0.000	True	bad ≠ good
	less	17.326	1.000	False	bad ≥ good
	greater	17.326	0.000	True	bad > good



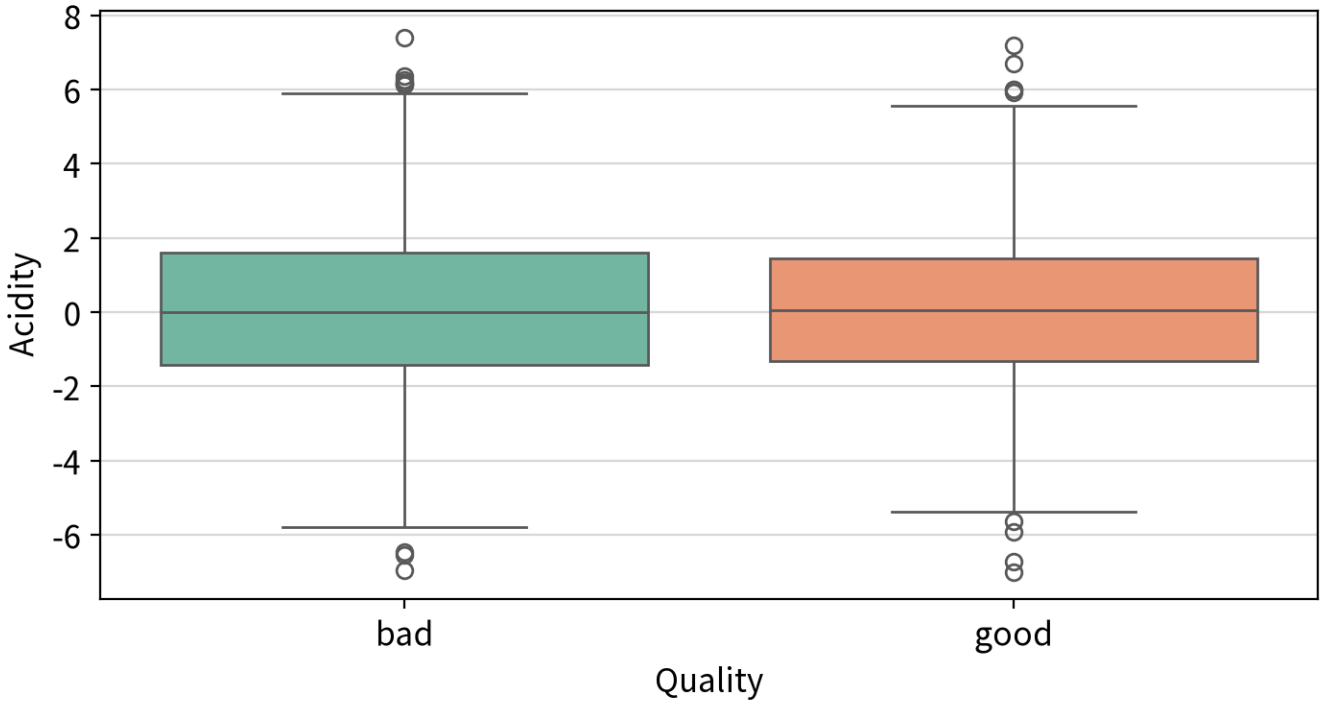
변수	Ripeness
검정 방법	T검정
유의확률	< 0.001
집단 차이	유의
방향	bad > good
단독 채택	채택

#05. 이변량 분석

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과확인 7/7)

▶ Acidity(산도) → Quality

test	alternative	statistic	p-value	significant	result
Mann-Whitney U test	two-sided	1990597.000	0.797	False	bad = good
	less	1990597.000	0.399	False	bad ≥ good
	greater	1990597.000	0.602	False	bad ≤ good



변수	**Acidity**
검정 방법	Mann-Whitney U
유의확률	0.797
집단 차이	차이 없음
방향	—
단독 채택	보류

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#05. 이변량 분석

실습

□ 2. 교차분석 (x: 명목형 독립변수 → y: 명목형 종속변수)

◎ 명목형 독립변수가 있을 경우 카이제곱 독립성 검정을 수행한다.

◎ 명목형 독립변수가 없을 경우 출력 결과가 없을 수 있다.

```python
for n in nominal_cols:
    # 빈 줄 출력용
    print()

    # 분석 단위 제목 출력
    display(Markdown(f"#### ▶ {n}({column_means[n]}) → {target}"))

    # 교차분석 (카이제곱 독립성 검정)
    display(my_stats.chi2_independence(df, x=n, y=target, plot=False))
```

Python

이 셀은 출력 결과가 없습니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#06. 다변량 분석

실습

1. 독립변수간 상관분석

◎ 연속형 독립변수끼리는 종속변수가 명목형이어도 상관분석을 그대로 쓸 수 있다.

◎ 목적이 다르다. 여기서는 설명력 확인이 아니라 다중공선성 점검이다.

```python
corr = my_stats.multi_correlation(df, columns=continuous_cols, plot=False)
my_stats.correlation_summary(corr)
```

Python

	Size	Weight	Sweetness	Crunchiness	Juiciness	Ripeness	Acidity
Size	1.000	-0.144	-0.325	0.172	-0.032	-0.155	0.210
Weight	-0.144	1.000	-0.120	-0.087	-0.091	-0.244	0.030
Sweetness	-0.325	-0.120	1.000	-0.017	0.098	-0.255	0.072
Crunchiness	0.172	-0.087	-0.017	1.000	-0.236	-0.184	0.074
Juiciness	-0.032	-0.091	0.098	-0.236	1.000	-0.124	0.231
Ripeness	-0.155	-0.244	-0.255	-0.184	-0.124	1.000	-0.195
Acidity	0.210	0.030	0.072	0.074	0.231	-0.195	1.000

	max-y	max-coef	count	columns
x				
Size	Sweetness	-0.325	0	-
Sweetness	Size	-0.325	0	-
Ripeness	Sweetness	-0.255	0	-
Weight	Ripeness	-0.244	0	-
Crunchiness	Juiciness	-0.236	0	-
Juiciness	Crunchiness	-0.236	0	-
Acidity	Juiciness	0.231	0	-

Strong($|r| \geq 0.7$) 조합이 하나도 나오지 않았다.

→ **다중공선성 문제 없음.**

→ 7개 변수를 모두 투입해도 계수가 불안정해지지 않는다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



단계 4: 최종 변수 선택

□ EDA 결과를 채택 / 보류 / 제외 3분류로 기록하고, 제외 대상만 실제로 뺀다.

EDA 결과 ▶

채택
집단 간 차이가 확인된 변수
모델에 투입

보류
검정에서 유의하지 않은 변수
모델에 투입

제외
식별자처럼 분석 대상이 아닌 변수
실제로 뺀다

순서를 어기면
이 단계의 검정은 **다른 변수를 통제하지 않은 단독 비교**다.
여기서 자르면 **되살아날 변수를 놓친다**.

실행 규칙
제외는 **식별자처럼 분석 대상이 아닌 변수만** 해당한다.
검정에서 유의하지 않게 나온 변수는 **"보류"로 분류해 모델에 투입**한다.

변수 제거의 판정 시점
변수 제거의 판정 시점은 **EDA가 아니라 모델 적합 이후**다.
단계 4에서는 **분류를 기록**하는 데서 멈추고, 실제 판정은 단계 5의 기준선 모형과 단계 7의 후진소거로 넘긴다.

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



최종 변수 선택 결과

채택여부	변수	검정방법	유의확률	방향	공선성 신호	근거
채택	Size	Mann-Whitney U	< 0.001	bad < good	X (VIF 1.41)	집단 차이 유의
채택	Sweetness	Mann-Whitney U	< 0.001	bad < good	X (VIF 1.48)	집단 차이 유의
채택	Juiciness	T검정	< 0.001	bad < good	X (VIF 1.22)	집단 차이 유의
채택	Ripeness	T검정	< 0.001	bad > good	X (VIF 1.48)	집단 차이 유의 (유일한 음의 방향)
보류	Weight	T검정	0.928	—	X (VIF 1.35)	단독 차이 없음, 억제효과 가능성 → 투입 후 계수로 판정
보류	Acidity	Mann-Whitney U	0.797	—	X (VIF 1.17)	단독 차이 없음, 억제효과 가능성 → 투입 후 계수로 판정
보류	Crunchiness	Mann-Whitney U	0.985	—	X (VIF 1.22)	단독 차이 없음, 억제효과 가능성 → 투입 후 계수로 판정
제외	A_id	—	—	—	—	행마다 값이 다른 식별자 (#02에서 제거)

- **제외는 A_id 하나뿐**이다. 나머지 7종은 전부 모델에 투입한 뒤 **후진소거법으로 판정**한다.
- 이유 — 공선성이 없어 변수를 다 넣어도 부작용이 없고, T검정에서 탈락한 3종은 **다른 변수를 통제했을 때 살아날 수 있기 때문**이다.

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



연습문제 사과 품질 분류 데이터셋 활용 로지스틱 회귀 #01

□ 탐색적 데이터 분석을 수행하고 다음 물음에 답하시오.

6. 종속변수를 제외하고 나면, 탐색적 분석의 대상이 되는 연속형 독립변수는 몇 개인가요? (정수 1개)
7. 종속변수를 제외하고 나면, 명목형 독립변수는 몇 개인가요? (정수 1개)
8. 척도 조합표의 아홉 가지 경우 중, 이 데이터에서 실제로 수행되는 분석 유형은 무엇인가요? (분석 기법 이름 1개)
9. 종속변수의 두 범주 중 더 많이 나타나는 쪽은 무엇인가요? (범주값 1개)
10. 그 최빈 범주가 전체에서 차지하는 비율은 얼마인가요? (소수 셋째 자리)
11. 7가지 연속형 독립변수 중 분포의 비대칭이 가장 큰(왜도의 절댓값이 가장 큰) 항목은 무엇인가요? (변수명 1개)
12. 각 측정 항목이 good / bad 판정과 관련이 있는지 하나씩 검정했을 때, 두 집단 사이에 차이가 가장 없다고 나온 항목은 무엇인가요? (변수명 1개)
13. 유의수준 5% 기준으로, 두 집단 사이에 차이가 유의하다고 판정된 항목은 몇 개인가요? (정수 1개)
14. 유의하다고 판정된 4개 항목 중, 유일하게 bad 집단의 평균이 더 큰 항목은 무엇인가요? (변수명 1개)
15. 검정 전에 정규성과 등분산성을 먼저 확인하기 때문에, 항목마다 적용되는 검정 방법이 달라집니다. 정규성 가정을 만족하지 못해 순위 기반 비모수 검정으로 판정된 항목은 몇 개인가요? (정수 1개)
16. 연속형 독립변수끼리 상관관계를 확인했을 때, 강한 상관(절댓값 0.7 이상)으로 분류된 조합은 몇 개인가요? (정수 1개)
17. 독립변수 조합 중 상관계수의 절댓값이 가장 큰 값은 얼마인가요? (부호를 포함해 소수 셋째 자리)
18. 이변량 분석 결과만으로 곧바로 채택할 수 있는 변수는 몇 개인가요? (정수 1개)
19. 단독 비교에서는 차이가 없었지만, 제거하지 않고 보류로 두는 변수는 몇 개인가요? (정수 1개)
20. 결국 모델에 투입되는 독립변수는 모두 몇 개인가요? (정수 1개)