[LAB-10] 06. [PBT] 로지스틱 회귀 파이프라인 (2) - 연습문제

4. 가정확인

문제 21

종속변수 `Quality` 를 0/1로 라벨링했을 때, `good` 에 부여되는 숫자는 무엇인가요? (정수 1개)

정답. `1`

해설. `my_prep.labeling()` 은 **알파벳 순서**로 0부터 매기므로 `bad = 0` , `good = 1` 이 됨.

이 방향이 이후 모든 해석을 결정함. 모형이 예측하는 것은 **P(Quality = good)** 이고, 뒤에 나오는 오즈비는 전부 "사과가 `good` 일 오즈"에 대한 값임. 만약 라벨이 반대로 붙었다면 모든 오즈비가 역수가 되어 결론이 뒤집힘.

문제 22

7개 변수를 모두 넣은 기준선 모형에서, 유의수준 5% 기준으로 유의하지 않은 독립변수는 몇 개인가요? (정수 1개)

정답. `1`

해설. `Crunchiness` **하나뿐**임($p = 0.253$). 나머지 6종은 모두 $p < 0.001$로 유의함.

이변량 분석에서는 3종(`Weight` · `Acidity` · `Crunchiness`)이 무관했는데, 모형에 넣으니 탈락 후보가 1종으로 줄었음. 단독 비교와 다변량 모형은 다른 질문에 답한다는 뜻임.

문제 23

이변량 분석(T검정)에서 유의확률 0.797로 "차이가 없다"고 나왔지만, 기준선 모형에서는 $z = -13.70$으로 강하게 유의해진 변수는 무엇인가요? (변수명 1개)

정답. `Acidity`

해설. T검정 $p = 0.797$ → 기준선 모형 $p < 0.001$로 **완전히 뒤집힘.** 오즈비는 **0.745**로, 산도가 1점 높아지면 `good` 일 오즈가 약 **25.5% 감소**함.

`Weight` 도 같은 일이 벌어짐(T검정 $p = 0.928$ → $z = 9.40$).

즉 EDA에서 유의하지 않다는 이유만으로 변수를 버렸다면, 강력한 예측 변수 2개를 통째로 잃었을 것임.

문제 24

문제 23처럼 단독 비교에서는 효과가 가려져 있다가 다른 변수를 통제하자 드러나는 현상을 무엇이라 하나요? (용어 1개)

정답. 억제효과

해설. 억제효과(suppression)임. 다른 변수가 만들어내는 변동을 걷어내야 비로소 그 변수의 순수한 효과가 보이는 경우임.

이것이 "탐색적 분석 결과만으로 변수를 버리면 안 되는" 이유임. 변수 제거의 판정 시점은 EDA가 아니라 **모형 적합 이후**임.

문제 25

기준선 모형에서 표준화 계수(βstd)가 가장 큰 변수는 무엇인가요? (변수명 1개)

정답. `Size`

해설. `Size` **1.252**가 가장 크고, `Sweetness` 1.105, `Juiciness` 0.854 순임.

영향력 비교는 오즈비가 아니라 βstd로 함. 오즈비는 "그 변수 1점당" 값이라 변수마다 1점의 의미가 다르면 직접 비교할 수 없음. 값의 범위를 통일한 표준화 계수라야 크기를 견줄 수 있음.

문제 26

Box-Tidwell 검정 결과, 7종 중 로짓 선형성을 위배한 변수는 몇 종인가요? (정수 1개)

정답. `5`

해설. `Weight` · `Crunchiness` · `Juiciness` · `Acidity` · `Size` **5종**이 $p < 0.05$로 위배임.

로지스틱 회귀에서 "선형성"은 종속변수와의 직선 관계가 아니라 로짓과의 직선 관계임. 이것이 깨지면 모형이 표현할 수 있는 관계의 모양 자체가 데이터와 맞지 않는다는 뜻임.

문제 27

위배 정도가 가장 심한(검정통계량 z의 절댓값이 가장 큰) 변수는 무엇인가요? (변수명 1개)

정답. `Weight`

해설. `Weight` **z = 11.16**이 가장 크고, `Crunchiness` 9.85, `Juiciness` −8.08, `Acidity` −5.55, `Size` 4.32 순임.

처방은 위배가 가장 심한 것부터 하나씩 함. 한꺼번에 고치면 어느 처방이 무엇을 바꿨는지 알 수 없기 때문임.

문제 28

7종 중 선형성을 충족해 처방 대상에서 제외된 변수는 무엇인가요? (변수명 1개)

정답. `Sweetness`

해설. `Sweetness` ($p = 0.545$)와 `Ripeness` ($p = 0.295$) 둘 다 초기 검정은 통과했지만, **루프를 돌리는 도중 `Ripeness` 는 위배로 바뀌어 5라운드에서 처방됨.** 끝까지 원본으로 남은 것은 `Sweetness` 하나임.

초기 진단 결과가 최종 처방 목록이 아님을 보여주는 대목임.

문제 29

`Weight` 를 처방한 다음 라운드에서 다시 진단했을 때, 위배로 잡힌 변수는 몇 종인가요? (정수 1개)

정답. `5`

해설. 라운드 1도 5종, 라운드 2도 **5종**임. 하나를 고쳤는데도 **숫자가 줄지 않음.**

라운드별 위배 개수는 5 → 5 → 3 → 3 → 2 → 1 → 0으로 움직임. **한 변수를 고치면 다른 변수의 진단 결과가 함께 바뀌기 때문**이며, 이것이 처방 후 반드시 **재진단**을 해야 하는 이유임.

문제 30

루프가 종료되기까지 실제로 처방이 이루어진 라운드는 몇 번인가요? (정수 1개)

정답. `6`

해설. `Weight` → `Crunchiness` → `Juiciness` → `Acidity` → `Ripeness` → `Size` 순으로 **6개 라운드**에서 처방됐고, **7라운드에서 위배 변수가 사라져 종료**됨.

처방 순서도 눈여겨볼 만함. `Crunchiness` 는 T검정 p = 0.985(완전 무관), 기준선 모형 p = 0.253(제거 후보)이었는데 **선형성 진단에서는 두 번째로 심한 위배**로 잡힘.

문제 31

6종에 공통으로 채택된 처방 방법은 무엇인가요? (영문 1개)

정답. `square`

해설. 6종 모두 **제곱항 추가(square)** 로 처방됨. `recipe` 에 `method: square` 와 중심화 기준값이 함께 기록되어, 신규 데이터에도 **똑같은 기준으로** 재현할 수 있음.

기준값을 다시 계산하면 안 됨. 신규 데이터의 평균으로 중심화하면 학습 때와 어긋나 예측이 망가짐.

문제 32

제곱항과 함께 후보였던 로그 변환이 이 데이터에서는 한 번도 시도되지 않았습니다. 7종 모두가 포함하고 있어 로그를 쓸 수 없게 만든 값은 무엇인가요? (용어 1개)

정답. 음수

해설. `ln` 의 정의역은 양수인데 7종 모두 최솟값이 음수임(`Size` −7.152, `Weight` −7.150, `Acidity` −7.011 …).

평행이동해서 억지로 쓸 수는 있지만 **이동량이 자의적이어서 계수 해석이 무너지므로** 기본 설정에서는 시도하지 않음 (`allow_shifted_log = False`).

> 참고 — 앞서 Box-Tidwell 검정에서 7종 모두 위치이동 `= True` 로 표시된 것도 같은 이유임. 검정을 위해 임시로 이동시킨 것이지, 모형에 그 값을 넣은 것은 아님.

문제 33

제곱항으로도 로그 변환으로도 해소되지 않아 구간화·스플라인이 필요하다고 기록된 변수는 몇 개인가요? (정수 1개)

정답. `0`

해설. `unresolved_` 가 **빈 목록**임. 위배 5종이 전부 제곱항으로 해소됨.

미해소가 나왔다면 그 변수는 원본 그대로 두고 한계점에 적어야 함. 해소되지 않았는데 억지로 처방하면 근거 없이 모형만 복잡해짐.

문제 34

Durbin-Watson 통계량은 얼마인가요? (소수 셋째 자리)

정답. `2.022`

해설. 기준 범위(1.5 ~ 2.5)의 **한가운데**라 독립성 만족임.

다만 **DW가 정상이라고 독립성이 보장되는 것은 아님.** 사과 4,000개가 서로 다른 개체이고 수집 순서에 의미가 없다는 **설계상의 근거**가 함께 있어야 함. 같은 나무에서 딴 사과가 섞여 있다면 DW가 정상이어도 독립이 아님.

문제 35

제곱항이 모형에 있으면 1차항이 유의하지 않아도 남겨야 한다는 원칙을 무엇이라 하나요? (용어 1개)

정답. 계층 원칙

해설. 계층 원칙(hierarchy principle)임. 1차항을 빼면 **곡선의 꼭짓점이 중심값에 고정**되어, 데이터가 말하는 곡선 모양이 왜곡되기 때문임.

후진소거법과 정면으로 충돌하는 지점임. 자동 규칙은 유의하지 않은 1차항을 지우려 하지만, 여기서는 통계적 원칙이 앞섬. 실제 판단은 #10의 성능 비교표에서 나란히 놓고 함.

6. 분석 파이프라인

문제 36

성능 비교를 위해 정의한 전처리 체크포인트는 모두 몇 개인가요? (정수 1개)

정답. `8`

해설. 가정 검정 미반영 4개(0 ~ 3번) + 가정 검정 반영 4개(4 ~ 7번) = **8개**임.

두 계열의 전처리 조합을 똑같이 맞춘 것이 핵심임. 그래야 다른 조건이 같은 상태에서 **로짓 선형성 처방만의 순수한 효과**를 읽을 수 있음.

문제 37

8개 체크포인트 전부에 공통으로 적용된 전처리 옵션은 무엇인가요? (옵션명 1개)

정답. `vif`

해설. 공선성 제거(`vif=True`)는 비교 대상에서 뺀 것이 아니라 **모든 체크포인트에 공통으로** 걸어 둔 것임. #06에서 이미 강한 상관 조합이 0개임을 확인했으므로 단계로 쪼갤 이유가 없기 때문임.

실제로 제거된 변수도 없음. 최대 VIF가 미반영 계열 1.48, 반영 계열 1.61로 기준(보통 10)에 한참 못 미침.

문제 38

가정 검정을 반영한 계열에서 후진소거법이 제거한 변수는 무엇인가요? (변수명 1개)

정답. `Crunchiness_c`

해설. `Crunchiness_c` (p = 0.787)가 제거됨. 미반영 계열에서는 원본 `Crunchiness` (p = 0.253)가 제거됐음.

문제는 `Crunchiness_c` 가 `Crunchiness_c2` 의 짝인 1차항이라는 점임. 짝을 지우면 계층 원칙 위반이므로, 이 자동 제거는 그대로 받아들이면 안 됨.

문제 39

정규화를 적용한 3번과 적용하지 않은 2번을 비교하면, 성능 지표 중 값이 달라지는 것은 몇 개인가요? (정수 1개)

정답. `0`

해설. 정확도·정밀도·재현율·F1·AUC·Pseudo R^2·AIC가 **전부 동일**함(0.749 / 0.741 / 0.766 / 0.754 / 0.823 / 0.257 / 4136.292). 반영 계열의 6번과 7번도 마찬가지임.

정규화는 계수의 척도만 바꿀 뿐 모형 자체를 바꾸지 않기 때문임. 로지스틱 회귀에서 스케일링은 성능 향상 수단이 아니라 **계수 비교를 편하게 하는 도구**임.

문제 40

AIC가 가장 낮은(가장 좋은) 모델의 이름은 무엇인가요? (모델명 1개)

정답. `5_가정반영+후진소거`

해설. AIC **3672.041**로 최소임. 그다음이 `4_가정반영` 3673.968임.

AUC 0.824 → 0.868, AIC 4128.9 → 3672.0. 이상치 대체·공선성 제거·정규화를 전부 합친 것보다 **로짓 선형성 처방 하나가 압도적으로 큰 개선**을 만들었음. 기계적 전처리는 잡음을 다듬는 일이지만, 제곱항 추가는 **모형이 표현할 수 있는 관계의 모양 자체를 바꾸는 일**이기 때문임.

문제 41

`compare_models()` 가 1순위로 지목한 모델을 그대로 쓰지 않고, 실제로 최종 채택한 모델은 무엇인가요? (모델명 1개)

정답. `4_가정반영`

해설. 자동 선택은 근소 격차 그룹 안에서 변수가 하나 적은 `5_가정반영+후진소거` 를 1순위로 지목함. 하지만 5번이 지운 변수가 제곱항의 짝인 `Crunchiness_c` 이므로, **계층 원칙에 따라 4번을 채택**함.

간명성 규칙이 통계적 원칙보다 앞설 수는 없음. 자동 선택 결과는 언제나 분석자가 검토해야 함.

문제 42

두 모델의 AIC 차이는 얼마인가요? (소수 둘째 자리)

정답. `1.93`

해설. 3673.968 − 3672.041 = **1.93**임.

이 숫자가 판단의 근거임. 변수 하나를 지워 얻는 AIC 이득이 2도 안 되는데, 그 대가로 계층 원칙을 깨야 한다면 남기는 쪽이 맞음. "원칙이니까 남긴다"가 아니라 **"이득이 이만큼 작으니 남긴다"** 로 말해야 보고서가 됨.

6. 결과보고

문제 43

최종 채택 모델의 독립변수는 몇 개인가요? (정수 1개)

정답. `13`

해설. `Sweetness` 1개 + 제곱항 처방을 받은 6종 × (1차항 + 제곱항) 2개 = **13개**임.

원래 7개였던 변수가 13개로 늘어남. **곡선을 표현할 수 있게 된 대가로 모형이 복잡해진 것**이며, 이는 한계점에 기록할 사항임.

문제 44

모형 적합도 보고에 제시된 Pseudo R^2는 얼마인가요? (소수 셋째 자리)

정답. `0.342`

해설. LL = −1822.984, LL-Null = −2772.581 → LLR $\chi^2(13) = 1899.193$, $p < .001$, Pseudo R^2 = **0.342**로 매우 우수한 적합임.

> 참고 — 성능 비교표에는 같은 값이 `0.343` 으로 찍힘. 실제 값이 0.3425 부근이라 **반올림 경계에 걸려 표시가 갈린 것**이지 다른 값이 아님. 보고서에 옮길 때는 **어느 출력에서 가져온 값인지** 밝혀야 검토가 가능함.

Pseudo R^2는 선형회귀의 R^2처럼 "분산 설명 비율"로 읽지 않음. 보통 0.2 ~ 0.4면 매우 우수한 적합으로 봄.

문제 45

13개 독립변수 중 유의수준 5% 기준으로 유의하지 않은 것은 무엇인가요? (변수명 1개)

정답. `Crunchiness_c`

해설. `Crunchiness_c` 하나임($z = 0.27$, $p = 0.787$). 나머지 12개는 모두 유의함.

이 변수가 바로 계층 원칙 때문에 일부러 남긴 1차항임. 보고서에서 "유의하지 않은데 왜 있느냐"는 질문이 반드시 나오므로, **의도적으로 남겼다는 근거를 함께 적어야 함.**

문제 46

최종 모형에서 표준화 계수(βstd)가 가장 큰 변수는 무엇인가요? (변수명 1개)

정답. `Size_c`

해설. `Size_c` **1.214**가 1위, `Sweetness` 1.105가 2위, `Juiciness_c` 0.937이 3위임. **크기·단맛·과즙이 품질을 결정하는 3대 축**임.

기준선 모형의 1위도 `Size` 였음(1.252). **처방 전후로 영향력 순위는 크게 흔들리지 않았고, 달라진 것은 관계의 모양임.**

문제 47

T검정에서 p = 0.985로 완전 무관, 기준선 모형에서도 p = 0.253으로 제거 후보였다가, 제곱항을 넣자 z = 10.40으로 강력한 예측 변수가 된 변수는 무엇인가요? (변수명 1개)

정답. `Crunchiness`

해설. 이 분석의 가장 큰 반전임. **양 극단이 모두 `good` 쪽이라 평균 비교로는 서로 상쇄되어 보이지 않았을 뿐**임(아래로 볼록한 ∪자 관계).

- EDA(T검정) → 평균 비교라서 ∪자 관계를 못 봄
- 기준선 모형 → 직선만 표현하므로 역시 못 봄
- **가정 검정(Box-Tidwell)에서만 잡힘**

세 단계를 모두 거쳐야 잡히는 변수가 있다는 뜻임. 어느 한 단계를 건너뛰면 놓침.

문제 48

최종 모형의 분류 정확도는 얼마인가요? (소수 셋째 자리)

정답. `0.792`

해설. 4,000개 중 **3,167개**를 맞힘(1555 + 1612). 게으른 모형의 바닥값 50.1%보다 **29%p 높음.**

정확도를 그대로 믿어도 되는 이유는 이 데이터가 균형 잡혀 있기 때문임(`good` 50.1%). 사건이 5%뿐인 불균형 데이터였다면 아무것도 안 하는 모형의 정확도가 95%가 되어 정확도만으로는 판단할 수 없음.

문제 49

진단 오즈비(DOR)는 얼마인가요? (소수 첫째 자리)

정답. `14.5`

해설. 모형이 `good` 이라고 판정한 사과가 실제로 `good` 일 오즈는, `bad` 라고 판정한 사과의 **약 14.5배**임.

정밀도 0.785 · 재현율 0.804 · 특이성 0.779로 **네 지표가 고르게 나온 것도 균형 데이터의 특징임.**

문제 50

혼동행렬에서, 실제로는 `good` 인데 모형이 `bad` 로 잘못 판정해 놓친 사과는 몇 개인가요? (정수 1개)

정답. `392`

해설. FN(False Negative) **392건**임. 반대로 `bad` 인데 `good` 으로 잘못 잡은 FP는 441건임.

두 오류의 무게는 상황에 따라 다름. 좋은 사과를 버리는 것(FN)이 손해라면 임계값을 낮춰야 하고, 나쁜 사과를 내보내는 것(FP)이 문제라면 높여야 함. 다음 문제로 이어지는 지점임.

문제 51

임계값을 0.3 ~ 0.7로 바꿔가며 비교했을 때, F1이 가장 높아지는 임계값은 얼마인가요? (소수 첫째 자리)

정답. `0.4`

해설. 정확도는 0.5에서 최대(0.792)지만, **F1은 0.4에서 최대(0.802)** 임.

임계값 0.5는 관례일 뿐 정답이 아님. 어떤 지표를 기준으로 삼느냐에 따라 최적점이 달라짐.

문제 52

내보내는 사과가 반드시 `good` 이어야 하는 프리미엄 등급 선별에서는 임계값을 높입니다. 이때 확보하려는 지표는 무엇인가요? (지표 이름 1개)

정답. 정밀도

해설. 임계값 0.7 → 정밀도 0.857 / 재현율 0.594, 임계값 0.3 → 재현율 0.932 / 정밀도 0.699로 **정확한 트레이드오프**가 나타남.

- **프리미엄 등급 선별**(내보낸 것은 반드시 `good` 이어야 함) → 임계값을 **높여** 정밀도 확보
- **폐기 대상 걸러내기**(좋은 사과를 버리면 손해) → 임계값을 **낮춰** 재현율 확보

정답은 통계가 아니라 목적이 정함.

문제 53

훈련·검증 데이터를 나누지 않고 학습 데이터에서 그대로 성능을 측정했습니다. 제곱항 6개를 추가하면서 함께 커진 위험은 무엇인가요? (용어 1개)

정답. 과적합

해설. 정확도 0.792와 AUC 0.868은 **낙관적인 값**임. 모형이 외운 데이터로 자기 성적을 매긴 셈이기 때문임.

변수를 7개에서 13개로 늘렸으므로 위험은 더 커짐. 성능이 좋아졌다는 결론을 내리려면 본래 **분리한 검증 데이터에서 확인**해야 함.

문제 54

“산도가 낮을수록 `good` 이다”라는 결과를 두고 “산도를 인위적으로 낮추면 사과가 좋아진다”고 말할 수는 없습니다. 이 분석이 밝힌 것은 인과관계가 아니라 무엇인가요? (용어 1개)

정답. 연관관계

해설. 관측 데이터로 적합한 회귀모형은 **연관관계(association)** 를 말할 뿐임. 인과를 주장하려면 실험 설계나 인과추론 절차가 필요함.

이 데이터에는 한계가 더 있음. 값이 이미 표준화된 상태라 **“크기 1점”이 몇 mm인지 알 수 없어 오즈비를 현장 단위로 옮길 수 없고,** `good` / `bad` 판정 기준도 공개되어 있지 않아 모형이 학습한 것은 “객관적 품질”이 아니라 **“이 데이터를 만든 사람의 판정 기준”** 일 수 있음.