# [LAB-10] 07. [PBT] Titanic Survival - 연습문제

## #01. 준비작업 및 데이터 품질 점검

### 1. 준비작업 (2문항)

#### 문제 1

데이터를 불러왔을 때, 원본 데이터의 관측치(행)는 몇 개인가요? (정수 1개)

**정답.** `1309`

**해설.** 타이타닉 승객 **1,309명**의 기록임. 이 숫자가 이후 모든 단계의 기준점이 됨. 중복이나 결측을 처리하면서 행이 줄면 곧바로 알아챌 수 있어야 함.

**앞 단원의 사과 데이터(4,000건)보다 3분의 1 수준임.** 관측치가 적으면 범주를 잘게 나눌 때 각 칸에 들어가는 표본이 빠르게 줄어듦. 뒤에서 호칭을 5종으로 나눌 때 이 제약이 실제로 드러남.

#### 문제 2

원본 데이터는 몇 개의 컬럼으로 이루어져 있나요? (정수 1개)

**정답.** `12`

**해설.** 식별자 1개( `PassengerId` ) + 종속변수 1개( `Survived` ) + 나머지 10개임.

이 12라는 숫자를 기억해야 하는 이유는 뒤에서 **컬럼 수가 두 번 바뀌기 때문**임. 분석 대상이 아닌 컬럼을 빼면서 줄고, 파생변수를 만들면서 다시 늘어남. 열 개수가 언제 왜 바뀌었는지 추적하지 못하면 분석 중간에 변수가 사라지거나 남아 있어도 알아채지 못함.

### 2. 데이터 품질 점검 (13문항)

#### 문제 3

원본 12개 컬럼 중 결측치가 하나라도 있는 컬럼은 몇 개인가요? (정수 1개)

**정답.** `4`

**해설.** `Age` (263건) · `Fare` (1건) · `Cabin` (1,014건) · `Embarked` (2건) **4개**임. 나머지 8개는 결측이 없음.

**앞 단원의 사과 데이터는 결측이 0건이었음.** 캐글 데이터셋 중에서는 그쪽이 오히려 예외이고, 이렇게 **군데군데 비어 있는 것이 실제 데이터의 모습**임. 결측이 있다는 사실 자체보다 **컬럼마다 비어 있는 정도가 전혀 다르다는 점**이 중요함. 1건과 1,014건은 같은 방법으로 처리할 수 없음.

#### 문제 4

결측 비율이 가장 높은 컬럼은 무엇인가요? (변수명 1개)

**정답.** `Cabin`

**해설.** `Cabin` 이 1,309건 중 **1,014건(77.5%)** 결측임. 그다음이 `Age` 263건(20.1%)이고, `Embarked` 2건· `Fare` 1건은 거의 없는 수준임.

**77.5%는 "채운다"는 선택지가 성립하지 않는 수준임.** 넷 중 셋이 비어 있는데 무엇으로 채우든 그것은 관측이 아니라 **우리가 만들어 낸 값**이 됨. 그래서 이 컬럼은 대체가 아니라 **제거** 대상이 됨.

## 문제 5

원본 상태에서 중복 점검을 수행했을 때, 중복된 행은 몇 개인가요? (정수 1개)

**정답.** `0`

**해설. 0건**임. 삭제된 행이 없으므로 이후에도 계속 원본을 그대로 사용함.

**이 0이 나온 이유는 `PassengerId` 가 아직 살아 있기 때문임.** 행마다 값이 다른 식별자가 하나라도 남아 있으면 **중복은 정의상 나올 수 없음.**

그래서 순서가 중요함. **중복 판정은 식별자가 살아 있을 때 해야 함.** 식별자를 먼저 지우고 세면 값이 우연히 같은 서로 다른 승객들이 중복으로 잡혀, **삭제하면 안 되는 행을 지우게 됨.**

## 문제 6

분석 대상이 아닌 컬럼을 제거하고 나면, 남은 데이터는 몇 개의 컬럼이 되나요? (정수 1개)

**정답.** `8`

**해설.** 12열에서 4개를 빼 **8열**이 됨. 빠지는 것은 `PassengerId` (식별자) · `Name` (자유 텍스트) · `Ticket` (문자열 식별자) · `Cabin` (결측 77.5%)이며, **제거 이유가 넷 다 다름.**

**제거는 사본에서만 함.** 원본 `origin` 은 그대로 둠. 여기서 지운 `Name` 으로 뒤에서 파생변수를 만들 수 있는 이유가 이것임. **원본을 보존하는 습관이 나중에 쓸 여지를 남김.**

## 문제 7

`Age` 의 결측 263건을 채우는 데 사용한 대체값은 얼마인가요? (소수 첫째 자리)

**정답.** `28.0`

**해설.** `Age` 의 **중앙값 28.0세**로 채움. 평균이 아니라 중앙값을 쓴 이유는 오른쪽 꼬리가 있는 분포라 평균이 극단값에 끌려가기 때문임.

**263건은 전체의 20.1%임. 다섯 명 중 한 명의 나이가 우리가 만들어 넣은 값이라는 뜻임.** 분포에는 28세 자리에 인공적인 봉우리가 생기고, 나이의 효과는 **실제보다 약하게** 추정될 가능성이 큼.

이 대체값은 뒤에서 한 번 더 문제가 됨. 호칭별 나이를 볼 때 대체값이 섞이면 분포가 왜곡되므로, 그 확인만은 **결측을 채우기 전인 `origin` 기준**으로 해야 함.

## 문제 8

`Embarked` 의 결측 2건을 채우는 데 사용한 값은 무엇인가요? (범주값 1개)

**정답.** `S`

**해설.** 최빈값인 **`S`** (Southampton)로 채움. 전체 1,309명 중 916명이 `S` 에서 탑승했음.

**명목형에는 평균도 중앙값도 쓸 수 없음.** "항구의 평균"이라는 말이 성립하지 않기 때문임. 그래서 대체 방법은 컬럼의 **자료형이 아니라 척도**를 보고 정해야 함. 2건뿐이라 어느 값을 넣든 영향은 미미하지만, **절차는 그대로 지킴.**

## 문제 9

이름에서 추출한 원본 호칭은 모두 몇 종인가요? (정수 1개)

**정답.** `18`

**해설.** `Mr` (757) · `Miss` (260) · `Mrs` (197) · `Master` (61) · `Rev` (8) · `Dr` (8) · `Col` (4) · `Ms` (2) · `Major` (2) · `Mlle` (2) · `Don` · `Mme` · `Lady` · `Sir` · `Capt` · `the Countess` · `Jonkheer` · `Dona` (각 1) = **18종**임.

이름은 `Braund, Mr. Owen Harris` 처럼 **`성, 호칭. 이름`** 형식으로 통일되어 있어, 쉼표와 마침표 사이를 뽑으면 호칭이 나옴.

**"자유 텍스트라 못 쓴다"고 배운 컬럼에서 변수를 하나 건져 낸 것임.** 형식이 있는 문자열은 버리기 전에 한 번 더 봐야 함.

## 문제 10

18종의 호칭을 의미별로 통합한 뒤, `Title` 의 범주는 몇 개가 되나요? (정수 1개)

**정답.** `5`

**해설.** `Mr` · `Miss` · `Mrs` · `Master` · `Officer` **5종**으로 묶음.

**통합하지 않으면 쓸 수 없음.** 18종 중 1건짜리가 6개나 되는데, 그대로 더미로 펼치면 **관측치 하나로 계수 하나를 추정**하게 되어 값이 아예 나오지 않거나 신뢰할 수 없음.

**통합 방식에는 정답이 없고 근거가 필요함.** `Officer` 를 성별에 따라 `Mr` · `Mrs` 로 흡수시키는 선택도, 귀족 경칭을 따로 묶어 `Royalty` 를 만드는 선택도 가능함. 여기서는 "이름에서 신분을 읽는다"는 목적에 맞춰 **직위를 별도 범주로 남겼고, 그 판단을 기록으로 남김.**

## 문제 11

`Title` 의 5개 범주 중 관측치가 가장 적은 것은 무엇인가요? (범주값 1개)

**정답.** `Officer`

**해설.** `Officer` **23건(1.8%)** 으로 가장 적음. `Mr` 760 · `Miss` 264 · `Mrs` 201 · `Master` 61 순임.

**23건은 경험칙(한 범주에 최소 10~20건)의 하한에 걸쳐 있음.** 더미 하나를 추정할 수는 있지만 **계수의 신뢰구간이 넓게 나올 것**을 각오해야 함.

**이것이 범주를 잘게 나눌 때 치르는 대가임.** 나누면 정보는 늘지만 각 칸의 표본은 줄어듦. 문제 1에서 확인한 1,309라는 관측치 수가 여기서 제약으로 작동함.

## 문제 12

`Master` 의 나이 최댓값은 몇 살인가요? (소수 첫째 자리)

**정답.** `14.5`

**해설.** `Master` 의 나이는 최소 0.33세, 중앙값 4.0세, **최대 14.5세**임. 즉 이 호칭은 그 자체로 **"남자아이"** 를 뜻함.

**이 한 줄이 `Title` 을 만든 이유를 설명함.** `Sex` 만 보면 6세 남아와 40세 남성이 똑같이 `male` 이지만, `Title` 은 둘을 구분함. **"여성과 어린이 먼저"의 '어린이'를 잡아낼 수 있는 유일한 변수임.**

> 주의 — 이 값은 **결측을 채우기 전인 `origin` 기준**임. 대체가 끝난 데이터로 집계하면 나이 결측이 모두 28세로 채워져 `Master` 의 최댓값이 **28.0세로 튐.** 대체값이 섞인 값으로는 "이 호칭이 무엇을 뜻하는가"를 판단할 수 없음.

## 문제 13

파생변수 두 개를 추가하고 나면, 데이터는 몇 개의 컬럼이 되나요? (정수 1개)

**정답.** `10`

**해설.** 8열에 `FamilySize` 와 `Title` 을 더해 **10열**이 됨.

**원재료를 지우지 않는다는 점이 중요함.** `FamilySize = SibSp + Parch + 1` 을 만들었지만 `SibSp` · `Parch` 를 그대로 둠. 어느 쪽이 나은지는 **모델을 적합해 성능으로 비교해야** 알 수 있기 때문임.

다만 그 대가로 **정의상 `FamilySize − SibSp − Parch = 1` (상수)** 인 관계가 생김. 셋을 동시에 모형에 넣으면 계수를 유일하게 결정할 수 없으므로, **다변량 분석에서 이 관계를 반드시 점검해야 함.**

## 문제 14

연속형 5종 중 이상치가 가장 많이 섞여 있는 항목은 무엇인가요? (변수명 1개)

**정답.** `Parch`

**해설.** `Parch` **307건(23.5%)** 으로 가장 많고, `Fare` 171건(13.1%) · `FamilySize` 125건(9.5%) · `Age` 101건(7.7%) · `SibSp` 57건(4.4%) 순임.

**그런데 이 23.5%는 이상치가 아님.** `Parch` 는 1사분위수와 3사분위수가 **모두 0**이라 IQR = 0이 되고, 상·하한이 모두 0으로 붙어 버림. 그 결과 **0이 아닌 값 307건이 전부 이상치로 잡힌 것**임.

**IQR 규칙은 값이 촘촘하게 퍼진 연속형 변수를 위한 도구임.** 0이 대부분인 카운트 변수에 기계적으로 적용하면 안 됨. `SibSp` 도 IQR = 1, `FamilySize` 도 IQR = 1로 매우 좁음.

## 문제 15

연속형 5종 중 분포의 비대칭이 가장 큰(왜도의 절댓값이 가장 큰) 항목은 무엇인가요? (변수명 1개)

**정답.** `Fare`

**해설.** 왜도는 `Fare` **4.370** 이 가장 크고, `SibSp` 3.844 · `Parch` 3.669 · `FamilySize` 2.853 · `Age` 0.541 순으로 **5종 모두 오른쪽 꼬리**임.

`Fare` 는 최댓값이 512.33인데 중앙값이 14.45임. **35배 차이**로, 1등석 최고가 객실과 3등석 요금의 격차임.

**앞 단원의 사과 데이터와 정반대임.** 그쪽은 이미 표준화되어 7종 모두 대칭이었지만, 타이타닉은 **원 단위(살, 명, 파운드)의 날것 그대로**라 왜도도 이상치도 큼.

**단, 왜도가 크다고 여기서 로그변환을 하지 않음.** 로지스틱 회귀는 **독립변수의 정규성을 가정하지 않기** 때문임. 변환이 필요한 경우는 로짓 선형성이 깨졌을 때이고, 그 판단은 가정 검정 단계에서 함.

## 3. 변수 유형 분류와 EDA 범위 (5문항)

### 문제 16

종속변수를 제외하고 나면, 명목형 독립변수는 몇 개인가요? (정수 1개)

**정답.** `4`

**해설.** `Pclass` · `Sex` · `Embarked` · `Title` **4개**임. 종속변수 `Survived` 는 명목형 목록에서 빠짐.

코드에서 `target_is_continuous` 를 `False` 로 두었기 때문에 종속변수를 **명목형 목록에서** 제거하는 분기를 탐. 선형 회귀였다면 반대쪽 분기를 타서 연속형 목록에서 제거했을 것임.

**앞 단원에서는 이 값이 0이었음.** 명목형 독립변수가 하나도 없어 교차분석이 아예 수행되지 않았음. 이 데이터는 4개나 있어 **절차가 실제로 갈라짐.**

### 문제 17

종속변수를 제외하고 나면, 연속형 독립변수는 몇 개인가요? (정수 1개)

**정답.** `5`

**해설.** `Age` · `SibSp` · `Parch` · `Fare` · `FamilySize` **5개**임.

**파생변수 `FamilySize` 가 여기 포함되어 있다는 점이 핵심임.** 기술 통계량을 내기 전에 파생변수를 만들었기 때문에 목록에 자동으로 들어옴. 뒤늦게 붙였다면 **검증을 건너뛴 변수가 하나 생겼을 것임.**

**직접 만든 변수라고 검정을 면제받지 않음.** 원본 변수와 똑같이 단변량·이변량·다변량 분석과 가정 검정을 모두 거침.

### 문제 18

척도 조합표의 아홉 가지 경우 중, 이 데이터에서 실제로 수행되는 분석 기법은 몇 가지인가요? (정수 1개)

**정답.** `2`

**해설. T검정**과 **교차분석** 두 가지임.

종속변수가 **명목형 2집단**이므로 후보는 세 줄로 좁혀지고, 그 **세 줄이 모두 적용됨.** 다만 그중 둘( `Sex` → `Survived` , `Pclass` · `Embarked` · `Title` → `Survived` )이 같은 교차분석이라 **기법으로 세면 두 가지**임.

**앞 단원과 갈리는 지점임.** 사과 데이터는 명목형 독립변수가 없어 T검정 한 가지만 수행됐음. 여기서는 교차분석이 실제로 돌아감.

**주의 — 종속변수가 명목형이면 상관분석을 쓸 수 없음.** 상관계수는 두 변수가 모두 연속형일 때 정의되는 지표이기 때문임. "이 변수가 생존과 관련이 있는가"라는 **같은 질문**에 답하는 도구가 연속형이면 T검정, 명목형이면 교차분석으로 바뀜.

### 문제 19

서열척도로 순서를 지정한 변수는 무엇인가요? (변수명 1개)

**정답.** `Pclass`

**해설.** `Pclass` 를 `[3, 2, 1]` , 즉 **낮은 등급 → 높은 등급** 순으로 재지정함.

`Pclass` 는 단순한 이름표가 아니라 **1등급 > 2등급 > 3등급의 등급**임. 다만 숫자로 저장되어 있다고 연속형으로 두면 **"3등급은 1등급의 3배"** 라는 잘못된 등간 가정이 들어가므로 명목형으로 선언한 뒤 순서만 부여함.

이렇게 하면 더미변수를 만들 때 **첫 범주인 3등급이 기준(reference)** 이 되어 "**3등급 대비** 1등급의 생존 오즈"라는 자연스러운 해석이 나옴.

**앞 단원에는 서열척도 대상이 없었음.** 코드는 그대로 두고 딕셔너리만 비워 두었었음.

### 문제 20

`Title` 의 기준(reference) 범주로 지정한 값은 무엇인가요? (범주값 1개)

**정답.** `Mr`

**해설.** `["Mr", "Officer", "Master", "Miss", "Mrs"]` 순으로 재배치해 맨 앞의 **`Mr`** 를 기준으로 삼음.

**`Title` 은 서열척도가 아님.** `Mr` 가 `Mrs` 보다 크거나 작다고 말할 수 없음. 그런데도 순서를 손대는 이유는 **더미의 기준을 정하기 위해서**임. 그래서 `ordered=False` 로 둠 — **순서를 부여한 것이 아니라 자리만 옮긴 것**임.

**손대지 않으면 사전순 첫 값인 `Master` 가 기준이 됨.** 그러면 모든 오즈비가 **"남자아이 대비"** 로 읽혀 해석이 어색해짐. 가장 많고(760명) 가장 불리한 범주를 기준으로 삼아야 **"성인 남성 대비 몇 배"** 로 읽힘.

**기준 범주 선택은 통계적 판정이 아니라 해석의 문제임.** 어느 것을 골라도 모형의 적합도는 같고, 달라지는 것은 **오즈비를 읽는 기준점**뿐임. 그래서 가장 이해하기 쉬운 범주를 고름.

## #02. 탐색적 데이터 분석

## 1. 단변량 분석 (6문항)

### 문제 1

종속변수 `Survived` 의 두 범주 중 더 많이 나타나는 쪽은 무엇인가요? (범주값 1개)

**정답.** `0`

**해설.** 사망( `0` ) **815건**, 생존( `1` ) **494건**으로 사망 쪽이 더 많음.

**종속변수가 명목형이 되면 단변량 분석의 관심사가 바뀜.** 선형회귀에서는 분포 모양(왜도·이상치)을 봤지만, 로지스틱 회귀에서는 **범주 비율(균형 여부)** 을 봄. 범주가 2개라는 사실 자체가 **이분형 → 로지스틱 회귀 적용 가능**이라는 확인이기도 함.

## 문제 2

그 최빈 범주가 전체에서 차지하는 비율은 얼마인가요? (소수 셋째 자리)

**정답.** `0.623`

**해설.** 815 ÷ 1,309 = **0.623**, 즉 **62 : 38의 약한 불균형**임.

**이 값이 곧 모형이 넘어야 할 바닥값(baseline)임.** 모두 "사망"이라고만 답하는 게으른 모형도 62.3%를 맞힘. 따라서 **정확도 70%짜리 모형은 좋은 모형이 아님.** 바닥값보다 8%p 나은 것에 불과함.

**앞 단원의 사과 데이터는 바닥값이 50.1%였음.** 같은 정확도라도 데이터마다 의미가 전혀 다름. 정확도를 볼 때는 **항상 바닥값과의 격차로 읽는 습관**을 들여야 함.

62 : 38은 리샘플링이 필요한 수준은 아니지만, **정확도 하나만 보지 말고 재현율·정밀도·AUC를 함께 확인**해야 함.

## 문제 3

명목형 독립변수 4종의 범주를 통틀어, 관측치가 가장 적은 범주는 무엇인가요? (범주값 1개)

**정답.** `Officer`

**해설.** `Title = Officer` **23건(1.8%)** 으로 가장 적음. 그다음이 `Title = Master` 61건, `Embarked = Q` 123건임.

**한 범주에 관측치가 지나치게 적으면 그 더미변수의 계수가 불안정해짐.** 경험칙으로 한 범주에 최소 10~20건은 있어야 하는데, 23건은 그 **하한에 걸쳐 있음.** 추정은 되지만 신뢰구간이 넓게 나올 것을 각오해야 함.

**이것이 범주를 잘게 나눌 때 치르는 대가임.** 나누면 정보는 늘지만 각 칸의 표본은 줄어듦. 다만 원본 호칭 18종을 그대로 썼다면 1건짜리 범주가 6개나 생겨 **아예 추정이 불가능**했을 것이므로, 5종으로 통합한 판단은 여기서 정당화됨.

## 문제 4

결측을 중앙값으로 채운 흔적이 히스토그램에 **인공적인 봉우리**로 남은 변수는 무엇인가요? (변수명 1개)

**정답.** `Age`

**해설.** `Age` 의 히스토그램 한가운데 **28세 자리에 뾰족한 막대**가 서 있음. 결측 263건을 중앙값 28세로 채운 자국임.

**그 자리의 데이터는 실제 관측이 아니라 우리가 만들어 넣은 값임.** 다섯 명 중 한 명꼴이므로 무시할 수 없는 양이며, 이후 결과를 볼 때 항상 염두에 둬야 함.

이 흔적은 다음 단계에서 실제로 영향을 드러냄. 이변량 분석에서 `Age` 가 "무관"으로 나오는 이유 중 하나가 **두 집단이 모두 28세 쪽으로 끌려갔기 때문**임.

## 문제 5

연속형 5종 중 사분위수 범위(IQR)가 0이어서 **이상치 판정 자체가 무의미**해진 변수는 무엇인가요? (변수명 1개)

**정답.** `Parch`

**해설.** `Parch` 는 1사분위수와 3사분위수가 **모두 0**이라 IQR = 0이 되고, 상·하한이 모두 0으로 붙어 버림. 그 결과 **0이 아닌 값 307건(23.5%)이 전부 이상치로 잡힘.** 상자그림도 상자에 두께가 없어 선 하나로 눌려 있음.

**이런 변수에 IQR 이상치 대체를 적용하면 0이 아닌 값이 전부 0으로 눌려 변수가 상수가 됨.** 그러면 설계행렬이 특이행렬이 되어 모형 적합 자체가 실패함.

**IQR 규칙은 값이 촘촘하게 퍼진 연속형 변수를 위한 도구임.** 0이 대부분인 카운트 변수에 기계적으로 적용하면 안 됨. `SibSp` (IQR 1)와 `FamilySize` (IQR 1)도 같은 함정을 갖고 있음.

## 문제 6

`FamilySize` 에서 단독 승객(가족 수 1명)이 차지하는 비율은 얼마인가요? (소수 셋째 자리)

**정답.** `0.604`

**해설.** 790 ÷ 1,309 = **0.604**, 즉 **승객의 60.4%가 혼자 탔음.**

`FamilySize` 의 왜도는 **2.85** 로 원재료인 `SibSp` (3.84)· `Parch` (3.67)보다 완만함. 둘을 더하면서 0이 몰려 있던 자리가 1로 옮겨가고 분포가 조금 퍼졌기 때문임. **그래도 60.4%가 한 값에 쏠려 있어 여전히 심하게 비대칭임.**

IQR = 1이라 상한이 **3.5**가 되고, 결국 **가족 4명부터 전부 이상치**(125건, 9.5%)로 잡힘. `Parch` 와 같은 함정이므로 **이상치 대체 대상에서 제외**해야 함.

> 참고 — 여기서 로그변환을 하지 않음. **로지스틱 회귀는 독립변수의 정규성을 가정하지 않기** 때문임. 왜도가 크다는 사실은 기록만 해 두고, 변환 여부는 **로짓 선형성 검정**이 결정함.

# 2. 이변량 분석 (8문항)

## 문제 7

연속형 독립변수 5종에 대한 집단 비교에서, 5종 모두에 선택된 검정 방법은 무엇인가요? (분석 기법 이름 1개)

**정답.** `Mann–Whitney U`

**해설.** 5종 모두 **정규성이 기각되어 Mann-Whitney U 검정**(순위 기반 비모수 검정)으로 전환됨.

**검정 방법은 분석자가 고르는 것이 아님.** 함수가 정규성·등분산성을 먼저 검정한 뒤 자동으로 선택함. 분석자가 할 일은 **어떤 검정이 선택됐는지 확인하고 결과표에 기록**하는 것임.

**앞 단원의 사과 데이터는 7종 중 4종만 비모수였음.** 표준화된 사과 데이터와 달리 타이타닉은 원 단위의 날것이라 **5종 전부가 정규성을 만족하지 못함.**

## 문제 8

유의수준 5% 기준으로, 두 집단 사이에 차이가 없다고 나온 변수는 무엇인가요? (변수명 1개)

**정답.** `Age`

**해설.** `Age` 만 유의하지 않고 나머지 4종( `Fare` · `FamilySize` · `Parch` · `SibSp` )은 모두 0.001 미만으로 유의함.

**그렇다고 "나이는 생존과 상관없다"로 읽으면 안 됨.** 어린이는 우선 구조되어 생존율이 높고 고령 남성은 낮은데, **양 끝이 반대 방향이라 평균 비교에서 상쇄**됨. 게다가 결측 263건을 28세로 채워 두 집단이 모두 그쪽으로 끌려간 상태임.

**이 단계의 "무관"은 최종 판정이 아님.** 다른 변수를 통제하면 숨어 있던 효과가 드러날 수 있으므로(억제효과), 기준선 모형에서 다시 확인함.

## 문제 9

그 변수의 유의확률은 얼마인가요? (소수 셋째 자리)

**정답.** `0.295`

**해설.** `Age` 의 유의확률은 **0.295** 임. 0.05는커녕 0.2도 넘는 값이라 "차이가 전혀 없다"에 가까워 보임.

**보고서에 "유의하지 않음"이라고만 쓰면 안 됨.** 0.051과 0.295는 같은 "유의하지 않음"이지만 의미가 전혀 다름. **무슨 검정으로 몇이 나왔는지를 남겨야** 나중에 판단이 뒤집혔을 때 그 폭을 가늠할 수 있음.

## 문제 10

가족 규모별 생존율이 가장 높은 가족 수는 몇 명인가요? (정수 1개)

**정답.** `4`

**해설.** 가족 4명일 때 생존율 **72.1%** 로 가장 높음. 1명 29.2% → 2명 53.2% → 3명 56.0% → **4명 72.1%** 까지 오르다가, 5명 22.7% → 11명 18.2%로 급락함.

**이 모양이 역U자임.** 적당한 크기의 가족은 서로 도와 유리했지만, 대가족은 흩어진 가족을 찾다가 탈출이 늦어졌다고 읽을 수 있음.

**T검정만 봤다면 이 모양을 절대 볼 수 없었음.** T검정은 두 집단의 순위 중심 위치만 비교하므로 "생존자 쪽이 대체로 크다"까지만 말해 줌. **카운트 변수는 값별 분포를 직접 그려 봐야 함.**

## 문제 11

그 가족 수에서의 생존율은 얼마인가요? (소수 셋째 자리)

**정답.** `0.721`

**해설.** 가족 4명 43건 중 생존이 **0.721**, 사망이 0.279임.

**단, 이 표는 다른 변수를 전혀 통제하지 않은 값임.** 대가족이 어느 등급에 몰려 있는지에 따라 이 곡선의 모양은 달라질 수 있음. **곡선이 보인다고 곧바로 제곱항을 넣어서는 안 되고, 모형 안에서 검정해야 함.**

또 4명 구간은 **43건**, 8명 구간은 **8건**에 불과함. 표본이 얇은 구간의 비율은 크게 흔들리므로 **인원수를 함께 보고 읽어야 함.**

## 문제 12

교차분석에서 Cramer's V가 가장 큰 변수는 무엇인가요? (변수명 1개)

**정답.** `Title`

**해설.** `Title` **V = 0.698(Strong)** 로 가장 크고, `Sex` 0.687(Strong) · `Pclass` 0.265(Weak) · `Embarked` 0.136(Weak) 순임. $\chi^2$도 `Title` 638.38 > `Sex` 617.31임.

**자유도를 4개나 쓰고도 `Sex` 를 이겼다는 점이 핵심임.** 범주를 늘리면 $\chi^2$는 대개 커지지만 Cramer's V는 자유도를 보정한 지표임. 그 보정을 거치고도 앞선다는 것은 **정보량이 실제로 더 많다**는 뜻임.

**직접 만든 파생변수가 원본 변수를 이긴 첫 장면임.** 다만 둘이 얼마나 겹치는지는 별도로 확인해야 하며, 함께 쓸 수 있는지는 다변량 분석에서 판정함.

## 문제 13

`Title` 의 5개 범주 중 생존율이 가장 높은 범주는 무엇인가요? (범주값 1개)

**정답.** `Mrs`

**해설.** `Mrs` **87.1%** · `Miss` 79.2% · `Master` 37.7% · `Officer` 21.7% · `Mr` 10.8% 순임.

**`Mrs` 와 `Miss` 가 갈린다는 점이 중요함.** `Sex` 로는 둘 다 82.6%의 `female` 하나였음. 기혼 여성이 미혼 여성보다 **7.9%p 높은데**, 아이를 동반한 어머니가 우선 구조된 정황으로 읽을 수 있음.

**호칭 하나가 성별·연령대·혼인 여부를 동시에 담고 있기 때문에** 이런 구분이 가능함.

## 문제 14

`Sex` 로는 보이지 않던 집단으로, 성인 남성( `Mr` 10.8%)의 약 **3배** 생존율을 보인 `Title` 범주는 무엇인가요? (범주값 1개)

**정답.** `Master`

**해설.** `Master` (남자아이) **37.7%** 로 `Mr` (10.8%)의 약 3배임.

**`Sex` 는 이 61명을 40세 남성과 똑같은 `male` 로 묶었음.** 그 집단 전체의 생존율은 12.9%임. `Title` 은 이들을 따로 떼어 **37.7%** 를 보여줌.

**"여성과 어린이 먼저"의 '어린이' 부분이 여기서 처음 드러남.** 앞 단계에서 `Master` 의 나이가 최대 14.5세임을 확인했기 때문에, 이 숫자를 "남자아이의 생존율"로 해석할 수 있는 것임. **파생변수를 만들 때 근거를 확인해 둔 것이 여기서 값을 함.**

# 3. 다변량 분석 (3문항)

## 문제 15

연속형 독립변수 조합 중 상관계수의 절댓값이 가장 큰 값은 얼마인가요? (소수 셋째 자리)

**정답.** `0.848`

**해설.** `SibSp – FamilySize` 조합의 **0.848(Strong)** 이 가장 크고, `Parch – FamilySize` 0.796(Strong) · `Fare – FamilySize` 0.521(Moderate) 순임.

**Strong 조합 세 개가 모두 `FamilySize` 와의 관계라는 점을 봐야 함.** 파생변수는 원본 컬럼으로 만든 것이라 **원재료와 겹칠 수밖에 없음.**

**앞 단원의 사과 데이터는 Strong 조합이 하나도 없었음.** 그때는 "다중공선성 문제 없음"으로 끝났지만, **파생변수를 만든 순간 이 점검이 형식적인 절차가 아니게 됨.**

## 문제 16

분산팽창지수(VIF)가 무한대( `inf` )로 나온 변수는 몇 개인가요? (정수 1개)

**정답.** `3`

**해설.** `SibSp` · `Parch` · `FamilySize` **3개**임. 나머지는 `Fare` 1.119 · `Age` 1.099로 기준(10)에 한참 못 미침.

**`inf` 는 오류가 아니라 정확한 답임.** VIF는 `1 / (1 – R²)` 로 계산되는데, 분모가 0이 되면 무한대가 됨. 이것을 **완전공선성(perfect multicollinearity)** 이라 하며, 셋을 함께 모형에 넣으면 설계행렬이 특이행렬이 되어 **계수를 유일하게 결정할 수 없음.**

**이것은 데이터의 문제가 아니라 우리가 만든 문제임.** `FamilySize` 를 정의하는 순간 예정된 결과였음. **파생변수를 만들면 원재료와의 관계를 반드시 확인해야 함.**

# 4. 최종 변수 선택 (3문항)

## 문제 17

이변량 분석 결과만으로 곧바로 **채택**할 수 있는 변수는 몇 개인가요? (정수 1개)

**정답.** `8`

**해설.** `Title` · `Sex` · `Pclass` · `Embarked` (교차분석 4종) + `Fare` · `FamilySize` · `Parch` · `SibSp` (집단 비교 4종) = **8개**임.

**앞 단원은 채택이 4개뿐이었음.** 명목형 독립변수가 없어 교차분석이 아예 수행되지 않았기 때문임. 이 데이터는 **교차분석 쪽에서만 4개가 추가로 나옴.**

다만 채택 목록 안에 **공선성 신호가 붙은 변수가 넷** 있음( `Title` ⍰ `Sex` , `FamilySize` ⍰ `SibSp` · `Parch` ). **"채택"은 "그대로 다 넣는다"는 뜻이 아니라 "쓸 만하다"는 판정일 뿐임.**

## 문제 18

단독 비교에서는 차이가 없었지만, 제거하지 않고 **보류**로 두는 변수는 무엇인가요? (변수명 1개)

**정답.** `Age`

**해설.** `Age` 하나임. 유의확률 0.295로 "차이가 없다"에 가까운데도 버리지 않음.

이유는 두 가지임. ① 공선성이 없어(VIF 1.10) 넣어도 부작용이 없고, ② **다른 변수를 통제하면 숨어 있던 효과가 드러날 수 있기 때문**임(억제효과).

**이변량 분석의 유의성만으로 변수를 버리면 안 됨.** 이 검정은 다른 변수를 통제하지 않은 **단독 비교**이므로, 여기서 자르면 되살아날 변수를 놓침. **변수 제거의 판정 시점은 탐색적 분석이 아니라 모델 적합 이후임.**

## 문제 19

탐색적 분석 결과 때문에 **제외**된 변수는 몇 개인가요? (정수 1개)

**정답.** `0`

**해설. 0개**임. 제외 목록에 오른 `PassengerId` · `Name` · `Ticket` · `Cabin` 네 개는 모두 **애초에 분석 대상이 아니어서** 앞 단계에서 이미 빠진 것이지, 이변량 분석 결과 때문이 아님.

**즉 EDA에서 탈락시킨 변수는 하나도 없음.** 유의하지 않게 나온 `Age` 조차 지우지 않고 모델에 투입한 뒤 후진소거법으로 판정함.

**"채택 / 보류 / 제외" 3분류에서 실제로 데이터를 건드리는 것은 '제외'뿐임.** 채택과 보류는 **기록일 뿐 둘 다 모델에 들어감.** 이 구분을 흐리면 EDA 단계에서 변수를 잘라 버리는 실수를 하게 됨.