Statistics Basic

LAB 10 - 로지스틱 회귀

7. [PBT] Titanic Survival

ITWILL 이광호 강사

1. 준비 작업 및 데이터 품질 점검

[LAB-10] 로지스틱 회귀 | 07-[PBT] Titanic Survival(1)(실습코드).ipynb

IT WILL 이광호 강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



분석 흐름 개요 (1)

□ 8단계 파이프라인에서 달라지는 지점

1 품질 점검	2 변수유형 분류	3 EDA	4 변수 선택	5 기준선 모형	6 가정 검정	7 파이프라인 비교	8 결과 보고

순서도 코드도 그대로다. **파란 4개 단계에서만 판단이 갈린다 — 모두 여섯 지점.**

단계	Apple Quality (4,000건)	Titanic (1,309건)
1 품질 점검	중복 0건 · 결측 0건 (이미 정제됨)	중복 190건 · Age 결측 20.1% · Cabin 결측 77.5%
1 품질 점검	**파생변수 없음**	**도메인 지식을 반영해 FamilySize, Title 두 개를 만든다**
3 EDA 이변량	**명목형 독립변수가 없어 T검정만**	**T검정 + 교차분석 둘 다 수행**
3 EDA 다변량	**Strong 조합 없음 (VIF 최대 1.48)**	**VIF = 무한대 (완전공선성)**
6 가정 검정	7종 중 5종 위배 → 제곱항 6개	4종 중 1종 위배 → 로그변환 1개 / 파생 계열은 위배 0
8 결과 보고	**균형 50:50 → 바닥값 50.1%**	**불균형 62:38 → 바닥값 62.3%**

이 덱은 이 여섯 지점만 따라간다. 나머지 단계는 앞 단원에서 한 그대로 지나간다.

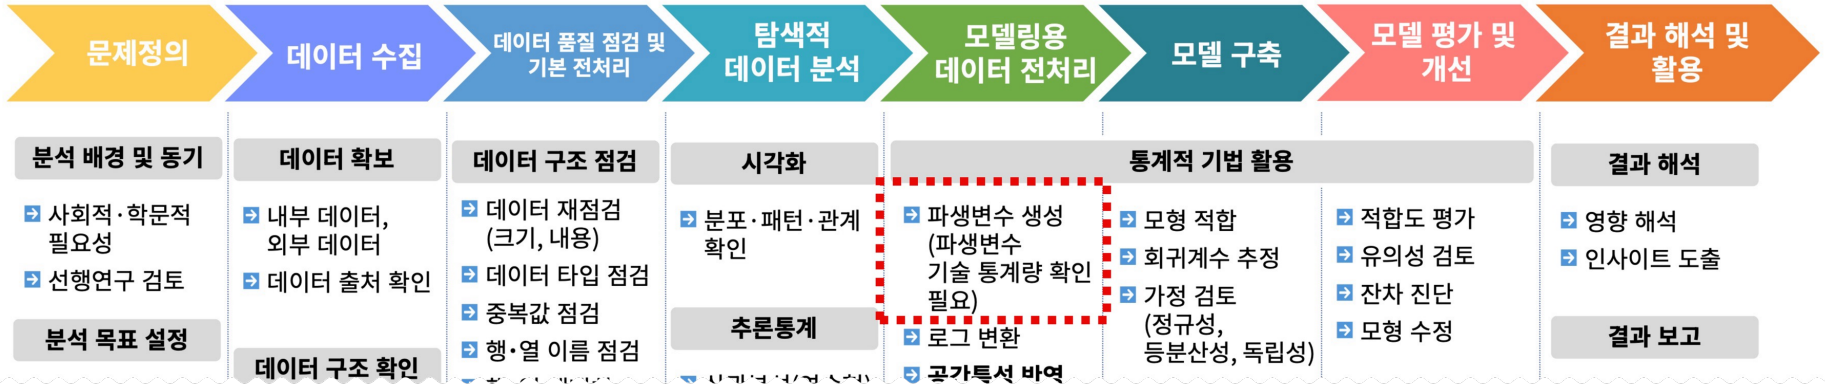
ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

분석 흐름 개요 (2)

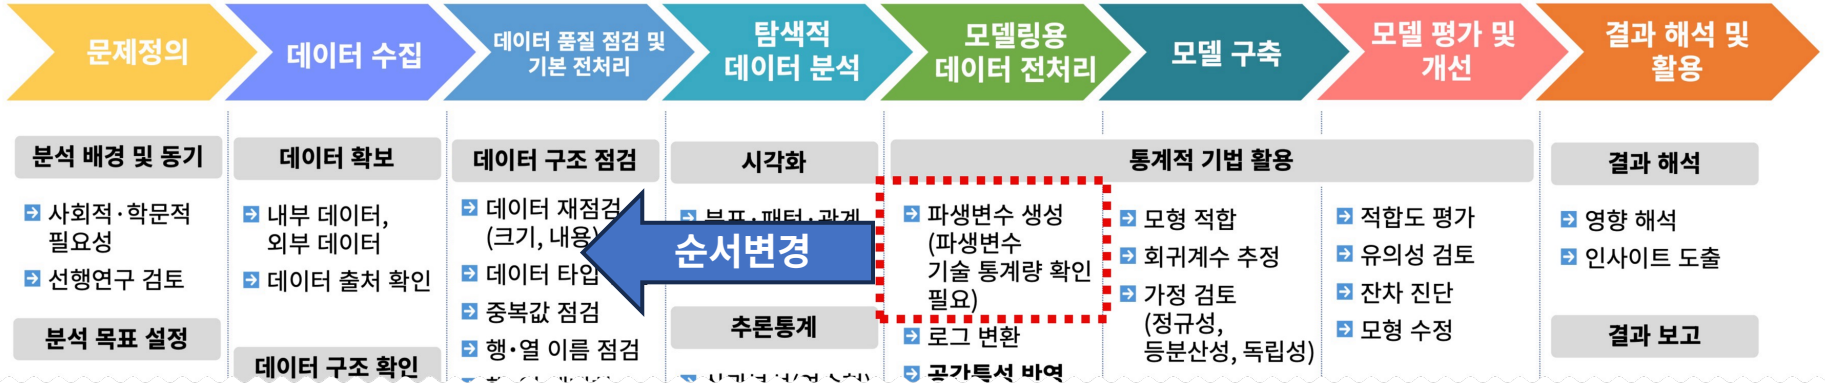
□ 도메인 지식이 부족할 경우의 파생변수 추가 위치

◎ 데이터의 분포, 패턴, 관계를 확인 후 이를 기반으로 파생변수를 추가해야 한다.



□ 확실한 도메인 지식이 있다면 기술통계량 확인 전 수행 가능

◎ **파생변수 추가와 결측치 대체는 확실한 도메인 지식이 뒷받침 된다면 품질점검 단계에서 수행해도 무관**하다. (이상치 처리는 반드시 모델링 전 수행)



ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#01. 준비작업

실습

1. 라이브러리 참조

```
1 from hossam import load_data
2 from helpers import *
3 from IPython.display import display, Markdown
4
5 from pandas import DataFrame, crosstab
```

✓ 마지막 실행: 오전 9:39:38, 기간: 1.7s Python

📦 아이티윌 이광호 강사가 제작한 라이브러리를 사용중입니다.
📚 자세한 사용 방법은 https://py.hossam.kr 을 참고하세요.
📧 Email: leekh4232@gmail.com
🎬 Youtube: https://www.youtube.com/@hossam-codingclub
📝 Blog: https://blog.hossam.kr/
🔖 Version: develop

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#01. 준비작업

실습

1. 데이터 불러오기

```
1 origin = load_data("titanic")
2 origin.head()
```

✓ 마지막 실행: 오전 11:06:34, 기간: 1.3s Python

📚 타이타닉호 침몰은 역사상 가장 악명 높은 난파 사고 중 하나입니다. 1912년 4월 15일, 첫 항해 중이던 타이타닉호는 빙산과 충돌하여 침몰했습니다. 당시 배에는 모든 승객과 승무원을 태울 수 있는 구명보트가 충분하지 않아 2,224명의 승객과 승무원 중 1,502명이 목숨을 잃었습니다. 생존에는 어느 정도 운이 작용했지만, 일부 집단은 다른 집단보다 생존 가능성이 더 높았던 것으로 보입니다. 이번 과제에서는 승객 데이터(예: 이름, 나이, 성별, 사회경제적 계층 등)를 사용하여 `어떤 유형의 사람들이 생존할 가능성이 더 높았을까?`라는 질문에 답하는 예측 모델을 구축해야 합니다. (출처: https://www.kaggle.com/datasets/yasserh/titanic-dataset)

변수명	설명
PassengerId	탑승객의 ID(인덱스와 같은 개념)
Survived	생존유무(0은 사망 1은 생존)
Pclass	객실의 등급(1=1등급, 2=2등급, 3=3등급)
Name	이름
Sex	성별
SibSp	동승한 형제 혹은 배우자의 수
Parch	동승한 자녀 혹은 부모의 수
Ticket	티켓번호
Fare	요금
Cabin	선실
Embarked	탑승지 (C = Cherbourg, Q = Queenstown, S = Southampton)

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.000	1	0	A/5 21171	7.250	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38.000	1	0	PC 17599	71.283	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.000	0	0	STON/O2. 3101282	7.925	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.000	1	0	113803	53.100	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.000	0	0	373450	8.050	NaN	S

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#01. 준비작업

실습

3. 컬럼 의미를 정리한 딕셔너리

```python
column_means = {
    "PassengerId": "탑승객 식별자",
    "Survived":    "생존 여부 (0=사망, 1=생존)",
    "Pclass":      "객실 등급 (1=1등급, 2=2등급, 3=3등급)",
    "Name":        "이름",
    "Sex":         "성별",
    "Age":         "나이",
    "SibSp":       "동승한 형제·배우자 수",
    "Parch":       "동승한 부모·자녀 수",
    "Ticket":      "티켓 번호",
    "Fare":        "요금",
    "Cabin":       "선실 번호",
    "Embarked":    "탑승 항구 (C=Cherbourg, Q=Queenstown, S=Southampton)",
}
```

✓ 마지막 실행: 오전 11:06:34, 기간: 0.0s Python

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

1. 자료형 확인

```
origin.info()
```

✓ 마지막 실행: 오전 11:06:34, 기간: 0.0s Python

```
<class 'pandas.DataFrame'>
RangeIndex: 1309 entries, 0 to 1308
Data columns (total 12 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  1309 non-null   int64
 1   Survived     1309 non-null   int64
 2   Pclass       1309 non-null   int64
 3   Name         1309 non-null   str
 4   Sex          1309 non-null   str
 5   Age          1046 non-null   float64
 6   SibSp        1309 non-null   int64
 7   Parch        1309 non-null   int64
 8   Ticket       1309 non-null   object
 9   Fare         1308 non-null   float64
 10  Cabin        295 non-null    str
 11  Embarked     1307 non-null   str
dtypes: float64(2), int64(5), object(1), str(4)
memory usage: 166.2+ KB
```

결측이 확인된다.

특히 Cabin은 분석에 사용하기 어려울 정도로 결측이 많다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#02. 데이터 품질 점검

2. 데이터 중복 점검

```
1 df0 = my_qtcheck.check_duplicates(origin, drop=True)
```

✓ 마지막 실행: 오후 12:59:03, 기간: 0.0s Python

```
중복된 행의 수: 0
```

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

3. 불필요한 컬럼 제거와 자료형 변환

◎ 분석 대상이 아닌 컬럼을 걷어낸다. 네 개를 각각 다른 이유로 제거한다.

컬럼	제거 이유
PassengerId	**행마다 값이 모두 다른 식별자**다. 숫자로 저장되어 있어 그대로 두면 연속형 독립변수로 잘못 투입된다.
Name	1,309개가 거의 모두 다른 **자유 텍스트**다. 그대로는 변수가 될 수 없다.
Ticket	형식이 제각각인 **문자열 식별자**다. (A/5 21171, 113803, STON/O2. 3101282 …)
Cabin	**결측이 1,014건(77.5%)**이다. 채울 근거가 없는 수준이므로 컬럼째 제거한다.

◎ 남은 컬럼 중 `Survived` · `Pclass` · `Sex` · `Embarked`를 **명목형(category)** 으로 변환

○ Survived 는 종속변수이고, Pclass는 1·2·3이라는 숫자로 저장되어 있지만 **"3등급은 1등급의 3배"가 아니므로** 연속형으로 두면 안 된다.

```python
# 원본에서 제거된 중복 데이터가 없으므로 계속 원본 사용
df0 = origin.drop(columns=["PassengerId", "Name", "Ticket", "Cabin"])
df1 = my_qtcheck.set_type(df0, as_category=["Survived", "Pclass",
"Sex", "Embarked"])
```

Python

출력 결과는 생략합니다.

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

4. 결측치 점검

```python
my_qtcheck.check_missing_values(df1)
```

Python

	Missing Count	Missing Ratio (%)
Survived	0	0.000
Pclass	0	0.000
Sex	0	0.000
Age	263	20.092
SibSp	0	0.000
Parch	0	0.000
Fare	1	0.076
Embarked	2	0.153

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

5. 결측치 대체

◎ 로지스틱 회귀는 결측치가 하나라도 있으면 적합되지 않는다. **모델링 전에 반드시 채워야 한다.**

◎ 컬럼의 성격에 따라 대체 방법을 다르게 쓴다.

○ **사전에 기술 통계량 확인 필요**
→ 여기서는 실습량을 고려하여 기술 통계량은 품질 점검 단계 마지막에만 확인한다.

컬럼	결측	대체 방법	이유
Age	263건 (20.1%)	**중앙값**	오른쪽 꼬리가 있는 분포라 평균은 극단값에 끌려간다
Fare	1건 (0.08%)	**중앙값**	왜도 4.37로 심하게 치우쳐 있다. 단 1건이라 영향은 미미하다
Embarked	2건 (0.15%)	**최빈값**	명목형이므로 평균·중앙값을 쓸 수 없다

```python
df2 = my_prep.replace_missing(df1, columns=["Age", "Fare"], method="median")
df3 = my_prep.replace_missing(df2, columns=["Embarked"], method="mode")

# 결측치가 모두 처리되었는지 확인
my_qtcheck.check_missing_values(df3)
```

✓ 마지막 실행: 오후 2:10:49, 기간: 0.0s Python

처리가 잘 되었다면 결측치가 0건으로 표시됩니다. → 출력 결과는 생략합니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

5. 결측치 대체 (결과 확인)

```
결측치 처리 방식: 'median'
컬럼                      결측치                 대체값
------------------------------------------------------
Age              263개(20.1%)                28.0
Fare               1개(0.1%)                14.4542
결측치 처리 방식: 'mode'
컬럼                      결측치                 대체값
------------------------------------------------------
Embarked           2개(0.2%)                 S
```

	Missing Count	Missing Ratio (%)
Survived	0	0.000
Pclass	0	0.000
Sex	0	0.000
Age	0	0.000
SibSp	0	0.000
Parch	0	0.000
Fare	0	0.000
Embarked	0	0.000

⚠ 한계 기록

Age의 20.1%를 하나의 값으로 채우는 것은 **가볍게 볼 일이 아니다.**

나이 분포에 중앙값 자리의 인공적인 봉우리가 생기고, 나이의 효과가 **실제보다 약하게** 추정된다.

이 한계는 반드시 기록해 두어야 한다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



파생변수 추가 (1)

☐ FamilySize — 흩어진 신호를 합친다

SibSp 형제 · 배우자 + **Parch** 부모 · 자녀 + **1** 본인 = **FamilySize**

◎ **SibSp**(형제·배우자)와 **Parch**(부모·자녀)는 **같은 사건을 둘로 쪼개 놓은 것**이다.

◎ 구조 상황에서 중요한 것은 "형제가 몇 명인가"가 아니라 **"찾아야 할 사람이 몇 명인가"**다.

○ 마지막 **+ 1**은 **본인**이다. 혼자 탄 승객이 0이 아니라 1이 되어 "가족 규모"라는 이름과 뜻이 맞는다.

⚠ **셋을 동시에 모형에 넣으면 안 된다.** 정의상 **FamilySize − SibSp − Parch = 1**(상수)이므로 **완전공선성**이 발생한다.
원재료를 남겨 둔 채 파생변수를 만들었으므로, **다변량 분석에서 이 관계를 반드시 점검해야 한다.**

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

6. 파생변수 생성 (1) - 동승자 수 계산

```python
# 결측 처리까지 끝난 데이터에 파생변수를 더한다 (df3 는 그대로 보존)
derived = df3.copy()

# 새로운 파생 변수 생성
derived["FamilySize"] = derived["SibSp"] + derived["Parch"] + 1

# 컬럼 의미 갱신
column_means["FamilySize"] = "동승 가족 수 (SibSp + Parch + 본인)"

# 결과 확인
derived.head()
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked	FamilySize
0	0	3	male	22.000	1	0	7.250	S	2
1	1	1	female	38.000	1	0	71.283	C	2
2	1	3	female	26.000	0	0	7.925	S	1
3	1	1	female	35.000	1	0	53.100	S	2
4	0	3	male	35.000	0	0	8.050	S	1

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



파생 변수 추가 (2)

□ Title - 이름에서 신분을 읽는다.

◎ 이름 형식이 **"Braund, Mr. Owen Harris" = 성, 호칭. 이름** 으로 구성되어 있음

- **원본 호칭 18종, 대부분 1~2건** → 그대로 더미변수로 변환하면 계수 추정 불가 → **5종으로 통합**
- 통합 방식에 정답은 없다 — 어떻게 묶었는지 반드시 기록한다

통합 호칭	포함	건수	나이 중앙값
Mr	Mr · Don · Sir · Jonkheer	760 (58.1%)	29.0세
Miss	Miss · Mlle · Ms	264 (20.2%)	22.0세
Mrs	Mrs · Mme · Dona · Lady · the Countess	201 (15.4%)	35.5세
Master	Master	61 (4.7%)	4.0세
Officer	Dr · Rev · Col · Major · Capt	23 (1.8%)	49.5세

- **Master는 최고령이 14.5세** — 이 호칭 자체가 "남자아이"를 뜻한다.
  Sex만 보면 6세 남아와 40세 남성이 똑같이 male
- Officer에 여성 1명(Dr. Alice Leader) — 호칭이 성별과 완전히 같지는 않다는 증거

ITWILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

7. 신분 파생 변수 추가 (1) - 이름에서 호칭 분리

◎ 타이타닉의 이름은 **Braund, Mr. Owen Harris**처럼 `성, 호칭. 이름` 형식으로 통일되어 있다.

◎ **쉼표와 마침표 사이**를 뽑으면 호칭이 나온다. 정규식 `,\s*([^\.]+)\.` 이 그 일을 한다.

◎ 뽑아 쓰는 대상은 **origin["Name"]** 이다.

○ 작업본에서는 이미 지운 컬럼이지만 원본에는 남아 있다.

```
1 # ── ① 이름에서 호칭 추출 : "성, 호칭. 이름" 형식이므로 쉼표와 마침표 사이를 뽑는다
2 title_raw = origin["Name"].str.extract(r",\s*([^\.]+)\.", expand=False)
3 title_raw = title_raw.str.strip()
4
5 display(Markdown("**원본 호칭 (통합 전 18종)**"))
6 display(title_raw.value_counts().rename("빈도").to_frame().T)
```

정규표현식 --> 문자열의 형식을 의미하는 표현식
다소 프로그래밍 적인 지식이 필요한 부분이므로
여기서는 설명하지 않습니다.

✓ 마지막 실행: 오후 12:14:07, 기간: 0.0s Python

원본 호칭 (통합 전 18종)

Name	Mr	Miss	Mrs	Master	Rev	Dr	Col	Ms	Major	Mlle	Don	Mme	Lady	Sir	Capt	the Countess	Jonkheer	Dona
빈도	757	260	197	61	8	8	4	2	2	2	1	1	1	1	1	1	1	1

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

8. 신분 파생 변수 추가 (2) - 의미별 호칭 정의 → 도메인 지식 필요

```
# ── 18종의 호칭을 의미가 같은 것끼리 묶어 5종으로 통합한다
#    (도메인 지식이 필요한 부분)
title_map = {
    # 성인 남성 – Don(스페인)·Sir(영국)·Jonkheer(네덜란드)는 남성 귀족 경칭
    "Mr": "Mr", "Don": "Mr", "Sir": "Mr", "Jonkheer": "Mr",
    # 미혼 여성 – Mlle(프랑스)=Miss, Ms=혼인 여부를 밝히지 않는 호칭
    "Miss": "Miss", "Mlle": "Miss", "Ms": "Miss",
    # 기혼 여성 – Mme(프랑스)·Dona(스페인)=Mrs, Lady·the Countess는 여성 귀족 경칭
    "Mrs": "Mrs", "Mme": "Mrs", "Dona": "Mrs", "Lady": "Mrs", "the Countess": "Mrs",
    # 남자아이
    "Master": "Master",
    # 전문직·군인·성직자 – 이름에 직위가 드러난 사람들
    "Dr": "Officer", "Rev": "Officer", "Col": "Officer", "Major": "Officer", "Capt": "Officer"
}
```

출력 결과가 없습니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#02. 데이터 품질 점검

9. 신분 파생 변수 추가 (3) - 호칭 파생변수 추가 → 신분을 의미

```
# ── Title 변수 추가 (origin 과 인덱스가 같으므로 그대로 붙는다)
derived["Title"] = title_raw.map(title_map)

# ── 매핑 누락 점검 : 결측이 1건이라도 있으면 title_map 에 빠진 호칭이 있다는 뜻이다
print("Title 매핑 누락 :", derived["Title"].isna().sum(), "건\n")

# ── 문자열이므로 명목형으로 선언한다. 그대로 두면 더미 인코딩 대상이 되지 않는다
derived = my_qtcheck.set_type(derived, as_category=["Title"])

# ── 컬럼 의미 사전도 함께 갱신한다 (이후 EDA 반복문이 이 사전을 참조한다)
column_means["Title"] = "이름에서 추출한 호칭 (Mr/Mrs/Miss/Master/Officer)"

display(origin[["Name"]].join(derived[["Title", "SibSp", "Parch", "FamilySize"]]).head())
display(derived["Title"].value_counts().rename("빈도").to_frame().T)
```

출력 결과는 다음 페이지에 제시합니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

9. 신분 파생 변수 추가 (3) - 호칭 파생변수 추가 → 신분을 의미 (결과 확인)

◎ 당시 사회는 신분(계급)이 나누어져 있었다. 이를 데이터에 반영한다.

```
Title 매핑 누락 : 0 건

<class 'pandas.DataFrame'>
RangeIndex: 1309 entries, 0 to 1308
Data columns (total 10 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   Survived    1309 non-null   category
 1   Pclass      1309 non-null   category
 2   Sex         1309 non-null   category
 3   Age         1309 non-null   float64
 4   SibSp       1309 non-null   int64
 5   Parch       1309 non-null   int64
 6   Fare        1309 non-null   float64
 7   Embarked    1309 non-null   category
 8   FamilySize  1309 non-null   int64
 9   Title       1309 non-null   category
dtypes: category(5), float64(2), int64(3)
memory usage: 57.9 KB
```

	Name	Title	SibSp	Parch	FamilySize
0	Braund, Mr. Owen Harris	Mr	1	0	2
1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	Mrs	1	0	2
2	Heikkinen, Miss. Laina	Miss	0	0	1
3	Futrelle, Mrs. Jacques Heath (Lily May Peel)	Mrs	1	0	2
4	Allen, Mr. William Henry	Mr	0	0	1

Title	Mr	Miss	Mrs	Master	Officer
빈도	760	264	201	61	23

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

10. 생성된 신분 파생 변수의 분포 확인

```python
# ── 호칭이 정말 '신분'을 담고 있는지 확인한다
display(Markdown("**호칭별 성별 분포**"))
display(crosstab(derived["Title"], derived["Sex"]))

# ⚠️ 나이는 결측을 채우기 전인 origin 기준으로 본다.
# -> derived 의 Age 는 중앙값 28세로 채워져 있어 호칭별 분포가 왜곡된다.
display(Markdown("**호칭별 나이 요약 (결측 대체 전 · `origin` 기준)**"))
display(origin.assign(Title=derived["Title"])
              .groupby("Title", observed=True)["Age"]
              .agg(["count", "median", "min", "max"]).T)
```

Python

출력 결과는 다음 페이지에 제시합니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

10. 생성된 신분 파생 변수의 분포 확인 (결과 확인)

호칭별 성별 분포

Sex	female	male
Title		
Master	0	61
Miss	264	0
Mr	0	760
Mrs	201	0
Officer	1	22

호칭별 나이 요약 (결측 대체 전 · `origin` 기준)

Title	Master	Miss	Mr	Mrs	Officer
count	53.000	213.000	584.000	174.000	22.000
median	4.000	22.000	29.000	35.500	49.500
min	0.330	0.170	11.000	14.000	23.000
max	14.500	63.000	80.000	76.000	70.000

호칭이 성별과 연령대 정보를 담고 있음을 알 수 있다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

11. 명목형 변수의 기술 통계량

```
1 cat_desc = my_qtcheck.categorical_summary(derived, value_counts=False)
2 cat_desc
```

✓ 마지막 실행: 오후 1:30:16, 기간: 0.0s Python

	Survived	Pclass	Sex	Embarked	Title
count	1309	1309	1309	1309	1309
unique	2	3	2	3	5
top	0	3	male	S	Mr
freq	815	709	843	916	760

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#02. 데이터 품질 점검

실습

□ 12. 연속형 변수의 기술 통계량

◎ 여기서 생성한 기술 통계량 표가 단변량 분석에서 활용되기 때문에,
여기서는 인사이트 발굴 없이 통계량 표만 확인하고 넘어가도 된다.

```
1 num_desc = my_qtcheck.numerical_summary(derived)
2 num_desc.T
```

✓ 마지막 실행: 오후 1:30:16, 기간: 0.0s Python

	Age	SibSp	Parch	Fare	FamilySize
count	1309.000	1309.000	1309.000	1309.000	1309.000
mean	29.503	0.499	0.385	33.281	1.884
std	12.905	1.042	0.866	51.741	1.584
min	0.170	0.000	0.000	0.000	1.000
25%	22.000	0.000	0.000	7.896	1.000
50%	28.000	0.000	0.000	14.454	1.000
75%	35.000	1.000	0.000	31.275	2.000
max	80.000	8.000	9.000	512.329	11.000
rel_diff	0.054	inf	inf	1.303	0.884
rdiff_flag	similar	large_diff	large_diff	large_diff	large_diff
iqr	13.000	1.000	0.000	23.379	1.000
upper_bound	54.500	2.500	0.000	66.344	3.500
lower_bound	2.500	-1.500	0.000	-27.173	-0.500
upper_outliers	67	57	307	171	125
upper_outliers_ratio	0.051	0.044	0.235	0.131	0.095
lower_outliers	34	0	0	0	0
lower_outliers_ratio	0.026	0.000	0.000	0.000	0.000
outliers	101	57	307	171	125
outliers_ratio	0.077	0.044	0.235	0.131	0.095
skew	0.541	3.844	3.669	4.370	2.853
skew_interpret	right tail	right tail	right tail	right tail	right tail
kurt	0.970	20.043	21.541	27.050	10.299
kurt_interpret	leptokurtic	leptokurtic	leptokurtic	leptokurtic	leptokurtic
log_need	log	log1p	log1p	log1p	log

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#03. 변수 유형 분류와 EDA 범위

실습

1. 변수 유형 분류

```python
target = "Survived"    # 종속변수
target_is_continuous = False    # 종속변수 연속형 여부  --> 로지스틱이므로 False
nominal_cols = my_qtcheck.get_categorical_column_names(derived) # 명목형 변수
continuous_cols = my_qtcheck.get_number_column_names(derived)   # 연속형 변수

if target_is_continuous:
    continuous_cols.remove(target)  # 연속형 변수 이름에서 종속변수 항목 제거
else:
    nominal_cols.remove(target)     # 명목형 변수 이름에서 종속변수 항목 제거

print("종속변수 :", target)
print("종속변수 유형: " + ("연속형" if target_is_continuous else "명목형"))
print("명목형   :", nominal_cols)
print("연속형   :", continuous_cols)
```

✓ 마지막 실행: 오후 1:30:16, 기간: 0.0s Python

```
종속변수 : Survived
종속변수 유형: 명목형
명목형   : ['Pclass', 'Sex', 'Embarked', 'Title']
연속형   : ['Age', 'SibSp', 'Parch', 'Fare', 'FamilySize']
```

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#03. 변수 유형 분류와 EDA 범위

실습

2. 범주 순서 지정 (서열척도 · 기준 범주) (1/2)

목적	대상	ordered	뜻
서열척도 선언	Pclass	True	범주 사이에 **크고 작음이 실제로 있다**
기준 범주 지정	Title	False	순서는 없지만 **더미의 기준을 정하고 싶다**

```
# ① 서열척도를 적용할 변수와 순서를 정의한다. (낮은 등급 → 높은 등급)
ordinal_map = {
    "Pclass": [3, 2, 1],    # 3등급 < 2등급 < 1등급 가설
}

# ② 서열은 없지만 더미변수의 기준(reference) 범주를 지정하기 위해 순서만 재배치할 변수
# -> 맨 앞에 둔 범주가 drop_first 로 빠지면서 기준이 된다.
reference_map = {
    "Title": ["Mr", "Officer", "Master", "Miss", "Mrs"],    # 기준: Mr (성인 남성)
}
```

명목형 변수: 이 후 더미변수로 만듦.
drop(False)
빈도가 가장 높은 변수를 앞에 배치하면 나머지 변수들이 삭제가 된다.

... 다음 페이지에 이어집니다 ...

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#03. 변수 유형 분류와 EDA 범위

실습

2. 범주 순서 지정 (서열척도 · 기준 범주) (2/2)

... 앞 페이지와 이어집니다. 같은 코드 블록에 작성하세요 ...

```python
# 정의된 내용에 따라 순서를 재지정한다.
# -> 데이터셋에 없는 컬럼은 건너뛰므로 다른 데이터셋에서도 오류가 나지 않는다.
df = derived.copy()

for col, order in ordinal_map.items():
    if col in df.columns:
        print(f"'{col}' 컬럼 순서 재지정 (서열척도)   : {order}")
        df[col] = df[col].cat.reorder_categories(order, ordered=True)

for col, order in reference_map.items():
    if col in df.columns:
        print(f"'{col}' 컬럼 순서 재지정 (기준 범주용) : {order}")
        # ordered=False -> 순서만 바꿀 뿐 서열척도로 선언하지는 않는다
        df[col] = df[col].cat.reorder_categories(order, ordered=False)
```

✓ 마지막 실행: 오후 1:30:16, 기간: 0.0s Python

```
'Pclass' 컬럼 순서 재지정 (서열척도)   : [3, 2, 1]
'Title' 컬럼 순서 재지정 (기준 범주용) : ['Mr', 'Officer', 'Master', 'Miss', 'Mrs']
```

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#03. 변수 유형 분류와 EDA 범위

3. EDA 범위 정리

종속유형	독립유형	분석 유형	대상 변수	적용	비고
연속형	연속형	상관분석	—	미적용	종속 명목형
연속형	명목형(2집단)	T검정	—	미적용	종속 명목형
연속형	명목형(3집단+)	ANOVA	—	미적용	종속 명목형
명목형(2집단)	**연속형**	**T검정**	**Age · SibSp · Parch · Fare · FamilySize → Survived**	**적용**	
명목형(2집단)	**명목형(2집단)**	**교차분석**	**Sex → Survived**	**적용**	
명목형(2집단)	**명목형(3집단+)**	**교차분석**	**Pclass · Embarked · Title → Survived**	**적용**	
명목형(3집단+)	연속형	ANOVA	—	미적용	종속 2집단
명목형(3집단+)	명목형(2집단)	교차분석	—	미적용	종속 2집단
명목형(3집단+)	명목형(3집단+)	교차분석	—	미적용	종속 2집단

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



연습문제 타이타닉 생존률 예측 #01

□ 분석 과정을 실습하고 다음 물음에 답하시오.

1. 데이터를 불러왔을 때, 원본 데이터의 관측치(행)는 몇 개인가요? (정수 1개)
2. 원본 데이터는 몇 개의 컬럼으로 이루어져 있나요? (정수 1개)
3. 원본 12개 컬럼 중 결측치가 하나라도 있는 컬럼은 몇 개인가요? (정수 1개)
4. 결측 비율이 가장 높은 컬럼은 무엇인가요? (변수명 1개)
5. 원본 상태에서 중복 점검을 수행했을 때, 중복된 행은 몇 개인가요? (정수 1개)
6. 분석 대상이 아닌 컬럼을 제거하고 나면, 남은 데이터는 몇 개의 컬럼이 되나요? (정수 1개)
7. Age의 결측 263건을 채우는 데 사용한 대체값은 얼마인가요? (소수 첫째 자리)
8. Embarked의 결측 2건을 채우는 데 사용한 값은 무엇인가요? (범주값 1개)
9. 이름에서 추출한 원본 호칭은 모두 몇 종인가요? (정수 1개)
10. 18종의 호칭을 의미별로 통합한 뒤, Title의 범주는 몇 개가 되나요? (정수 1개)
11. Title의 5개 범주 중 관측치가 가장 적은 것은 무엇인가요? (범주값 1개)
12. Master의 나이 최댓값은 몇 살인가요? (소수 첫째 자리)
13. 파생변수 두 개를 추가하고 나면, 데이터는 몇 개의 컬럼이 되나요? (정수 1개)
14. 연속형 5종 중 이상치가 가장 많이 섞여 있는 항목은 무엇인가요? (변수명 1개)
15. 연속형 5종 중 분포의 비대칭이 가장 큰(왜도의 절댓값이 가장 큰) 항목은 무엇인가요? (변수명 1개)
16. 종속변수를 제외하고 나면, 명목형 독립변수는 몇 개인가요? (정수 1개)
17. 종속변수를 제외하고 나면, 연속형 독립변수는 몇 개인가요? (정수 1개)
18. 척도 조합표의 아홉 가지 경우 중, 이 데이터에서 실제로 수행되는 분석 기법은 몇 가지인가요? (정수 1개)
19. 서열척도로 순서를 지정한 변수는 무엇인가요? (변수명 1개)
20. Title의 기준(reference) 범주로 지정한 값은 무엇인가요? (범주값 1개)

2. 탐색적 데이터 분석

[LAB-10] 로지스틱 회귀 | 07-[PBT] Titanic Survival(2)(실습코드).ipynb

IT WILL 이광호 강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#04. 단변량 분석

실습

1. 명목형 종속변수에 대한 단변량 분석

```python
# 명목형 분포는 카운트 플롯으로 처리한다.
my_plot.countplot(data=df, x=target, hue=target, palette="Set2",
                  title=f"종속변수 {target}({column_means[target]}) 분포")

# 명목형 기술통계량
display(cat_desc[[target]].T)

# 추가적으로 빈도표 생성
freq = df[target].value_counts().rename("빈도").to_frame()
freq["비율"] = df[target].value_counts(normalize=True)
display(freq)
```

✓ 마지막 실행: 오후 2:12:22, 기간: 0.1s Python

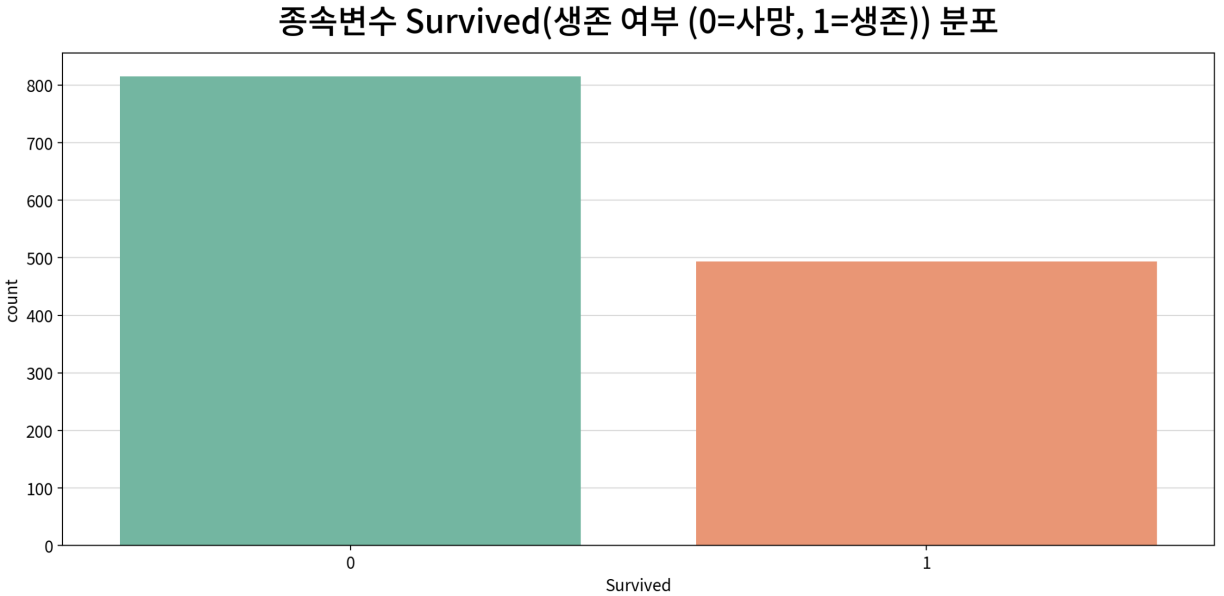
출력 결과는 다음 페이지에 제시합니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#04. 단변량 분석

1. 명목형 종속변수에 대한 단변량 분석 (결과 확인)



	count	unique	top	freq
Survived	1309	2	0	815

	빈도	비율
Survived		
0	815	0.623
1	494	0.377

점검 항목	Survived 관찰값
범주 수	2 (0=사망 / 1=생존) → **이분형**이므로 로지스틱 회귀 적용 가능
최빈 범주	사망 **815건 (62.3%)**
최소 범주	생존 **494건 (37.7%)**
균형 여부	**약한 불균형** (62 : 38)

- **정확도의 바닥값(baseline)은 62.3%**다. 모두 “사망”이라고만 답하는 게으른 모형도 62.3%를 맞힌다.
- 즉 정확도 70%짜리 모형은 **좋은 모형이 아니다.** 바닥값보다 8%p 나은 것에 불과하다.
- Apple Quality의 바닥값 50.1%와 비교해야 한다. **같은 정확도라도 데이터마다 의미가 다르다.**
- 62 : 38 정도면 리샘플링 없이 진행하되, **정확도 하나만 보지 말고 재현율·정밀도·AUC를 함께 확인**해야 한다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#04. 단변량 분석

2. 명목형 독립변수에 대한 단변량 분석

◎ 명목형 독립변수도 **범주별 빈도의 쏠림**을 확인한다.

○ 한 범주에 관측치가 지나치게 적으면 그 더미변수의 계수가 불안정해지기 때문이다.

```python
for n in nominal_cols:
    display(Markdown(f"### ▶ {n}({column_means[n]}) 분포"))
    freq = df[n].value_counts().rename("빈도").to_frame()
    freq["비율"] = df[n].value_counts(normalize=True)
    display(freq.T)

    my_plot.countplot(data=df, x=n, hue=n, palette="Set2", width=720, height=400)
```

✓ 마지막 실행: 오후 2:12:22, 기간: 0.2s Python

출력 결과는 다음 페이지에 제시합니다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



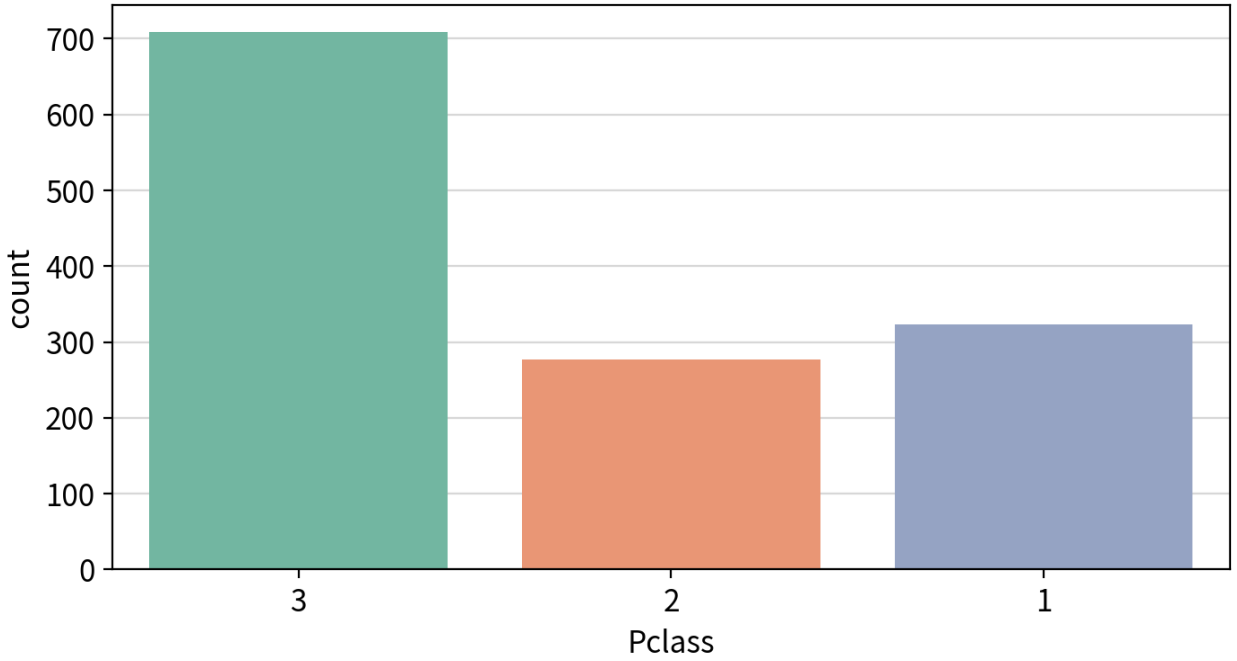
#04. 단변량 분석

2. 명목형 독립변수에 대한 단변량 분석 (결과 확인 1/4)

▶ Pclass(객실 등급 (1=1등급, 2=2등급, 3=3등급)) 분포

Pclass	3	1	2
빈도	709.000	323.000	277.000
비율	0.542	0.247	0.212

- 3등급 승객이 절반을 넘는다는 사실 자체가 **타이타닉의 승객 구성**이다.
- 표본 편향이 아니라 모집단의 모습이다.



- **범주 분포 :** 3등급 709 (54.2%) · 1등급 323 (24.7%) · 2등급 277 (21.2%)
- **판 단 :** 3등급이 절반 이상이지만 나머지 범주도 충분하다

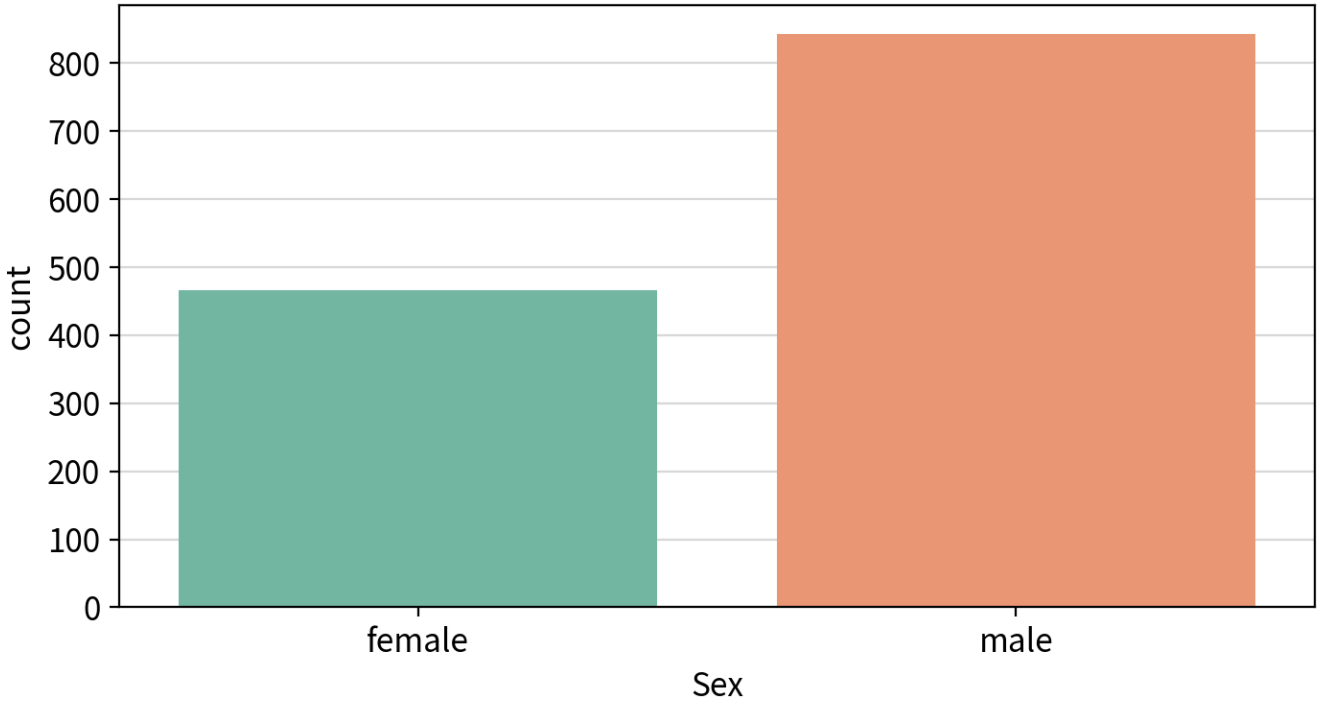
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

2. 명목형 독립변수에 대한 단변량 분석 (결과 확인 2/4)

▶ Sex(성별) 분포

Sex	male	female
빈도	843.000	466.000
비율	0.644	0.356



- **범주 분포 :** 남성 843 (64.4%) · 여성 466 (35.6%)
- **판 단 :** 두 범주 모두 표본이 충분하다. 문제 없음

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

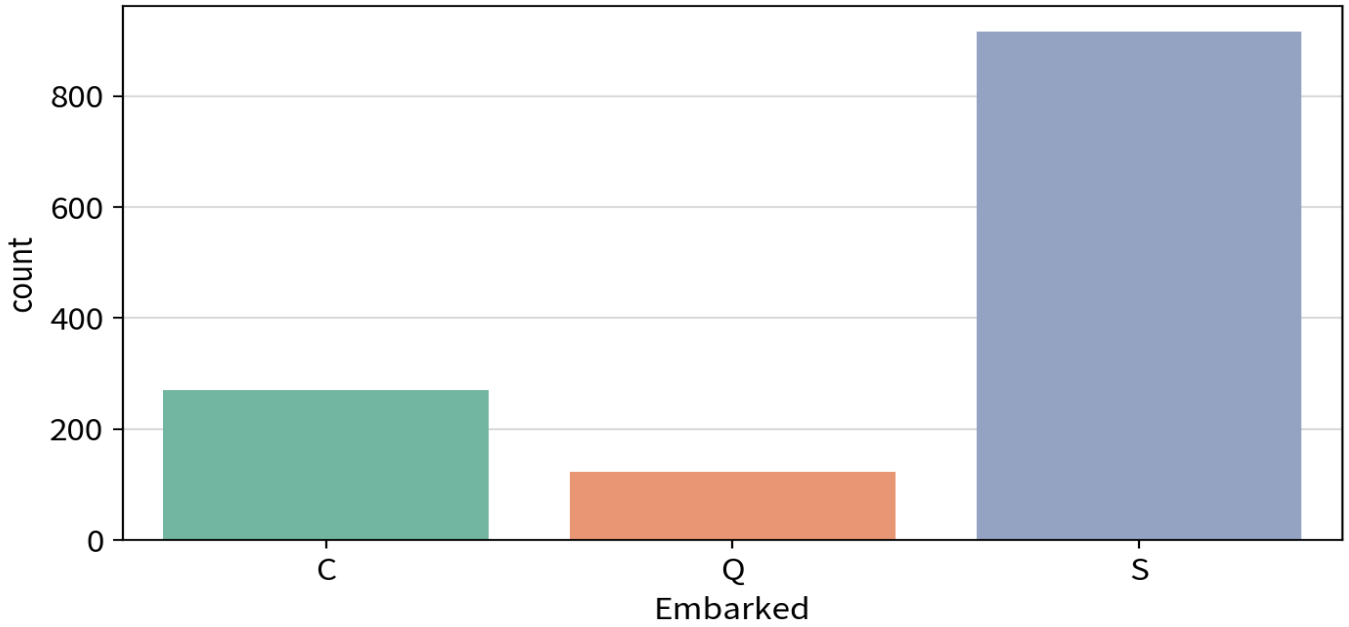


#04. 단변량 분석

2. 명목형 독립변수에 대한 단변량 분석 (결과 확인 3/4)

▶ Embarked(탑승 항구 (C=Cherbourg, Q=Queenstown, S=Southampton)) 분포

Embarked	S	C	Q
빈도	916.000	270.000	123.000
비율	0.700	0.206	0.094



- **범주 분포 :** S 916 (70.0%) · C 270 (20.6%) · **Q 123 (9.4%)**
- **판 단 :** Q가 다소 적으나 100건 이상이므로 사용 가능

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



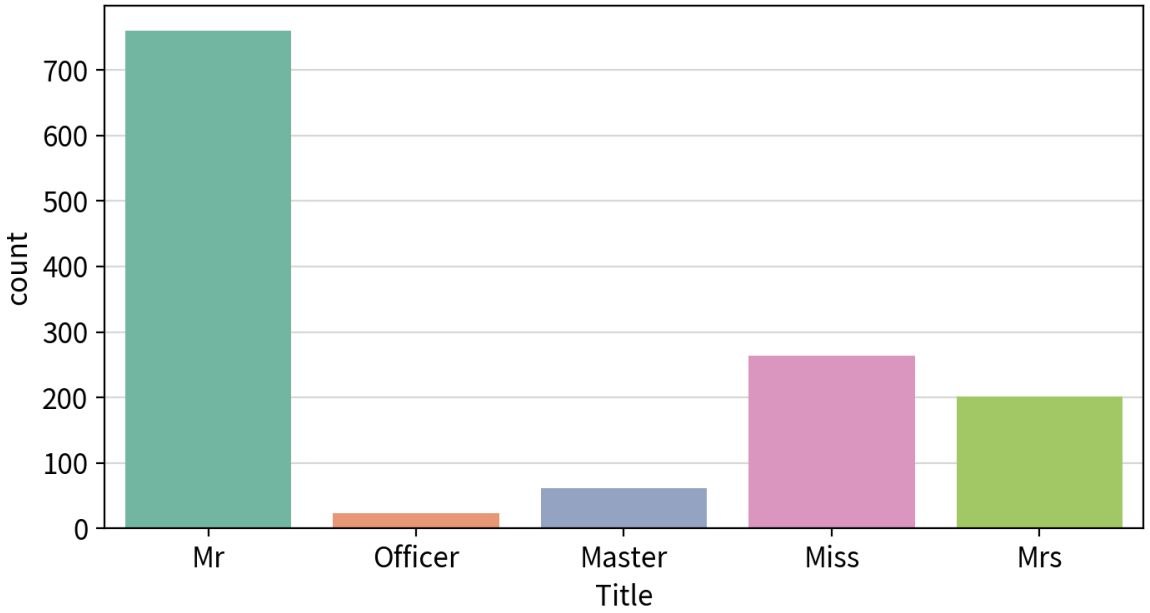
#04. 단변량 분석

2. 명목형 독립변수에 대한 단변량 분석 (결과 확인 4/4)

▶ Title(이름에서 추출한 호칭 (Mr/Mrs/Miss/Master/Officer)) 분포

Title	Mr	Miss	Mrs	Master	Officer
빈도	760.000	264.000	201.000	61.000	23.000
비율	0.581	0.202	0.154	0.047	0.018

- 최소 범주는 **Officer 23건**.
  경험칙(범주당 10~20건)의 **하한**에 걸쳐 있다.
- 추정은 되지만 **신뢰구간이 넓어질 것**을 각오해야 한다.
- **잘게 나눌수록 정보는 늘고 표본은 줄어든다.**
  파생변수의 숙명적 교환이다.
- 호칭 18종을 그대로 썼다면 1건짜리 범주가 6개 생겨
  추정 자체가 불가능했다. 5종 통합이 정당화된다.



- **범주 분포 :** Mr 760 (58.1%) · Miss 264 (20.2%) · Mrs 201 (15.4%) · Master 61 (4.7%) · **Officer 23 (1.8%)**
- **판 단 :** **Officer**가 경계선 — 추정은 가능하나 신뢰구간이 넓어진다

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#04. 단변량 분석

3. 연속형 독립변수에 대한 단변량 분석

```python
for f in continuous_cols:
    fig, ax = my_plot.init(rows=1, cols=2, width=960, height=640,
                           title=f"독립변수 {f}({column_means[f]}) 분포")
    my_plot.histplot(data=df, x=f, kde=True, ax=ax[0])
    my_plot.boxplot(data=df, x=f, ax=ax[1])
    my_plot.show()

    display(num_desc[num_desc.index == f].T)
```

✓ 마지막 실행: 오후 2:12:23, 기간: 0.6s Python

출력 결과는 다음 페이지에 제시합니다.

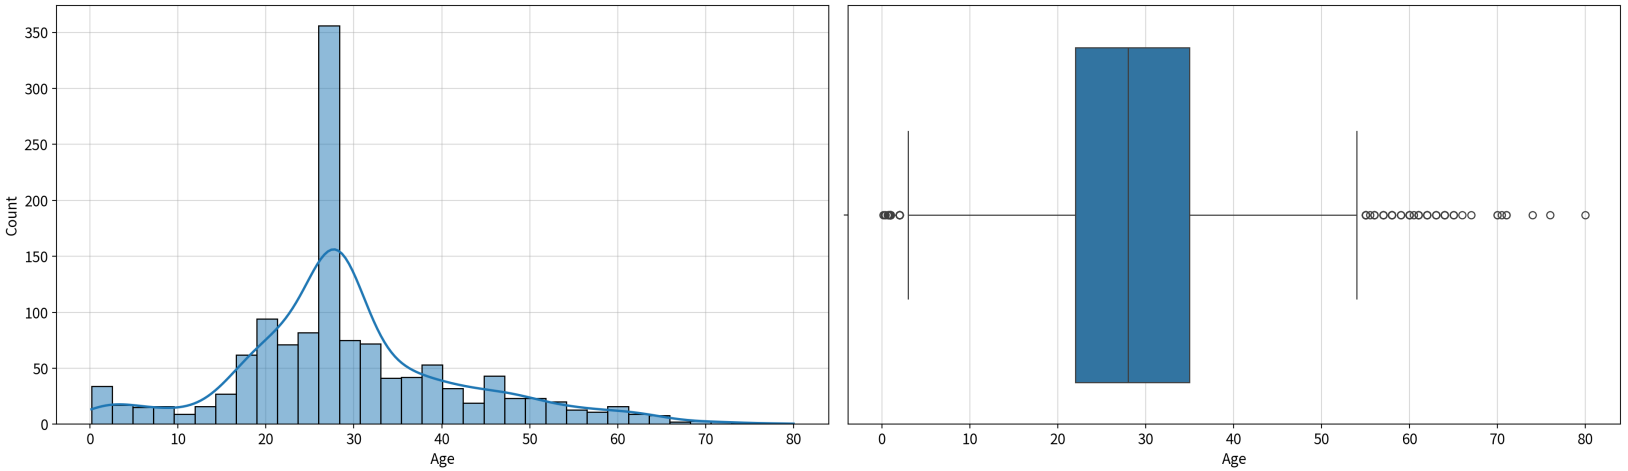
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

3. 연속형 독립변수에 대한 단변량 분석 (결과 확인 1/5)

	Age
count	1309.000
mean	29.503
std	12.905
min	0.170
25%	22.000
50%	28.000
75%	35.000
max	80.000
rel_diff	0.054
rdiff_flag	similar
iqr	13.000
upper_bound	54.500
lower_bound	2.500
upper_outliers	67
upper_outliers_ratio	0.051
lower_outliers	34
lower_outliers_ratio	0.026
outliers	101
outliers_ratio	0.077
skew	0.541
skew_interpret	right tail
kurt	0.970
kurt_interpret	leptokurtic
log_need	log

독립변수 Age(나이) 분포



왜도 약한 오른쪽 꼬리 (+0.54) **봉우리 28세 인공 봉우리** **이상치** 101건 (7.7%)
판단·조치 중앙값 대체의 흔적 — 로짓 선형성 검정에서 재확인

- **히스토그램 한가운데 뾰족한 막대**는 결측 263건을 중앙값 28세로 채운 자국이다.
- 실제 관측값이 아니라 **우리가 만들어 넣은 값**이므로, 이후 결과 해석에서 항상 염두에 둬야 한다.

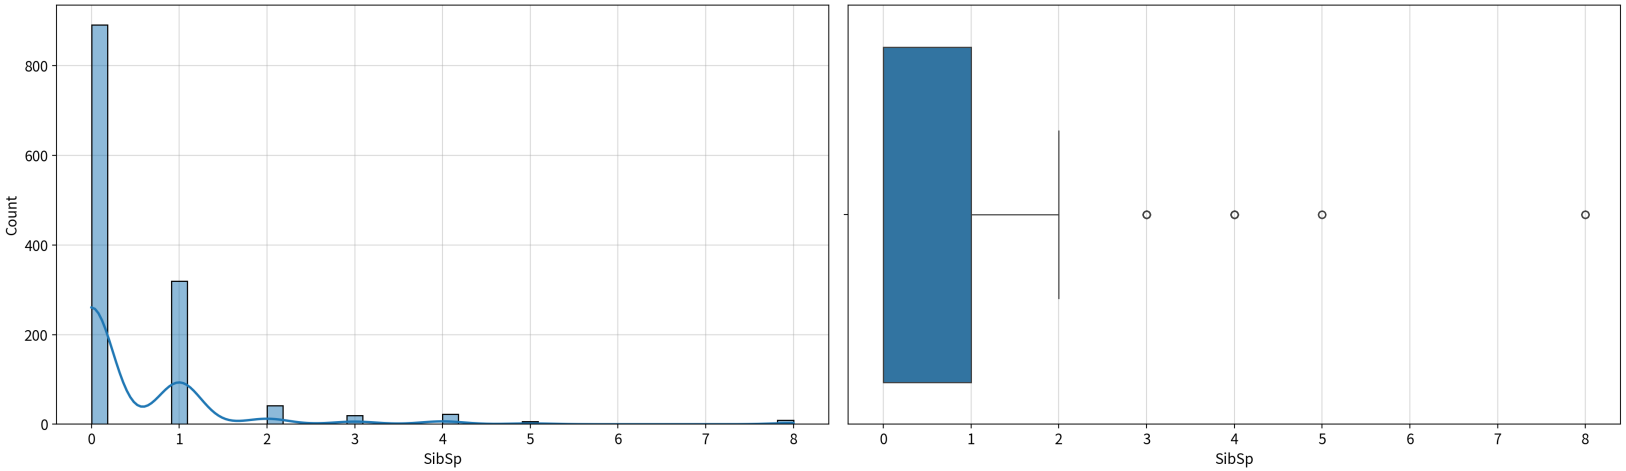
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

3. 연속형 독립변수에 대한 단변량 분석 (결과 확인 2/5)

	SibSp
count	1309.000
mean	0.499
std	1.042
min	0.000
25%	0.000
50%	0.000
75%	1.000
max	8.000
rel_diff	inf
rdiff_flag	large_diff
iqr	1.000
upper_bound	2.500
lower_bound	-1.500
upper_outliers	57
upper_outliers_ratio	0.044
lower_outliers	0
lower_outliers_ratio	0.000
outliers	57
outliers_ratio	0.044
skew	3.844
skew_interpret	right tail
kurt	20.043
kurt_interpret	leptokurtic
log_need	log1p

독립변수 SibSp(동승한 형제·배우자 수) 분포



왜도 심한 오른쪽 꼬리 (+3.84) **봉우리** 0에 집중 **이상치** 57건 (4.4%)
판단·조치 카운트 변수 — IQR 규칙 부적합

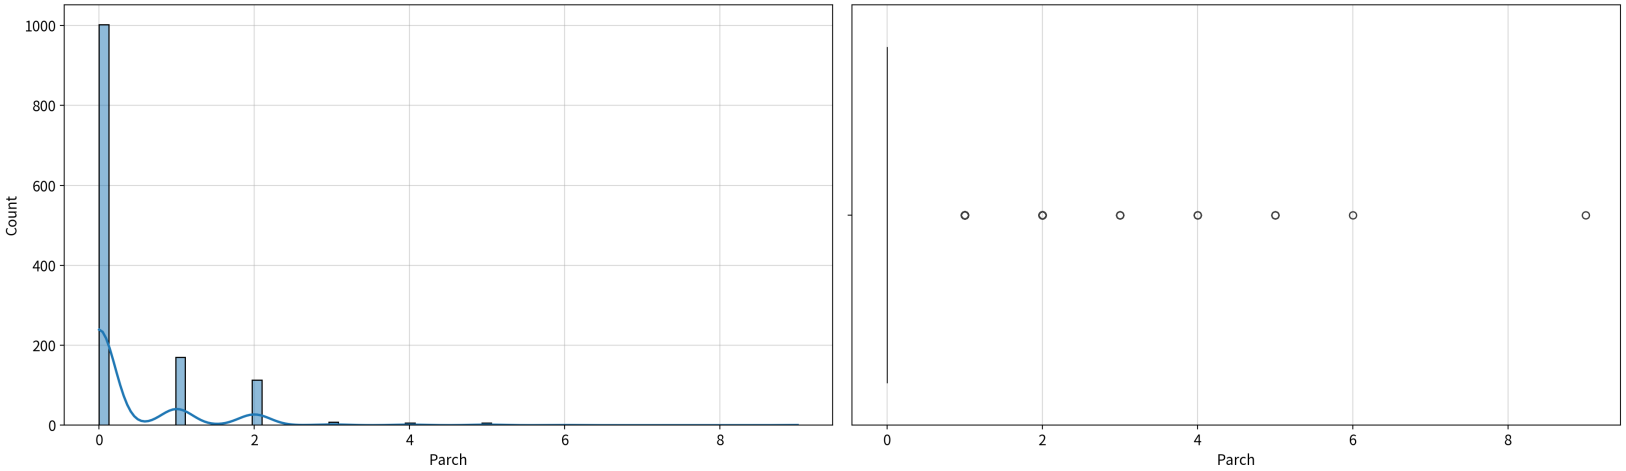
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

3. 연속형 독립변수에 대한 단변량 분석 (결과 확인 3/5)

	Parch
count	1309.000
mean	0.385
std	0.866
min	0.000
25%	0.000
50%	0.000
75%	0.000
max	9.000
rel_diff	inf
rdiff_flag	large_diff
iqr	0.000
upper_bound	0.000
lower_bound	0.000
upper_outliers	307
upper_outliers_ratio	0.235
lower_outliers	0
lower_outliers_ratio	0.000
outliers	307
outliers_ratio	0.235
skew	3.669
skew_interpret	right tail
kurt	21.541
kurt_interpret	leptokurtic
log_need	log1p

독립변수 Parch(동승한 부모·자녀 수) 분포



왜도 심한 오른쪽 꼬리 (+3.67) **봉우리** 0에 집중 **이상치 307건 (23.5%)**
판단·조치 IQR = 0 → 이상치 판정 자체가 무의미

- **상자그림의 상자가 선 하나로 눌려 있다.** Q1 = Q3 = 0이라 상자에 두께가 없다.
- 이런 변수에 IQR 이상치 대체를 적용하면 **0이 아닌 값이 전부 0으로 눌려 변수가 상수가 된다.**

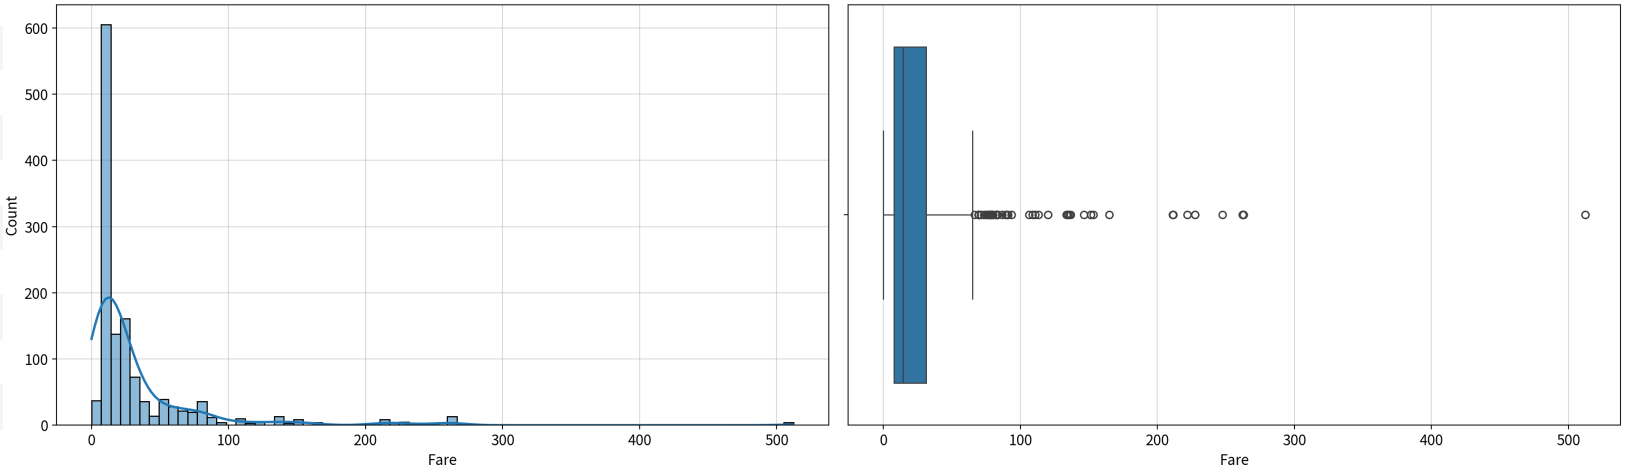
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

3. 연속형 독립변수에 대한 단변량 분석 (결과 확인 4/5)

	Fare
count	1309.000
mean	33.281
std	51.741
min	0.000
25%	7.896
50%	14.454
75%	31.275
max	512.329
rel_diff	1.303
rdiff_flag	large_diff
iqr	23.379
upper_bound	66.344
lower_bound	-27.173
upper_outliers	171
upper_outliers_ratio	0.131
lower_outliers	0
lower_outliers_ratio	0.000
outliers	171
outliers_ratio	0.131
skew	4.370
skew_interpret	right tail
kurt	27.050
kurt_interpret	leptokurtic
log_need	log1p

독립변수 Fare(요금) 분포



왜도 극심한 오른쪽 꼬리 (+4.37) **봉우리** 저가 구간에 집중 **이상치** 171건 (13.1%)
판단·조치 상위 요금은 실제 1등석 가격 — **정보이지 오류가 아니다**

⚠ **여기서 로그변환을 하지 않는다.**
로지스틱 회귀는 **독립변수의 정규성을 가정하지 않기** 때문이다.
왜도가 크다는 사실은 기록해 두되, 변환 여부는 **로짓 선형성 검정**이 결정한다.

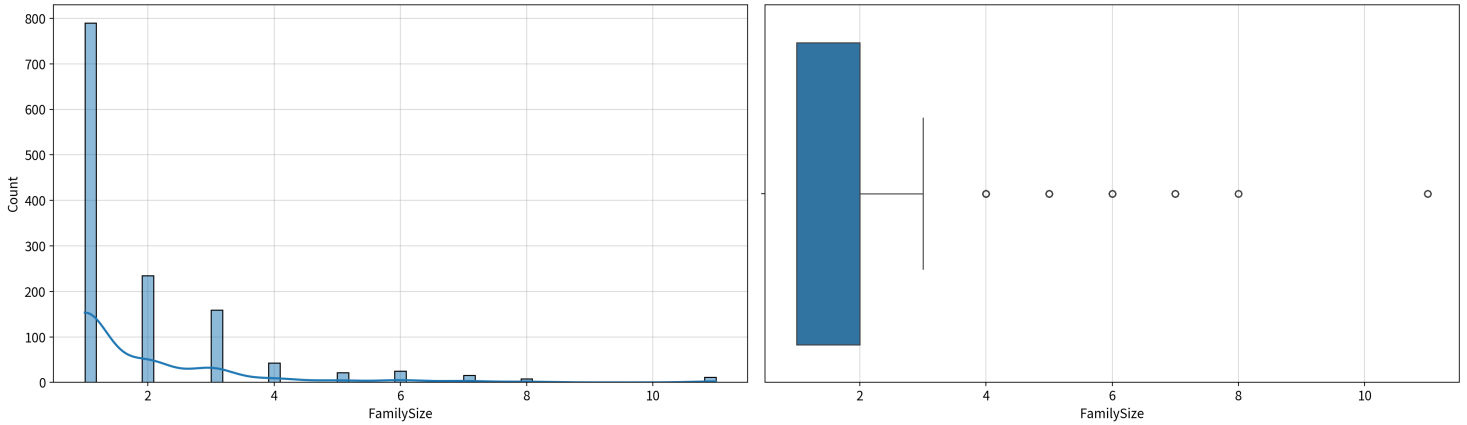
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#04. 단변량 분석

3. 연속형 독립변수에 대한 단변량 분석 (결과 확인 5/5)

	FamilySize
count	1309.000
mean	1.884
std	1.584
min	1.000
25%	1.000
50%	1.000
75%	2.000
max	11.000
rel_diff	0.884
rdiff_flag	large_diff
iqr	1.000
upper_bound	3.500
lower_bound	-0.500
upper_outliers	125
upper_outliers_ratio	0.095
lower_outliers	0
lower_outliers_ratio	0.000
outliers	125
outliers_ratio	0.095
skew	2.853
skew_interpret	right tail
kurt	10.299
kurt_interpret	leptokurtic
log_need	log

독립변수 FamilySize(동승 가족 수 (SibSp + Parch + 본인)) 분포



왜도 오른쪽 꼬리 (+2.85) **봉우리 1명에 집중 (60.4%)** **이상치** 125건 (9.5%)
판단·조치 카운트 변수 — IQR = 1이라 4명부터 이상치로 잡힘

- **왜도 2.85로 원재료보다 완만하다.** (SibSp 3.84 · Parch 3.67) 둘을 더하며 0에 몰려 있던 자리가 1로 옮겨가 분포가 조금 퍼졌다.
- 그래도 **60.4%가 1명(단독 승객)**이라 여전히 한쪽으로 심하게 쏠려 있다.
- **IQR = 1이라 상한이 3.5** — 가족 4명부터 전부 이상치가 된다. Parch와 같은 함정이므로 **이상치 대체 대상에서 제외**한다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수)

```
# 연속형 독립변수 이름을 탐색하면서 반복
for f in continuous_cols:
    # 빈 줄 출력용
    print()

    # 분석 단위 제목 출력
    display(Markdown(f"#### ▶ {f}({column_means[f]}) → {target}"))

    # 수집된 데이터가 long 타입이므로 검정 대상만 wide 타입으로 변환해야 한다.
    # -> 선형회귀 때와 hue/values 가 서로 뒤바뀐다. (종속변수가 집단 기준이 되므로)
    wide_df = my_prep.long2wide(df, hue=target, values=f)
    display(my_stats.test_independent(wide_df,
                group1=wide_df.columns[0], group2=wide_df.columns[1], plot=False))

    # 시각화: 종속변수 집단별 분포 비교
    my_plot.boxplot(data=df, x=target, y=f, hue=target, palette="Set2",
                    width=720, height=400)
```

출력 결과는 다음 페이지에 제시합니다.

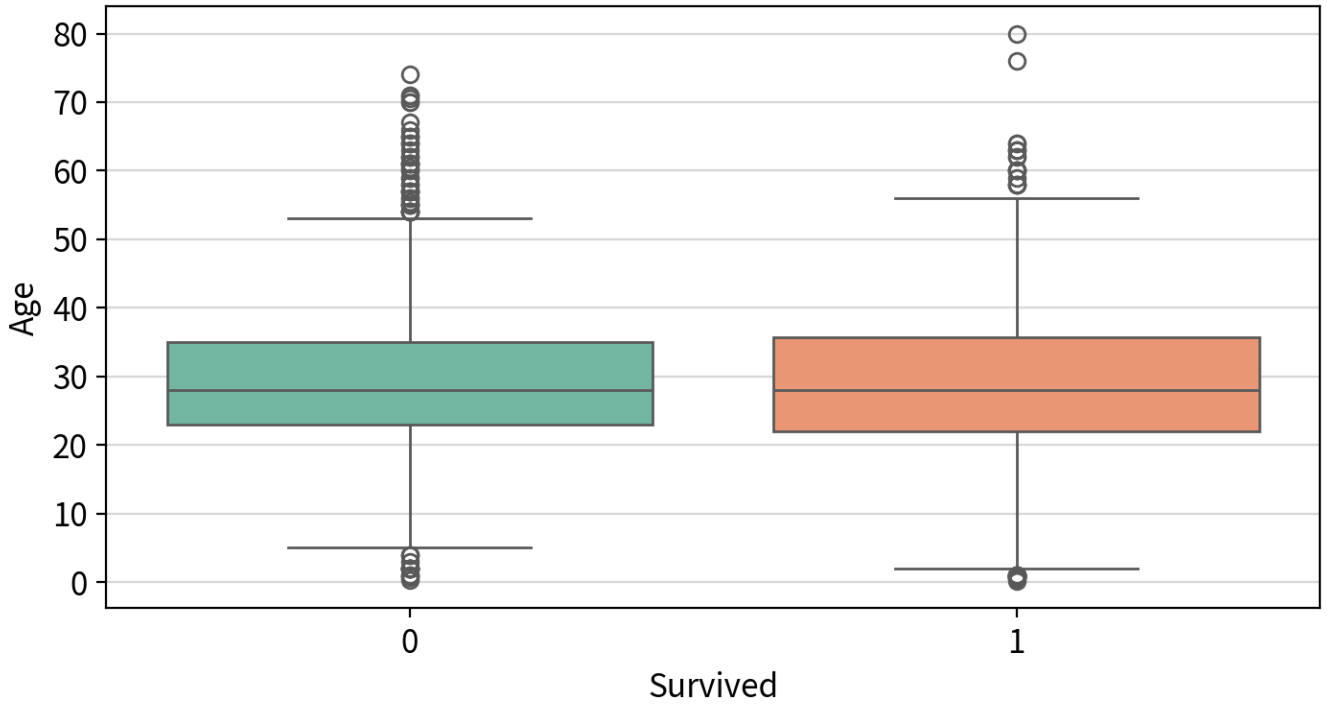
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#05. 이변량 분석

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과 확인 1/5)

▶ Age(나이) → Survived

test	alternative	statistic	p-value	significant	result
Mann-Whitney U test	two-sided	208212.000	0.295	False	0 = 1
	less	208212.000	0.853	False	0 ≥ 1
	greater	208212.000	0.147	False	0 ≤ 1



- 검정 Mann-Whitney U
- 유의확률 **0.295**
- 집단 차이 **차이 없음**
- 방향 —
- 단독 채택 **보류**

- p = 0.295지만 **"나이는 무관"으로 읽으면 안 된다.**
- 어린이는 우선 구조되어 생존율이 높고 고령 남성은 낮다. **양 끝이 반대 방향이라 평균 비교에서 상쇄**된다.
- 결측 263건을 중앙값 28세로 채워 두 집단 모두 28세 쪽으로 끌려간 상태다.
- **이 단계의 "무관"은 최종 판정이 아니다.** 기준선 모형에서 다시 확인한다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

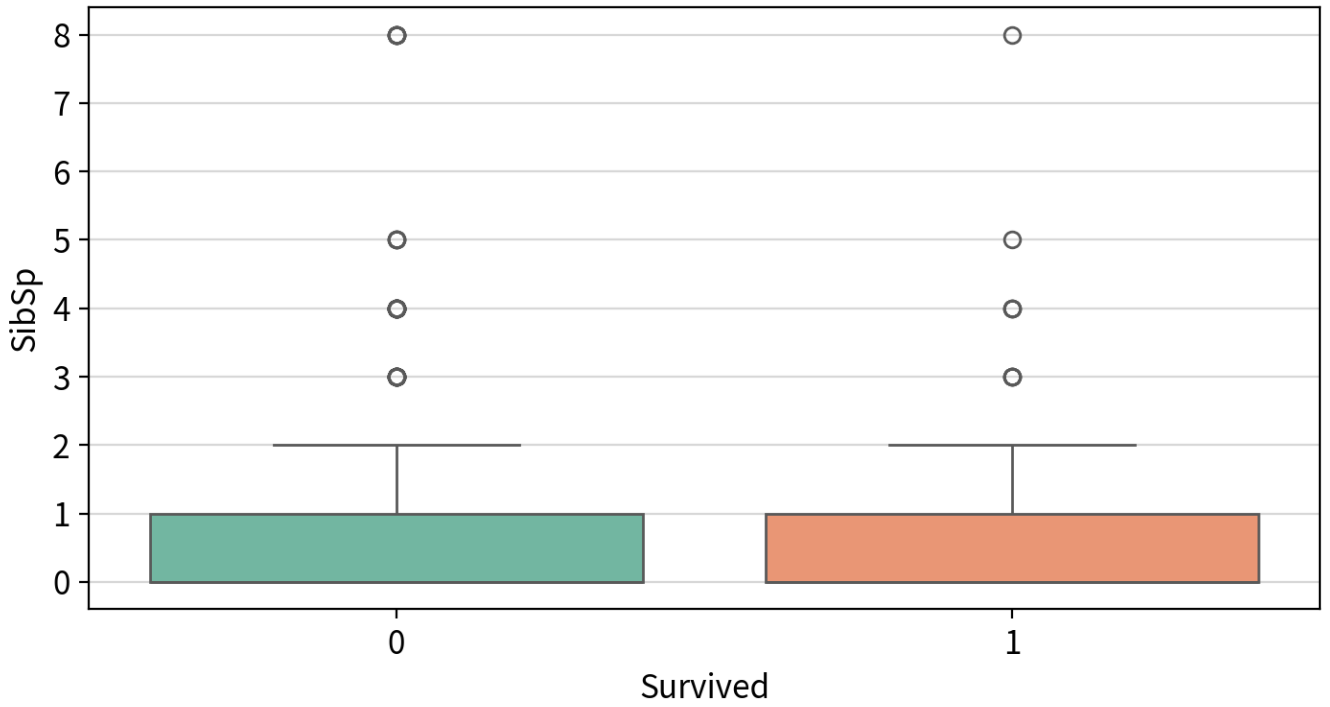
#05. 이변량 분석

실습

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과 확인 2/5)

▶ SibSp(동승한 형제·배우자 수) → Survived

		statistic	p-value	significant	result
test	alternative				
Mann-Whitney U test	two-sided	180053.500	0.000	True	0 ≠ 1
	less	180053.500	0.000	True	0 < 1
	greater	180053.500	1.000	False	0 ≤ 1



- **검정** Mann-Whitney U
- **유의확률** **< 0.001**
- **집단 차이 유의**
- **방향** 사망 < 생존
- **단독 채택 가능**

- 평균은 **0.497 대 0.502**로 거의 같은데 유의하게 나온다.
- **평균이 아니라 순위 분포가 다르기 때문**이다.
- 동승자가 있는 비율은 사망 **27.2%**, 생존 **39.7%**. 평균만 봐서는 놓치는 차이다.
- Mann-Whitney U가 평균이 아니라 **순위**를 비교하는 검정임이 드러난 사례다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

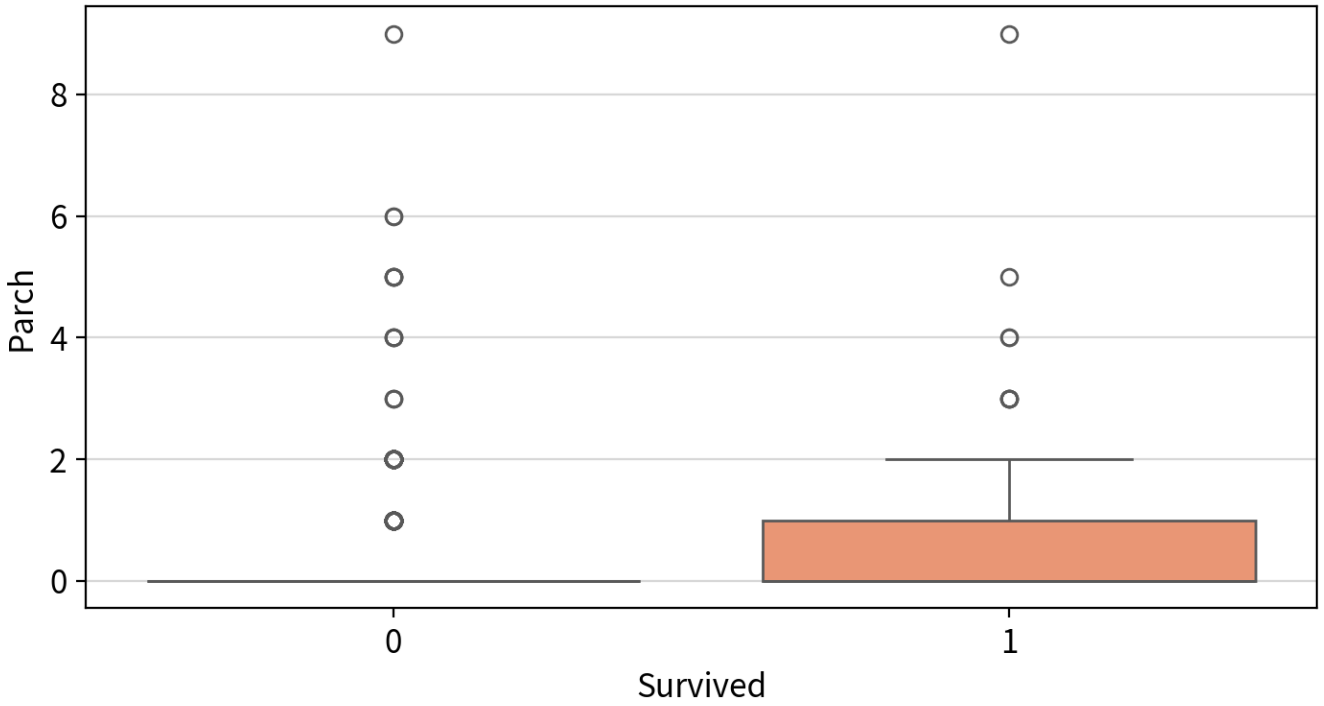


#05. 이변량 분석

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과 확인 3/5)

▶ Parch(동승한 부모·자녀 수) → Survived

		statistic	p-value	significant	result
test	alternative				
Mann-Whitney U test	two-sided	171848.000	0.000	True	0 ≠ 1
	less	171848.000	0.000	True	0 < 1
	greater	171848.000	1.000	False	0 ≤ 1



- **검정** Mann-Whitney U
- **유의확률** **< 0.001**
- **집단 차이 유의**
- **방향** 사망 0.31 < 생존 0.51
- **단독 채택 가능**

- 부모·자녀 동반 수가 많은 쪽이 생존 집단에서 더 높은 순위를 차지한다.
- 유의한 네 변수(Fare · FamilySize · Parch · SibSp)는 모두 **사망 < 생존**이라는 같은 방향을 가리킨다.

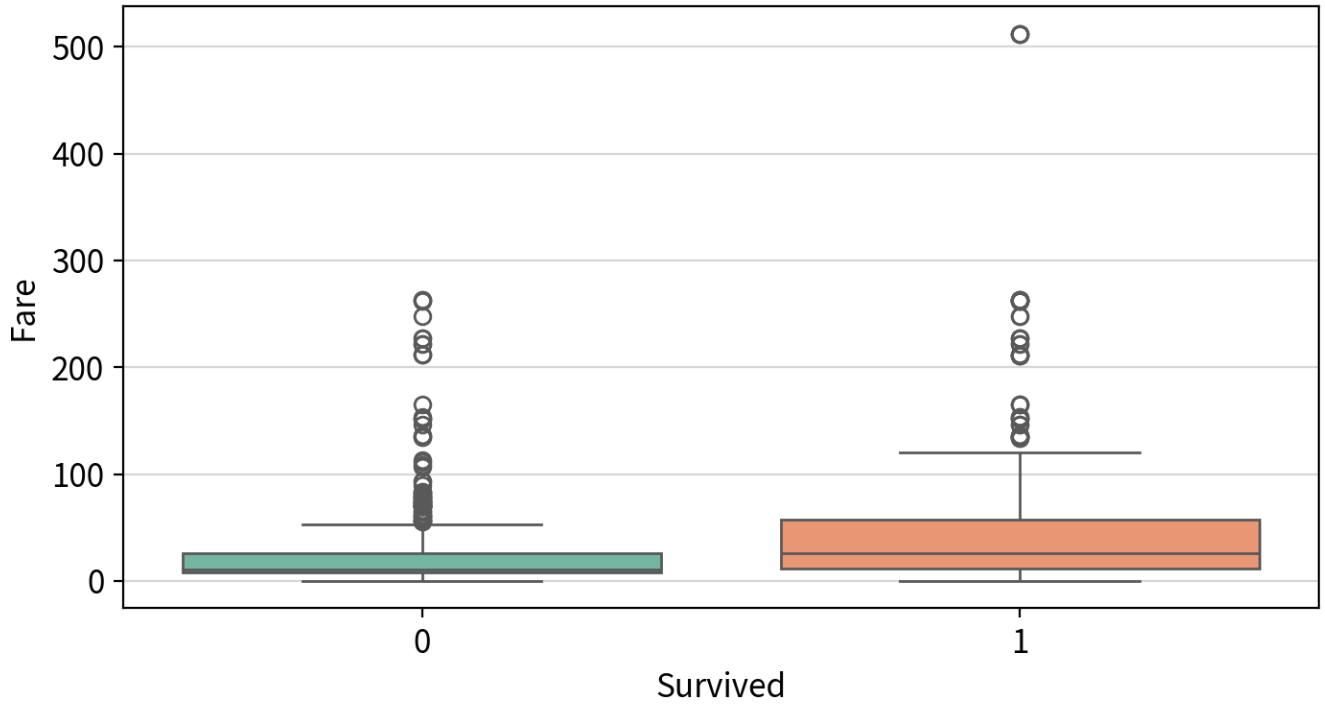
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

#05. 이변량 분석

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과 확인 4/5)

▶ Fare(요금) → Survived

test	alternative	statistic	p-value	significant	result
Mann-Whitney U test	two-sided	132978.000	0.000	True	0 ≠ 1
	less	132978.000	0.000	True	0 < 1
	greater	132978.000	1.000	False	0 ≤ 1



- 검정 Mann-Whitney U
- 유의확률 < 0.001
- 집단 차이 유의
- 방향 사망 23.87 < 생존 48.81
- 단독 채택 가능

- **다섯 변수 중 차이가 가장 크다.**
  생존자의 평균 요금이 사망자의 **2배**다.
- 요금은 곧 객실 등급이므로,
  이 차이의 상당 부분은
  Pclass와 겹칠 것으로 예상된다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

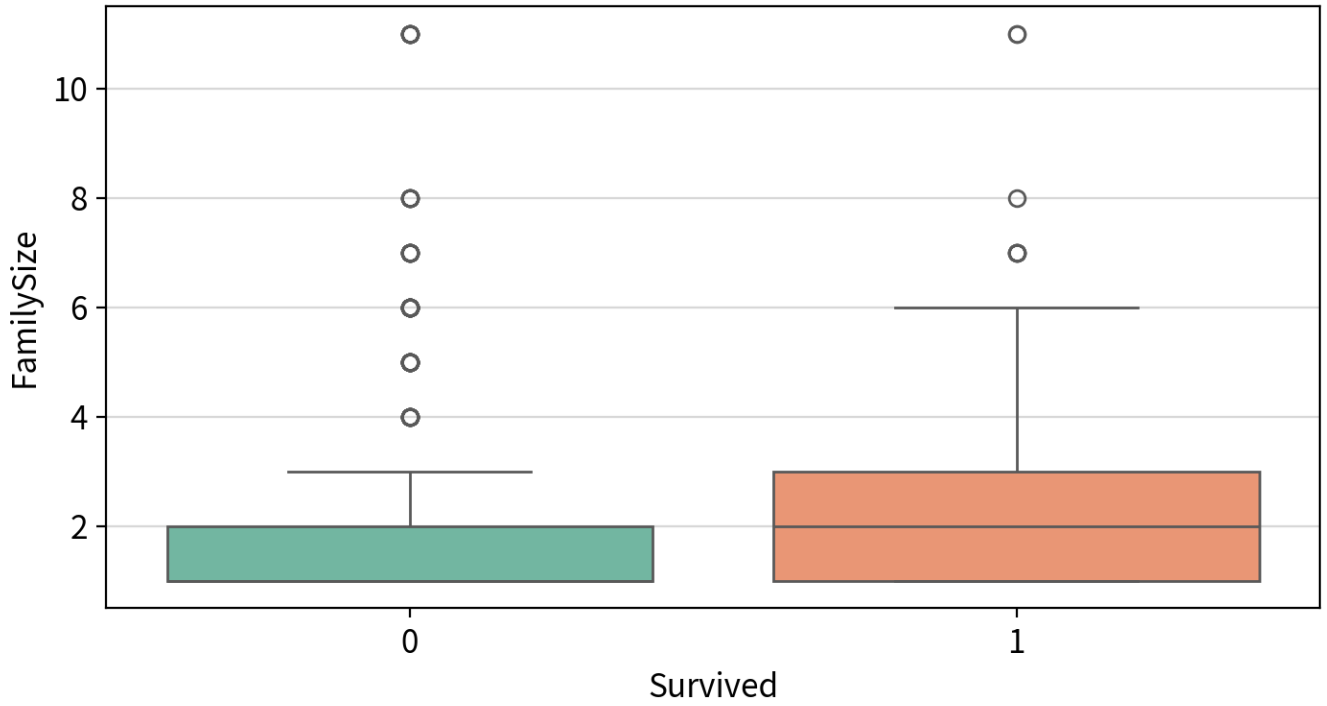


#05. 이변량 분석

1. T-Test (x: 연속형 독립변수 → y: 2집단 명목형 종속변수) (결과 확인 5/5)

▶ FamilySize(동승 가족 수 (SibSp + Parch + 본인)) → Survived

		statistic	p-value	significant	result
test	alternative				
Mann-Whitney U test	two-sided	161466.000	0.000	True	0 ≠ 1
	less	161466.000	0.000	True	0 < 1
	greater	161466.000	1.000	False	0 ≤ 1



- 검정 Mann-Whitney U
- 유의확률 **< 0.001**
- 집단 차이 유의
- 방향 사망 1.81 < 생존 2.01
- 단독 채택 가능

- **평균 차이는 0.2명뿐** (1.81 vs 2.01)이지만 유의하다. SibSp와 같은 이유다.
- 평균이 아니라 **순위 분포**가 다르기 때문이다.
- 가족 규모별 생존율을 직접 보면 그 모양이 드러난다. → 다음 장

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#05. 이변량 분석

2. FamilySize 범주별 분포

◎ T검정은 두 집단의 **순위 중심 위치**만 비교한다.
- 즉 **"생존자 쪽이 대체로 크다/작다"**까지만 말해 준다.

◎ 그런데 `FamilySize` 는 값이 1~11인 카운트 변수라 **범주별 생존율의 모양**을 직접 볼 수 있다.
- 평균 비교가 놓치는 것이 없는지 확인한다.

```python
# 가족 규모별 생존율을 직접 계산한다
fs_rate = df.groupby("FamilySize", observed=True)[target].value_counts(normalize=True).unstack()
fs_rate.columns = ["사망률", "생존률"]
fs_rate["인원수"] = df["FamilySize"].value_counts().sort_index()
display(fs_rate)

# 시각화: 가족 규모별 생존 빈도
my_plot.countplot(data=df, x="FamilySize", hue=target, palette="Set2",
                  width=720, height=400)
```

✓ 마지막 실행: 오후 2:12:23, 기간: 0.0s Python

출력 결과는 다음 페이지에 제시합니다.

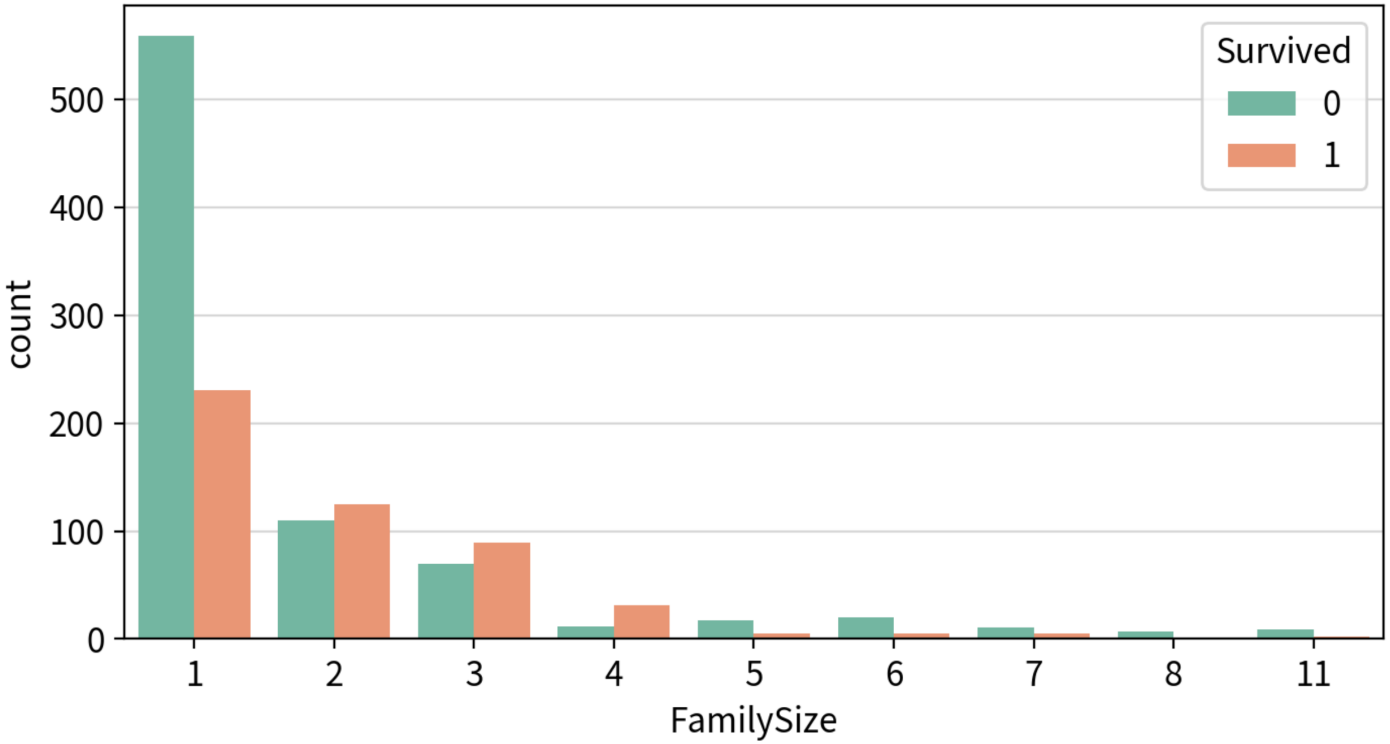
1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#05. 이변량 분석

2. FamilySize 범주별 분포 (결과 확인)

FamilySize	사망률	생존률	인원수
1	0.708	0.292	790
2	0.468	0.532	235
3	0.440	0.560	159
4	0.279	0.721	43
5	0.773	0.227	22
6	0.800	0.200	25
7	0.688	0.312	16
8	0.875	0.125	8
11	0.818	0.182	11



- 1명 29.2% → 4명 72.1%까지 오르다가 5명 22.7%
  → 11명 18.2%로 급락하는 **역U자**다. **평균 하나로는 이 모양을 표현할 수 없다.**
- 양 끝이 서로를 상쇄해 평균 차이가 0.2명으로 줄어든 것이다.
  → **"유의하다"보다 "어떻게 유의한가"가 중요하다.**

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



#05. 이변량 분석

실습

3. 교차분석 (x: 명목형 독립변수 → y: 명목형 종속변수)

◎ 명목형 독립변수가 있을 경우 카이제곱 독립성 검정을 수행한다.

```python
for n in nominal_cols:
    # 빈 줄 출력용
    print()

    # 분석 단위 제목 출력
    display(Markdown(f"#### ▶ {n}({column_means[n]}) → {target}"))

    # 교차분석 (카이제곱 독립성 검정)
    display(my_stats.chi2_independence(df, x=n, y=target, plot=False))

    # 범주별 생존율 표
    rate = df.groupby(n, observed=True)[target].value_counts(normalize=True).unstack()
    display(rate)

    # 시각화: 범주별 생존 비율
    my_plot.countplot(data=df, x=n, hue=target, palette="Set2", width=720, height=400)
```

✓ 마지막 실행: 오후 2:12:23, 기간: 0.2s Python

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

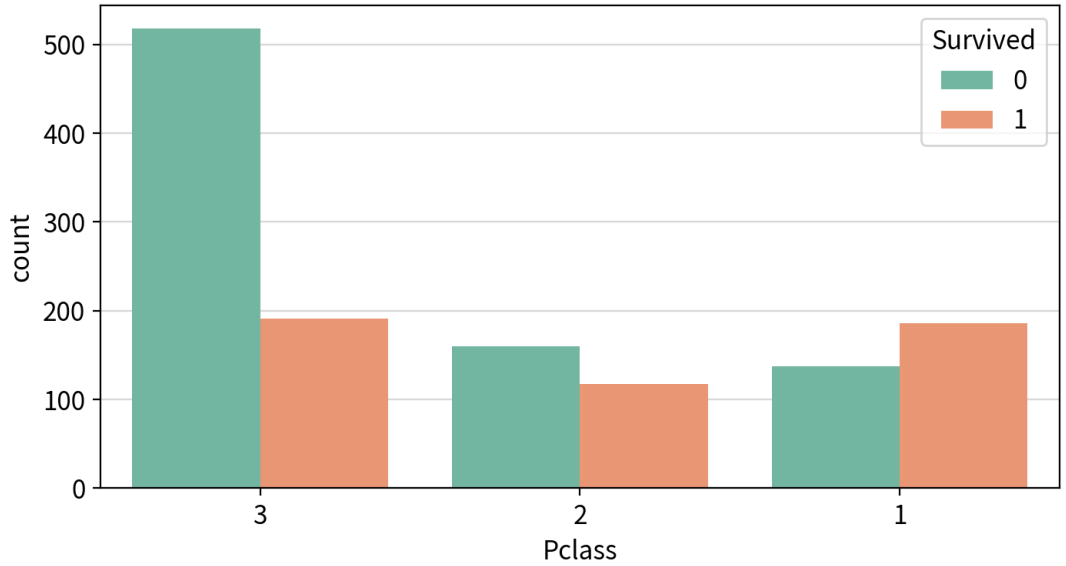
#05. 이변량 분석

3. 교차분석 (x: 명목형 독립변수 → y: 명목형 종속변수) (결과 확인 1/4)

▶ Pclass(객실 등급 (1=1등급, 2=2등급, 3=3등급)) → Survived

		test	chi2	dof	p-value	significant	effect(V)	strength	min_expected	assumption
row	col									
Pclass	Survived	Chi-square test of independence	91.724	2	0.000	True	0.265	Weak	104.540	True

Survived	0	1
Pclass		
3	0.731	0.269
2	0.578	0.422
1	0.424	0.576



⚠ **효과 크기가 Weak라고 해서 버리면 안 된다.**
유의확률은 “관계가 있는가”,
Cramer's V는 “얼마나 센가”를 말한다.
변수 채택은 **통제 모형**에서 판정한다.

χ^2 91.72 · 자유도 2 · 유의확률 < 0.001 · Cramer's V 0.265 · Weak · 채택 가능
범주별 생존율 **1등급 57.6% · 2등급 42.2% · 3등급 26.9%** — 단조 감소

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

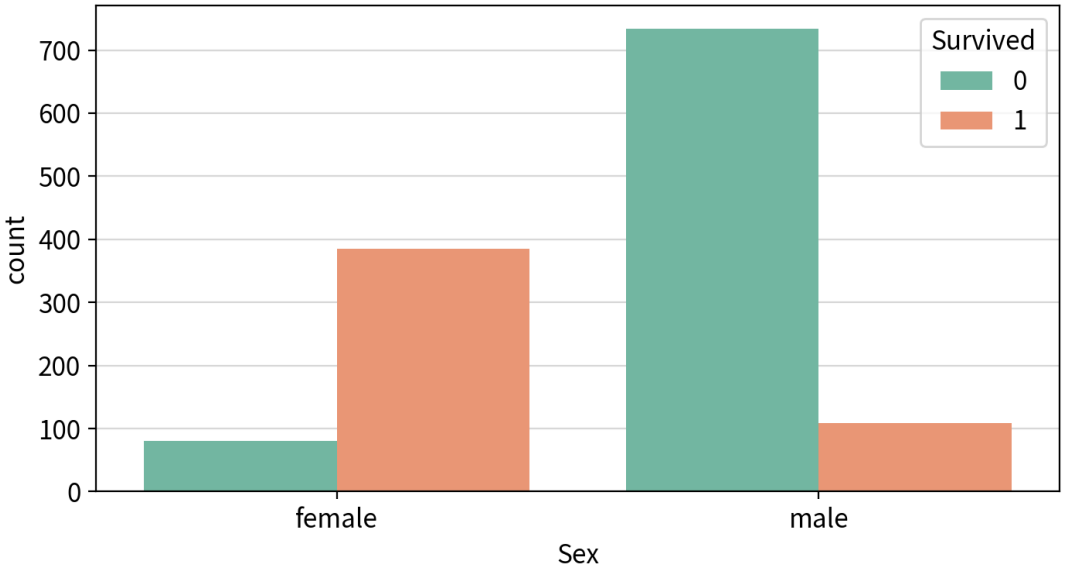
#05. 이변량 분석

3. 교차분석 (x: 명목형 독립변수 → y: 명목형 종속변수) (결과 확인 2/4)

▶ Sex(성별) → Survived

row	col	test	chi2	dof	p-value	significant	effect(V)	strength	min_expected	assumption
Sex	Survived	Chi-square test of independence	617.313	1	0.000	True	0.687	Strong	175.860	True

Survived	0	1
Sex		
female	0.174	0.826
male	0.871	0.129



⚠ **Title과 Sex의 중복은 따로 확인해야 한다.**
#02 교차표에서 Mr·Master는 전원 남성, Miss·Mrs는 전원 여성이었다.
함께 쓸 수 있는지는 **다변량 분석**에서 정량 판정한다.

χ^2 617.31 · 자유도 1 · 유의확률 < 0.001 · Cramer's V 0.687 · Strong · 채택 가능
범주별 생존율 여성 82.6% vs 남성 12.9% — 6.4배 차이

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

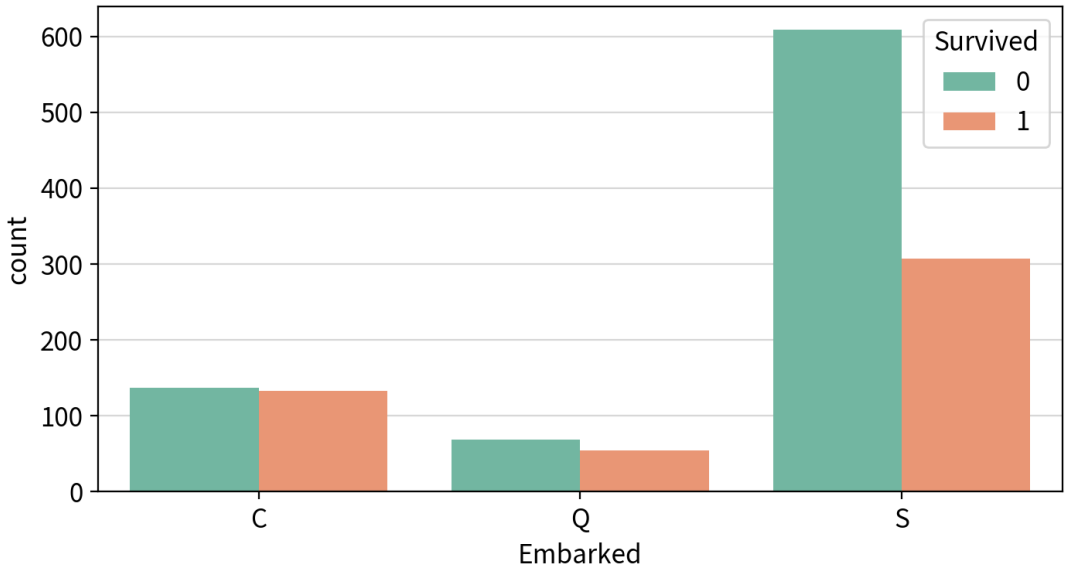
#05. 이변량 분석

3. 교차분석 (x: 명목형 독립변수 → y: 명목형 종속변수) (결과 확인 3/4)

▶ Embarked(탑승 항구 (C=Cherbourg, Q=Queenstown, S=Southampton)) → Survived

		test	chi2	dof	p-value	significant	effect(V)	strength	min_expected	assumption
row	col									
Embarked	Survived	Chi-square test of independence	24.194	2	0.000	True	0.136	Weak	46.420	True

Survived	0	1
Embarked		
C	0.507	0.493
Q	0.561	0.439
S	0.665	0.335



- V 0.136으로 **네 변수 중 가장 약하다.**
  그래도 p < 0.001이라 관계 자체는 분명하다.
- C 49.3% → S 33.5%로 항구에 따라
  15.8%p 차이가 난다.

χ^2 24.19 · **자유도** 2 · **유의확률** < 0.001 · **Cramer's V** 0.136 · **Weak · 채택 가능**
범주별 생존율 **C 49.3% · Q 43.9% · S 33.5%**

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측

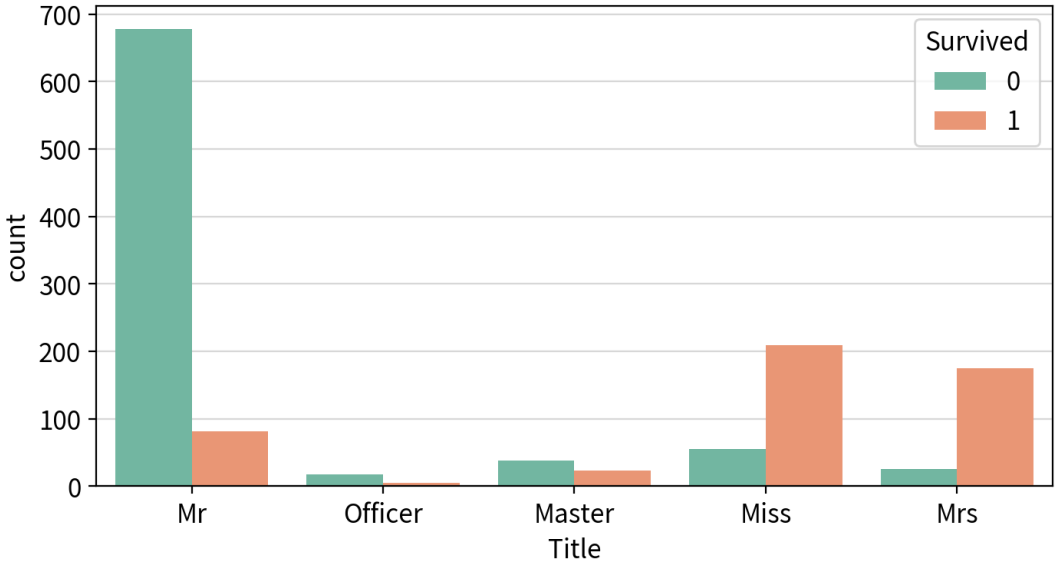
#05. 이변량 분석

3. 교차분석 (x: 명목형 독립변수 → y: 명목형 종속변수) (결과 확인 4/4)

▶ Title(이름에서 추출한 호칭 (Mr/Mrs/Miss/Master/Officer)) → Survived

row	col	test	chi2	dof	p-value	significant	effect(V)	strength	min_expected	assumption
Title	Survived	Chi-square test of independence	638.384	4	0.000	True	0.698	Strong	8.680	True

Survived	0	1
Title		
Mr	0.892	0.108
Officer	0.783	0.217
Master	0.623	0.377
Miss	0.208	0.792
Mrs	0.129	0.871



- **Title이 Sex를 앞선다** — V 0.698 > 0.687
- 자유도 4를 쓰고도 이겼으니 정보량이 더 많다.
- 차이의 출처는 **Master 37.7%** — Sex는 이 61명을 male 12.9%로 묶었다.

χ^2 **638.38** · **자유도** 4 · **유의확률** < 0.001 · **Cramer's V 0.698** · **Strong** · **채택 가능**
범주별 생존율 **Mrs 87.1%** · **Miss 79.2%** · **Master 37.7%** · **Officer 21.7%** · **Mr 10.8%**
Mrs vs Miss 기혼이 +7.9%p · Officer 21.7%는 표본 23명뿐이라 해석에 신중

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



#06. 다변량 분석

실습

□ 독립변수간 상관 분석

◎ 연속형 독립변수끼리는 종속변수가 명목형이어도 상관분석을 그대로 쓸 수 있다.

◎ **파생변수 `FamilySize`가 들어왔으므로 이번 점검은 특히 중요**하다.

○ **파생변수는 원본 컬럼으로 만든 것이라 원재료와 겹칠 수밖에 없기 때문**이다.

```
1 corr = my_stats.multi_correlation(df, columns=continuous_cols, plot=False)
2 display(my_stats.correlation_summary(corr))
3
4 # 분산팽창지수(VIF)로 한 번 더 확인
5 display(my_stats.compute_vif(df[continuous_cols]))
```

✓ 마지막 실행: 오후 2:12:24, 기간: 0.1s Python

	Age	SibSp	Parch	Fare	FamilySize
Age	1.000	-0.102	-0.182	0.173	-0.135
SibSp	-0.102	1.000	0.438	0.446	0.848
Parch	-0.182	0.438	1.000	0.400	0.796
Fare	0.173	0.446	0.400	1.000	0.521
FamilySize	-0.135	0.848	0.796	0.521	1.000

x	max-y	max-coef	count	columns
FamilySize	SibSp	0.848	2	SibSp, Parch
SibSp	FamilySize	0.848	1	FamilySize
Parch	FamilySize	0.796	1	FamilySize
Fare	FamilySize	0.521	0	-
Age	Parch	-0.182	0	-

	VIF
FamilySize	inf
Parch	inf
SibSp	inf
Fare	1.119
Age	1.099

무한대

파생변수와 원변수간의 VIF값이 무한대로 나온다(다중공선성 매우 큼)
어떤 변수를 제거할지는 모델링 과정에서 모델을 살펴보고 결정해야 한다.

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



최종 변수 채택

채택여부	변수	검정방법	유의확률	방향	공선성 신호	근거
채택	**Title**	교차분석	< 0.001	Mrs > Miss > Master > Officer > Mr	**Sex와 V = 0.998**	V = 0.698 (**Strong**) — **가장 높음**
채택	**Sex**	교차분석	< 0.001	여성 > 남성	**Title과 V = 0.998**	V = 0.687 (**Strong**)
채택	**Pclass**	교차분석	< 0.001	1등급 > 3등급	X	등급 순서대로 단조 감소
채택	**Embarked**	교차분석	< 0.001	C > S	X	유의하나 Pclass와 겹칠 가능성
채택	**Fare**	Mann-Whitney U	< 0.001	생존 > 사망	X (VIF 1.12)	집단 차이 유의
채택	**FamilySize**	Mann-Whitney U	< 0.001	생존 > 사망	**VIF = ∞**	SibSp·Parch를 합친 변수
채택	**Parch**	Mann-Whitney U	< 0.001	생존 > 사망	**VIF = ∞**	집단 차이 유의
채택	**SibSp**	Mann-Whitney U	< 0.001	생존 > 사망	**VIF = ∞**	순위 분포 차이 유의
보류	**Age**	Mann-Whitney U	**0.295**	—	X (VIF 1.10)	단독 차이는 없으나 **억제효과 가능성** → 투입 후 계수로 판정
제외	**PassengerId**	—	—	—	—	행마다 값이 다른 **식별자** (#02에서 제거)
제외	**Name**	—	—	—	—	**자유 텍스트** — 단, **Title**을 추출한 뒤 제거 (#02)
제외	**Ticket**	—	—	—	—	문자열 **식별자** (#02에서 제거)
제외	**Cabin**	—	—	—	—	**결측 77.5%** (#02에서 제거)

IT WILL 이광호강사

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT] 사과 품질 분류
7. [PBT] 타이타닉 생존률 예측



연습문제 사과 품질 분류 데이터셋 활용 로지스틱 회귀 #02 (1/2)

□ EDA를 수행하고 다음 물음에 답하시오.

21. 종속변수 Survived의 두 범주 중 더 많이 나타나는 쪽은 무엇인가요? (범주값 1개)
22. 그 최빈 범주가 전체에서 차지하는 비율은 얼마인가요? (소수 셋째 자리)
23. 명목형 독립변수 4종의 범주를 통틀어, 관측치가 가장 적은 범주는 무엇인가요? (범주값 1개)
24. 결측을 중앙값으로 채운 흔적이 히스토그램에 인공적인 봉우리로 남은 변수는 무엇인가요? (변수명 1개)
25. 연속형 5종 중 사분위수 범위(IQR)가 0이어서 이상치 판정 자체가 무의미해진 변수는 무엇인가요? (변수명 1개)
26. FamilySize에서 단독 승객(가족 수 1명)이 차지하는 비율은 얼마인가요? (소수 셋째 자리)
27. 연속형 독립변수 5종에 대한 집단 비교에서, 5종 모두에 선택된 검정 방법은 무엇인가요? (분석 기법 이름 1개)
28. 유의수준 5% 기준으로, 두 집단 사이에 차이가 없다고 나온 변수는 무엇인가요? (변수명 1개)
29. 그 변수의 유의확률은 얼마인가요? (소수 셋째 자리)
30. 가족 규모별 생존율이 가장 높은 가족 수는 몇 명인가요? (정수 1개)
31. 그 가족 수에서의 생존율은 얼마인가요? (소수 셋째 자리)
32. 교차분석에서 Cramer's V가 가장 큰 변수는 무엇인가요? (변수명 1개)
33. Title의 5개 범주 중 생존율이 가장 높은 범주는 무엇인가요? (범주값 1개)

1. 로지스틱 회귀의 이해
2. 로지스틱 회귀의 해석
3. 다중 로지스틱 회귀
4. 분류 성능 평가
5. 로지스틱 회귀의 가정
6. [PBT]
사과 품질 분류
7. [PBT]
타이타닉 생존률 예측



연습문제 사과 품질 분류 데이터셋 활용 로지스틱 회귀 #02 (2/2)

□ EDA를 수행하고 다음 물음에 답하시오.

34. Sex로는 보이지 않던 집단으로, 성인 남성(Mr 10.8%)의 약 3배 생존율을 보인 Title 범주는 무엇인가요? (범주값 1개)
35. 연속형 독립변수 조합 중 상관계수의 절댓값이 가장 큰 값은 얼마인가요? (소수 셋째 자리)
36. 분산팽창지수(VIF)가 무한대(inf)로 나온 변수는 몇 개인가요? (정수 1개)
37. 이변량 분석 결과만으로 곧바로 채택할 수 있는 변수는 몇 개인가요? (정수 1개)
38. 단독 비교에서는 차이가 없었지만, 제거하지 않고 보류로 두는 변수는 무엇인가요? (변수명 1개)
39. 탐색적 분석 결과 때문에 제외된 변수는 몇 개인가요? (정수 1개)